KG 구축 how 보완 (2)
개체 해소·연결 · 저장 · 검색·답변

따른 문헌의 원리와 실제 수행 과정, 그리고 11/26 시연 계획

2026.11 · 문경민

1. KG 구축 단계와 방법론 구체화 현황

- 10/30 자료에서 정리한 세 단계(자료 준비, 구조화 자료 매핑, 비정형 텍스트 추출)를 마치면 Entity 264 개와 속성 616 개가 만들어지고, 같은 행·같은 자료에서 함께 만든 근거만 이어져 있다.
- 이번 자료는 그 다음 단계인 개체 해소·연결(2 장), 저장(3 장), 검색·답변(4 장)의 방법론을 같은 방식(따른 원리 → 과정 → 결과)으로 정리했다. 10/30 자료의 온톨로지와 KG 는 바꾸지 않았다.
- 검증은 11/02 회의에 따라 다른 연구들이 KG·온톨로지를 어떻게 검증했는지 조사한 뒤 정리한다. 각 원리의 자세한 설명은 부록 C 에 있다.

표 1. 단계별 하는 일과 방법론 정리 여부

단계	하는 일	방법론 정리
자료 준비	소스 구분과 전처리	**정리함 (10/30)**
구조화 자료 매핑	정형 표의 행·열을 Entity 와 속성으로	**정리함 (10/30)**
비정형 텍스트 추출	비고에서 운영행위, 별표 3 에서 운영기준을 뽑음	**정리함 (10/30)**
개체 해소·연결	서로 다른 자료의 Entity 를 관계로 이음	**이번에 정리 (2 장)**
저장	CSV 를 Cypher 로 바꿔 Neo4j 에 넣음	**이번에 정리 (3 장)**
검색·답변	질문에 맞는 근거를 KG 에서 찾아 LLM 이 답함	**이번에 정리 (4 장)**
검증	만든 KG 가 맞는지 확인	**선행연구 조사 후**

2. 개체 해소·연결

2.1 따른 원리와 진행 방식

- 따른 원리: Purohit 외(2024)는 GraphAide 에서 뉴스 기사 1,846 건으로 KG 를 만들 때, 글에서 뽑은 대상의 표기를 기준 지식베이스(DARPA Wikidata)의 식별자(QID)에 대응시켰다. 표기마다 가장 가까운 QID 를 찾아, 같은 QID 를 받은 표기는 같은 노드가 된다(부록 C.1).
- 원리: 기준 식별자를 하나 정하고, 자료마다 다르게 적힌 같은 대상을 그 식별자에 대응시킨다.
- 우리는 K-water 댐 코드(DAM_CD)를 기준 식별자로 삼았다. 대상이 댐 4 개라서 대응은 코드 일치와 대응 표로 했고, GraphAide 의 벡터 검색과 LLM 재순위는 쓰지 않았다.
- 진행 방식: 먼저 자료마다 다른 댐 표기를 기준 식별자에 대응시키고(2.2), 그 다음 관계마다 시작 Entity 에서 끝 Entity 의 ID 를 찾아 관계 줄을 쓴다(2.3). 결과는 kgv4_relations.csv 에 쌓인다.

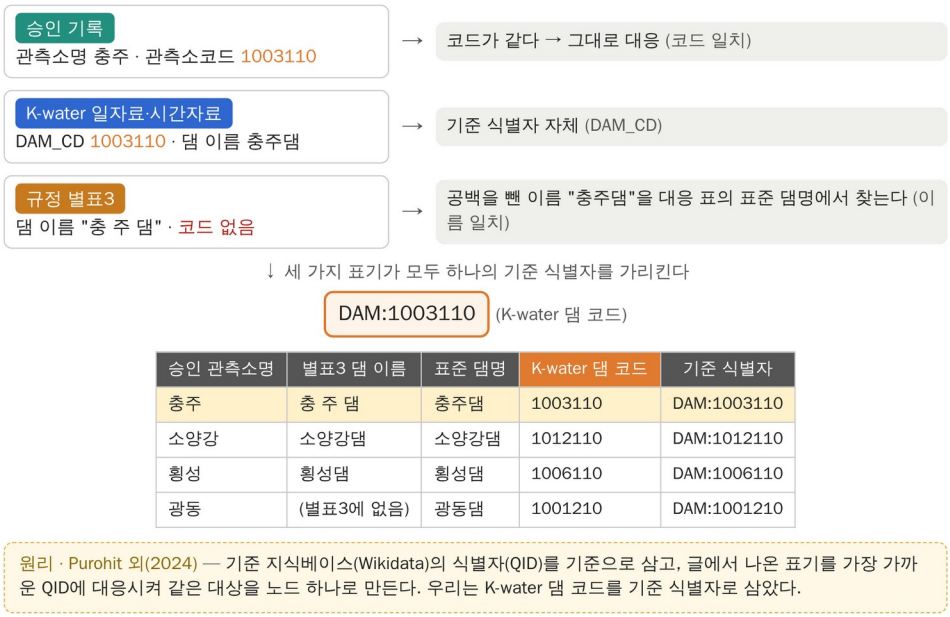
2.2 댐 표기를 기준 식별자에 대응 (개체 해소)

입력: 자료마다 다른 댐 표기

- 승인 기록: 관측소명("충주")과 관측소코드(1003110). 자료 준비 때 대조한 결과, 관측소코드는 4 개 댐 모두 K-water 댐 코드와 같았다.
- K-water 일자료·시간자료: 댐 코드(DAM_CD) 자체가 기준 식별자이다.
- 규정 별표 3: 댐 이름만 있고 코드가 없다. 원문에는 글자 사이에 공백이 있다("충 주 댐").

과정

- 승인 기록은 관측소코드가 댐 코드와 같으므로 코드로 그대로 대응한다.
- 별표 3 은 비정형 텍스트 추출에서 공백을 허용해 읽은 이름("충주댐")을 대응 표의 표준 댐명에서 찾아 댐 코드를 얻는다.
- 대응 표는 승인 관측소명, 별표 3 댐 이름, 표준 댐명, 댐 코드를 한 줄에 둔 4 줄짜리 표이다. 광동댐은 별표 3 에 없다.



승인 관측소명	별표3 댐 이름	표준 댐명	K-water 댐 코드	기준 식별자
충주	충 주 댐	충주댐	1003110	DAM:1003110
소양강	소양강댐	소양강댐	1012110	DAM:1012110
횡성	횡성댐	횡성댐	1006110	DAM:1006110
광동	(별표3에 없음)	광동댐	1001210	DAM:1001210

원리 · Purohit 외(2024) — 기준 지식베이스(Wikidata)의 식별자(QID)를 기준으로 삼고, 글에서 나온 표기를 가장 가까운 QID에 대응시켜 같은 대상을 노드 하나로 만든다. 우리는 K-water 댐 코드를 기준 식별자로 삼았다.

그림 1. 댐 표기 세 가지를 기준 식별자 DAM:1003110 에 대응시키기

2.3 관계별 연결

진행 방식

- 관계마다 ① 시작 Entity 를 하나씩 읽고 ② 그 Entity 에 들어 있는 키로 끝 Entity 의 ID 를 정하고 ③ 관계 줄을 쓰며, 끝을 찾은 방법(규칙)과 값의 성격을 함께 남긴다.
- 근거 연결(supportedBy 175 개)은 지난 단계에서 Entity 를 만들 때 이미 이었으므로, 이번 단계에서 잇는 관계는 아래 5 종 243 개이다.

표 2. 관계별 끝 Entity 를 찾는 키

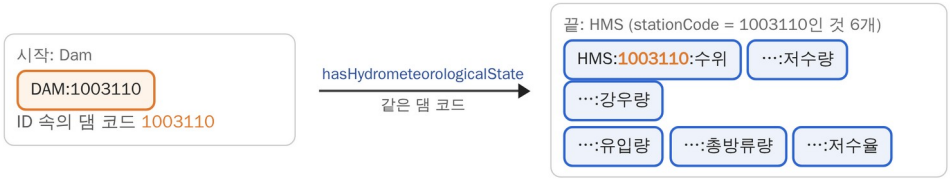
관계	시작 → 끝	끝 Entity 를 찾는 키	값의 성격	개수
hasHydrometeorologicalState	Dam → HMS	같은 댐 코드 (HMS ID 속의 DAM_CD)	원본 그대로	24
concernsDam	Approval → Dam	승인 행의 관측소코드 = 댐 코드	원본 그대로	80
authorizes	Approval → Operation	같은 순차번호 (그 승인 행의 비고에서 뽑은 행위)	연구용 구성	68

관계	시작 → 끝	끝 Entity 를 찾는 키	값의 성격	개수
performedOnDam	Operation → Dam	순차번호 → 승인 행의 관측소코드	원본에서 유도	68
appliesToDam	Criterion → Dam	별표 3 댐 이름 → 대응 표 → 댐 코드	이름 일치	3

값의 성격: 원본 그대로 = 원본의 코드가 같아서 이음 / 원본에서 유도 = 원본의 키를 한 번 거쳐 이음 / 연구용 구성 = 원본에 직접 적힌 관계가 아니라 연구에서 정해 이음 / 이름 일치 = 코드가 없어 이름으로 이음.

수문·기상 상태: hasHydrometeorologicalState

- 댐을 하나씩 꺼내, 같은 댐 코드로 만든 HMS 6 개를 찾아 관계 6 개를 쓴다. HMS 의 ID 에 댐 코드가 들어 있으므로 찾는 데 다른 자료가 필요 없다.



① 댐을 하나씩 꺼낸다 → ② 같은 댐 코드로 만든 HMS 6개를 찾는다 → ③ 관계 줄 6개를 쓴다. 4개 댐 × 6 = 24개. 값의 성격: 원본 그대로(코드 일치).

그림 2. Dam → HMS: 같은 댐 코드로 잇는다

승인: concernsDam

- 승인을 하나씩 꺼내, 그 승인 행의 관측소코드(1003110)로 댐 ID(DAM:1003110)를 정한다. 승인 80 개가 모두 댐 하나에 이어진다.

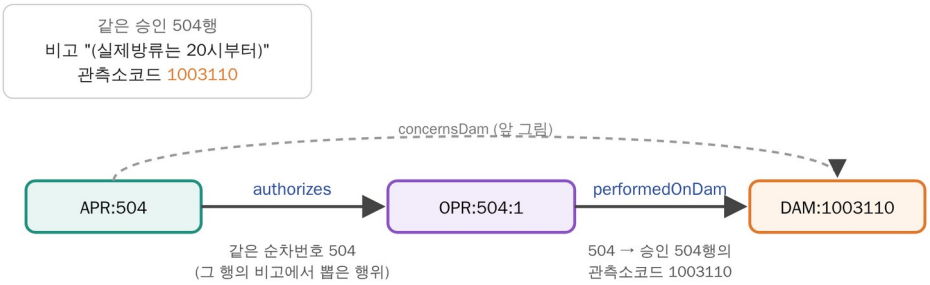


순차번호	관측소코드	관측소명	→ 시작 Entity	→ 끝 Entity
504	1003110	충주	APR:504	DAM:1003110
473	1006110	횡성	APR:473	DAM:1006110
··· 승인 80개 → 80개 모두 댐 하나에 이어짐 (충주 15, 소양강 6, 횡성 24, 광동 35)				

그림 3. Approval → Dam: 승인 행의 관측소코드로 잇는다

운영행위: authorizes, performedOnDam

- 운영행위 ID(OPR:504:1)에 든 순차번호 504 로 같은 승인 행을 찾는다. 그 승인(APR:504)에서 운영행위로 authorizes 를, 그 행의 관측소코드로 정한 댐으로 performedOnDam 을 쓴다.
- authorizes 는 "같은 승인 행의 비고에서 뽑은 행위를 그 승인이 허가했다"고 연구에서 정해 이은 것이라 값의 성격이 연구용 구성이다(검토할 점 1).



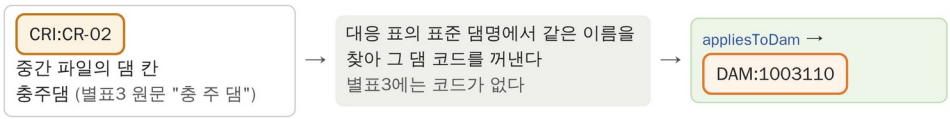
운영행위 ID의 순차번호(504)가 같은 승인 행을 가리키므로, 승인과 댐을 다른 표에서 찾지 않는다.

authorizes 68개(값의 성격: 연구용 구성 — 실행 확인 아님), performedOnDam 68개(값의 성격: 원본에서 유도). 운영행위 68개가 모두 승인 하나와 댐 하나에 이어진다.

그림 4. Approval → Operation → Dam: 순차번호가 같은 승인 행을 가리킨다

기준: appliesToDam

- 기준을 하나씩 꺼내, 별표 3 에서 읽은 댐 이름을 대응 표의 표준 댐명에서 찾아 댐 코드를 얻는다. 별표 3 에는 코드가 없어 이름으로 이었다는 사실을 값의 성격(이름 일치)으로 남긴다.

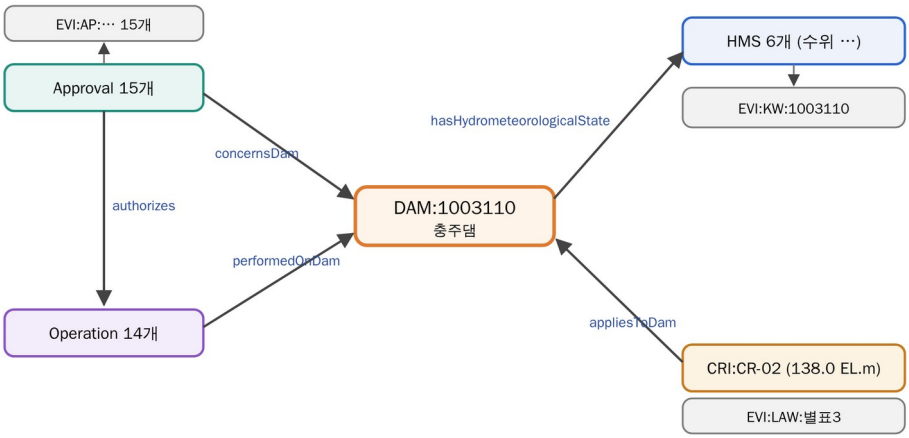


기준 3개 → 충주(CR-02), 소양강(CR-01), 횡성(CR-03) 각각 댐 하나. 값의 성격: 이름 일치(name-match) — 코드가 아니라 이름으로 찾은 연결임을 관계에 남긴다.

그림 5. Criterion → Dam: 별표 3 의 댐 이름을 대응 표로 댐 코드에 대응시킨다

결과

- 관계 243 개가 더해져 KG 의 관계는 모두 418 개가 된다(kgv4_relations.csv).
- 연결 확인(10/19 질문 "연결이 실제로 되나"): 승인 80 개 모두 댐에(concernsDam), 운영행위 68 개 모두 댐과 승인에(performedOnDam, authorizes), 기준 3 개 모두 댐에(appliesToDam), 댐 4 개 모두 HMS 6 개씩에 이어졌다. 승인 중 운영행위로 이어진 것은 63 개이며, 나머지 17 개는 변경 승인이라 운영행위를 만들지 않은 것이다.
- 이제 댐 하나에서 출발해 그 댐의 상태, 승인, 운영행위, 기준과 각각의 근거까지 관계를 따라 찾아갈 수 있다(그림 6).



실선 화살표가 이번 단계에서 이은 관계이다(회색 상자는 지난 단계에서 이은 근거). 이제 댐 하나에서 출발해 그 댐의 상태, 승인, 운영행위, 기준과 각각의 근거까지 관계를 따라 찾아갈 수 있다.

그림 6. 개체 해소·연결이 끝난 상태 — 충주댐에 이어진 Entity

3. 저장

3.1 따른 원리와 진행 방식

- 따른 원리: Huang 외(2026)는 추출한 지식을 JSON 으로 모은 뒤, 온톨로지의 관계에 따라 Python 스크립트가 JSON 의 키-값을 읽어 Cypher 문을 만들고, 노드와 관계를 Neo4j 에 일괄 적재했다. Neo4j 는 Cypher 로 조회·추가·삭제·수정이 효율적이고 여러 관계를 건너는 질의(다중 홉 질의)에 강해서 골랐다고 밝혔다(부록 C.2).
- 우리는 모은 형태가 JSON 이 아니라 CSV 파일이다. Python 스크립트가 kgv4_entities, kgv4_properties, kgv4_relations 의 줄을 읽어 Cypher 파일을 만들고, 적재 스크립트가 그 파일을 Neo4j 에 넣는다. 출처 파일(kgv4_provenance)은 Neo4j 에 넣지 않고 CSV 로 둔다.
- 측정값과 규정 원문은 KG 에 넣지 않고 외부 저장소에 두며, KG 에는 그것을 찾아가는 키만 둔다(3.3).

3.2 CSV → Cypher → Neo4j

과정 1. Entity → 노드

- entities 와 properties 의 줄을 Entity ID 로 모아 노드 문 하나를 쓴다. 라벨은 Entity 와 Class 두 개이다(예: Entity:Approval).
- 속성은 자료형에 따라 바꾼다: 날짜는 date(), 일시는 datetime(), 숫자는 숫자로. 그래야 "2020 년 8 월 안의 운영행위"처럼 기간으로 찾을 수 있다.
- MERGE 는 같은 id 의 노드가 있으면 새로 만들지 않는다. 그래서 다시 적재해도 노드가 겹치지 않는다. 파일 첫 줄에서 id 가 유일하다는 제약을 건다.

과정 2. 관계 → 관계

- relations 의 줄마다 시작·끝 노드를 id 로 찾고(MATCH), 그 사이에 관계를 만든다(MERGE). 규칙과 값의 성격은 관계의 속성으로 남겨, Neo4j 에서도 어떻게 이은 관계인지 볼 수 있다.

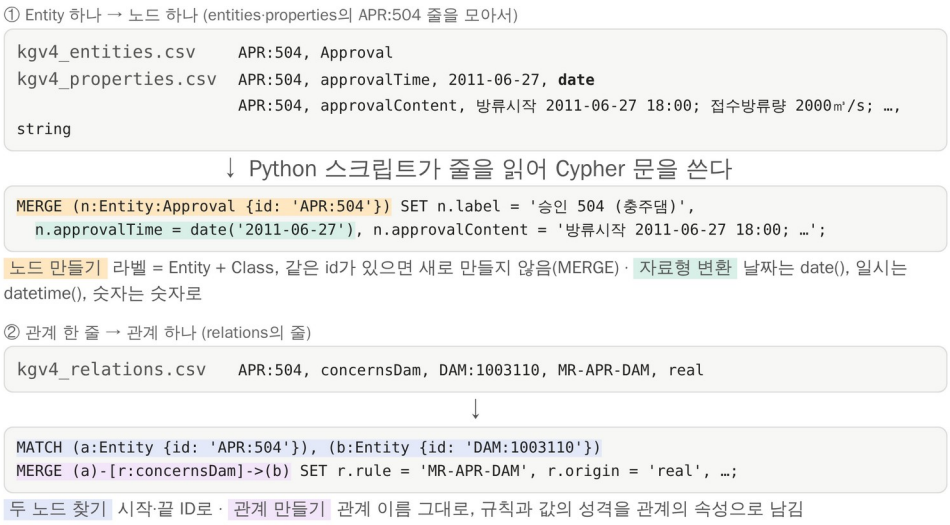


그림 7. CSV 줄이 Cypher 문이 되는 과정 (APR:504 노드와 concernsDam 관계)

과정 3. 적재

- Neo4j 5.26 을 시작하고, 기존 노드를 모두 지운 뒤, Cypher 파일(684 줄: 주석 1, 제약 1, 노드 264, 관계 418)을 실행한다. 끝나면 노드 수와 관계 수를 세어 "nodes: 264, rels: 418"인지 확인한다.

3.3 KG 밖에 두는 것: 측정 저장소와 문서 저장소

- 측정 저장소: 4 개 댐의 시간자료 508,246 행. KG 의 HMS 에 있는 stationCode(댐 코드)와 시각으로 한 행을 읽는다.
- 문서 저장소: 연계운영규정 별표 3 원문 1 건. KG 의 근거 Entity(EVI:LAW:별표 3)에 있는 sourceLocator("별표 3")로 원문을 읽는다.

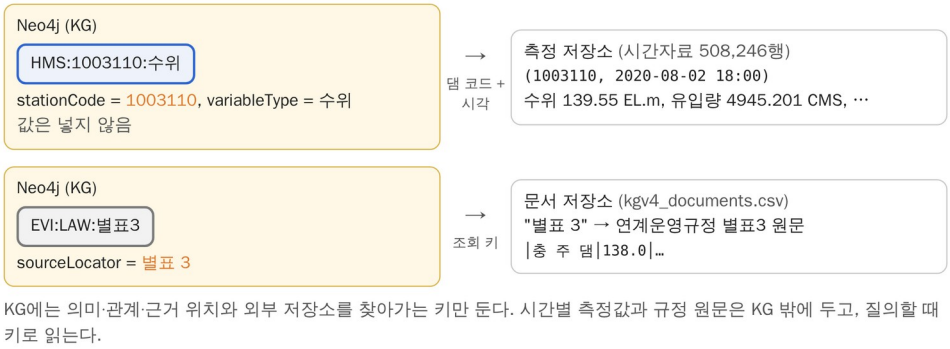


그림 8. KG 에서 외부 저장소로 가는 키

결과

Neo4j 노드 (Class 별)	개수	Neo4j 관계 (종류별)	개수
EvidenceSource	85	supportedBy	175
Approval	80	concernsDam	80
Operation	68	authorizes	68
HydrometeorologicalState	24	performedOnDam	68
Dam	4	hasHydrometeorologicalState	24
Criterion	3	appliesToDam	3
합계	264	합계	418

4. 검색·답변

4.1 따른 원리와 진행 방식

- 따른 원리: Purohit 외(2024)의 GraphAide 는 질의 단계에서 LLM 이 자연어 질문을 부분 그래프 조회 템플릿으로 바꾸고, 이를 Cypher 로 Neo4j 에서 실행한 결과를 LLM 에 맥락으로 주어 답변을 만든다. KG 의 관계를 따라 찾은 근거를 주므로 LLM 이 없는 사실을 지어내는 것(환각)을 줄인다(부록 C.1).
- 우리는 조회 템플릿을 CQ 마다 미리 정해 두었다(Cypher 6 개). LLM 은 질문에서 의도(CQ1~CQ6)와 값(댐, 기간)만 뽑고, 그 다음은 코드가 정해진 순서대로 KG 와 저장소를 조회한다. GraphAide 의 Cypher 자동 생성, 질의 확장, 벡터 검색, 에이전트는 쓰지 않았다.
- 진행 방식: 질문 하나가 6 단계를 거친다. LLM 은 ①과 ⑥ 두 곳에서 쓰고(같은 모델, 지시문만 다름), ②~⑤ 는 코드가 한다(그림 9). 아래에서 서버 실행 기록의 질문 하나를 따라간다(Qwen3-32B, 2026-10-16).



LLM은 ①과 ⑥ 두 곳에서만 쓰고(같은 모델, 프롬프트만 다름), KG와 저장소에서 근거를 찾는 ②~⑤는 코드가 정해진 순서대로 한다. 서버 실행 기록: Qwen3-32B, 38.8초.

그림 9. 질문 하나가 답변까지 가는 전체 경로

4.2 질문 하나를 따라가기

입력

- 질문: "2020 년 8 월 충주댐 방류 승인과 운영행위, 그때의 수문 상태를 알려줘."

과정 1. 의도·값 추출 (LLM)

- LLM 에 지시문과 질문을 준다. 지시문에는 의도 목록(CQ1~CQ6), 허용 댐 4 개, 값의 형식, 규칙 5 개가 있다(목록 밖 의도를 만들지 않음, 질문에 없는 값을 추측하지 않음, 이유를 묻는 질문과 범위 밖 댐은 의도를 비우고 이유를 적음, JSON 하나만 출력).
- 이 질문에서 LLM 은 "방류 승인" → CQ4, "운영행위" → CQ3, "그때의 수문 상태" → CQ2, 댐 = 충주댐, 기간 = 2020-08-01 ~ 2020-08-31 을 뽑았다.

```
"2020년 8월 충주댐 방류 승인과 운영행위, 그때의 수문 상태를 알려줘."
```

↓ 의도 목록(CQ1~CQ6)과 허용 댐 4개를 적은 지시문과 함께 LLM에 준다

질문 속 표현	뽑은 값	의미
방류 승인	CQ4	과거 방류 승인
운영행위	CQ3	과거 운영행위
그때의 수문 상태	CQ2	과거 시점의 수문·기상 상태
충주댐	dam = 충주댐	허용 댐 4개 중 하나 ("충주"라고 해도 충주댐으로)
2020년 8월	period = 2020-08-01 ~ 2020-08-31	시점이 없으면 "전체"

출력은 JSON 하나뿐이다. 목록 밖의 댐(예: 팔당댐), 이유를 묻는 질문("왜 방류했나")은 의도를 비우고 이유를 적는다 → 이후 단계에서 "질의 불가"로 답한다.

그림 10. 질문 속 표현이 의도와 값이 되는 과정

과정 2. 입력 확인 (코드)

- 의도가 CQ1~CQ6 안인지, 댐이 4 개 댐 안인지 확인하고 이름을 표준 댐명으로 바꾼다("충주" → 충주댐).
- 기간의 끝 날짜는 그 날 전체로 읽어 [2020-08-01 00:00, 2020-09-01 00:00)으로 바꾼다. 확인을 통과하지 못하면 조회하지 않고 "질의 불가: 이유"를 답변 단계로 넘긴다.

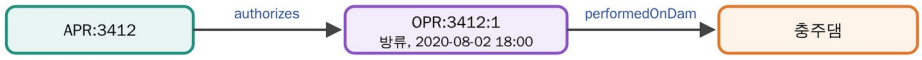
과정 3. KG 조회 (코드, Cypher 템플릿)

- 먼저 충주댐의 HMS 에서 stationCode(1003110)를 얻는다. 측정 저장소를 찾아갈 키이다.

- CQ3: 충주댐에서 performedOnDam 을 거꾸로 따라가 기간 안의 운영행위를 찾고, authorizes 로 그것을 허가한 승인을 찾는다 → OPR:3412:1 ← APR:3412.
- CQ4: concernsDam 으로 승인일이 기간 안인 승인을 찾는다 → APR:3412, APR:3519, APR:3647. 뒤의 둘은 변경 승인이라 운영행위가 없다.
- 2 장에서 이은 관계가 여기서 조회 경로로 쓰인다. CQ 별 경로는 그림 11 의 표와 같다.

CQ3 운영행위 템플릿 (값 $dam = '충주댐', $s = 2020-08-01, $e = 2020-09-01)

```
MATCH (o:Operation)-[:performedOnDam]->(d:Dam {damName:$dam})
WHERE o.operationTime >= datetime($s) AND o.operationTime < datetime($e)
OPTIONAL MATCH (a:Approval)-[:authorizes]->(o)
RETURN o.id, o.operationType, o.operationTime, a.id
```



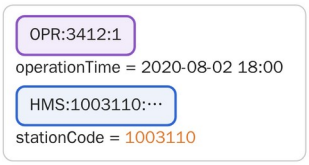
충주댐에서 출발해 관계를 거꾸로 따라가, 기간 안의 운영행위와 그것을 허가한 승인을 찾는다

의도	따라가는 관계 (Cypher 템플릿)	외부 저장소	이 질문의 결과
CQ1 현재 상태	Dam → hasHydrometeorologicalState → HMS (stationCode 얻기)	측정: 가장 최근 시각	—
CQ2 과거 상태	(운영행위가 있으면) 운영 시각	측정: 그 시각	2020-08-02 18:00 1 행
CQ3 운영행위	Operation → performedOnDam → Dam, Approval → authorizes → Operation	—	OPR:3412:1 ← APR:3412
CQ4 승인	Approval → concernsDam → Dam (승인일이 기간 안)	—	APR:3412, 3519, 3647
CQ5 운영기준	Criterion → appliesToDam → Dam	문서: sourceLocator	—
CQ6 근거	조회한 항목마다 → supportedBy → EvidenceSource	—	—

그림 11. CQ3 Cypher 템플릿과 따라가는 관계, CQ 별 조회 경로

과정 4. 외부 저장소 조회 (코드)

- CQ2 와 CQ3 이 함께 있으면 운영행위 시각마다 그 시각의 측정값을 읽는다. 키는 stationCode 1003110 과 시각 2020-08-02 18:00 이다.
- CQ1 은 저장된 가장 최근 시각의 값을, CQ5 는 문서 저장소에서 별표 3 원문을 읽는다.



→

측정 저장소에서 (1003110, 2020-08-02 18:00) 한 행

수위	저수량	강우량	유입량	총방류량	저수율
139.55 EL.m	2126.472 MCM	1.901 mm	4945.201 CMS	707.145 CMS	77.3 %

출처 번호 [MEA:1003110:2020080218] (측정 · 댐 코드 · 시각 라벨)

정각이 아닌 운영 시각(예: 06:30)은 앞뒤 정시 두 행을 함께 준다. 값은 저장소의 원값 그대로이며 계산한 값은 넣지 않는다.

그림 12. 운영 시각과 댐 코드로 측정 저장소의 한 행을 읽는다

과정 5. 근거 묶음 (코드)

- 조회 결과를 의도별 구역으로 나누고, 항목마다 출처 번호를 붙인다. 출처 번호는 KG 의 Entity ID 이고, 측정값은 [MEA:댐 코드:시각]이다.
- 값은 저장소의 원값 그대로 쓰고 계산한 값은 넣지 않는다. 끝에 근거 사용 원칙 3 문장을 붙인다.

```
[질문] 2020년 8월 충주댐 방류 승인과 운영행위, 그때의 수문 상태를 알려줘.
[대상] 충주댐, 기간 2020-08-01 ~ 2020-08-31

[근거 1. 운영행위와 허가한 승인]  (CQ3) 운영행위의 시각은 비고에 적힌 시각, 없으면 승인된 방류 시작 시각이다.
[OPR:3412:1] 방류, 시각 2020-08-02 18:00 ← 승인 [APR:3412]

[근거 2. 운영 시각의 상태]  (CQ2)
[MEA:1003110:2020080218] 2020-08-02 18:00  수위 139.55 EL.m, 저수량 2126.472 MCM, 강우량 1.901 mm,
   유입량 4945.201 CMS, 총방류량 707.145 CMS, 저수율 77.3 %

[근거 3. 방류 승인]  (CQ4)
[APR:3412] 승인일 2020-08-02: 방류시작 2020-08-02 18:00; 접수방류량 3000㎥/s
[APR:3519] 승인일 2020-08-06: 방류시작 2020-08-02 18:00; 접수방류량 7000㎥/s; 비고: 방류기간 (당초) … (변경)
…
[APR:3647] 승인일 2020-08-12: 방류시작 2020-08-06 06:00; 접수방류량 7000㎥/s; 비고: 수문방류 변경승인(방류기
간연장) …

[근거 사용 원칙] 근거에 있는 내용만 사실로 쓰고 출처 번호를 붙인다 / 비교·해석은 판단임을 밝힌다 / 없으면 "자료에 없
음"
```

의도별 구역 출처 번호 = KG의 Entity ID, 측정값은 MEA 원칙 3문장

그림 13. 근거 묶음 — LLM 에 주는 근거 전체

과정 6. 답변 (LLM)

- LLM 에 답변 지시문과 근거 묶음을 준다. 지시문: 근거 묶음에 있는 내용만 사실로 쓰고 출처 번호를 붙인다, 비교·해석은 "판단"으로 나누고 쓴 근거를 적는다, 없으면 "자료에 없음".
- 주의 사항도 함께 준다: 운영행위 시각은 비고의 시각이거나 승인된 방류 시작 시각이다, "현재"는 저장된 가장 최근 시각이며 실시간이 아니다, 방류 사유는 자료에 없으므로 단정하지 않는다.

```
근거
- 2020년 8월 2일 18:00에 방류가 승인되었으며, 방류량은 3000㎥/s로 접수되었습니다. [APR:3412]
- 이후 8월 6일에 방류 승인이 변경되어 방류량이 7000㎥/s로 증가하고, 방류 기간이 8월 2일 18:00부터 8월 16일 24:00
까지로
  확정되었습니다. [APR:3519]
- 8월 12일에는 방류 기간이 다시 연장되어 8월 6일 06:00부터 8월 22일 00:00까지로 확정되었습니다. [APR:3647]
- 방류가 시작된 2020년 8월 2일 18:00 기준, 수위는 139.55 EL.m, … 저수율은 77.3%입니다.
[MEA:1003110:2020080218]

판단
- 방류량은 처음 3000㎥/s에서 이후 7000㎥/s로 증가했습니다. 방류 기간은 여러 차례 변경되며 최종적으로 8월 22일
00:00까지
  연장되었습니다. (근거: [APR:3412], [APR:3519], [APR:3647])
- … 이는 댐의 수문 상황과 유입량 변화에 따라 조정된 것으로 판단됩니다. (근거: [APR:3412], …)
```

사실마다 출처 번호 판단마다 쓴 근거 빨간 글씨: 자료에 없는 사유를 추정한 문장 → 검토할 점 3

그림 14. 답변 — 근거(출처 번호)와 판단(쓴 근거)으로 나뉜다

결과

- 질문마다 의도 원문, 의도 JSON, 조회 결과, 근거 묶음, 답변이 파일로 남는다. 서버에서 질문 5 개를 실행한 결과는 표 3 과 같다.

표 3. 서버 실행 결과 (Qwen3-32B, 2026-10-16)

질문	뽑은 의도	결과	시간
충주댐 현재 상태를 제한수위와 비교하고, 비슷한 수문 상태일 때의 승인·운영행위	CQ1, CQ5, CQ4, CQ3	근거와 판단으로 답함	159.6 초
소양강댐의 홍수기 제한수위와 그 근거	CQ5, CQ6	190.3 EL.m 과 별표 3 근거로 답함	14.1 초
2020 년 8 월 충주댐 승인·운영행위·수문 상태	CQ2, CQ3, CQ4	4.2 의 예	38.8 초
광동댐 제한수위	CQ5	별표 3 에 없어 "자료에 없음"	7.7 초
팔당댐의 현재 수위	없음 (거절)	범위 밖 댐이라 질의 불가	2.4 초

5. 검토할 점

1. authorizes 는 연구용 구성 (개체 해소·연결)

- 운영행위가 승인 비고에서 구성한 것이므로, "그 승인이 그 운영행위를 허가했다"는 연결도 연구에서 정한 것이다. 실행을 확인한 연결이 아니다.
- 답변 지시문에 "실제 수행이 확정된 것처럼 쓰지 않는다"를 넣어 다루고 있다. 실제 운영 기록을 얻으면 다시 정한다.

2. 같은 코드를 같은 시설로 봄 (개체 해소·연결)

- 승인 파일의 관측소코드와 K-water 댐 코드가 같으면 같은 댐으로 보았다(4 개 댐 모두 이름도 일치). 두 기관의 코드가 같은 시설을 뜻한다는 공식 자료로 확인하지는 않았다.
- 별표 3 은 코드가 없어 이름으로 이었다(appliesToDam 3 개).

3. 답변 품질과 속도 (검색·답변, 서버 실행 기록)

- 2020 년 8 월 질문의 판단에 "댐의 수문 상황과 유입량 변화에 따라 조정된 것으로 판단됩니다"처럼 자료에 없는 사유를 추정한 문장이 있다. 지시문의 "사유를 단정하지 않는다"를 어긴 것이다.
- 광동댐 질문의 답변에서 출처 자리에 의도 이름([CQ5])을 적었다.
- 같은 종합 질문을 5 번 실행했을 때 CQ2(과거 상태)를 뽑은 것은 1 번이었다. 의도 추출이 실행마다 다를 수 있다.
- 종합 질문은 159.6 초 걸렸다. 첫 질문에서 측정 저장소(50 만 행)를 읽는 시간이 들어 있다.
- 시연 전에 지시문을 고치고, 정해 둔 질문 세트로 반복해서 확인한다.

6. 다음 계획

11/26 시연 구조

- 이번에 정리한 검색·답변 구조를 그대로 쓰고, 처음 보는 사람이 직접 질문할 수 있도록 아래를 더한다.
- 채팅 화면: 노트북 브라우저에서 질문하고 답변을 본다. 답변의 출처 번호를 누르면 원문(승인 기록 행, 별표 3 원문, 측정값)이 보인다.
- 답할 수 있는 범위 안내: 대상 댐 4 개와 질문 종류(CQ1~CQ6), 예시 질문을 화면에 둔다. 범위 밖 질문과 인사에는 범위와 예시 질문으로 안내한다.
- 이어지는 질문: "그럼 소양강댐은?"처럼 앞 질문의 댐·기간을 이어받는다.
- 속도: 측정 저장소를 서버를 켤 때 미리 읽어 둔다.
- 접속: 노트북 → 핫스팟 → 연구실 서버. 인터넷이 안 될 때를 대비해 시연 동영상을 찍어 둔다.
- 시연 때 밝힐 점: "현재"는 저장된 마지막 시각(2026-09-28)이며 실시간이 아니다. 범용 LLM 을 썼다. 실제 운영에 쓰려면 자료 연결 확대와 에이전트 등이 더 필요하다.

11/20 발표 자료

- 처음 보는 사람을 위한 설명 순서로 만든다: 왜 필요한가 → 무엇을 만들었나(온톨로지·KG) → 어떻게 답하나(이번 4 장) → 시연 → 한계와 향후 계획.

검증

- 11/02 회의에 따라 다른 연구들의 KG·온톨로지 검증 방법을 조사해 분석한 뒤, 적용할 방안을 정리한다.

부록 A. 용어 정리

표 4. 용어 정의

용어	본 연구에서의 정의
개체 해소	자료마다 다르게 적힌 같은 대상(충주, 충 주 댐, 1003110)을 하나의 기준 식별자에 대응시키는 일. 문헌의 entity disambiguation.
기준 식별자	같은 대상을 가리키는 표기들을 모으는 기준 ID. 본 연구는 K-water 댐 코드, GraphAide 는 Wikidata 의 QID.

용어	본 연구에서의 정의
Neo4j	Entity 를 노드로, 관계를 관계(엣지)로 저장하는 그래프 데이터베이스.
Cypher	Neo4j 에 노드·관계를 넣고 찾는 질의 언어. MERGE(없으면 만듦), MATCH(찾음) 등.
조회 템플릿	CQ 마다 미리 정해 둔 Cypher 문. 댐 이름과 기간만 바꿔 넣어 실행한다.
의도	질문이 요구하는 CQ(CQ1~CQ6). 한 질문에 여러 개가 있을 수 있다.
근거 묶음	KG 와 저장소에서 찾은 근거를 의도별 구역과 출처 번호를 붙여 LLM 에 주는 글.
출처 번호	근거 항목마다 붙이는 표시. KG 의 Entity ID 이거나 측정값의 [MEA:댐 코드:시각].
환각	LLM 이 자료에 없는 사실을 지어내는 것.

부록 B. Ontology 가 답해야 할 질문과 관계

표 5. 세부 질문 (CQ1~CQ6)

번호	질문 대상	세부 질문
CQ1	현재 수문·기상 상태	대상 댐의 현재 또는 기준시점의 강우, 수위, 유입량, 방류량 등 수문·기상 상태는 무엇인가?
CQ2	과거 수문·기상 상태	선택된 과거 시점 또는 사례에서 대상 댐의 강우, 수위, 유입량, 방류량 등 수문·기상 상태는 어떠했는가?
CQ3	과거 운영행위	해당 과거 시점 또는 사례에서 실제로 수행된 댐 운영행위는 무엇이었는가?
CQ4	과거 방류 승인	해당 과거 시점 또는 사례에서 어떤 방류 승인이 있었으며, 그 승인내용은 무엇인가?
CQ5	현재 운영기준	현재 대상 댐에 적용되는 운영기준은 무엇이며, 현재 운영 판단과 관련된 기준값은 무엇인가?
CQ6	공식 근거	각 수문·기상 상태, 운영행위, 승인내용 및 운영기준을 확인할 수 있는 공식 자료 또는 근거문서는 무엇인가?

표 6. Relation (9 개)

Subject	Relation	Object	의미
Dam	hasHydrometeorologicalState	HydrometeorologicalState	댐이 해당 수문·기상 변수 정보와 연결됨
Operation	performedOnDam	Dam	운영행위가 특정 Dam 에서 수행됨
Approval	authorizes	Operation	Approval 이 특정 Operation 을 승인함
Approval	concernsDam	Dam	Approval 이 특정 Dam 에 관한 것임
Criterion	appliesToDam	Dam	운영기준이 특정 Dam 에 적용됨
HydrometeorologicalState	supportedBy	EvidenceSource	상태를 확인할 수 있는 근거자료
Operation	supportedBy	EvidenceSource	운영행위를 확인할 수 있는 근거자료
Approval	supportedBy	EvidenceSource	승인을 확인할 수 있는 근거자료
Criterion	supportedBy	EvidenceSource	운영기준을 확인할 수 있는 근거자료

부록 C. 근거 문헌의 원리

C.1 Purohit 외(2024) — 개체 해소, 검색·답변

- 무엇인가: 여러 출처의 정형·비정형 자료로 KG 를 만들고, 그 KG 를 조회·추론하는 질의 시스템 GraphAide 를 제안한 학회 논문이다 (IEEE BigData 2024). OpenAI LLM, Chroma 벡터 DB, Neo4j, LangChain 으로 구현했다.
- KG 생성 단계의 개체 해소: 기준 지식베이스로 DARPA Wikidata(DWD)를 쓰고, QID 마다 설명 문서를 만들어 벡터 DB 에 넣었다. 온톨로지와 DWD 에 기반한 에이전트가 글에서 대상의 표기를 뽑고, RAG 기반 후보 재순위로 가장 가까운 QID 를 고른다. → 기준 식별자에 대응시키는 원리만 따랐고, 벡터 DB 와 LLM 재순위는 쓰지 않았다.
- 질의 단계: LLM 이 질문을 여러 형태로 확장하고, 이를 부분 그래프 조회 템플릿으로 바꿔 Cypher 를 자동 생성한다. 그래프 조회 결과와 벡터 검색 결과를 합쳐 LLM 의 맥락으로 주고, 답변을 모아 하나의 응답을 만든다. 정해진 순서(chain)와 에이전트를 함께 쓴다. → KG 조회 결과를 LLM 의 근거로 주는 원리를 따랐고, Cypher 는 CQ 마다 미리 정한 템플릿으로 대신했다.
- 평가: RAGAS 지표와 전문가 정성 평가를 쓴다고 밝혔으며, 정식 평가는 향후 과제로 두었다.

C.2 Huang 외(2026) — 저장

- 추출한 지식을 JSON 으로 통합하고, DDO 의 의미·계층 관계에 따라 Python 스크립트가 JSON 키-값을 읽어 Cypher 문을 만든다. 이 문들로 DDKG 의 노드를 일괄 생성하고 Entity 사이의 관계를 만들어 Neo4j 에 적재한다.
- 저장소로 Neo4j 를 고른 이유: Cypher 로 조회·추가·삭제·수정이 효율적이고, 다중 홉 추론과 복잡한 질의에 강하다.
- 구축한 DDKG 는 노드 201,362 개, 관계 953,447 개이다. → JSON 대신 CSV 를 모은 형태로 쓴 것 외에는 같은 순서(모음 → 스크립트로 Cypher 생성 → 일괄 적재)를 따랐다.

부록 D. 참고문헌

- Huang, J., Hou, W., Zhang, S., Du, Z., & Yin, J. (2026). Dam defects ontology and knowledge graph construction from multi-source hazard data using large language models. Advanced Engineering Informatics, 76, 104987.
- Purohit, S., Chin, G., Mackey, P. S., & Cottam, J. A. (2024). GraphAide: Advanced Graph-Assisted Query and Reasoning System. 2024 IEEE International Conference on Big Data. https://doi.org/10.1109/BigData62323.2024.10825705