KG 구축 how 보완 (2)
Relation 채우기 · 저장 · 검색·답변

따른 문헌의 원리와 실제 수행 과정, 그리고 11/26 시연 계획

2026.11 · 문경민

1. KG 구축 단계와 방법론 구체화 현황

- KG 구축은 온톨로지가 정해 둔 틀(Class, Data Property, Relation)에 자료의 실제 값을 채우는 일이다. 10/30 자료에서는 Class(Entity)와 Data Property(속성값)를 채우는 과정을 정리했다. 그 결과 Entity 264 개와 속성값 616 개가 만들어졌다.
- 이번 자료는 남은 Relation 을 채우는 과정(2 장), 채운 결과를 Neo4j 에 넣는 저장(3 장), 채워진 KG 로 질문에 답하는 검색·답변(4 장)을 같은 방식(따른 원리 → 과정 → 결과)으로 정리했다. 온톨로지와 KG 의 내용은 10/30 자료와 같다.
- 검증은 11/02 회의에 따라 다른 연구들이 KG·온톨로지를 어떻게 검증했는지 조사한 뒤 정리한다. 각 원리의 자세한 설명은 부록 C 에 있다.

표 1. 단계별 하는 일과 방법론 정리 여부

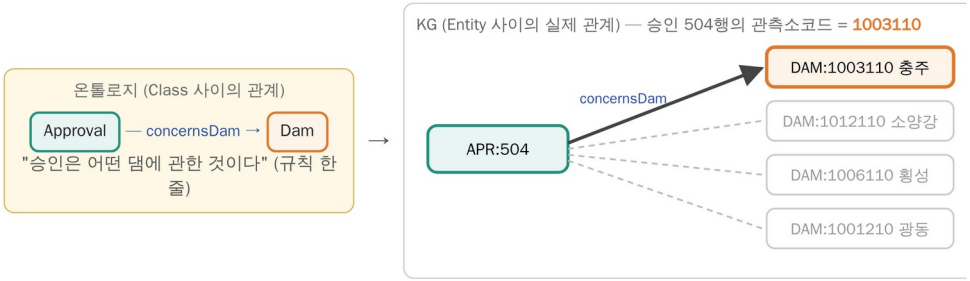
단계	하는 일	방법	방법론 정리
자료 준비	소스 구분과 전처리	—	**정리함 (10/30)**
Class·Data Property 채우기	Entity 와 속성값을 채움	구조화 자료 매핑(정형 표), 비정형 텍스트 추출(비고, 별표 3)	**정리함 (10/30)**
Relation 채우기	Relation 마다 실제 시작·끝 Entity 를 이음	자료 속 키로 끝 Entity 를 정함(댐 표기 맞추기 포함)	**이번 (2 장)**
저장	채운 결과를 Neo4j 에 넣음	CSV → Cypher → Neo4j	**이번 (3 장)**
검색·답변	질문에 맞는 근거를 KG 에서 찾아 LLM 이 답함	의도 추출 → Cypher 템플릿 조회 → 근거 묶음 → 답변	**이번 (4 장)**
검증	만든 KG 가 맞는지 확인	—	**선행연구 조사 후**

2. Relation 채우기

2.1 왜 Relation 을 따로 채우는가

- 그림 1 의 왼쪽은 온톨로지의 Relation 한 줄 "Approval —concernsDam→ Dam"이다. 이것은 Class 사이의 규칙이라 어느 승인이 어느 댐에 관한 것인지는 들어 있지 않다.
- 오른쪽은 KG 이다. 승인 APR:504 에서 댐 4 개로 가는 선은 모두 온톨로지 규칙에 맞는다(점선). 승인 80 개 × 댐 4 개 = 320 가지 조합이 형식상 맞지만, 실제 관계는 80 개뿐이다.

- 실제 관계를 고르는 것은 자료 안의 키이다. 승인 504 행의 관측소코드가 1003110 이므로 APR:504 의 끝 Entity 는 DAM:1003110(충주댐)이다(실선).
- Class 와 Data Property 만 채우면 KG 에는 선이 하나도 없어서 "충주댐의 승인"을 조회해도 아무것도 나오지 않는다. Relation 채우기는 속성 칸에 값을 채우는 것과 같은 일이며, 채우는 값이 숫자나 글자가 아니라 다른 Entity(끝 Entity)라는 점만 다르다.



온톨로지 규칙만 보면 승인 80개 × 댐 4개 = 320가지 조합이 모두 형식상 맞다(점선). 그중 실제 관계 80개를 고르는 근거가 자료 안의 키이다(실선: 관측소코드 1003110 → 충주댐).

그림 1. 온톨로지가 허락한 조합(점선) 가운데 자료 속 키로 실제 관계(실선)를 고른다

Class·Data Property 채우기 다음에 하는 이유

- 끝 Entity 가 먼저 만들어져 있어야 한다. 승인 표를 옮길 때는 다른 자료(K-water 일자료)에서 만드는 댐 Entity 가 아직 없을 수 있다.
- 자료마다 다르게 적힌 댐("충주", 1003110, "충 주 댐")을 같은 댐으로 알아봐야 끝 Entity 를 정할 수 있다(2.3).
- 그래서 모든 Entity 를 만든 뒤에 Relation 을 채운다. 근거 관계(supportedBy)도 온톨로지의 Relation 이므로 이 단계에서 함께 정리한다(10/30 자료 과정 4 의 근거 연결).

2.2 따른 원리와 진행 방식

- 따른 원리: Purohit 외(2024)는 GraphAide 에서 뉴스 기사 1,846 건으로 KG 를 만들 때, 글에서 뽑은 대상의 표기를 기준 지식베이스(DARPA Wikidata)의 식별자(QID)에 대응시켰다. 같은 QID 를 받은 표기는 같은 Entity 가 된다(부록 C.1).
- 원리: 기준 식별자를 하나 정하고, 자료마다 다르게 적힌 같은 대상을 그 식별자에 대응시킨다. 우리는 K-water 댐 코드를 기준 식별자로 삼았다. 대상이 댐 4 개라서 코드 일치와 대응 표로 했고, GraphAide 의 벡터 검색과 LLM 재순위는 쓰지 않았다.
- 참고로 Huang 외(2026)는 댐마다 관련 Entity 를 JSON 파일 하나로 묶어 적재했고, 본문에 서로 다른 자료의 같은 대상을 맞추는 단계는 따로 없다. 우리 자료는 승인 기록, K-water 자료, 규정이 서로 다른 기관에서 따로 와서 댐 표기를 맞추는 과정이 필요하다.
- 진행 방식: 먼저 댐 표기를 기준 식별자에 맞춘다(2.3). 그 다음 Relation 마다 시작 Entity 를 하나씩 읽고, 자료 속 키로 끝 Entity 를 정해 관계 한 줄을 쓰며, 끝 Entity 를 정한 방법(규칙)과 값의 성격을 남긴다. 키가 어느 자료에서 나오는지에 따라 세 가지 방식이 있다(표 2, 2.4~2.6).

표 2. Relation 별 끝 Entity 를 정하는 키

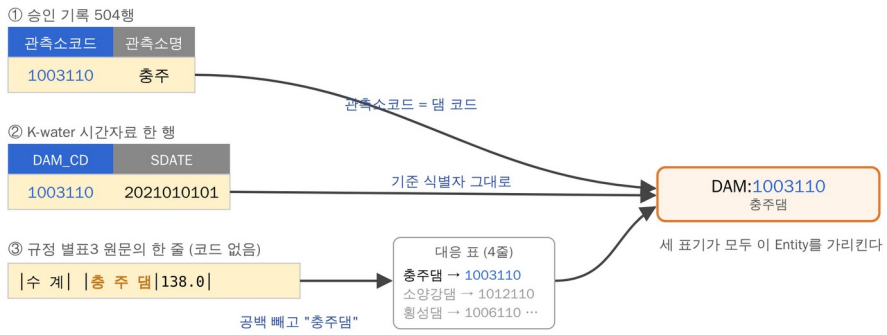
Relation	시작 → 끝	끝 Entity 를 정하는 키	방식	값의 성격	개수
supportedBy	Approval → EvidenceSource	같은 순차번호	2.4 승인 한 행	원본 그대로	80
supportedBy	Operation → EvidenceSource	운영행위 ID 의 순차번호	2.4 승인 한 행	원본에서 유도	68
authorizes	Approval → Operation	같은 순차번호	2.4 승인 한 행	연구용 구성	68
concernsDam	Approval → Dam	관측소코드 = 댐 코드	2.4 승인 한 행	원본 그대로	80
performedOnDam	Operation → Dam	순차번호 → 관측소코드	2.4 승인 한 행	원본에서 유도	68

Relation	시작 → 끝	끝 Entity 를 정하는 키	방식	값의 성격	개수
hasHydrometeorological State	Dam → HMS	같은 댐 코드	2.5 댐 코드	원본 그대로	24
supportedBy	HMS → EvidenceSource	같은 댐 코드	2.5 댐 코드	원본 그대로	24
appliesToDam	Criterion → Dam	별표 3 댐 이름 → 대응표	2.6 별표 3 이름	이름 일치	3
supportedBy	Criterion → EvidenceSource	규정 하나 → 고정 ID	2.6 별표 3 이름	원본 그대로	3
합계					418

값의 성격: 원본 그대로 = 원본의 키가 같아서 이음 / 원본에서 유도 = 원본의 키를 한 번 거쳐 이음 / 연구용 구성 = 원본에 직접 적힌 관계가 아니라 연구에서 정해 이음 / 이름 일치 = 코드가 없어 이름으로 이음.

2.3 댐 표기 맞추기 (개체 해소)

- 그림 2 의 왼쪽은 충주댐이 자료마다 적힌 모습이다. ① 승인 기록은 관측소코드 1003110 과 관측소명 "충주", ② K-water 자료는 DAM_CD 1003110, ③ 규정 별표 3 은 "충 주 댐"이라는 이름뿐이고 코드가 없다.
- ① 은 관측소코드가 K-water 댐 코드와 같아서 그대로 맞춘다(자료 준비 때 4 개 댐 모두 같음을 확인). ② 는 기준 식별자 자체이다.
- ③ 은 비정형 텍스트 추출에서 공백을 빼고 읽은 "충주댐"을 대응 표(표준 댐명 → 댐 코드, 4 줄)에서 찾아 1003110 을 얻는다. 광동댐은 별표 3 에 없다.
- 결과: 세 표기가 모두 하나의 Entity DAM:1003110 을 가리킨다. 이후 2.4~2.6 에서 댐을 끝 Entity 로 정할 때 이 대응을 쓴다.



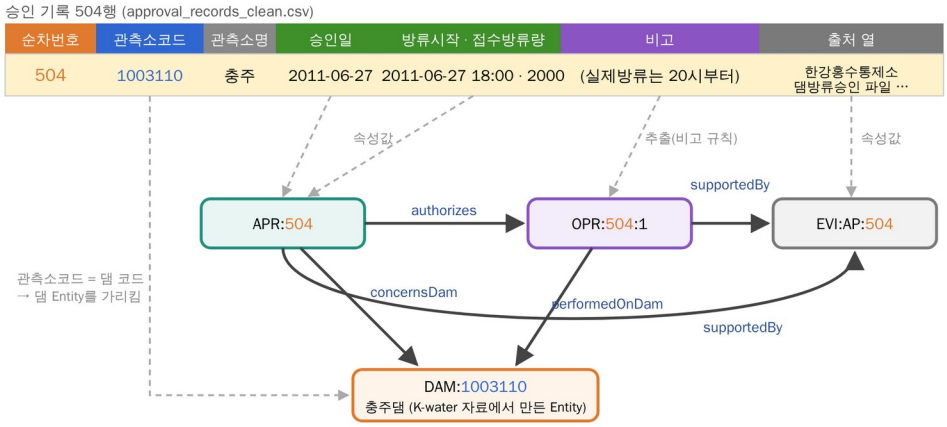
원리 · Purohit 외(2024) — 기준 식별자(QID)를 정하고, 자료마다 다르게 적힌 같은 대상을 그 식별자에 대응시킨다. 우리의 기준 식별자는 K-water 댐 코드이다.

그림 2. 자료마다 다른 충주댐 표기 세 가지를 기준 식별자 DAM:1003110 에 맞춘다

2.4 승인 기록 한 행으로 채우는 관계

- 표 2 의 9 줄 중 5 줄은 승인 기록의 한 행에서 끝 Entity 가 정해진다. 그림 3 의 위쪽은 승인 504 행을 칸 그대로 그린 것이다.
- 점선은 칸에서 Entity 로 가는 길이다(10/30 단계). 승인일·방류시작·접수방류량 칸으로 APR:504 를, 비고를 추출해 OPR:504:1 을, 출처 열로 EVI:AP:504 를 만들었다. 세 ID 에 모두 이 행의 순차번호 504(주황)가 들어 있다.
- 실선은 이번에 채우는 관계이다. ① APR:504 → OPR:504:1(authorizes), ② APR:504 → EVI:AP:504 와 OPR:504:1 → EVI:AP:504(supportedBy)는 ID 의 순차번호가 같은 것끼리 잇는다. ③ APR:504 → DAM:1003110(concernsDam)과 OPR:504:1 → DAM:1003110(performedOnDam)은 이 행의 관측소코드 1003110(파랑)으로 끝 Entity 를 정한다.

- authorizes 는 "같은 승인 행의 비고에서 뽑은 행위를 그 승인이 허가했다"고 연구에서 정해 이은 것이라 값의 성격이 연구용 구성이다(검토할 점 1).
- 결과: 승인 80 행에 같은 방법을 적용해 supportedBy 148 개(승인 80, 운영행위 68), authorizes 68 개, concernsDam 80 개, performedOnDam 68 개를 채운다. 변경 승인 17 개는 운영행위가 없어 authorizes 가 없다.

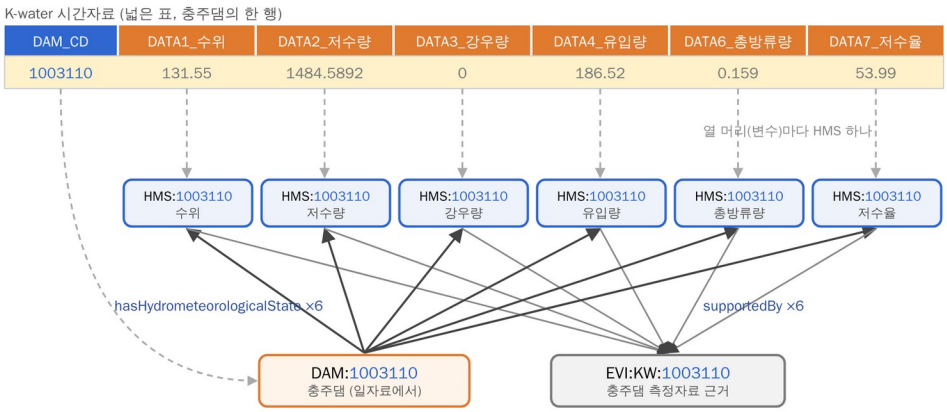


한 행에서 Entity 3개(APR, OPR, EVI:AP)가 나오고, 세 ID에 모두 순차번호 504가 들어간다. 그래서 순차번호만 보면 같은 행에서 나온 Entity끼리의 관계(authorizes, supportedBy)를 바로 정할 수 있다. 댐은 그 행의 관측소코드 1003110으로 정한다(concernsDam, performedOnDam).

그림 3. 승인 504 행 하나에서 채우는 관계 — 순차번호 504 와 관측소코드 1003110 이 끝 Entity 를 정한다

2.5 댐 코드로 채우는 관계

- 그림 4 의 위쪽은 K-water 시간자료의 충주댐 한 행이다. 10/30 단계에서 이 표의 DAM_CD 와 열 머리(변수)로 HMS 6 개를, 댐마다 측정자료 근거 EVI:KW 하나를 만들었고, 댐 Entity 는 일자료에서 만들었다(점선).
- 세 종류 Entity 의 ID 에 모두 같은 댐 코드 1003110(파랑)이 들어 있다. 그래서 ① DAM:1003110 → HMS 6 개 (hasHydrometeorologicalState), ② HMS 6 개 → EVI:KW:1003110(supportedBy)을 코드가 같은 것끼리 잇는다. 다른 자료를 찾을 필요가 없다.
- 결과: 4 개 댐 × 6 개 변수로 hasHydrometeorologicalState 24 개, supportedBy 24 개를 채운다.



세 종류 Entity의 ID에 모두 같은 댐 코드 1003110이 들어 있어, 코드가 같은 것끼리 잇는다.

그림 4. 댐 코드로 채우는 관계 — 같은 코드 1003110 을 가진 Dam, HMS, 측정자료 근거를 잇는다

2.6 별표 3 댐 이름으로 채우는 관계

- 그림 5 의 위쪽은 비정형 텍스트 추출로 만든 중간 파일 criterion_list.csv 의 한 줄이다. 10/30 단계에서 이 줄로 CRI:CR-02 를 만들었다(점선).
- 별표 3 에는 댐 코드가 없다. 그래서 ① 이 줄의 댐 이름 "충주댐"을 대응 표에서 찾아 댐 코드 1003110 을 얻고, ② CRI:CR-02 → DAM:1003110(appliesToDam)을 쓴다. 코드가 아니라 이름으로 정한 끝 Entity 이므로 값의 성격을 "이름 일치"로 남긴다.

- ③ 근거는 규정 하나뿐이라 근거 Entity 도 하나(고정 ID EVI:LAW:별표 3)이다. 기준 3 개 모두 CRI → EVI:LAW:별표 3(supportedBy)으로 잇는다.
- 결과: appliesToDam 3 개(충주, 소양강, 횡성), supportedBy 3 개를 채운다.

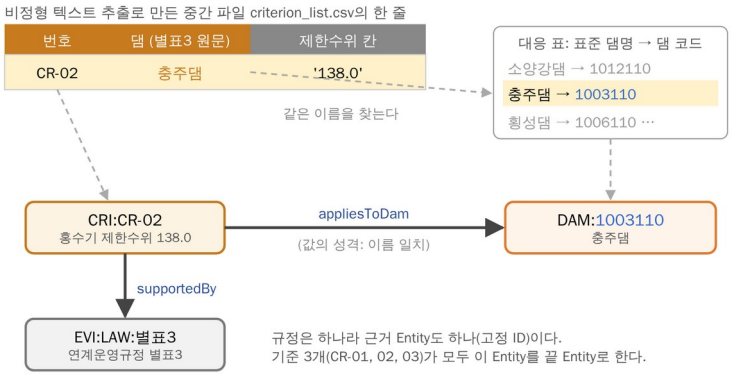


그림 5. 별표 3 댐 이름으로 채우는 관계 — 이름을 대응 표로 댐 코드에 맞춘다

2.7 결과: Relation 이 채워진 CSV

- Relation 9 종(온톨로지의 관계 9 개)의 실제 관계 418 개가 kgv4_relations.csv 에 한 줄씩 채워진다. 그림 6 은 그 파일의 실제 줄이다.
- 한 줄은 Relation 하나이며, 시작 Entity(subject), Relation 이름(relation), 끝 Entity(object), 끝 Entity 를 정한 규칙(rule), 값의 성격(origin), 설명(note)으로 이루어진다. 예를 들어 "APR:504, concernsDam, DAM:1003110"은 승인 504 가 충주댐에 관한 것이라는 관계 하나이다.
- 이로써 KG 에 들어갈 내용은 CSV 파일 세 개에 모두 채워졌다. kgv4_entities(Entity 와 Class), kgv4_properties(Data Property 값), kgv4_relations(Relation)이다. 이 세 파일을 그래프로 저장하는 것이 3 장이다.
- 연결 확인(10/19 질문 "연결이 실제로 되나"): 4 개 댐 전체에서 승인 80 개 모두 댐과 근거에, 운영행위 68 개 모두 댐·승인·근거에, HMS 24 개 모두 댐과 근거에, 기준 3 개 모두 댐과 근거에 이어졌다. 승인 중 운영행위로 이어진 것은 63 개이며, 나머지 17 개는 변경 승인이다.

kgv4_relations.csv — 전체 418줄 중 충주댐의 Entity 몇 개(승인 504, 운영행위 504:1, 수위 HMS, 기준 CR-02, 댐)가 시작인 줄 14개

subject (시작 Entity)	relation	object (끝 Entity)	rule	origin (값의 성격)	note
DAM:1003110	hasHydrometeorologicalState	HMS:1003110:수위	MR-HMS	real	
HMS:1003110:수위	supportedBy	EVI:KW:1003110	MR-SUP-HMS	real	
DAM:1003110	hasHydrometeorologicalState	HMS:1003110:저수량	MR-HMS	real	
DAM:1003110	hasHydrometeorologicalState	HMS:1003110:강우량	MR-HMS	real	
DAM:1003110	hasHydrometeorologicalState	HMS:1003110:유입량	MR-HMS	real	
DAM:1003110	hasHydrometeorologicalState	HMS:1003110:총방류량	MR-HMS	real	
DAM:1003110	hasHydrometeorologicalState	HMS:1003110:저수율	MR-HMS	real	
APR:504	supportedBy	EVI:AP:504	MR-SUP-APR	real	
APR:504	concernsDam	DAM:1003110	MR-APR-DAM	real	승인 레코드의 관측소코드 = 댐 코드 (DAM_CD)
OPR:504:1	performedOnDam	DAM:1003110	MR-OPR-DAM	derived	승인 행의 시설 코드
APR:504	authorizes	OPR:504:1	MR-AUTH	constructed	같은 승인 행의 비고에서 분류한 행위 (연구용 구성, 실행 확인 아님)
OPR:504:1	supportedBy	EVI:AP:504	MR-SUP-OPR	derived	
CRI:CR-02	appliesToDam	DAM:1003110	MR-CRI-DAM	name-match	별표3 시설명 일치(코드 없음)
CRI:CR-02	supportedBy	EVI:LAW:별표3	MR-SUP-CRI	real	
… 나머지 404줄					

그림 6. kgv4_relations.csv 의 실제 줄 — 충주댐 Entity 몇 개가 시작인 줄 14 개

3. 저장

3.1 따른 원리와 진행 방식

- 따른 원리: Huang 외(2026)는 추출한 지식을 JSON 으로 모은 뒤, 온톨로지의 관계에 따라 Python 스크립트가 JSON 의 키-값을 읽어 Cypher 문을 만들고, Entity 와 Relation 을 Neo4j 에 한꺼번에 넣었다. Neo4j 는 Cypher 로 조회·추가·삭제·수정이 효율적이고 여러 Relation 을 건너는 질의에 강해서 골랐다고 밝혔다(부록 C.2).
- Neo4j 는 Entity 와 Relation 을 그래프(점과 선) 모양으로 저장하는 데이터베이스이다. Cypher 는 Neo4j 에 Entity 와 Relation 을 넣고 찾을 때 쓰는 명령 문장이다. CSV 는 줄의 목록이라 "충주댐에서 출발해 관계를 따라간다"는 질의를 바로 할 수 없어서, 그래프로 저장한다.
- 우리는 모은 형태가 JSON 이 아니라 2 장까지 채운 CSV 파일 세 개이다. Python 스크립트가 이 파일의 줄을 읽어 Cypher 문을 쓰고(과정 1·2), 그 문을 모은 파일을 Neo4j 에서 실행한다(과정 3). 출처 파일(kgv4_provenance)은 Neo4j 에 넣지 않고 CSV 로 둔다.
- 아래 그림들은 CSV 의 칸과 Cypher 문의 자리를 같은 번호와 같은 색으로 표시했다. 번호가 같은 칸의 값이 Cypher 문의 그 자리에 들어간다.

3.2 CSV → Cypher → Neo4j

과정 1. Entity 를 Cypher 문으로 쓰고 Neo4j 에 넣기

- 원리: Entity 하나는 Cypher 문 하나가 되고, 실행하면 Neo4j 에 Entity 하나가 생긴다. Class 와 Data Property 값도 그 문 안에 함께 들어간다.
- 그림 7 의 위는 입력이다. kgv4_entities.csv 의 APR:504 줄 1 개와 kgv4_properties.csv 의 APR:504 줄 2 개를 Python 스크립트가 Entity ID 로 모은다.
- 가운데가 그 줄들로 쓴 Cypher 문이다. ① entity_id(APR:504)는 {id: 'APR:504'} 자리에, ② class(Approval)는 : Approval 자리에, ③ label 은 n.label 자리에 들어간다. ④⑦ property(approvalTime, approvalContent)는 n. 뒤의 이름 자리에, ⑥⑧ value 는 = 뒤의 값 자리에 들어간다. ⑤ datatype 이 date 이면 값을 date( )로 감싸 글자가 아니라 날짜로 넣는다. 그래야 4 장에서 "2020 년 8 월 안"처럼 기간으로 비교해 찾을 수 있다.
- 문장의 뜻은 그림의 설명과 같다. MERGE 는 이 Entity 가 없으면 만들고 있으면 그대로 쓰라는 뜻이라서, 같은 문을 다시 실행해도 APR:504 가 둘이 되지 않는다. SET 은 Data Property 값을 넣으라는 뜻이다.
- 맨 아래가 실행 결과이다. Neo4j 에 Entity APR:504 가 Class 와 Data Property 값을 가진 채 생긴다. 264 개 Entity 마다 이런 문이 하나씩 쓰인다.

kgv4_entities.csv (APR:504 줄)

entity_id	class	label
① APR:504	② Approval	③ 승인 504 (충주댐)

kgv4_properties.csv (APR:504 줄 2개)

entity_id	property	value	datatype
APR:504	④ approvalTime	⑥ 2011-06-27	⑤ date
APR:504	⑦ approvalContent	⑧방류시작 2011-06-27 18:00; 접수방류량 2000㎥/s; 비고: (실제방류는 20시부터	string

```
MERGE (n:Entity:Approval {id: 'APR:504'})
SET n.label = '승인 504 (충주댐)',
    n.approvalTime = date('2011-06-27'),
    n.approvalContent = '방류시작 2011-06-27 …';
```

MERGE — 이 Entity가 없으면 만들고, 있으면 그대로 쓴다.
( ) — Entity 하나. :Approval은 Class, {id: 'APR:504'}는 이 Entity의 ID. n은 이 문 안에서 부르는 이름.
SET — Data Property 값을 넣는다. property가 이름이 되고 value가 값이 된다.
date( ) — datatype이 date라서 글자가 아니라 날짜 값으로 넣는다(일시는 datetime( ), 숫자는 숫자).
:Entity — 모든 Entity에 붙는 공통 이름표. Class를 몰라도 ID 하나로 찾을 수 있게 한다.

↓ Neo4j에서 실행하면

Entity APR:504 (Class: Approval)
label = 승인 504 (충주댐)
approvalTime = 2011-06-27 (날짜)
approvalContent = 방류시작 2011-06-27 18:00; …

그림 7. 과정 1 — CSV 칸이 Cypher 문의 자리로 들어가고, 실행하면 Neo4j 에 Entity 가 생긴다 (APR:504)

과정 2. Relation 을 Cypher 문으로 쓰고 Neo4j 에 넣기

- 원리: Relation 하나는 Cypher 문 하나가 된다. Relation 은 두 Entity 사이에 긋는 것이므로, 문은 두 Entity 를 먼저 찾고 그 사이에 Relation 을 만든다.

- 그림 8 의 위는 kgv4_relations.csv 의 한 줄이다. ① subject(APR:504)와 ② object(DAM:1003110)는 MATCH 문에서 찾을 두 Entity 의 ID 자리에, ③ relation(concernsDam)은 화살표 안의 이름 자리에, ④⑤⑥ rule, origin, note 는 SET 뒤의 값 자리에 들어간다.
- MATCH 는 이미 있는 Entity 를 찾으라는 뜻이고, 찾은 두 Entity 를 이 문 안에서 a 와 b 로 부른다. (a)-[r:concernsDam]->(b)는 a 에서 b 로 가는 concernsDam Relation 이라는 뜻이며, MERGE 로 없을 때만 만든다.
- 맨 아래가 실행 결과이다. 두 Entity 사이에 방향이 있는 선 하나가 생기고, 그 선에 규칙과 값의 성격이 남는다. 418 개 Relation 마다 이런 문이 하나씩 쓰인다.

kgv4_relations.csv (한 줄 = Relation 하나)

subject	relation	object	rule	origin	note
① APR:504	③ concernsDam	② DAM:1003110	④ MR-APR-DAM	⑤ real	⑥ 관측소코드 = 댐 코드(DAM_CD)

```
MATCH (a:Entity {id: 'APR:504'}), (b:Entity {id: 'DAM:1003110'})
MERGE (a)-[r:concernsDam]->(b)
SET r.rule = 'MR-APR-DAM', r.origin = 'real',
    r.note = '승인 레코드의 관측소코드 = 댐 코드(DAM_CD)';
```

MATCH — 이미 있는 Entity를 찾는다. ID가 APR:504인 Entity를 a, DAM:1003110인 Entity를 b라고 부른다.
MERGE — 없으면 만든다. (a)-[r:concernsDam]->(b)는 a에서 b로 가는 Relation r이고, 이름이 concernsDam이다.
SET — Relation r에 규칙(rule), 값의 성격(origin), 설명(note)을 넣는다.

↓ Neo4j에서 실행하면

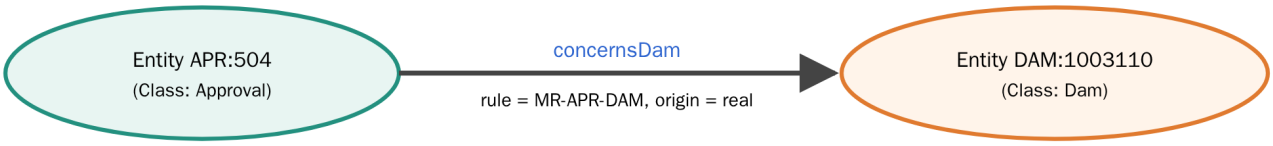


그림 8. 과정 2 — 관계 CSV 한 줄이 Cypher 문이 되고, 실행하면 두 Entity 사이에 Relation 이 생긴다

과정 3. Cypher 문을 모아 Neo4j 에서 실행하기

- 원리: 과정 1·2 에서 쓴 문을 파일 하나에 모아, Neo4j 가 위에서부터 한 번에 실행하게 한다.
- 그림 9 의 왼쪽이 그 파일(kgv4_load.cypher, 684 줄)이다. 주석 1 줄, ID 가 겹치지 않게 막는 규칙 1 줄, Entity 문 264 줄, Relation 문 418 줄 순서이다. Relation 문은 두 Entity 를 찾아야 하므로 Entity 문이 모두 끝난 뒤에 온다.
- 오른쪽은 실행 순서이다. ① Neo4j 를 켜고 ② 이전에 넣은 Entity 와 Relation 을 모두 지운 뒤 ③ 파일을 실행하고 ④ Entity 와 Relation 수를 세어 264 개, 418 개인지 확인한다.
- 매번 지우고 처음부터 넣으므로, CSV 를 고친 뒤 다시 실행하면 Neo4j 의 KG 가 CSV 와 항상 같아진다.

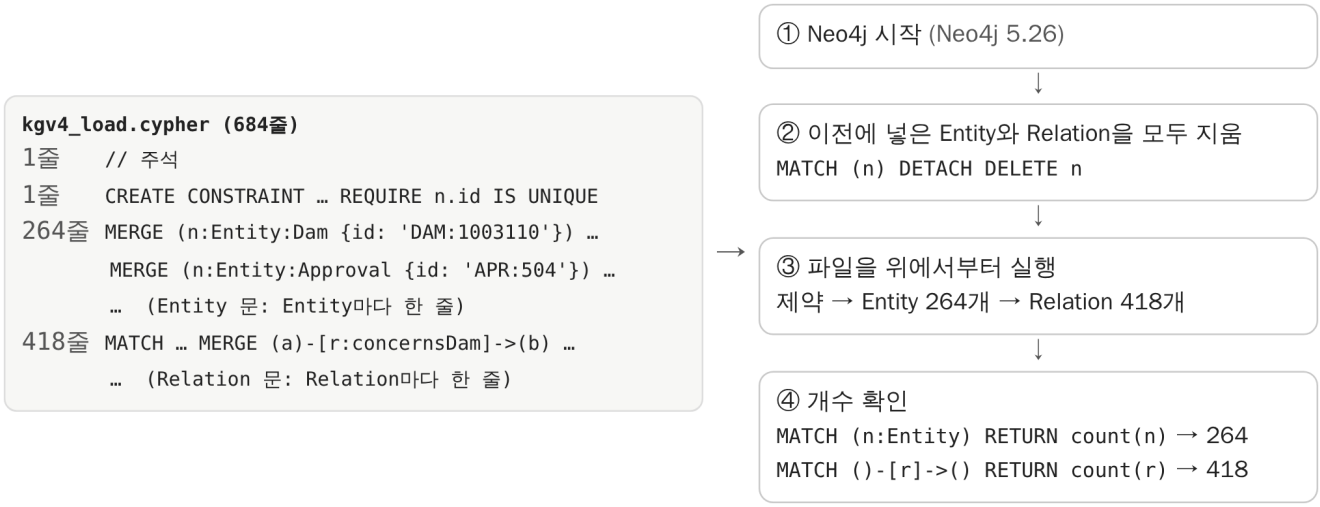


그림 9. 과정 3 — Cypher 파일의 구성과 실행 순서

3.3 KG 밖에 두는 것: 측정 저장소와 문서 저장소

- 시간별 측정값(508,246 행)과 규정 원문은 KG 에 넣지 않고 CSV 파일로 둔다. KG 에는 그 파일의 행을 찾아갈 값만 Data Property 로 둔다.
- 그림 10 의 ①은 측정 저장소이다. Entity HMS:1003110:수위의 stationCode(1003110)가 DAM_CD 열과 같고, 찾을 시각(2020-08-02 18:00)이 SDATE_raw 열(2020080218)과 같은 행을 찾는다. 그 행의 DATA1_수위 열이 그 시각의 수위 139.55 EL.m 이다.
- ②는 문서 저장소이다. Entity EVI:LAW:별표 3 의 sourceLocator("별표 3")가 sourceLocator 열과 같은 행을 찾으면, 그 행의 text 가 규정 원문이다.

① 측정 저장소 — KG의 Entity가 가진 값(stationCode, 시각)으로 CSV의 행을 찾는다

Entity HMS:1003110:수위
stationCode = 1003110
variableType = 수위

→ DAM_CD = stationCode, SDATE_raw = 찾는 시각(2020-08-02 18:00 → 2020080218), 열 = variableType이 든 열(DATA1_수위)

kwater_mywater_hydr_H_aligned_wide.csv.gz (2010-08~2020-12) · kwater_mywater_hydr_H_wide.csv.gz (2021-01~2026-09)도 같은 열 · 4개 댐 합계 508,246행

source_file	retrieval_time_utc	param1_resolution	DAM_CD	SDATE_raw	DATA1_수위(EL.m)	DATA2_저수량(MCM)	DATA3_강우량(mm)	DATA4_유입량(CMS)	DATA5_source_label_unknown	DATA6_총방류량(CMS)	DATA7_저수율(%)
01_raw/KWater/mywater_aligned/hydr/H/1003110/2020-07-09_2020-08-07.json	2026-10-09T01:36:21Z	H	1003110	2020080217	139.37	2111.215	0.711	4693.654	4693.654	707.265	76.8
01_raw/KWater/mywater_aligned/hydr/H/1003110/2020-07-09_2020-08-07.json	2026-10-09T01:36:21Z	H	1003110	2020080218	139.55	2126.472	1.901	4945.201	4945.201	707.145	77.3
01_raw/KWater/mywater_aligned/hydr/H/1003110/2020-07-09_2020-08-07.json	2026-10-09T01:36:21Z	H	1003110	2020080219	139.69	2138.381	0.273	4015.509	4015.509	707.453	77.8

② 문서 저장소 — KG의 Entity가 가진 값(sourceLocator)으로 CSV의 행을 찾는다

Entity EVI:LAW:별표3
sourceLocator = 별표 3

→ sourceLocator 열이 "별표 3"인 행의 text가 규정 원문이다

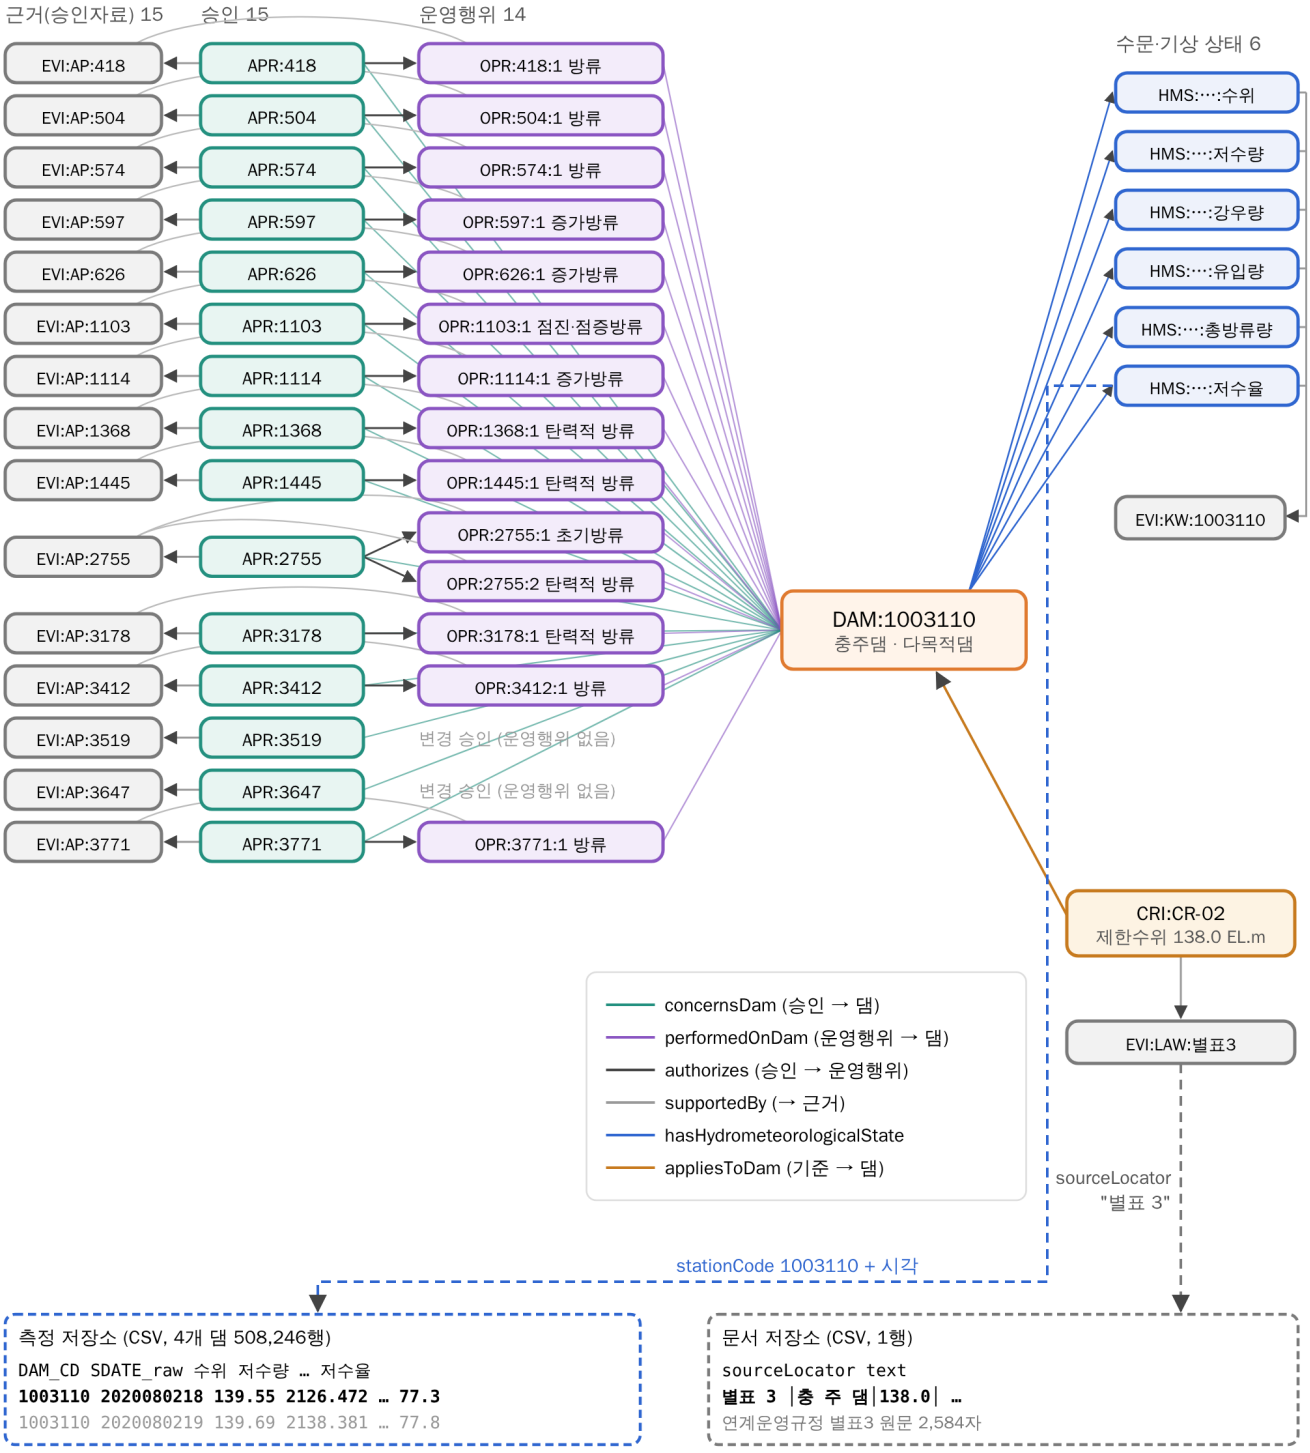
kgv4_documents.csv (1행)

sourceLocator	doc_title	text (2,584자 중 앞부분)
별표 3	댐과 보 등의 연계운영규정 (기후에너지환경부 훈령 제42호, 시행 2026-07-08)	댐의 홍수기 제한수위(제6조) [별표 3] 댐의 홍수기 제한수위(제6조) ┌──┬──┬──┬──┐ |구 분 |댐 종류 |댐 명 |홍수기 제한수위 |시설별 최저 운영수위| | | | |(EL.m) |(EL.m) | ├──┼──┼──┼──┤ |한 강 |다목적댐 |소양강댐 |190.3 |- |수 계 | |충 주 댐 |138.0 |- | | |횡 성 댐 |178.2 |- | ├──┼──┼──┤ | |수력발전댐|화 천 댐 |175.0 |- | | |춘 천 댐 |102.0 |98.0 | | |의 암 댐 | 70.5 |67.0 …

그림 10. 외부 저장소 CSV 의 실제 모습과, KG 의 값으로 행을 찾는 방법

3.4 결과: Neo4j 에 저장된 KG

- Neo4j 에 Entity 264 개와 Relation 418 개가 저장된다(표 3).
- 그림 11 의 위는 Neo4j 에 저장된 충주댐의 Entity 53 개와 Relation 을 생략 없이 그린 것이다. 가운데 DAM:1003110 에서 왼쪽으로 승인 15 개(초록 선)와 운영행위 14 개(보라 선)가, 오른쪽 위로 HMS 6 개(파란 선)가, 오른쪽 아래로 기준 CR-02(주황 선)가 이어진다. 승인마다 왼쪽에 근거, 오른쪽에 운영행위가 있고, 3519 와 3647 은 변경 승인이라 운영행위가 없다.
- 아래의 점선은 KG 에 이어진 것이 아니라, KG 의 값으로 외부 저장소의 행을 끌어오는 길이다. HMS 의 stationCode 와 시각으로 측정값을, EVI:LAW:별표 3 의 sourceLocator 로 규정 원문을 가져온다. 4 장의 검색이 이 KG 의 Relation 을 따라가고, 이 점선으로 값을 가져온다.



위: Neo4j에 저장된 충주댐의 Entity 53개와 Relation. 아래 점선: KG에 넣지 않은 측정값과 규정 원문을 Entity의 값(stationCode, sourceLocator)으로 찾아오는 길. 충주댐에 이어진 Entity 53개(댐 1, 승인 15, 승인자료 근거 15, 운영행위 14, HMS 6, 측정자료 근거 1, 기준 1, 규정 근거 1)와 그 관계를 모두 그렸다. 4개 댐 전체로는 Entity 264개, 관계 418개이다.

그림 11. Neo4j 에 저장된 KG(충주댐 Entity 53 개)와 외부 저장소로 가는 길

표 3. Neo4j 에 저장된 Entity 와 Relation 수

Class	Entity 수	Relation	Relation 수
EvidenceSource	85	supportedBy	175

Class	Entity 수	Relation	Relation 수
Approval	80	concernsDam	80
Operation	68	authorizes	68
HydrometeorologicalState	24	performedOnDam	68
Dam	4	hasHydrometeorologicalState	24
Criterion	3	appliesToDam	3
합계	264	합계	418

4. 검색·답변

4.1 따른 원리와 진행 방식

- 따른 원리: Purohit 외(2024)의 GraphAide 는 질의 단계에서 LLM 이 자연어 질문을 부분 그래프 조회 템플릿으로 바꾸고, 이를 Cypher 로 Neo4j 에서 실행한 결과를 LLM 에 맥락으로 주어 답변을 만든다. KG 의 관계를 따라 찾은 근거를 주므로 LLM 이 없는 사실을 지어내는 것(환각)을 줄인다(부록 C.1).
- 우리는 조회 템플릿을 CQ 마다 미리 정해 두었다(Cypher 6 개). LLM 은 질문에서 의도(CQ1~CQ6)와 값(댐, 기간)만 뽑고, 그 다음은 코드가 정해진 순서대로 KG 와 저장소를 조회한다. GraphAide 의 Cypher 자동 생성, 질의 확장, 벡터 검색, 에이전트는 쓰지 않았다.
- 진행 방식: 질문 하나가 6 단계를 거친다. LLM 은 ①과 ⑥ 두 곳에서 쓰고(같은 모델, 지시문만 다름), ②~⑤ 는 코드가 한다(그림 12). 아래에서 서버 실행 기록의 질문 하나를 따라간다(Qwen3-32B, 2026-10-16).

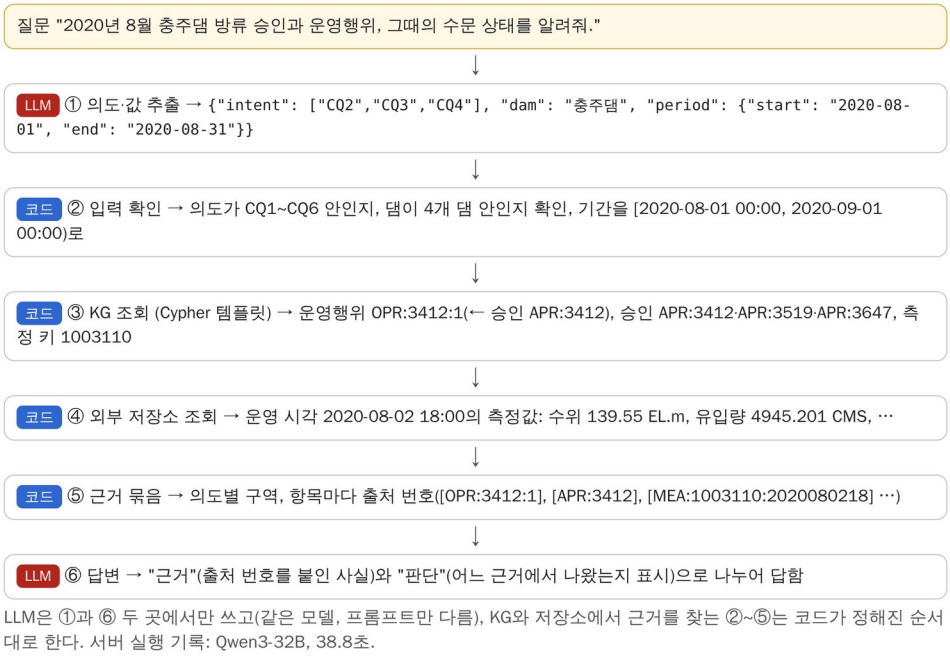


그림 12. 질문 하나가 답변까지 가는 전체 경로

4.2 질문 하나를 따라가기

입력

- 질문: "2020 년 8 월 충주댐 방류 승인과 운영행위, 그때의 수문 상태를 알려줘."

과정 1. 의도·값 추출 (LLM)

- LLM 에 지시문과 질문을 준다. 지시문에는 의도 목록(CQ1~CQ6), 허용 댐 4 개, 값의 형식, 규칙 5 개가 있다(목록 밖 의도를 만들지 않음, 질문에 없는 값을 추측하지 않음, 이유를 묻는 질문과 범위 밖 댐은 의도를 비우고 이유를 적음, JSON 하나만 출력).
- 이 질문에서 LLM 은 "방류 승인" → CQ4, "운영행위" → CQ3, "그때의 수문 상태" → CQ2, 댐 = 충주댐, 기간 = 2020-08-01 ~ 2020-08-31 을 뽑았다.

```
"2020년 8월 충주댐 방류 승인과 운영행위, 그때의 수문 상태를 알려줘."
```

↓ 의도 목록(CQ1~CQ6)과 허용 댐 4개를 적은 지시문과 함께 LLM에 준다

질문 속 표현	뽑은 값	의미
방류 승인	CQ4	과거 방류 승인
운영행위	CQ3	과거 운영행위
그때의 수문 상태	CQ2	과거 시점의 수문·기상 상태
충주댐	dam = 충주댐	허용 댐 4개 중 하나 ("충주"라고 해도 충주댐으로)
2020년 8월	period = 2020-08-01 ~ 2020-08-31	시점이 없으면 "전체"

출력은 JSON 하나뿐이다. 목록 밖의 댐(예: 팔당댐), 이유를 묻는 질문("왜 방류했나")은 의도를 비우고 이유를 적는다 → 이후 단계에서 "질의 불가"로 답한다.

그림 13. 질문 속 표현이 의도와 값이 되는 과정

과정 2. 입력 확인 (코드)

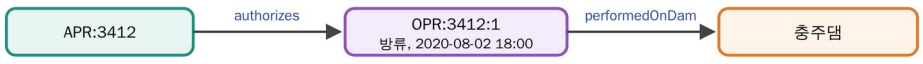
- 의도가 CQ1~CQ6 안인지, 댐이 4 개 댐 안인지 확인하고 이름을 표준 댐명으로 바꾼다("충주" → 충주댐).
- 기간의 끝 날짜는 그 날 전체로 읽어 [2020-08-01 00:00, 2020-09-01 00:00)으로 바꾼다. 확인을 통과하지 못하면 조회하지 않고 "질의 불가: 이유"를 답변 단계로 넘긴다.

과정 3. KG 조회 (코드, Cypher 템플릿)

- 먼저 충주댐의 HMS 에서 stationCode(1003110)를 얻는다. 측정 저장소를 찾아갈 키이다.
- CQ3: 충주댐에서 performedOnDam 을 거꾸로 따라가 기간 안의 운영행위를 찾고, authorizes 로 그것을 허가한 승인을 찾는다 → OPR:3412:1 ← APR:3412.
- CQ4: concernsDam 으로 승인일이 기간 안인 승인을 찾는다 → APR:3412, APR:3519, APR:3647. 뒤의 둘은 변경 승인이라 운영행위가 없다.
- 2 장에서 채운 관계가 여기서 조회 경로로 쓰인다. CQ 별 경로는 그림 14 의 표와 같다.

CQ3 운영행위 템플릿 (값 $dam = '충주댐', $s = 2020-08-01, $e = 2020-09-01)

```
MATCH (o:Operation)-[:performedOnDam]->(d:Dam {damName:$dam})
WHERE o.operationTime >= datetime($s) AND o.operationTime < datetime($e)
OPTIONAL MATCH (a:Approval)-[:authorizes]->(o)
RETURN o.id, o.operationType, o.operationTime, a.id
```



충주댐에서 출발해 관계를 거꾸로 따라가, 기간 안의 운영행위와 그것을 허가한 승인을 찾는다

의도	따라가는 관계 (Cypher 템플릿)	외부 저장소	이 질문의 결과
CQ1 현재 상태	Dam → hasHydrometeorologicalState → HMS (stationCode 얻기)	측정: 가장 최근 시각	—
CQ2 과거 상태	(운영행위가 있으면) 운영 시각	측정: 그 시각	2020-08-02 18:00 1행
CQ3 운영행위	Operation → performedOnDam → Dam, Approval → authorizes → Operation	—	OPR:3412:1 ← APR:3412
CQ4 승인	Approval → concernsDam → Dam (승인일이 기간 안)	—	APR:3412, 3519, 3647
CQ5 운영기준	Criterion → appliesToDam → Dam	문서: sourceLocator	—
CQ6 근거	조회한 항목마다 → supportedBy → EvidenceSource	—	—

그림 14. CQ3 Cypher 템플릿과 따라가는 관계, CQ 별 조회 경로

과정 4. 외부 저장소 조회 (코드)

- CQ2 와 CQ3 이 함께 있으면 운영행위 시각마다 그 시각의 측정값을 읽는다. 키는 stationCode 1003110 과 시각 2020-08-02 18:00 이다.
- CQ1 은 저장된 가장 최근 시각의 값을, CQ5 는 문서 저장소에서 별표 3 원문을 읽는다.



그림 15. 운영 시각과 댐 코드로 측정 저장소의 한 행을 읽는다

과정 5. 근거 묶음 (코드)

- 조회 결과를 의도별 구역으로 나누고, 항목마다 출처 번호를 붙인다. 출처 번호는 KG 의 Entity ID 이고, 측정값은 [MEA:댐 코드:시각]이다.
- 값은 저장소의 원값 그대로 쓰고 계산한 값은 넣지 않는다. 끝에 근거 사용 원칙 3 문장을 붙인다.

```
[질문] 2020년 8월 충주댐 방류 승인과 운영행위, 그때의 수문 상태를 알려줘.
[대상] 충주댐, 기간 2020-08-01 ~ 2020-08-31

[근거 1. 운영행위와 허가한 승인]  (CQ3) 운영행위의 시각은 비교에 적힌 시각, 없으면 승인된 방류 시작 시각이다.
[OPR:3412:1] 방류, 시각 2020-08-02 18:00 ← 승인 [APR:3412]

[근거 2. 운영 시각의 상태]  (CQ2)
[MEA:1003110:2020080218] 2020-08-02 18:00  수위 139.55 EL.m, 저수량 2126.472 MCM, 강우량 1.901 mm,
   유입량 4945.201 CMS, 총방류량 707.145 CMS, 저수율 77.3 %

[근거 3. 방류 승인]  (CQ4)
[APR:3412] 승인일 2020-08-02: 방류시작 2020-08-02 18:00; 접수방류량 3000㎥/s
[APR:3519] 승인일 2020-08-06: 방류시작 2020-08-02 18:00; 접수방류량 7000㎥/s; 비고: 방류기간 (당초) … (변경)
…
[APR:3647] 승인일 2020-08-12: 방류시작 2020-08-06 06:00; 접수방류량 7000㎥/s; 비고: 수문방류 변경승인(방류기
간연장) …

[근거 사용 원칙] 근거에 있는 내용만 사실로 쓰고 출처 번호를 붙인다 / 비교·해석은 판단임을 밝힌다 / 없으면 "자료에 없
음"
```

의도별 구역 출처 번호 = KG의 Entity ID, 측정값은 MEA 원칙 3문장

그림 16. 근거 묶음 — LLM 에 주는 근거 전체

과정 6. 답변 (LLM)

- LLM 에 답변 지시문과 근거 묶음을 준다. 지시문: 근거 묶음에 있는 내용만 사실로 쓰고 출처 번호를 붙인다, 비교·해석은 "판단"으로 나누고 쓴 근거를 적는다, 없으면 "자료에 없음".
- 주의 사항도 함께 준다: 운영행위 시각은 비고의 시각이거나 승인된 방류 시작 시각이다, "현재"는 저장된 가장 최근 시각이며 실시간이 아니다, 방류 사유는 자료에 없으므로 단정하지 않는다.

```
근거
- 2020년 8월 2일 18:00에 방류가 승인되었으며, 방류량은 3000㎥/s로 접수되었습니다. [APR:3412]
- 이후 8월 6일에 방류 승인이 변경되어 방류량이 7000㎥/s로 증가하고, 방류 기간이 8월 2일 18:00부터 8월 16일 24:00
까지로
  확정되었습니다. [APR:3519]
- 8월 12일에는 방류 기간이 다시 연장되어 8월 6일 06:00부터 8월 22일 00:00까지로 확정되었습니다. [APR:3647]
- 방류가 시작된 2020년 8월 2일 18:00 기준, 수위는 139.55 EL.m, … 저수율은 77.3%입니다.
[MEA:1003110:2020080218]

판단
- 방류량은 처음 3000㎥/s에서 이후 7000㎥/s로 증가했습니다. 방류 기간은 여러 차례 변경되며 최종적으로 8월 22일
00:00까지
  연장되었습니다. (근거: [APR:3412], [APR:3519], [APR:3647])
- … 이는 댐의 수문 상황과 유입량 변화에 따라 조정된 것으로 판단됩니다. (근거: [APR:3412], …)
```

사실마다 출처 번호 판단마다 쓴 근거 빨간 글씨: 자료에 없는 사유를 추정한 문장 → 검토할 점 3

그림 17. 답변 — 근거(출처 번호)와 판단(쓴 근거)으로 나뉜다

결과

- 질문마다 의도 원문, 의도 JSON, 조회 결과, 근거 묶음, 답변이 파일로 남는다. 서버에서 질문 5 개를 실행한 결과는 표 4 와 같다.

표 4. 서버 실행 결과 (Qwen3-32B, 2026-10-16)

질문	뽑은 의도	결과	시간
충주댐 현재 상태를 제한수위와 비교하고, 비슷한 수문 상태일 때의 승인·운영행위	CQ1, CQ5, CQ4, CQ3	근거와 판단으로 답함	159.6 초
소양강댐의 홍수기 제한수위와 그 근거	CQ5, CQ6	190.3 EL.m 과 별표 3 근거로 답함	14.1 초
2020 년 8 월 충주댐 승인·운영행위·수문 상태	CQ2, CQ3, CQ4	4.2 의 예	38.8 초
광동댐 제한수위	CQ5	별표 3 에 없어 "자료에 없음"	7.7 초
팔당댐의 현재 수위	없음 (거절)	범위 밖 댐이라 질의 불가	2.4 초

5. 검토할 점

1. authorizes 는 연구용 구성 (Relation 채우기)

- 운영행위가 승인 비고에서 구성한 것이므로, "그 승인이 그 운영행위를 허가했다"는 연결도 연구에서 정한 것이다. 실행을 확인한 연결이 아니다.
- 답변 지시문에 "실제 수행이 확정된 것처럼 쓰지 않는다"를 넣어 다루고 있다. 실제 운영 기록을 얻으면 다시 정한다.

2. 같은 코드를 같은 시설로 봄 (Relation 채우기)

- 승인 파일의 관측소코드와 K-water 댐 코드가 같으면 같은 댐으로 보았다(4 개 댐 모두 이름도 일치). 두 기관의 코드가 같은 시설을 뜻한다는 공식 자료로 확인하지는 않았다.
- 별표 3 은 코드가 없어 이름으로 이었다(appliesToDam 3 개).

3. 답변 품질과 속도 (검색·답변, 서버 실행 기록)

- 2020 년 8 월 질문의 판단에 "댐의 수문 상황과 유입량 변화에 따라 조정된 것으로 판단됩니다"처럼 자료에 없는 사유를 추정한 문장이 있다. 지시문의 "사유를 단정하지 않는다"를 어긴 것이다.
- 광동댐 질문의 답변에서 출처 자리에 의도 이름([CQ5])을 적었다.
- 같은 종합 질문을 5 번 실행했을 때 CQ2(과거 상태)를 뽑은 것은 1 번이었다. 의도 추출이 실행마다 다를 수 있다.
- 종합 질문은 159.6 초 걸렸다. 첫 질문에서 측정 저장소(50 만 행)를 읽는 시간이 들어 있다.
- 시연 전에 지시문을 고치고, 정해 둔 질문 세트로 반복해서 확인한다.

6. 다음 계획

11/26 시연 구조

- 이번에 정리한 검색·답변 구조를 그대로 쓰고, 처음 보는 사람이 직접 질문할 수 있도록 아래를 더한다.
- 채팅 화면: 노트북 브라우저에서 질문하고 답변을 본다. 답변의 출처 번호를 누르면 원문(승인 기록 행, 별표 3 원문, 측정값)이 보인다.
- 답할 수 있는 범위 안내: 대상 댐 4 개와 질문 종류(CQ1~CQ6), 예시 질문을 화면에 둔다. 범위 밖 질문과 인사에는 범위와 예시 질문으로 안내한다.
- 이어지는 질문: "그럼 소양강댐은?"처럼 앞 질문의 댐·기간을 이어받는다.
- 속도: 측정 저장소를 서버를 켤 때 미리 읽어 둔다.
- 접속: 노트북 → 핫스팟 → 연구실 서버. 인터넷이 안 될 때를 대비해 시연 동영상을 찍어 둔다.

- 시연 때 밝힐 점: "현재"는 저장된 마지막 시각(2026-09-28)이며 실시간이 아니다. 범용 LLM 을 썼다. 실제 운영에 쓰려면 자료 연결 확대와 에이전트 등이 더 필요하다.

11/20 발표 자료

- 처음 보는 사람을 위한 설명 순서로 만든다: 왜 필요한가 → 무엇을 만들었나(온톨로지·KG) → 어떻게 답하나(이번 4 장) → 시연 → 한계와 향후 계획.

검증

- 11/02 회의에 따라 다른 연구들의 KG·온톨로지 검증 방법을 조사해 분석한 뒤, 적용할 방안을 정리한다.

부록 A. 용어 정리

표 5. 용어 정의

용어	본 연구에서의 정의
Relation 채우기	온톨로지가 허락한 Class 사이의 관계 가운데, 자료 속 키로 Entity 사이의 실제 관계(시작 Entity → 끝 Entity)를 골라 잇는 일.
개체 해소	자료마다 다르게 적힌 같은 대상(충주, 충 주 댐, 1003110)을 하나의 기준 식별자에 대응시키는 일. 문헌의 entity disambiguation.
기준 식별자	같은 대상을 가리키는 표기들을 모으는 기준 ID. 본 연구는 K-water 댐 코드, GraphAide 는 Wikidata 의 QID.
Neo4j	Entity 와 Relation 을 그래프(점과 선) 모양으로 저장하는 데이터베이스.
Cypher	Neo4j 에 Entity 와 Relation 을 넣고 찾을 때 쓰는 명령 문장. MERGE(없으면 만듦), MATCH(찾음), SET(값을 넣음) 등.
조회 템플릿	CQ 마다 미리 정해 둔 Cypher 문. 댐 이름과 기간만 바꿔 넣어 실행한다.
의도	질문이 요구하는 CQ(CQ1~CQ6). 한 질문에 여러 개가 있을 수 있다.
근거 묶음	KG 와 저장소에서 찾은 근거를 의도별 구역과 출처 번호를 붙여 LLM 에 주는 글.
출처 번호	근거 항목마다 붙이는 표시. KG 의 Entity ID 이거나 측정값의 [MEA:댐 코드:시각].
환각	LLM 이 자료에 없는 사실을 지어내는 것.

부록 B. Ontology 가 답해야 할 질문과 관계

표 6. 세부 질문 (CQ1~CQ6)

번호	질문 대상	세부 질문
CQ1	현재 수문·기상 상태	대상 댐의 현재 또는 기준시점의 강우, 수위, 유입량, 방류량 등 수문·기상 상태는 무엇인가?
CQ2	과거 수문·기상 상태	선택된 과거 시점 또는 사례에서 대상 댐의 강우, 수위, 유입량, 방류량 등 수문·기상 상태는 어떠했는가?
CQ3	과거 운영행위	해당 과거 시점 또는 사례에서 실제로 수행된 댐 운영행위는 무엇이었는가?
CQ4	과거 방류 승인	해당 과거 시점 또는 사례에서 어떤 방류 승인이 있었으며, 그 승인내용은 무엇인가?
CQ5	현재 운영기준	현재 대상 댐에 적용되는 운영기준은 무엇이며, 현재 운영 판단과 관련된 기준값은 무엇인가?
CQ6	공식 근거	각 수문·기상 상태, 운영행위, 승인내용 및 운영기준을 확인할 수 있는 공식 자료 또는 근거문서는 무엇인가?

표 7. Relation (9 개)

Subject	Relation	Object	의미
Dam	hasHydrometeorologicalState	HydrometeorologicalState	댐이 해당 수문·기상 변수 정보와 연결됨
Operation	performedOnDam	Dam	운영행위가 특정 Dam 에서 수행됨
Approval	authorizes	Operation	Approval 이 특정 Operation 을 승인함
Approval	concernsDam	Dam	Approval 이 특정 Dam 에 관한 것임
Criterion	appliesToDam	Dam	운영기준이 특정 Dam 에 적용됨
HydrometeorologicalState	supportedBy	EvidenceSource	상태를 확인할 수 있는 근거자료
Operation	supportedBy	EvidenceSource	운영행위를 확인할 수 있는 근거자료
Approval	supportedBy	EvidenceSource	승인을 확인할 수 있는 근거자료
Criterion	supportedBy	EvidenceSource	운영기준을 확인할 수 있는 근거자료

부록 C. 근거 문헌의 원리

C.1 Purohit 외(2024) — Relation 채우기(개체 해소), 검색·답변

- 무엇인가: 여러 출처의 정형·비정형 자료로 KG 를 만들고, 그 KG 를 조회·추론하는 질의 시스템 GraphAide 를 제안한 학회 논문이다 (IEEE BigData 2024). OpenAI LLM, Chroma 벡터 DB, Neo4j, LangChain 으로 구현했다.
- KG 생성 단계의 개체 해소: 기준 지식베이스로 DARPA Wikidata(DWD)를 쓰고, QID 마다 설명 문서를 만들어 벡터 DB 에 넣었다. 온톨로지와 DWD 에 기반한 에이전트가 글에서 대상의 표기를 뽑고, RAG 기반 후보 재순위로 가장 가까운 QID 를 고른다. → 기준 식별자에 대응시키는 원리만 따랐고, 벡터 DB 와 LLM 재순위는 쓰지 않았다.
- 질의 단계: LLM 이 질문을 여러 형태로 확장하고, 이를 부분 그래프 조회 템플릿으로 바꿔 Cypher 를 자동 생성한다. 그래프 조회 결과와 벡터 검색 결과를 합쳐 LLM 의 맥락으로 주고, 답변을 모아 하나의 응답을 만든다. 정해진 순서(chain)와 에이전트를 함께 쓴다. → KG 조회 결과를 LLM 의 근거로 주는 원리를 따랐고, Cypher 는 CQ 마다 미리 정한 템플릿으로 대신했다.
- 평가: RAGAS 지표와 전문가 정성 평가를 쓴다고 밝혔으며, 정식 평가는 향후 과제로 두었다.

C.2 Huang 외(2026) — 저장

- 추출한 지식을 JSON 으로 통합하고, DDO 의 의미·계층 관계에 따라 Python 스크립트가 JSON 키-값을 읽어 Cypher 문을 만든다. 이 문들로 DDKG 의 Entity 를 일괄 생성하고 Entity 사이의 관계를 만들어 Neo4j 에 적재한다.
- 저장소로 Neo4j 를 고른 이유: Cypher 로 조회·추가·삭제·수정이 효율적이고, 다중 홉 추론과 복잡한 질의에 강하다.
- 구축한 DDKG 는 Entity 201,362 개, Relation 953,447 개이다. → JSON 대신 CSV 를 모은 형태로 쓴 것 외에는 같은 순서(모음 → 스크립트로 Cypher 생성 → 일괄 적재)를 따랐다.

부록 D. 참고문헌

- Huang, J., Hou, W., Zhang, S., Du, Z., & Yin, J. (2026). Dam defects ontology and knowledge graph construction from multi-source hazard data using large language models. Advanced Engineering Informatics, 76, 104987.
- Purohit, S., Chin, G., Mackey, P. S., & Cottam, J. A. (2024). GraphAide: Advanced Graph-Assisted Query and Reasoning System. 2024 IEEE International Conference on Big Data. https://doi.org/10.1109/BigData62323.2024.10825705