Advanced Engineering Informatics 76 (2026) 104987

Contents lists available at ScienceDirect

Advanced Engineering Informatics

journal homepage: www.elsevier.com/locate/aei

Full length article

Dam defects ontology and knowledge graph construction from Multi-Source hazard data using large language models

Jianfeng Huang [a,b], Wenang Hou [a,b,c,*], Shichen Zhang [a,b], Zhenhan Du [a,b,d], Jiangshan Yin [a,b]

[a] Department of Dam Safety Management, Nanjing Hydraulic Research Institute, Nanjing 210029, China
[b] Key Laboratory of Reservoir and Dam Safety, Ministry of Water Resources, Nanjing Hydraulic Research Institute, Nanjing 210029, China
[c] College of Civil and Transportation Engineering, Hohai University, Nanjing 210024, China
[d] College of Water Resource and Hydropower, Sichuan University, Chengdu 610065, China

ARTICLE INFO

Keywords:
Dam engineering hazards
Large language models
Knowledge extraction
Fine-tuning
Knowledge graph

ABSTRACT

During dam operation, large volumes of information on dam defects are documented in various paper-based reports. This information is essential for effective dam safety management, yet its dispersed distribution and unstructured textual form make it difficult to transform into structured and reusable knowledge. Therefore, it is imperative to mine knowledge from these resources to construct a knowledge graph for effective utilization. This study presents the construction and application of such a graph by leveraging large language models (LLMs). A dam defects ontology (DDO) was designed to systematically model dam entity properties, spatial distribution, technical parameters, and safety hazards, with particular emphasis on detailed hierarchical knowledge modeling of engineering hazard forms and their components. To mitigate the "hallucination" problem of LLMs in the specialized domain of dam safety, a domain-adaptive Ontology-guided Hazard Classification Framework (OHCF) was developed. OHCF integrates four core modules—fine-tuning, temperature-perturbed voting, ontology-constraint consistency checking, and expert validation—to improve the accuracy of dam hazard entity recognition. In addition, OHCF dynamically expands the DDO through a semi-supervised mechanism. Experimental results show that all evaluation metrics of OHCF exceed 90 %. Based on the proposed method, this study mined dam safety evaluation reports for 22,076 defective and dangerous dams in China and constructed a dam defects knowledge graph (DDKG). Moreover, the proposed DDKG exhibits broad application potential in dam hazard risk analysis and in supporting expert decision-making for dam safety management.

1. Introduction

Reservoir and dam projects are globally important infrastructure, providing multiple functions such as flood control and disaster mitigation, water supply, agricultural irrigation, and hydropower generation. The safety of these projects is directly related to social stability. With the increase in operating years, dam projects commonly experience structural aging and functional degradation [1]. Coupled with the current frequent occurrence of natural disasters and intensified human activities, the safety situation of dams is continuously becoming more severe. Traditional risk analysis methods are mostly oriented toward individual projects and rely heavily on expert judgment or numerical computation [2–4]. Analyses of risk factors across multiple projects at regional scales remain limited. The emergence of data-driven methods has introduced new perspectives for risk assessment [5–7]. Using advanced knowledge engineering techniques, extensive amounts of dispersed hazard information can be structurally reorganized, enabling the identification of deep correlations. This provides a solid knowledge foundation for risk tracing and scientific decision-making.

At present, much of the critical key information related to dam defects is recorded in unstructured text [8]. These textual data are heterogeneous in format and poorly structured, making it difficult to effectively apply the embedded knowledge to correlation analysis and reasoning. This has led to the dilemma of being "rich in data but poor in knowledge," which constrains in-depth and systematic knowledge discovery of the mechanisms of dam defects and hazards.

Knowledge graphs (KGs) [9] offer an efficient tool for transforming this information into structured knowledge for organization and

* Corresponding author..
E-mail address: wahou@nhri.cn (W. Hou).

https://doi.org/10.1016/j.aei.2026.104987
Received 26 January 2026; Received in revised form 28 April 2026; Accepted 18 June 2026
Available online 22 June 2026
1474-0346/© 2026 Elsevier Ltd. All rights are reserved, including those for text and data mining, AI training, and similar technologies.

해석 (p.1)

제목·저자

대규모 언어모델을 이용한 다중 출처 위험(hazard) 데이터로부터의 댐 결함 온톨로지 및 지식그래프 구축
Jianfeng Huang, Wenang Hou(교신저자), Shichen Zhang, Zhenhan Du, Jiangshan Yin
난징수리과학연구원 댐안전관리부, 수리부 저수지·댐안전 중점실험실, 허하이대학교 토목·교통공학원, 쓰촨대학교 수자원·수력발전학원
키워드: 댐 공학 위험, 대규모 언어모델, 지식 추출, 미세조정, 지식그래프

초록 (Abstract)

During dam operation, large volumes of information on dam defects…

댐 운영 중에는 댐 결함에 관한 많은 양의 정보가 다양한 종이 기반 보고서에 기록된다. 이 정보는 효과적인 댐 안전관리에 필수적이지만, 흩어져 분포하고 비정형 텍스트 형태로 되어 있어 구조화되고 재사용 가능한 지식으로 바꾸기 어렵다. 따라서 이러한 자료에서 지식을 발굴하여 효과적으로 활용할 수 있는 지식그래프를 구축하는 것이 시급하다. 본 연구는 대규모 언어모델(LLM)을 활용하여 그러한 그래프를 구축하고 응용한 결과를 제시한다. 댐 개체의 속성, 공간적 분포, 기술 파라미터, 안전 위험을 체계적으로 모델링하기 위해 댐 결함 온톨로지(DDO)를 설계하였으며, 특히 공학적 위험 형태와 그 구성요소에 대한 세밀한 계층적 지식 모델링에 중점을 두었다. 댐 안전이라는 전문 분야에서 LLM의 '환각' 문제를 완화하기 위해, 도메인 적응형 온톨로지 기반 위험 분류 프레임워크(OHCF)를 개발하였다. OHCF는 미세조정, 온도 교란 투표, 온톨로지 제약 일관성 검사, 전문가 검증의 네 가지 핵심 모듈을 통합하여 댐 위험 개체 인식의 정확도를 높인다. 또한 OHCF는 준지도(semi-supervised) 메커니즘을 통해 DDO를 동적으로 확장한다. 실험 결과 OHCF의 모든 평가 지표가 90 %를 넘었다. 제안 방법을 바탕으로 본 연구는 중국의 결함·위험 댐 22,076개의 댐 안전평가 보고서를 분석하여 댐 결함 지식그래프(DDKG)를 구축하였다. 나아가 제안된 DDKG는 댐 위험 리스크 분석과 댐 안전관리를 위한 전문가 의사결정 지원에 폭넓은 응용 가능성을 보여준다.

1. 서론 (Introduction)

Reservoir and dam projects are globally important infrastructure…

저수지와 댐 사업은 홍수 방어와 재해 저감, 용수 공급, 농업 관개, 수력 발전 등 여러 기능을 제공하는 세계적으로 중요한 기반시설이다. 이러한 사업의 안전은 사회 안정과 직결된다. 운영 연수가 늘어나면서 댐 사업은 흔히 구조적 노후화와 기능 저하를 겪는다[1]. 여기에 현재 자연재해가 빈번히 발생하고 인간 활동이 강화되면서 댐의 안전 상황은 계속 심각해지고 있다. 전통적인 리스크 분석 방법은 대부분 개별 사업을 대상으로 하며 전문가 판단이나 수치 계산에 크게 의존한다[2–4]. 지역 규모에서 여러 사업에 걸친 리스크 요인 분석은 여전히 제한적이다. 데이터 기반 방법의 등장은 (→ 오른쪽 열로 이어짐) 리스크 평가에 새로운 관점을 도입하였다[5–7]. 고급 지식공학 기법을 사용하면 흩어진 방대한 위험 정보를 구조적으로 재조직하여 깊은 상관관계를 식별할 수 있다. 이는 리스크 추적과 과학적 의사결정을 위한 견고한 지식 기반을 제공한다.

At present, much of the critical key information related to dam defects…

현재 댐 결함과 관련된 핵심 정보의 상당 부분은 비정형 텍스트로 기록되어 있다[8]. 이러한 텍스트 데이터는 형식이 이질적이고 구조화가 잘 되어 있지 않아, 그 안에 담긴 지식을 상관 분석과 추론에 효과적으로 적용하기 어렵다. 이로 인해 '데이터는 풍부하지만 지식은 빈약한' 딜레마가 생기며, 이는 댐 결함과 위험의 메커니즘에 대한 심층적이고 체계적인 지식 발견을 제약한다.

Knowledge graphs (KGs) [9] offer an efficient tool…

지식그래프(KG)[9]는 이러한 정보를 조직과 (→ 2쪽으로 이어짐) 분석을 위한 구조화된 지식으로 변환하는 효율적인 도구를 제공한다.

메모

analysis. They can reveal complex semantic relationships among entities and provide a feasible solution to the above problem. Constructing KGs from large volumes of engineering text relies on effective knowledge extraction. In this regard, deep learning-based natural language processing has made significant progress [10]. In particular, recent advances in large language models (LLMs) have created new opportunities for large-scale knowledge extraction from massive text corpora [11,12]. LLMs exhibit strong capabilities in contextual understanding and reasoning, and can perform tasks by following natural language instructions[13–16].

However, when applied to the specialized domain of dam engineering, LLMs face combined challenges related to domain adaptability, knowledge complexity, and application economics [17]. General-purpose models lack a deep understanding of specialized dam engineering knowledge, which hinders accurate mapping of domain-specific terminology and parsing complex hierarchical relationships, often resulting in factual errors. Moreover, applying large-scale models for dataset processing incurs high computational costs, limiting their efficiency and scalability in practical engineering applications.

To address these challenges, this study develops a dam defects ontology (DDO) to provide a structured representation framework for dam hazard knowledge. An Ontology-guided Hazard Classification Framework (OHCF) is further proposed, which leverages LLMs to standardize the classification of unstructured hazard descriptions. Based on this process, a dam defects knowledge graph (DDKG) is constructed to achieve the structured integration of hazard information across multiple dam projects, thereby supporting dam safety management.

The remainder of this paper is organized as follows. Section 2 reviews related work. Section 3 details the proposed methodology. Section 4 evaluates model performance and presents case studies using the KG. Section 5 concludes the study and outlines future research directions.

2. Related works

2.1. Knowledge representation in hydraulic engineering

With the deepening application of digital twin technology in the hydraulic sector, the efficient organization and utilization of massive information throughout the entire engineering lifecycle have become a pivotal challenge for the industry's intelligent advancement. Consequently, numerous studies have focused on developing specialized ontologies to represent relevant data and requirements in a structured manner.

As an explicit and formal specification of a shared conceptualization [18], an ontology serves as a fundamental pillar of the Semantic Web infrastructure and plays a critical role in the construction of knowledge graphs [19]. In the engineering domain, ontologies are introduced to model specialized knowledge and provide a robust organizational framework for domain-specific data. Given the inherent complexity of ontology construction, evaluating and reusing existing domain ontologies has become a crucial preliminary step for researchers embarking on new projects.

To date, various ontologies tailored for hydraulic engineering safety have been developed. Zhang et al. [20] constructed a knowledge ontology for hydraulic engineering safety management centered on the causes of engineering hazards and corresponding countermeasures, providing a structured knowledge model to enhance decision-making in risk management. Gan et al. [21] developed a multi-layered, ontology-driven KG framework for the resilience enhancement of underground structures, integrating resilience quantification and disaster chain analysis to bridge the gap between subjective experience and intelligent decision-making. Utilizing unstructured data—including risk prevention manuals and design schemes from the Middle Route of the South-to-North Water Diversion Project—Liu et al. [22] developed an emergency plan ontology, which provides key support for the intelligent generation and reuse of emergency strategies. Focusing on the four dimensions of "structure-process-environment-material," Zhou et al. [23] proposed a unified knowledge management framework by bridging Building Information Modeling and domain ontologies to address the fragmentation of heterogeneous monitoring data, enabling efficient knowledge extraction and semantic integration in dam safety systems. Furthermore, Baudrit et al. [24] developed a holistic, graph-based knowledge model for dam systems by utilizing the formalism of conceptual graphs to unify heterogeneous, cross-disciplinary knowledge flux, providing a convenient framework for capitalizing experience, predicting structural states, and supporting forensic civil engineering.

While the aforementioned studies all aim to enhance the operation and maintenance of hydraulic engineering, they vary significantly in their representation granularity and thematic focus. In general, existing research still falls short in characterizing the specific manifestations of defects and the intricate relationships between relevant influencing factors. This limitation hinders the capacity of current models to support fine-grained analysis and advanced reasoning within the domain of dam safety.

2.2. Construction of knowledge graphs

In 2012, Google introduced the concept of the KGs [25], which has since been extensively researched and applied across various domains [26–29]. KG is a structured semantic network that depicts real-world knowledge through "entity-relation-entity" triplets. While an ontology serves as the conceptual framework defining the schema layer of knowledge, KG represents the knowledge base instantiated by real-world data within this framework.

A key step in constructing the KG data layer is the extraction of domain entities from unstructured text, which is commonly formulated as a Named Entity Recognition (NER) task in Natural Language Processing (NLP). NER aims to identify entity mentions in text and assign them predefined entity type labels. Early NER methods typically relied on complex manually crafted rules [30–32]. With the rise of deep learning, NER systems achieved substantial performance improvements by automatically learning textual feature representations. Recurrent Neural Networks [33,34] and Convolutional Neural Networks [35–37] were initially used to encode contextual information. Subsequently, the Transformer [38] architecture, built on self-attention mechanisms, led to the development of Pre-trained Language Models (PLMs) such as BERT [39]. Through supervised fine-tuning on labeled datasets, PLM-based methods have demonstrated strong performance in various NER tasks [40–42]. However, such methods usually depend on substantial high-quality annotated data and well-defined label systems [43]. When these label systems are constrained by limited expert knowledge, the resulting models may struggle to generalize to domain-specific concepts that are weakly represented, ambiguously defined, or absent from the predefined schema.

Recently, the application of LLMs in NER has gained widespread attention [44]. Having undergone deep pre-training on massive and diverse unlabeled data, LLMs possess robust generalization capabilities and extensive linguistic knowledge. In downstream tasks like NER, LLMs can achieve superior performance guided solely by natural language instructions. Numerous studies have utilized LLMs to assist in KG construction [45–49]. Mainstream methodologies typically rely on meticulously designed structured prompts, combining few-shot examples with the target text to guide the model in generating standardized outputs for extracting entities, attributes, and relationships. Furthermore, research has demonstrated that LLMs can effectively assist in the construction and expansion of ontology models [50,51]. Nevertheless, the direct application of LLMs in specialized domains such as hydraulic engineering remains challenging. This is primarily due to the distribution shift between the training data and domain-specific contexts, resulting in insufficient mastery of specialized terminology and domain knowledge [52]. To enhance the utility of models in specific fields, recent studies have introduced strategies such as Parameter-Efficient

해석 (p.2)

(1쪽에서 이어짐) analysis. They can reveal complex semantic relationships…

KG는 개체 간의 복잡한 의미 관계를 드러낼 수 있으며 위 문제에 대한 실현 가능한 해법을 제공한다. 대량의 공학 텍스트로부터 KG를 구축하는 일은 효과적인 지식 추출에 달려 있다. 이와 관련하여 딥러닝 기반 자연어처리는 상당한 진전을 이루었다[10]. 특히 최근 대규모 언어모델(LLM)의 발전은 방대한 텍스트 말뭉치로부터 대규모로 지식을 추출할 새로운 기회를 만들었다[11,12]. LLM은 문맥 이해와 추론에서 강력한 능력을 보이며, 자연어 지시를 따라 작업을 수행할 수 있다[13–16].

However, when applied to the specialized domain of dam engineering…

그러나 댐 공학이라는 전문 분야에 적용할 때 LLM은 도메인 적응성, 지식의 복잡성, 적용의 경제성과 관련된 복합적인 어려움에 직면한다[17]. 범용 모델은 댐 공학 전문 지식에 대한 깊은 이해가 부족하여 도메인 고유 용어를 정확히 대응시키고 복잡한 계층 관계를 해석하는 데 어려움을 겪으며, 그 결과 사실 오류가 자주 발생한다. 또한 대규모 모델을 데이터셋 처리에 적용하면 계산 비용이 높아, 실제 공학 응용에서 효율성과 확장성이 제한된다.

To address these challenges, this study develops a dam defects ontology (DDO)…

이러한 과제를 해결하기 위해 본 연구는 댐 위험 지식에 대한 구조화된 표현 틀을 제공하는 댐 결함 온톨로지(DDO)를 개발한다. 나아가 LLM을 활용하여 비정형 위험 서술의 분류를 표준화하는 온톨로지 기반 위험 분류 프레임워크(OHCF)를 제안한다. 이 과정을 바탕으로 댐 결함 지식그래프(DDKG)를 구축하여 여러 댐 사업에 걸친 위험 정보를 구조적으로 통합하고, 이를 통해 댐 안전관리를 지원한다.

The remainder of this paper is organized as follows…

이 논문의 나머지 구성은 다음과 같다. 2장은 관련 연구를 검토한다. 3장은 제안 방법론을 자세히 설명한다. 4장은 모델 성능을 평가하고 KG를 이용한 사례 연구를 제시한다. 5장은 연구를 결론짓고 향후 연구 방향을 제시한다.

2. 관련 연구 / 2.1 수리공학 분야의 지식 표현

With the deepening application of digital twin technology…

수리 분야에서 디지털 트윈 기술의 적용이 심화되면서, 공학 전 생애주기에 걸친 방대한 정보를 효율적으로 조직하고 활용하는 일이 산업의 지능화를 위한 핵심 과제가 되었다. 그 결과 많은 연구가 관련 데이터와 요구사항을 구조화된 방식으로 표현하기 위한 전문 온톨로지 개발에 집중해 왔다.

As an explicit and formal specification of a shared conceptualization [18]…

공유된 개념화에 대한 명시적이고 형식적인 명세로서[18], 온톨로지는 시맨틱 웹 기반 구조의 근본적인 기둥이며 지식그래프 구축에서 결정적인 역할을 한다[19]. 공학 분야에서 온톨로지는 전문 지식을 모델링하고 도메인 데이터에 견고한 조직 틀을 제공하기 위해 도입된다. 온톨로지 구축의 본질적인 복잡성 때문에, 기존 도메인 온톨로지를 평가하고 재사용하는 일은 새로운 프로젝트를 시작하는 연구자에게 중요한 사전 단계가 되었다.

To date, various ontologies tailored for hydraulic engineering safety…

지금까지 수리공학 안전을 위한 다양한 온톨로지가 개발되었다. Zhang 등[20]은 공학 위험의 원인과 대응책을 중심으로 수리공학 안전관리 지식 온톨로지를 구축하여 리스크 관리의 의사결정을 강화하는 구조화된 지식 모델을 제공하였다. Gan 등[21]은 지하 구조물의 회복력 강화를 위한 다층의 온톨로지 기반 KG 프레임워크를 개발하였으며, 회복력 정량화와 재해 연쇄 분석을 통합하여 주관적 경험과 지능형 의사결정 사이의 간극을 메웠다. Liu 등[22]은 남수북조 중선 사업의 리스크 예방 매뉴얼과 설계안 같은 비정형 데이터를 활용하여 비상계획 온톨로지를 개발하였고, 이는 비상 전략의 지능적 생성과 재사용을 핵심적으로 지원한다. Zhou 등[23]은 '구조-공정-환경-재료'의 네 차원에 초점을 맞추어 BIM(건물정보모델링)과 도메인 온톨로지를 연결함으로써 이질적인 모니터링 데이터의 단편화를 해결하는 통합 지식관리 프레임워크를 제안하였고, 댐 안전 시스템에서 효율적인 지식 추출과 의미 통합을 가능하게 하였다. 또한 Baudrit 등[24]은 개념 그래프 형식론을 이용하여 이질적이고 학제적인 지식 흐름을 통합하는 댐 시스템의 총체적 그래프 기반 지식 모델을 개발하여, 경험의 활용, 구조 상태 예측, 법공학적 토목공학 지원을 위한 편리한 틀을 제공하였다.

While the aforementioned studies all aim to enhance the operation…

앞서 언급한 연구들은 모두 수리공학의 운영과 유지관리를 향상시키는 것을 목표로 하지만, 표현의 세밀도와 주제 초점에서 상당히 다르다. 일반적으로 기존 연구는 결함의 구체적인 양상과 관련 영향 요인 사이의 복잡한 관계를 특성화하는 데 여전히 부족하다. 이러한 한계는 현재 모델이 댐 안전 분야에서 세밀한 분석과 고급 추론을 지원하는 능력을 저해한다.

2.2 지식그래프의 구축

In 2012, Google introduced the concept of the KGs [25]…

2012년 Google이 KG 개념을 도입한 이후[25], KG는 다양한 분야에서 폭넓게 연구·적용되어 왔다[26–29]. KG는 '개체-관계-개체' 삼항으로 현실 세계의 지식을 묘사하는 구조화된 의미 네트워크이다. 온톨로지가 지식의 스키마 계층을 정의하는 개념적 틀이라면, KG는 이 틀 안에서 현실 세계 데이터로 인스턴스화된 지식 베이스를 나타낸다.

A key step in constructing the KG data layer is the extraction of domain entities…

KG 데이터 계층을 구축하는 핵심 단계는 비정형 텍스트에서 도메인 개체를 추출하는 것이며, 이는 흔히 자연어처리(NLP)의 개체명 인식(NER) 과제로 정식화된다. NER은 텍스트에서 개체 언급을 식별하고 미리 정의된 개체 유형 라벨을 부여하는 것을 목표로 한다. 초기 NER 방법은 대개 복잡한 수작업 규칙에 의존했다[30–32]. 딥러닝이 부상하면서 NER 시스템은 텍스트 특징 표현을 자동으로 학습하여 성능을 크게 향상시켰다. 처음에는 순환신경망[33,34]과 합성곱신경망[35–37]이 문맥 정보를 부호화하는 데 쓰였다. 이후 자기주의(self-attention) 메커니즘에 기반한 Transformer[38] 구조가 BERT[39]와 같은 사전학습 언어모델(PLM)의 개발로 이어졌다. 라벨이 붙은 데이터셋으로 지도 미세조정을 하여, PLM 기반 방법은 다양한 NER 과제에서 강한 성능을 보였다[40–42]. 그러나 이러한 방법은 대개 상당한 양의 고품질 주석 데이터와 잘 정의된 라벨 체계에 의존한다[43]. 이 라벨 체계가 제한된 전문가 지식에 묶여 있으면, 결과 모델은 표현이 약하거나, 정의가 모호하거나, 미리 정의된 스키마에 없는 도메인 개념으로 일반화하는 데 어려움을 겪을 수 있다.

Recently, the application of LLMs in NER has gained widespread attention [44]…

최근 NER에서 LLM의 적용이 폭넓은 주목을 받고 있다[44]. 방대하고 다양한 비라벨 데이터로 깊은 사전학습을 거친 LLM은 강력한 일반화 능력과 폭넓은 언어 지식을 갖추고 있다. NER 같은 하위 과제에서 LLM은 자연어 지시만으로도 우수한 성능을 낼 수 있다. 많은 연구가 KG 구축을 보조하는 데 LLM을 활용하였다[45–49]. 주류 방법론은 대개 정교하게 설계된 구조화 프롬프트에 의존하며, 소수 예시(few-shot)를 대상 텍스트와 결합하여 모델이 개체, 속성, 관계를 추출하는 표준화된 출력을 생성하도록 유도한다. 또한 LLM이 온톨로지 모델의 구축과 확장을 효과적으로 보조할 수 있다는 연구도 있다[50,51]. 그럼에도 수리공학 같은 전문 분야에 LLM을 직접 적용하는 것은 여전히 어렵다. 이는 주로 학습 데이터와 도메인 고유 맥락 사이의 분포 차이 때문이며, 그 결과 전문 용어와 도메인 지식의 숙달이 불충분해진다[52]. 특정 분야에서 모델의 유용성을 높이기 위해 최근 연구는 (→ 3쪽으로 이어짐) 매개변수 효율적 미세조정(PEFT)…

메모

Fine-Tuning [53] and Chain-of-Thought [54], effectively improving the structural regularity of model outputs and the ability to capture complex semantics.

In summary, while LLMs offer new possibilities for NER, their inherent hallucination issues may lead to the incorrect or arbitrary assignment of entity labels, thereby compromising the reliability of extraction results and hindering the structured organization and integration of knowledge.

2.3. Knowledge gap

The above studies show growing interest in building hydraulic engineering knowledge systems to support intelligent safety management and in using large language models for domain-specific knowledge processing. However, several research gaps remain. First, although existing studies in hydraulic engineering have laid a solid foundation for ontology construction, they are still insufficient for the fine-grained representation of dam defects, particularly in modeling hazard forms and affected components. Second, existing knowledge extraction methods based on PLMs, such as BERT, remain insufficiently flexible for dam engineering texts. Hazard descriptions in such texts are often fragmented, nested, and expressed in diverse ways, which increases the difficulty of knowledge extraction. Although these methods have shown good performance in classification tasks with a small number of labels, they usually require substantially more annotated data when applied to tasks involving larger label sets and more complex class relationships. In addition, these models are typically constrained by predefined categories derived from expert knowledge, making it difficult to identify previously undefined concepts. Third, although large language models have shown strong potential in NER tasks, their direct application to dam safety scenarios is still limited by insufficient domain knowledge, which often leads to significant hallucination problems.

To address these gaps, this study develops a fine-grained dam defect ontology and proposes OHCF to support ontology-guided hazard knowledge recognition and ontology expansion for dam defect knowledge graph construction.

3. Methodology

This section describes the implementation of ontology construction, data layer development, and KG storage. Fig. 1 illustrates the overall construction framework of the DDKG, which comprises three main components: DDO construction, knowledge extraction, and knowledge fusion.

3.1. DDO construction

An ontology is a standardized representation of concepts, entities, attributes, and their semantic relationships within a specific domain. In the construction of KGs, the ontology layer serves as the core structural backbone. The clarity and completeness of its design directly determine its knowledge coverage and representational accuracy of the KG [55]. In dam engineering, developing a structured and standardized ontology for defects is essential for unifying hazard terminology, enabling correlation analysis of complex causative mechanisms, and supporting downstream applications such as intelligent diagnosis and decision-making.

In this study, a seven-step methodology is adopted to construct the DDO. The process comprises the following steps: (1) defining the dam hazard domain ontology and related tasks; (2) considering the reuse of existing ontology models related to dam hazards; (3) enumerating relevant terminology; (4) defining ontology classes and hierarchical structures; (5) defining class attributes and relationships; (6) specifying constraints; and (7) creating instances.

The DDO is constructed using the Web Ontology Language (OWL) and is stored and managed with the Protégé tool. OWL is an ontology language recommended by the World Wide Web Consortium (W3C) for defining vocabularies and describing resources. By specifying classes, properties, and values, OWL provides a standardized method for users to

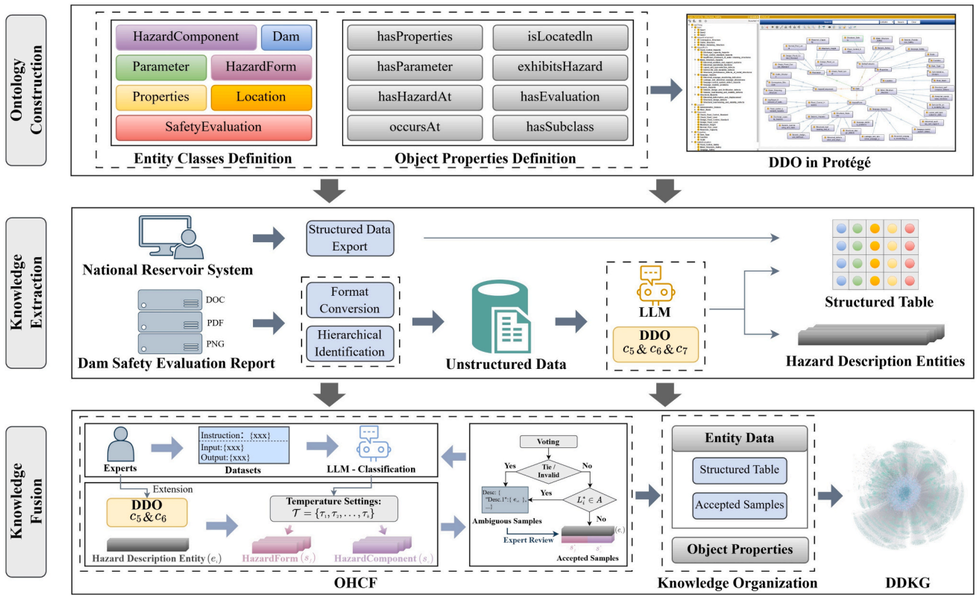


Fig. 1. Construction framework of DDKG.

해석 (p.3)

(2쪽에서 이어짐) Fine-Tuning [53] and Chain-of-Thought [54]…

…[53]과 사고의 연쇄(Chain-of-Thought)[54] 같은 전략을 도입하여, 모델 출력의 구조적 규칙성과 복잡한 의미를 포착하는 능력을 효과적으로 향상시켰다. 요컨대, LLM은 NER에 새로운 가능성을 제공하지만, 고유의 환각 문제로 개체 라벨이 잘못되거나 임의로 부여될 수 있으며, 이는 추출 결과의 신뢰성을 떨어뜨리고 지식의 구조적 조직과 통합을 방해한다.

2.3 지식 공백 (Knowledge gap)

The above studies show growing interest in building hydraulic engineering knowledge systems…

위 연구들은 지능형 안전관리를 지원하기 위한 수리공학 지식 시스템 구축과, 도메인 지식 처리에 대규모 언어모델을 사용하는 것에 대한 관심이 커지고 있음을 보여준다. 그러나 몇 가지 연구 공백이 남아 있다. 첫째, 수리공학 분야의 기존 연구가 온톨로지 구축의 견고한 기반을 마련했지만, 댐 결함, 특히 위험 형태와 영향받는 구성요소를 모델링하는 세밀한 표현에는 여전히 부족하다. 둘째, BERT 같은 PLM에 기반한 기존 지식 추출 방법은 댐 공학 텍스트에 대해 충분히 유연하지 않다. 이러한 텍스트의 위험 서술은 흔히 단편적이고, 중첩되며, 다양한 방식으로 표현되어 지식 추출의 어려움을 키운다. 이 방법들은 라벨 수가 적은 분류 과제에서는 좋은 성능을 보였지만, 라벨 집합이 크고 클래스 관계가 복잡한 과제에 적용할 때는 대개 훨씬 더 많은 주석 데이터가 필요하다. 또한 이 모델들은 전문가 지식에서 나온 미리 정의된 범주에 묶여 있어, 이전에 정의되지 않은 개념을 식별하기 어렵다. 셋째, 대규모 언어모델은 NER 과제에서 강한 잠재력을 보였지만, 댐 안전 시나리오에 직접 적용하는 것은 도메인 지식 부족으로 여전히 제한되며, 이는 흔히 심각한 환각 문제로 이어진다. 이러한 공백을 해결하기 위해, 본 연구는 세밀한 댐 결함 온톨로지를 개발하고, 댐 결함 지식그래프 구축을 위한 온톨로지 기반 위험 지식 인식과 온톨로지 확장을 지원하는 OHCF를 제안한다.

3. 방법론 (Methodology)

This section describes the implementation of ontology construction…

이 장은 온톨로지 구축, 데이터 계층 개발, KG 저장의 구현을 설명한다. 그림 1은 DDKG의 전체 구축 틀을 보여주며, 이는 DDO 구축, 지식 추출, 지식 융합의 세 가지 주요 구성요소로 이루어진다.

3.1 DDO 구축

An ontology is a standardized representation of concepts, entities, attributes…

온톨로지는 특정 도메인 안의 개념, 개체, 속성, 그리고 그들 사이의 의미 관계를 표준화하여 표현한 것이다. KG 구축에서 온톨로지 계층은 핵심 구조적 뼈대 역할을 한다. 그 설계의 명확성과 완전성이 KG의 지식 포괄 범위와 표현 정확도를 직접 결정한다[55]. 댐 공학에서 결함에 대한 구조화·표준화된 온톨로지를 개발하는 것은 위험 용어를 통일하고, 복잡한 원인 메커니즘의 상관 분석을 가능하게 하며, 지능형 진단과 의사결정 같은 하위 응용을 지원하는 데 필수적이다.

In this study, a seven-step methodology is adopted to construct the DDO…

본 연구는 DDO를 구축하기 위해 7단계 방법론을 채택한다. 그 과정은 다음 단계로 이루어진다. (1) 댐 위험 도메인 온톨로지와 관련 과업 정의, (2) 댐 위험과 관련된 기존 온톨로지 모델의 재사용 검토, (3) 관련 용어 나열, (4) 온톨로지 클래스와 계층 구조 정의, (5) 클래스 속성과 관계 정의, (6) 제약 명시, (7) 인스턴스 생성.

The DDO is constructed using the Web Ontology Language (OWL)…

DDO는 웹 온톨로지 언어(OWL)로 구축되며 Protégé 도구로 저장·관리된다. OWL은 어휘를 정의하고 자원을 기술하기 위해 W3C(월드와이드웹 컨소시엄)가 권고하는 온톨로지 언어이다. 클래스, 속성, 값을 명시함으로써 OWL은 사용자가 (→ 4쪽으로 이어짐) 도메인 고유의 클래스와 속성을 기술하는 표준화된 방법을 제공한다.

그림 1. DDKG의 구축 틀

메모

describe domain-specific classes and attributes.

The structure of the DDO can be represented using the triple form shown in Equation (1):

$$DDO = \langle C, P, H \rangle \tag{1}$$

where $C = \{c_i | i \in N^*\}$ is the set of top-level classes; c_i is the $i-$th top-level class; $P = \{p_{ij} | i, j \in N^*, i \neq j\}$ is the set of object properties, where p_{ij} represents a directed relationship $c_i \rightarrow c_j$; $H = \{S_i | c_i \in C^*\}$ is the set of all subclasses under each top-level class, where $S_i = \{c_i(j_1, j_2, \ldots, j_k) | i, k, j_k \in N^*\}$ represents the subclass set under top-level class c_i, and $c_i(j_1, j_2, \cdots, j_k)$ denotes a path index sequence (e.g., $c_3(2,1)$ represents the first child of the second subclass under top-level class c_3).

Dam defects arise from the coupled effects of intrinsic engineering factors and environmental conditions. Therefore, seven top-level classes are initially defined in the DDO, as summarized in Table 1.

To further enhance the semantic expressiveness and structural rigor of the DDO, both semantic and hierarchical relationships are constructed. Semantic relationships are primarily established by defining object properties to link different top-level entity classes. Table 2 provides the object properties defined in the ontology structure. All top-level classes are connected to the Dam entity to anchor all related information to specific engineering instances. Specifically, HazardForm is linked to HazardComponent via "occursAt.".

Hierarchical relationships are constructed using "hasSubclass" to form internal hierarchical structures for each top-level class, aiming to increase the depth and granularity of knowledge representation. For example, subclasses such as "dam height" and "reservoir capacity" are defined under the Parameter class. Hierarchical relationships allow subclasses to inherit object properties from their parent classes. This effectively improves the reusability, scalability, and reasoning capability of the model. Fig. 2 shows the DDO modeling in Protégé.

Among the top-level classes, "c_5 HazardForm" and "c_6 HazardComponent" are directly related to engineering hazards and constitute the most critical elements of the DDKG. These entities must be extracted from unstructured text, which poses considerable challenges. For instance, although LLMs can recognize entities such as "spillway" and "Side wall," they often fail to correctly parse the intrinsic "whole–part" logic between them. LLMs may incorrectly classify entities with subordinate relationships as being on the same hierarchical level, thereby overlooking the fact that the "Side wall" is a constituent subunit of the "spillway." Such parsing errors can directly compromise the integrity of the DDKG's knowledge structure.

To overcome these limitations in semantic understanding, this study refines the hierarchical construction of top-level classes c_5 and c_6 based on expert knowledge. The detailed construction is described below.

(a) Hierarchical structure of HazardForm.

To ensure scientific rigor and validity of hierarchical structures, it is generally needed to reference industry technical standards or national/regional administrative regulations. In China, for example, the *Guidelines on Dam Safety Evaluation* (SL 258–2017) specify that the safety of a dam project is assessed based on five categories of specialized indicators: flood control, seepage, structural integrity, seismic performance, and metal structure. These indicators provide a standardized basis for dam safety evaluation.

Table 1
Top-level entity classes of the DDO.

c_i	Entity class
c_1	Dam
c_2	Properties
c_3	Location
c_4	Parameter
c_5	HazardForm
c_6	HazardComponent
c_7	SafetyEvaluation

Table 2
Definitions of object properties in the DDO.

p_{ij}	Object properties	Domains	Ranges
p_{12}	hasProperties	c_1	c_2
p_{13}	isLocatedIn	c_1	c_3
p_{14}	hasParameter	c_1	c_4
p_{15}	exhibitsHazard	c_1	c_5
p_{16}	hasHazardAt	c_1	c_6
p_{17}	hasEvaluation	c_1	c_7
p_{56}	occursAt	c_5	c_6

As a result, hazard issues corresponding to these five categories are defined as level-1 subclasses of HazardForm. Under each level-1 subclass, level-2 and level-3 subclasses are further defined to capture detailed manifestations of engineering hazards. Table 3 presents the hierarchical structure of the HazardForm class.

(b) Hierarchical structure of Hazard Component.

The HazardComponent class is used to locate the specific structural positions where engineering hazards occur. Dam engineering structures can be broadly classified into water-retaining structures, outlet structures, and conveyance structures according to their functions. Water-retaining structures include the dam body, dam foundation, and dam abutment. Outlet structures comprise spillways, flood discharge tunnels, and bottom outlets. Conveyance structures consist of intake structures, conveyance pipelines, and control structures. Table 4 lists the hierarchical structure of the HazardComponent class in detail, with the three types of structures serving as its level-1 subclasses.

In practical applications, hierarchical modeling of complex engineering entities such as a dam project based solely on expert experience is inevitably constrained by knowledge boundaries. As a result, the ontology coverage may be limited. To address this, during knowledge extraction, the ontology is conceptually supplemented or hierarchically expanded based on identified undefined entities, as described in Section 3.2.3.

3.2. Data layer construction

The data layer is designed to extract knowledge from multi-source heterogeneous data generated during the long-term operation of reservoir dam engineering systems, based on the DDO. This section presents the construction of the DDKG data layer and provides a detailed description of OHCF. The overall framework of data layer construction is displayed in Fig. 3.

3.2.1. Knowledge sources and preprocessing

The China Reservoir Operation and Management Platform stores a large volume of fundamental engineering data in the form of structured tables, which largely satisfy the data requirements of top-level classes c_1–c_4 in the DDO.

In contrast, the data corresponding to top-level classes c_5–c_7 are derived from unstructured text. These texts are highly heterogenous in formats, including PDF, DOC, and PNG files, and the original documents often contain redundant or irrelevant information. Prior to knowledge extraction, the texts are preprocessed to eliminate noise and normalize the data.

For a given unstructured text D, its format is first converted into a structured markdown representation D_{md}. State-of-the-art optical character recognition models [56] are then applied to perform layout parsing and format conversion. Next, regular expressions are used to delimit the boundaries of text blocks $D_{md,i}$ that contain relevant knowledge entities and remove redundant content. Finally, the extracted text blocks are integrated into a single corpus, denoted as T:

$$T = \{D_{md,1}, D_{md,2}, \cdots, D_{md,n}\} \tag{2}$$

해석 (p.4)

(3쪽에서 이어짐) describe domain-specific classes and attributes. The structure of the DDO…

…도메인 고유의 클래스와 속성을 기술하는 표준화된 방법을 제공한다. DDO의 구조는 식 (1)의 삼항 형식으로 나타낼 수 있다.
DDO = 〈C, P, H〉 (1)
여기서 C = {ci | i∈N*}는 최상위 클래스의 집합이고 ci는 i번째 최상위 클래스이다. P = {pij | i,j∈N*, i≠j}는 객체 속성(object property)의 집합이며, pij는 방향이 있는 관계 ci→cj를 나타낸다. H = {Si | ci∈C*}는 각 최상위 클래스 아래 모든 하위 클래스의 집합이며, Si = {ci(j1,j2,⋯,jk) | i,k,jk∈N*}는 최상위 클래스 ci 아래의 하위 클래스 집합을 나타내고, ci(j1,j2,⋯,jk)는 경로 색인 순서열을 뜻한다(예: c3(2,1)은 최상위 클래스 c3의 두 번째 하위 클래스의 첫 번째 자식을 나타낸다).

Dam defects arise from the coupled effects of intrinsic engineering factors…

댐 결함은 공학 내부 요인과 환경 조건의 결합 효과로 발생한다. 따라서 DDO에는 처음에 7개의 최상위 클래스를 정의하였으며, 이는 표 1에 요약되어 있다.

To further enhance the semantic expressiveness and structural rigor of the DDO…

DDO의 의미 표현력과 구조적 엄밀성을 더 높이기 위해 의미 관계와 계층 관계를 모두 구성한다. 의미 관계는 주로 서로 다른 최상위 개체 클래스를 연결하는 객체 속성을 정의하여 구성한다. 표 2는 온톨로지 구조에 정의된 객체 속성을 보여준다. 모든 최상위 클래스는 관련 정보를 구체적인 공학 인스턴스에 고정(anchor)하기 위해 Dam 개체에 연결된다. 구체적으로 HazardForm은 'occursAt'을 통해 HazardComponent와 연결된다. 계층 관계는 'hasSubclass'를 사용하여 각 최상위 클래스 내부의 계층 구조를 형성하며, 지식 표현의 깊이와 세밀도를 높이는 것을 목표로 한다. 예를 들어 Parameter 클래스 아래에는 '댐 높이', '저수 용량' 같은 하위 클래스가 정의된다. 계층 관계를 통해 하위 클래스는 상위 클래스의 객체 속성을 상속할 수 있다. 이는 모델의 재사용성, 확장성, 추론 능력을 효과적으로 향상시킨다. 그림 2는 Protégé에서의 DDO 모델링을 보여준다.

Among the top-level classes, "c5 HazardForm" and "c6 HazardComponent"…

최상위 클래스 중 'c5 HazardForm(위험 형태)'과 'c6 HazardComponent(위험 부위)'는 공학 위험과 직접 관련되며 DDKG의 가장 핵심적인 요소이다. 이 개체들은 비정형 텍스트에서 추출해야 하므로 상당한 어려움이 따른다. 예를 들어 LLM은 '여수로(spillway)'와 '측벽(Side wall)' 같은 개체를 인식할 수는 있지만, 그 사이의 내재적인 '전체-부분' 논리를 올바르게 해석하지 못하는 경우가 많다. LLM은 종속 관계에 있는 개체를 같은 계층으로 잘못 분류하여, '측벽'이 '여수로'의 구성 하위 단위라는 사실을 간과할 수 있다. 이러한 해석 오류는 DDKG 지식 구조의 무결성을 직접 훼손할 수 있다.

To overcome these limitations in semantic understanding…

이러한 의미 이해의 한계를 극복하기 위해, 본 연구는 전문가 지식을 바탕으로 최상위 클래스 c5와 c6의 계층 구성을 정교화한다. 자세한 구성은 다음과 같다.

(a) Hierarchical structure of HazardForm. To ensure scientific rigor…

(a) HazardForm의 계층 구조. 계층 구조의 과학적 엄밀성과 타당성을 확보하려면 일반적으로 산업 기술 표준이나 국가·지역 행정 규정을 참조해야 한다. 예를 들어 중국에서는 「댐 안전평가 지침(SL 258–2017)」이 댐 사업의 안전을 홍수 방어, 침투, 구조 안정성, 내진 성능, 금속 구조의 다섯 가지 전문 지표 범주로 평가하도록 규정한다. 이 지표들은 댐 안전평가의 표준화된 기준을 제공한다. 그 결과, 이 다섯 범주에 해당하는 위험 문제를 HazardForm의 1단계 하위 클래스로 정의한다. 각 1단계 하위 클래스 아래에는 공학 위험의 세부 양상을 담기 위해 2단계와 3단계 하위 클래스를 추가로 정의한다. 표 3은 HazardForm 클래스의 계층 구조를 보여준다.

(b) Hierarchical structure of Hazard Component…

(b) HazardComponent의 계층 구조. HazardComponent 클래스는 공학 위험이 발생한 구체적인 구조적 위치를 특정하는 데 쓰인다. 댐 공학 구조물은 기능에 따라 크게 차수(물막이) 구조물, 방류 구조물, 도수 구조물로 나눌 수 있다. 차수 구조물에는 댐 본체, 기초, 댐 접합부(abutment)가 포함된다. 방류 구조물에는 여수로, 홍수 방류 터널, 바닥 배수구(저층 방류구)가 포함된다. 도수 구조물은 취수 구조물, 도수 관로, 제어 구조물로 이루어진다. 표 4는 HazardComponent 클래스의 계층 구조를 자세히 나열하며, 세 가지 구조물 유형이 1단계 하위 클래스가 된다.

In practical applications, hierarchical modeling of complex engineering entities…

실제 응용에서, 댐 사업 같은 복잡한 공학 개체의 계층 모델링을 전문가 경험만으로 하는 것은 지식의 경계에 의해 불가피하게 제약된다. 그 결과 온톨로지의 포괄 범위가 제한될 수 있다. 이를 해결하기 위해, 3.2.3절에서 설명하는 것처럼 지식 추출 과정에서 식별된 미정의 개체를 바탕으로 온톨로지를 개념적으로 보완하거나 계층적으로 확장한다.

3.2 데이터 계층 구축

The data layer is designed to extract knowledge from multi-source heterogeneous data…

데이터 계층은 DDO를 바탕으로, 저수지 댐 공학 시스템의 장기 운영 중에 생성된 다중 출처의 이질적 데이터로부터 지식을 추출하도록 설계된다. 이 절은 DDKG 데이터 계층의 구축을 제시하고 OHCF를 자세히 설명한다. 데이터 계층 구축의 전체 틀은 그림 3에 나타나 있다.

3.2.1 지식 출처와 전처리

The China Reservoir Operation and Management Platform stores…

중국 저수지 운영관리 플랫폼은 많은 양의 기본 공학 데이터를 정형 표 형태로 저장하며, 이는 DDO의 최상위 클래스 c1–c4의 데이터 요구를 대부분 충족한다.

In contrast, the data corresponding to top-level classes c5–c7…

반면 최상위 클래스 c5–c7에 해당하는 데이터는 비정형 텍스트에서 나온다. 이 텍스트들은 PDF, DOC, PNG 파일 등 형식이 매우 이질적이며, 원본 문서에는 중복되거나 관련 없는 정보가 많이 들어 있다. 지식 추출에 앞서 잡음을 제거하고 데이터를 정규화하기 위해 텍스트를 전처리한다.

For a given unstructured text D, its format is first converted…

주어진 비정형 텍스트 D에 대해, 먼저 그 형식을 구조화된 마크다운 표현 Dmd로 변환한다. 이때 최신 광학 문자 인식(OCR) 모델[56]을 적용하여 레이아웃 분석과 형식 변환을 수행한다. 다음으로 정규식을 사용하여 관련 지식 개체를 포함하는 텍스트 블록 Dmd,i의 경계를 구분하고 중복 내용을 제거한다. 마지막으로 추출된 텍스트 블록을 하나의 말뭉치 T로 통합한다.
T = {Dmd,1, Dmd,2, ⋯, Dmd,n} (2)

표 1. DDO의 최상위 개체 클래스

c1 Dam(댐), c2 Properties(특성), c3 Location(위치), c4 Parameter(매개변수), c5 HazardForm(위험 형태), c6 HazardComponent(위험 부위), c7 SafetyEvaluation(안전평가)

표 2. DDO의 객체 속성 정의 (속성: 정의역 → 치역)

p12 hasProperties: c1 → c2
p13 isLocatedIn: c1 → c3
p14 hasParameter: c1 → c4
p15 exhibitsHazard: c1 → c5
p16 hasHazardAt: c1 → c6
p17 hasEvaluation: c1 → c7
p56 occursAt: c5 → c6

메모

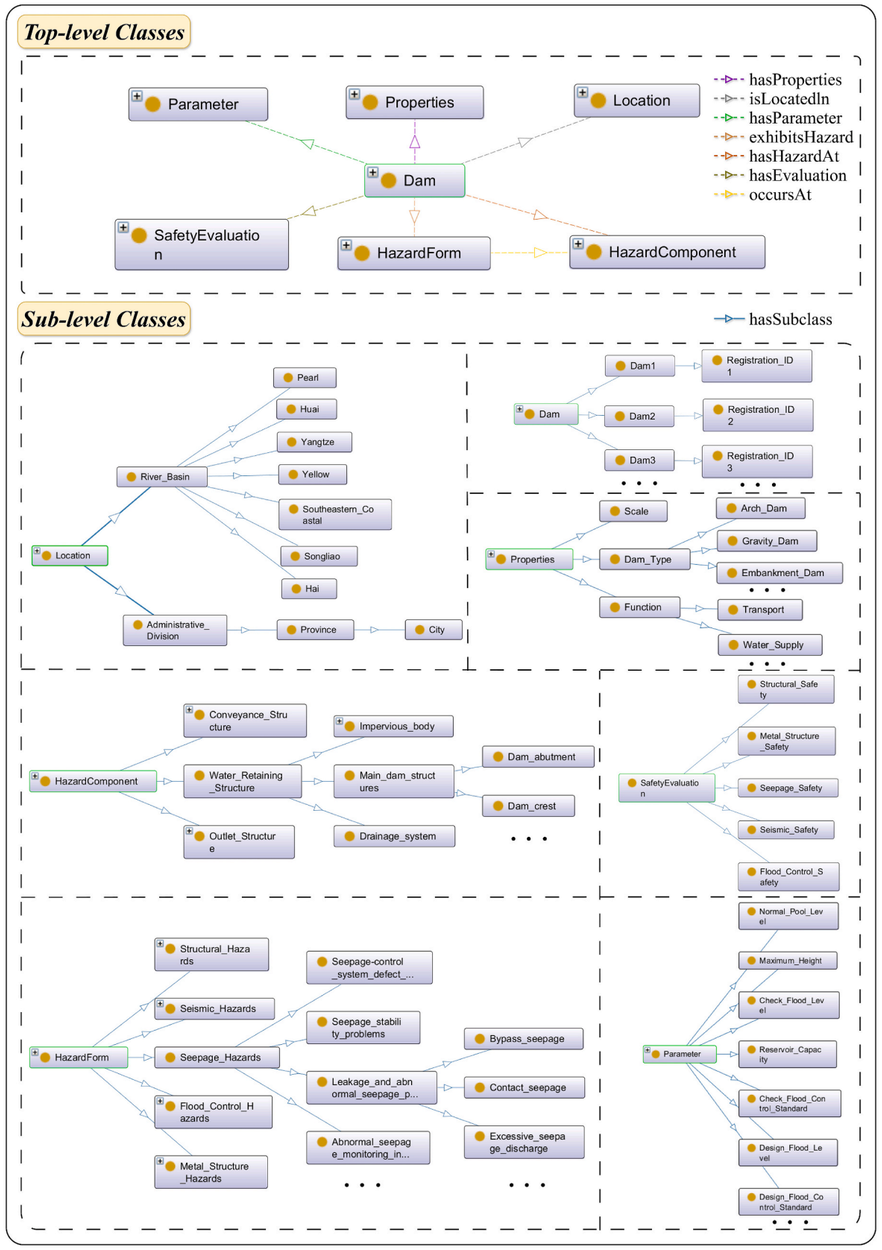


Fig. 2. DDO in Protégé.

해석 (p.5)

그림 2. Protégé에서의 DDO

메모

Table 3
Subclasses of "c_5 Hazard Form".

Subclass (level 1)	Subclass (level 2)	Subclass (level 3)
c_5(1) Flood Control Hazards	c_5(1,1) Flood control standard hazards	c_5(1,1,1) Floods exceeding design standard; c_5(1,1,2) Insufficient design flood standard; c_5(1,1,3) Design flood estimates fail to meet requirements; c_5(1,1,4) Failure to meet the requirements for recent extraordinary flood operation standards
	c_5(1,2) Insufficient freeboard of water-retaining structures	c_5(1,2,1) Insufficient water-retaining elevation; c_5(1,2,2) Incomplete enclosure of water-retaining structures
	c_5(1,3) Discharge capacity hazards	c_5(1,3,1) Missing flood control facilities; c_5(1,3,2) Insufficient discharge capacity
c_5(2) Seepage Hazards	c_5(2,1) Seepage-control system defect hazards	c_5(2,1,1) Incomplete or failed impervious body; c_5(2,1,2) Inadequate grouting; c_5(2,1,3) Abnormal filter and drainage facilities; c_5(2,1,4) Seepage-control defects at contact zones
	c_5(2,2) Leakage and abnormal seepage phenomena	c_5(2,2,1) Excessive seepage discharge; c_5(2,2,2) Contact seepage; c_5(2,2,3) Bypass seepage; c_5(2,2,4) Diffuse seepage; c_5(2,2,5) Turbid seepage water
	c_5(2,3) Seepage stability problems	c_5(2,3,1) Insufficient seepage stability; c_5(2,3,2) Piping; c_5(2,3,3) Soil flow
	c_5(2,4) Abnormal seepage monitoring indicators	c_5(2,4,1) Abnormal changes in seepage discharge; c_5(2,4,2) Abnormal phreatic line; c_5(2,4,3) Abnormal uplift pressure
c_5(3) Structural Hazards	c_5(3,1) Structural design defects	c_5(3,1,1) Insufficient width; c_5(3,1,2) Insufficient elevation; c_5(3,1,3) Missing protective components
	c_5(3,2) Abnormal deformation and displacement	c_5(3,2,1) Excessive settlement; c_5(3,2,2) Abnormal displacement; c_5(3,2,3) Deformation failing to meet requirements
	c_5(3,3) Structural load-bearing and stability defects	c_5(3,3,1) Insufficient structural strength; c_5(3,3,2) Insufficient stability
c_5(4) Seismic Hazards	c_5(4,1) Seismic design and fortification defects	c_5(4,1,1) Insufficient seismic fortification intensity; c_5(4,1,2) Incorrect seismic fortification category; c_5(4,1,3) Incorrect design seismic parameters
	c_5(4,2) Seismic load-bearing and stability defects	c_5(4,2,1) Insufficient seismic strength; c_5(4,2,2) Insufficient seismic stability; c_5(4,2,3) Inadequate seismic measures; c_5(4,2,4) Potential structural liquefaction
c_5(5) Metal Structure Hazards	c_5(5,1) Layout and type-selection defects	c_5(5,1,1) Unreasonable layout; c_5(5,1,2) Unreasonable type selection; c_5(5,1,3) Insufficient lifting height of the hoisting mechanism; c_5(5,1,4) Insufficient span of the hoisting mechanism
	c_5(5,2) Service-life and durability defects	c_5(5,2,1) Exceeded the service life for depreciation and retirement; c_5(5,2,2) Surface corrosion and rusting; c_5(5,2,3) Seal failure
	c_5(5,3) Structural performance defects of metal structures	c_5(5,3,1) Insufficient strength of metal structures; c_5(5,3,2) Insufficient stability of metal structures
	c_5(5,4) Abnormal operational functions	c_5(5,4,1) Insufficient hoisting force; c_5(5,4,2) Jamming or failure in opening and closing operations; c_5(5,4,3) Abnormal safety protection devices; c_5(5,4,4) Abnormal locking or pressure-equalizing devices
	c_5(5,5) Abnormal auxiliary and support systems	c_5(5,5,1) Abnormal power supply; c_5(5,5,2) Abnormal control system

Table 4
Subclasses of "c_6 HazardComponent".

Subclass (level 1)	Subclass (level 2)	Subclass (level 3)
c_6(1) Water-retaining structures	c_6(1,1) Main dam structures	c_6(1,1,1) Dam crest; c_6(1,1,2) Dam abutment; c_6(1,1,3) Dam foundation; c_6(1,1,4) Dam toe; c_6(1,1,5) Dam body; c_6(1,1,6) Dam slope/surface; c_6(1,1,7) Wave wall; c_6(1,1,8) Flood control system
	c_6(1,2) Impervious body	c_6(1,2,1) Dam impervious body; c_6(1,2,2) Foundation impervious body
	c_6(1,3) Drainage system	c_6(1,3,1) Dam body drainage; c_6(1,3,2) Foundation drainage; c_6(1,3,3) Abutment drainage
c_6(2) Outlet structures	c_6(2,1) Spillway	c_6(2,1,1) Spillway intake/control section; c_6(2,1,2) Chute; c_6(2,1,3) Side wall; c_6(2,1,4) Spillway energy dissipation structures; c_6(2,1,5) Spillway metal structures
	c_6(2,2) Flood discharge tunnel	c_6(2,1,1) Spillway intake/control section; c_6(2,1,2) Chute; c_6(2,1,3) Side wall; c_6(2,1,4) Spillway energy dissipation structures; c_6(2,1,5) Spillway metal structures
	c_6(2,4) Other outlet structures	c_6(2,3,1) Bottom outlet; c_6(2,3,2) Emergency spillway; c_6(2,3,3) Emptying pipe; c_6(2,3,4) Other outlet metal structures
c_6(3) Conveyance structures	c_6(3,1) Intake structures	c_6(3,1,1) Intake tower; c_6(3,1,2) Inclined intake pipe; c_6(3,1,3) Metal structures of intake facilities
	c_6(3,3) Conveyance pipelines	c_6(3,2,1) Conveyance culvert; c_6(3,2,2) Conveyance tunnel; c_6(3,2,3) Metal structures of conveyance pipelines

3.2.2. Rule-based knowledge extraction

Entities associated with the top-level class c_7 represent safety evaluation results in dam safety reports, including flood-control, seepage, structural, seismic, and metal-structure safety evaluations. Each evaluation is classified into Grade A, B, or C, corresponding to no defect, minor defect, and serious defect, respectively. Because these results are generally described in highly standardized forms, they can be directly extracted using regular expressions. For example, from the expression "the flood-control safety rating is Grade C", the flood-control safety evaluation result can be accurately extracted as "C", without the need for deep learning-based recognition.

3.2.3. LLM-based knowledge extraction

In contrast, the extraction of engineering hazard entities is more challenging, with the core difficulty lying in how to accurately assign hazard information expressed in complex and diverse forms to the predefined category system of the DDO.

General-purpose language models achieve relatively low accuracy on this highly specialized task, as also supported by the experimental results presented in Section 4.2.3. Although general-purpose LLMs show limited performance in fine-grained classification, under explicit instruction constraints they are still able to extract hazard-related descriptive fragments from engineering reports efficiently, that is, they can effectively determine which parts of the text correspond to hazard

해석 (p.6)

메모

3.2.2 규칙 기반 지식 추출

Entities associated with the top-level class c7 represent safety evaluation results…

최상위 클래스 c7과 연관된 개체는 댐 안전 보고서의 안전평가 결과를 나타내며, 홍수 방어, 침투, 구조, 내진, 금속 구조 안전평가를 포함한다. 각 평가는 A, B, C 등급으로 분류되며, 각각 결함 없음, 경미한 결함, 심각한 결함에 해당한다. 이 결과들은 일반적으로 고도로 표준화된 형태로 서술되므로 정규식으로 바로 추출할 수 있다. 예를 들어 '홍수 방어 안전 등급은 C등급이다'라는 표현에서, 딥러닝 기반 인식 없이도 홍수 방어 안전평가 결과를 'C'로 정확히 추출할 수 있다.

3.2.3 LLM 기반 지식 추출

In contrast, the extraction of engineering hazard entities is more challenging…

반면 공학 위험 개체의 추출은 더 어려우며, 핵심 난점은 복잡하고 다양한 형태로 표현된 위험 정보를 DDO의 미리 정의된 범주 체계에 어떻게 정확히 배정하느냐에 있다.

General-purpose language models achieve relatively low accuracy…

범용 언어모델은 이처럼 고도로 전문적인 과제에서 비교적 낮은 정확도를 보이며, 이는 4.2.3절의 실험 결과로도 뒷받침된다. 범용 LLM은 세밀한 분류에서는 성능이 제한적이지만, 명시적인 지시 제약 아래에서는 공학 보고서로부터 위험 관련 서술 조각을 효율적으로 추출할 수 있다. 즉 텍스트의 어느 부분이 위험 (→ 7쪽으로 이어짐) 서술에 해당하는지를 효과적으로 판단할 수 있다.

표 3. 'c5 HazardForm(위험 형태)'의 하위 클래스 (1단계 / 2단계 / 3단계)

c5(1) 홍수 방어 위험
· (1,1) 홍수 방어 기준 위험: 설계 기준 초과 홍수, 설계 홍수 기준 부족, 설계 홍수 산정이 요구 미충족, 최근 이상홍수 운영 기준 미충족
· (1,2) 차수 구조물 여유고 부족: 차수 표고 부족, 차수 구조물 폐합 불완전
· (1,3) 방류 능력 위험: 홍수 방어 시설 누락, 방류 능력 부족
c5(2) 침투 위험
· (2,1) 침투 방지 체계 결함: 차수체 불완전·기능 상실, 그라우팅 부적절, 필터·배수 시설 이상, 접촉부 침투 방지 결함
· (2,2) 누수·이상 침투 현상: 과다 침투량, 접촉 침투, 우회 침투, 확산 침투, 탁한 침투수
· (2,3) 침투 안정 문제: 침투 안정성 부족, 파이핑, 토사 유출
· (2,4) 침투 계측 지표 이상: 침투량 이상 변화, 침윤선 이상, 양압력 이상
c5(3) 구조 위험
· (3,1) 구조 설계 결함: 폭 부족, 표고 부족, 보호 부재 누락
· (3,2) 이상 변형·변위: 과다 침하, 이상 변위, 변형이 요구 미충족
· (3,3) 구조 하중 지지·안정 결함: 구조 강도 부족, 안정성 부족
c5(4) 내진 위험
· (4,1) 내진 설계·방호 결함: 내진 설계 강도 부족, 내진 범주 오류, 설계 지진 파라미터 오류
· (4,2) 내진 하중 지지·안정 결함: 내진 강도 부족, 내진 안정성 부족, 내진 조치 부적절, 구조 액상화 가능성
c5(5) 금속 구조 위험
· (5,1) 배치·형식 선정 결함: 배치 불합리, 형식 선정 불합리, 권양기 양정 부족, 권양기 경간 부족
· (5,2) 내용연수·내구성 결함: 감가·폐기 내용연수 초과, 표면 부식·녹, 수밀 기능 상실
· (5,3) 금속 구조 성능 결함: 금속 구조 강도 부족, 안정성 부족
· (5,4) 운전 기능 이상: 권양력 부족, 개폐 동작 걸림·고장, 안전 보호 장치 이상, 잠금·압력 평형 장치 이상
· (5,5) 보조·지원 계통 이상: 전원 공급 이상, 제어 계통 이상

표 4. 'c6 HazardComponent(위험 부위)'의 하위 클래스

c6(1) 차수 구조물
· (1,1) 주 댐 구조물: 댐 마루, 댐 접합부, 기초, 댐 선단(toe), 댐 본체, 댐 사면·표면, 파랑벽(wave wall), 홍수 방어 계통
· (1,2) 차수체: 댐 차수체, 기초 차수체
· (1,3) 배수 계통: 댐 본체 배수, 기초 배수, 접합부 배수
c6(2) 방류 구조물
· (2,1) 여수로: 유입·조절부, 급경사 수로, 측벽, 감세 구조물, 여수로 금속 구조물
· (2,2) 홍수 방류 터널: (원문에서 여수로와 같은 항목 반복)
· (2,4) 기타 방류 구조물: 바닥 배수구, 비상 여수로, 배수관, 기타 방류 금속 구조물
c6(3) 도수 구조물
· (3,1) 취수 구조물: 취수탑, 경사 취수관, 취수 시설 금속 구조물
· (3,3) 도수 관로: 도수 암거, 도수 터널, 도수 관로 금속 구조물
※ 역자 주: (원문 표의 번호 표기 일부가 어긋나 있음: (2,2)·(2,4)·(3,3) 등)

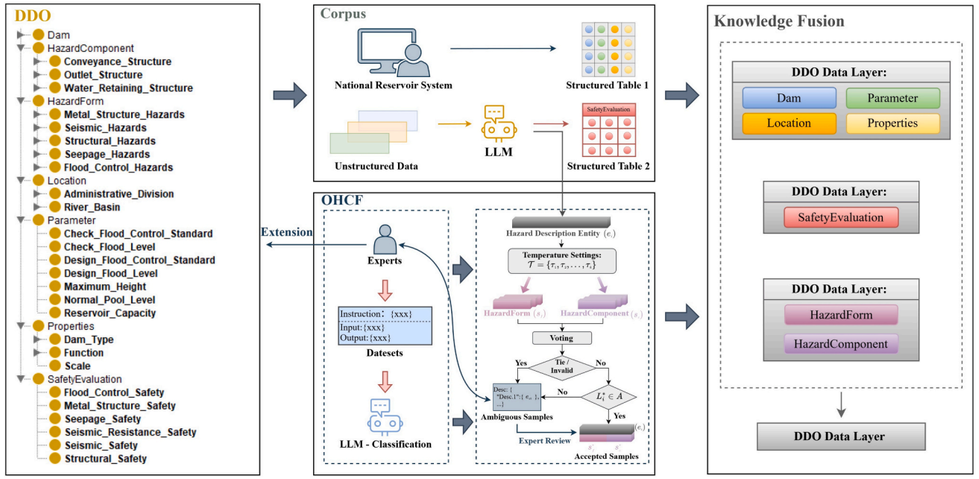


Fig. 3. Framework for data layer construction.

descriptions. Accordingly, given an input report text T, the extraction prompt P_1 is first used to identify hazard-related descriptive fragments. However, the results obtained at this stage are usually still descriptive fragments directly extracted from the original text, and often contain nested expressions, meaning that a single sentence may simultaneously include multiple combinations of hazard forms and hazard components. This creates an obstacle to subsequent hazard classification. To address this issue, this study further designs a description-splitting prompt P_2 to decompose complex hazard expressions into hazard description units that are semantically more explicit and structurally more singular, as shown in Fig. 4. The above two-step process can be formulated as Equation (3).

$$T \xrightarrow{P_1} H = \{h_1, h_2, \ldots, h_m\} \xrightarrow{P_2} E = \{e_1, e_2, \ldots, e_n\} \tag{3}$$

where h_i denotes a hazard-related descriptive fragment extracted from the original text, and e_i denotes a hazard description unit obtained after description splitting. Based on our instance-level observations, general-purpose LLMs can perform both tasks in a relatively stable manner using prompts alone, without task-specific training.

On this basis, OHCF is designed to classify each hazard description unit into the third-level labels of classes c_5 and c_6 defined in the DDO. OHCF consists of four stage:

a) LLM fine-tuning.

To improve the model's ability to perform fine-grained classification under limited computational resources, low-rank adaptation (LoRA) is

```
===== PROMPT =====
You are an expert in processing textual descriptions from dam safety appraisal reports.
Please semantically decompose the input hazard description into several hazard description units with clear and singular meanings.

Requirements:
1. Each output sentence should contain only one hazard component and one hazard form.
2. If multiple hazard forms share the same hazard component in the original text,
   the shared component should be explicitly completed in each decomposed sentence.
3. Do not change the original meaning or add information that is not present in the input text.
4. List the results as complete hazard description sentences.

===== INPUT =====
The downstream slope of the dam lacks slope protection, and there are issues
with an elevated phreatic line exit point and multiple areas of diffuse seepage.

===== MODEL =====
deepseek-v3

===== OUTPUT =====
1. The downstream slope of the dam lacks slope protection.
2. The downstream slope of the dam has an elevated phreatic line exit point.
3. The downstream slope of the dam has multiple areas of diffuse seepage.
```

Fig. 4. Example of nested hazard description splitting using prompting.

해석 (p.7)

(6쪽에서 이어짐) descriptions. Accordingly, given an input report text T…

따라서 입력 보고서 텍스트 T가 주어지면, 먼저 추출 프롬프트 P1을 사용하여 위험 관련 서술 조각을 식별한다. 그러나 이 단계에서 얻은 결과는 대개 여전히 원문에서 직접 추출한 서술 조각이며, 중첩된 표현을 포함하는 경우가 많다. 즉 한 문장이 여러 위험 형태와 위험 부위의 조합을 동시에 포함할 수 있다. 이는 이후의 위험 분류에 장애가 된다. 이 문제를 해결하기 위해 본 연구는 그림 4와 같이 복잡한 위험 표현을 의미가 더 명확하고 구조가 더 단일한 위험 서술 단위로 분해하는 서술 분할 프롬프트 P2를 추가로 설계한다. 위의 두 단계 과정은 식 (3)으로 정식화할 수 있다.

T →(P1) H = {h1, h2, …, hm} →(P2) E = {e1, e2, …, en} (3)

여기서 hi는 원문에서 추출한 위험 관련 서술 조각이고, ei는 서술 분할 후 얻은 위험 서술 단위이다. 인스턴스 수준의 관찰에 따르면, 범용 LLM은 과제 특화 학습 없이 프롬프트만으로 두 과제를 비교적 안정적으로 수행할 수 있다.

On this basis, OHCF is designed to classify each hazard description unit…

이를 바탕으로 OHCF는 각 위험 서술 단위를 DDO에 정의된 클래스 c5와 c6의 3단계 라벨로 분류하도록 설계된다. OHCF는 네 단계로 구성된다.

a) LLM fine-tuning. To improve the model's ability…

a) LLM 미세조정. 제한된 계산 자원에서 세밀한 분류를 수행하는 모델의 능력을 높이기 위해, 저랭크 적응(LoRA)을 (→ 8쪽으로 이어짐) 채택하여 경량 LLM을 미세조정한다.

그림 3. 데이터 계층 구축의 틀 / 그림 4. 프롬프트를 이용한 중첩 위험 서술 분할 예시

메모

adopted to fine-tune a lightweight LLM, enabling it to learn the semantic mapping between hazard description units and the ontology-defined labels.

LoRA is an efficient parameter-adaptation method for fine-tuning large models [57]. It requires updates to only a small number of parameters to improve performance on downstream tasks. The core principle of LoRA is to freeze the original weight matrix $W_0 \in \mathbb{R}^{m\times n}$ of the model and update only the parameters of the incremental matrix ΔW. The incremental update can be expressed as Equation (4), where ΔW is decomposed into two smaller matrices A and B. The output h of the fine-tuned model is obtained by summing the products of the original weight matrix W_0 and the incremental matrix ΔW with the same input vector x, as shown in Equation (5).

$$W_0 + \Delta W = W_0 + BA, A \in \mathbb{R}^{(r\times n)}, B \in \mathbb{R}^{(m\times r)} \tag{4}$$

$$h = W_0 x + \Delta W x = W_0 x + BAx \tag{5}$$

After fine-tuning, the functionality of the model can be formally described as a function f_{θ^*}, which generates corresponding standardized entity labels for any candidate entity:

$$f_{\theta^*} : e_i \rightarrow (s_f, s_c), s_f = c_5(j_1, j_2, j_3), s_c = c_6(k_1, k_2, k_3) \tag{6}$$

b) Temperature-perturbed voting strategy for hazard classification

For generative models, the result of a single inference is not necessarily the globally optimal solution. To further reduce the probability of misclassification, a voting mechanism is introduced. Specifically, n different model temperatures $\mathscr{T} = \{\tau_1, \tau_2, ..., \tau_n\}$ are used to independently perform n inference runs for a given hazard description entity e_i. The frequency with which each candidate label appears across these runs is then counted as its number of votes. Following the majority principle, the candidate labels that receive the highest number of votes are selected as the final and most reliable classification result L_i^*, as defined in Equations (7) – (9).

$$L_i^* = (s_f^*, s_c^*) \tag{7}$$

$$s_f^* = \underset{s_f \in S_5}{\operatorname{argmax}} \sum_{k=1}^{n} \mathbb{I}(s_{f,k} = s_f) \tag{8}$$

$$s_c^* = \underset{s_c \in S_6}{\operatorname{argmax}} \sum_{k=1}^{n} \mathbb{I}(s_{c,k} = s_c) \tag{9}$$

where $s_{f,k}$ and $s_{c,k}$ are the c_5 class and c_6 class obtained from the k−th independent inference of e_i, respectively, while s_f^* and s_c^* are the highest-scoring results among the k inference results, that is, the optimal solutions.

For samples where the model fails to produce classification labels or where the voting results in a tie, the system uniformly assigns a "*False*" identifier and forwards these samples to Stage d for further processing.

c) Ontology-constraint consistency checking.

Although the temperature-perturbed voting strategy improves the stability of hazard classification, the model may still generate clearly inconsistent label pairs. For example, if the hazard description "the existing wave wall crest elevation is insufficient" is classified after voting as the label pair (s_f^*: c_5(1,2,1) Insufficient water-retaining elevation, s_c^*: c_6(1,2,1) Dam impervious body), the resulting pair is obviously inconsistent with engineering knowledge.

To further improve the reliability of classification results, this study introduces an ontology-constraint consistency checking module. A constraint-conflict set A, defined as a sparse subset of the cartesian product, is introduced to record clearly incompatible c_5 and c_6 label pairs according to the DDO hierarchy and engineering knowledge, as expressed in Equation (10).

$$A \subseteq S_f \times S_c \tag{10}$$

Based on this constraint-conflict set, a classification consistency checking function V is defined. V takes the final classification result $L_i^* = (s_f^*, s_c^*)$ from Stage b as input, determines whether the classification result violates the predefined ontology constraints, and outputs a Boolean value:

$$V(L_i^*) = V(s_f^*, s_c^*) = \begin{cases} \textit{False} & \text{if } (s_f^*, s_c^*) \in A \\ \textit{True} & \text{if } (s_f^*, s_c^*) \notin A \end{cases} \tag{11}$$

Entity samples for which $V(L_i^*) = \textit{Ture}$ are accepted, but samples with $V(L_i^*) = \textit{False}$ are forwarded to Stage d for further handling.

d) Expert review and ontology expansion

Samples marked as "*False*" are automatically aggregated by the system and submitted to an expert review queue, where they await manual evaluation by domain experts.

During the review process, experts first determine whether the concept corresponding to a given sample already exists in the DDO. If the concept is already present, experts correct the classification label by linking the hazard description unit to the correct existing ontology node. If the expert confirms that the concept is new, a corresponding node is added to the DDO, and the hazard description entity is then associated with this newly created node. In this semi-automated workflow, the system automatically filters ambiguous samples and experts perform final label correction and ontology evolution. In this way, the DDO achieves dynamic updating and iterative expansion.

3.3. KG storage

In this paper, the Neo4j graph database is selected as the underlying storage platform for DDKG. Utilizing the Cypher query language, Neo4j enables efficient knowledge querying, addition, deletion, and modification. It also exhibits superior performance in executing deep associative queries and multi-hop reasoning [58], providing robust support for subsequent knowledge retrieval and interaction.

The knowledge extracted in Section 3.2 is integrated into JSON format. Based on the semantic and hierarchical relationships within the DDO, a Python script was developed to parse JSON key-value pairs and generate corresponding Cypher statements. This process facilitates the batch creation of DDKG nodes and the construction of inter-entity relationships, completing the injection of dam hazard knowledge into the Neo4j database.

4. Case study

This section begins by outlining the data sources for the case study. Subsequently, ablation experiments are conducted to systematically validate the effectiveness of the key components of OHCF. Finally, the DDKG is established, and its application in dam defect analysis is demonstrated.

4.1. Data sources

In China, dam projects are categorized into Class I, II, and III based on their safety status. Class III dams, which are characterized by significant safety hazards, offer safety appraisal reports that serve as an invaluable data source for risk information. The knowledge in the DDKG is derived from two primary datasets: (1) basic engineering attributes, hydrological records, and geospatial data collected from the China Reservoir Operation and Management Platform; and (2) safety appraisal reports of 22,076 distressed dams across China recorded between 2000 and 2025.

The safety assessment reports of dams in China have a unified standardized structure. The entities related to the top-level classes c_5 to c_7 exist in the following four parts of the report: on-site inspection (including engineering appearance inspection, geological exploration,

해석 (p.8)

(7쪽에서 이어짐) adopted to fine-tune a lightweight LLM…

…경량 LLM을 미세조정하여, 위험 서술 단위와 온톨로지에 정의된 라벨 사이의 의미적 대응을 학습하게 한다.

LoRA is an efficient parameter-adaptation method for fine-tuning large models [57]…

LoRA는 대형 모델을 미세조정하기 위한 효율적인 파라미터 적응 방법이다[57]. 하위 과제의 성능을 높이기 위해 소수의 파라미터만 갱신하면 된다. LoRA의 핵심 원리는 모델의 원래 가중치 행렬 W0∈R^(m×n)을 고정하고 증분 행렬 ΔW의 파라미터만 갱신하는 것이다. 증분 갱신은 식 (4)로 표현할 수 있으며, 여기서 ΔW는 두 개의 더 작은 행렬 A와 B로 분해된다. 미세조정된 모델의 출력 h는 같은 입력 벡터 x에 원래 가중치 행렬 W0과 증분 행렬 ΔW를 각각 곱한 값을 더하여 얻으며, 식 (5)와 같다.

W0 + ΔW = W0 + BA, A∈R^(r×n), B∈R^(m×r) (4)

h = W0x + ΔWx = W0x + BAx (5)

미세조정 후 모델의 기능은 임의의 후보 개체에 대해 해당하는 표준화된 개체 라벨을 생성하는 함수 fθ*로 형식적으로 기술할 수 있다.

fθ*: ei → (sf, sc), sf = c5(j1,j2,j3), sc = c6(k1,k2,k3) (6)

b) Temperature-perturbed voting strategy for hazard classification…

b) 위험 분류를 위한 온도 교란 투표 전략. 생성 모델에서 한 번의 추론 결과가 반드시 전역 최적 해는 아니다. 오분류 확률을 더 줄이기 위해 투표 메커니즘을 도입한다. 구체적으로, 주어진 위험 서술 개체 ei에 대해 서로 다른 n개의 모델 온도 T = {τ1, τ2, …, τn}을 사용하여 n번의 추론을 독립적으로 수행한다. 그런 다음 각 후보 라벨이 이 실행들에서 나타난 빈도를 득표수로 센다. 다수결 원칙에 따라 가장 많은 표를 받은 후보 라벨을 최종적이며 가장 신뢰할 수 있는 분류 결과 L*i로 선택하며, 식 (7)–(9)로 정의된다.

L*i = (s*f, s*c) (7)

s*f = argmax_{sf∈S5} Σ_{k=1}^{n} I(sf,k = sf) (8)

s*c = argmax_{sc∈S6} Σ_{k=1}^{n} I(sc,k = sc) (9)

여기서 sf,k와 sc,k는 ei의 k번째 독립 추론에서 얻은 c5 클래스와 c6 클래스이고, s*f와 s*c는 k개의 추론 결과 중 점수가 가장 높은 결과, 즉 최적 해이다. 모델이 분류 라벨을 내지 못하거나 투표 결과가 동점인 샘플에는 시스템이 일괄적으로 'False' 식별자를 부여하고 추가 처리를 위해 d단계로 넘긴다.

c) Ontology-constraint consistency checking…

c) 온톨로지 제약 일관성 검사. 온도 교란 투표 전략이 위험 분류의 안정성을 높이기는 하지만, 모델은 여전히 명백히 일관되지 않은 라벨 쌍을 생성할 수 있다. 예를 들어 '기존 파랑벽 마루 표고가 부족하다'라는 위험 서술이 투표 후 라벨 쌍 (s*f: c5(1,2,1) 차수 표고 부족, s*c: c6(1,2,1) 댐 차수체)으로 분류된다면, 그 결과 쌍은 공학 지식과 명백히 맞지 않는다.

To further improve the reliability of classification results…

분류 결과의 신뢰성을 더 높이기 위해, 본 연구는 온톨로지 제약 일관성 검사 모듈을 도입한다. 데카르트 곱의 희소한 부분집합으로 정의되는 제약 충돌 집합 A를 도입하여, DDO 계층과 공학 지식에 따라 명백히 양립할 수 없는 c5와 c6 라벨 쌍을 기록하며, 이는 식 (10)과 같다.

A ⊆ Sf × Sc (10)

이 제약 충돌 집합을 바탕으로 분류 일관성 검사 함수 V를 정의한다. V는 b단계의 최종 분류 결과 L*i = (s*f, s*c)를 입력으로 받아, 그 분류 결과가 미리 정의된 온톨로지 제약을 위반하는지 판단하고 불리언 값을 출력한다.

V(L*i) = V(s*f, s*c) = False (s*f, s*c)∈A인 경우 / True (s*f, s*c)가 A에 속하지 않는 경우 (11)

V(L*i) = True인 개체 샘플은 수용되고, V(L*i) = False인 샘플은 추가 처리를 위해 d단계로 넘겨진다.

d) Expert review and ontology expansion…

d) 전문가 검토와 온톨로지 확장. 'False'로 표시된 샘플은 시스템이 자동으로 모아 전문가 검토 대기열에 제출하며, 도메인 전문가의 수동 평가를 기다린다.

During the review process, experts first determine whether the concept…

검토 과정에서 전문가는 먼저 해당 샘플에 대응하는 개념이 DDO에 이미 있는지 판단한다. 개념이 이미 있으면, 전문가는 위험 서술 단위를 올바른 기존 온톨로지 노드에 연결하여 분류 라벨을 수정한다. 전문가가 새로운 개념이라고 확인하면, DDO에 해당 노드를 추가하고 위험 서술 개체를 새로 만든 노드에 연결한다. 이 준자동 작업 흐름에서 시스템은 모호한 샘플을 자동으로 걸러내고, 전문가는 최종 라벨 수정과 온톨로지 진화를 수행한다. 이런 방식으로 DDO는 동적 갱신과 반복적 확장을 이룬다.

3.3 KG 저장

In this paper, the Neo4j graph database is selected as the underlying storage platform…

본 논문은 DDKG의 기반 저장 플랫폼으로 Neo4j 그래프 데이터베이스를 선택한다. Cypher 질의 언어를 활용하여 Neo4j는 효율적인 지식 질의, 추가, 삭제, 수정을 가능하게 한다. 또한 깊은 연관 질의와 다중 홉(multi-hop) 추론 실행에서 우수한 성능을 보여[58], 이후의 지식 검색과 상호작용을 견고하게 지원한다.

The knowledge extracted in Section 3.2 is integrated into JSON format…

3.2절에서 추출한 지식은 JSON 형식으로 통합된다. DDO 안의 의미 관계와 계층 관계를 바탕으로, JSON의 키-값 쌍을 파싱하여 해당하는 Cypher 문을 생성하는 Python 스크립트를 개발하였다. 이 과정은 DDKG 노드의 일괄 생성과 개체 간 관계 구성을 용이하게 하여, 댐 위험 지식을 Neo4j 데이터베이스에 주입하는 일을 완료한다.

4. 사례 연구 (Case study)

This section begins by outlining the data sources for the case study…

이 장은 먼저 사례 연구의 데이터 출처를 개괄한다. 이어서 OHCF의 핵심 구성요소의 효과를 체계적으로 검증하기 위해 제거 실험(ablation)을 수행한다. 마지막으로 DDKG를 구축하고 댐 결함 분석에서의 응용을 시연한다.

4.1 데이터 출처

In China, dam projects are categorized into Class I, II, and III…

중국에서 댐 사업은 안전 상태에 따라 1류, 2류, 3류로 분류된다. 상당한 안전 위험이 있는 것이 특징인 3류 댐은 안전 감정 보고서를 제공하며, 이는 위험 정보의 귀중한 데이터 출처가 된다. DDKG의 지식은 두 가지 주요 데이터셋에서 나온다. (1) 중국 저수지 운영관리 플랫폼에서 수집한 기본 공학 속성, 수문 기록, 지리공간 데이터, (2) 2000년부터 2025년까지 기록된 중국 전역 22,076개 위험 댐의 안전 감정 보고서.

The safety assessment reports of dams in China have a unified standardized structure…

중국의 댐 안전평가 보고서는 통일된 표준 구조를 가진다. 최상위 클래스 c5–c7과 관련된 개체는 보고서의 다음 네 부분에 들어 있다. 현장 점검(공학 외관 점검, 지질 조사, (→ 9쪽으로 이어짐)…

메모

etc.), dam safety analysis and evaluation (sub-item analysis on aspects such as flood control, seepage, and structure of the project), summary of main issues, and safety assessment conclusions. Using the preprocessing method in Section 3.2.1, these four main sections in each dam safety assessment report are identified and extracted through regular expressions, serving as the corpus for subsequent entity recognition.

4.2. Model training and evaluation

4.2.1. Dataset construction

Currently, there are no publicly available model training datasets for hydraulic engineering safety hazards. Therefore, this study constructs a domain-specific dataset using a semi-automated annotation workflow, which consists of three stages: preliminary machine labeling [59], expert verification, and data augmentation [60]. DeepSeek-V3-671B was first used to generate preliminary labels for the extracted hazard description samples. These labels were then verified and corrected by domain experts, and data augmentation was subsequently performed based on the expert-corrected samples.

Fig. 5 illustrates the comprehensive workflow for the fine-tuning dataset construction. The dataset structure adopts the Alpaca format [61], which follows the "Instruction-Input-Output" triplet paradigm. In this framework, "Input" consists of pre-processed raw report text, while "Output" represents the corrected structured entity set. The "Instruction" is composed of three elements: role setting, task description, and output requirements. Role setting is designed to assign a specific identity and function to the model, guiding its comprehension of the task background; the task description defines the specific operations and objectives the model is expected to execute; and the output requirements dictate the desired format and content of the results—in this study, the output format is specified as JSON format.

A total of 120,471 hazard description samples were extracted and subjected to initial machine labeling. These annotated samples were mapped to the five hazard categories through the hierarchical relationships defined in the DDO. Subsequently, 1,200 samples were randomly selected from the annotated corpus for manual verification and validation by experts. To further enhance the dataset, the LLM) was prompted to perform semantic rewriting on the original hazard descriptions. This process generated new instances that are semantically equivalent but linguistically diverse, thereby enriching the training data. The statistics for the hazard samples at each stage of the process are summarized in Table 5.

Table 5
Number of hazard samples at each stage.

Type	Sample size	Expert-corrected samples	Data augmentation
Flood control	210	241	1205
Seepage	313	339	1695
Structural	372	353	1765
Seismic	187	188	940
Metal structure	218	179	895
Total	1300	1300	6500

4.2.2. Experimental configuration and evaluation metrics

Given that the tasks in this study are based on Chinese engineering texts, we selected open-source LLMs trained primarily on Chinese corpora for the experiments, including DeepSeek-V3-671B, Qwen3-32B, GLM4-32B, Qwen3-14B, GLM4-9B, and Qwen3-8B. All experiments were conducted on a server equipped with eight NVIDIA H800 80 GB GPUs, using Python 3.10 and CUDA 12.6. Model fine-tuning was implemented with the LLaMA-Factory framework, and no model quantization was applied. It should be noted that DeepSeek-V3-671B was not fine-tuned due to limitations in computational resources and dataset size; instead, it was used only as a baseline reference.

During fine-tuning, the maximum learning rate was set to 5×10^{-4}, and the number of training epochs was set to 7. The dataset was divided into training, validation, and test subsets at a ratio of 7:1:2. To reduce the risk of overfitting, an early stopping strategy was adopted [62]. Specifically, fine-tuning was terminated in advance if the validation loss continued to increase over several epochs.

Specifically, fine-tuning was terminated in advance if the validation loss continued to increase over several epochs "False" were regarded as null-output cases, indicating that no target entity was identified. The evaluation metrics included macro-averaged precision P_{macro}, macro-averaged recall R_{macro}, and macro-averaged F1-score $F1_{\text{macro}}$, with the calculation formulas presented in Equations (12) to (14).

$$P_{macro} = \frac{1}{n}\sum_{i=1}^{n} P_i = \frac{1}{n}\sum_{i=1}^{n} \frac{TP_i}{TP_i + FP_i} \tag{12}$$

$$R_{macro} = \frac{1}{n}\sum_{i=1}^{n} R_i = \frac{1}{n}\sum_{i=1}^{n} \frac{TP_i}{TP_i + FN_i} \tag{13}$$

$$F1_{\text{macro}} = \frac{1}{n}\sum_{i=1}^{n} F1_i = \frac{1}{n}\sum_{i=1}^{n} 2 \cdot \frac{P_i \cdot R_i}{P_i + R_i} \tag{14}$$

where TP_i is the number of samples whose true labels are class i and are

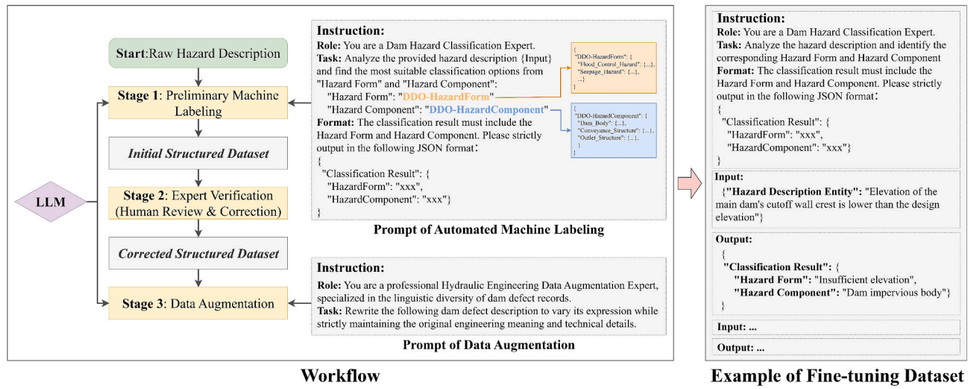


Fig. 5. Dataset construction.

해석 (p.9)

(8쪽에서 이어짐) etc.), dam safety analysis and evaluation…

…등), 댐 안전 분석·평가(사업의 홍수 방어, 침투, 구조 등 측면의 세부 항목 분석), 주요 문제 요약, 안전평가 결론. 3.2.1절의 전처리 방법을 사용하여, 각 댐 안전평가 보고서에서 이 네 개의 주요 부분을 정규식으로 식별·추출하고, 이후 개체 인식을 위한 말뭉치로 사용한다.

4.2 모델 학습과 평가 / 4.2.1 데이터셋 구축

Currently, there are no publicly available model training datasets…

현재 수리공학 안전 위험에 대해 공개된 모델 학습 데이터셋은 없다. 따라서 본 연구는 준자동 주석 작업 흐름을 사용하여 도메인 특화 데이터셋을 구축하며, 이는 예비 기계 라벨링[59], 전문가 검증, 데이터 증강[60]의 세 단계로 이루어진다. 먼저 DeepSeek-V3-671B를 사용하여 추출된 위험 서술 샘플에 예비 라벨을 생성하였다. 이 라벨들은 이후 도메인 전문가가 검증·수정하였고, 전문가가 수정한 샘플을 바탕으로 데이터 증강을 수행하였다.

Fig. 5 illustrates the comprehensive workflow for the fine-tuning dataset construction…

그림 5는 미세조정 데이터셋 구축의 전체 작업 흐름을 보여준다. 데이터셋 구조는 'Instruction)-입력(Input)-출력(Output)' 삼항 패러다임을 따르는 Alpaca 형식[61]을 채택한다. 이 틀에서 '입력'은 전처리된 원본 보고서 텍스트이고, '출력'은 수정된 구조화 개체 집합이다. '지시'는 역할 설정, 과제 설명, 출력 요구사항의 세 요소로 구성된다. 역할 설정은 모델에 특정 정체성과 기능을 부여하여 과제 배경의 이해를 유도하도록 설계된다. 과제 설명은 모델이 수행해야 할 구체적인 작업과 목표를 정의한다. 출력 요구사항은 결과의 원하는 형식과 내용을 규정하며, 본 연구에서는 출력 형식을 JSON으로 지정한다.

A total of 120,471 hazard description samples were extracted…

총 120,471개의 위험 서술 샘플을 추출하여 초기 기계 라벨링을 하였다. 이 주석 샘플들은 DDO에 정의된 계층 관계를 통해 다섯 가지 위험 범주에 대응되었다. 이후 주석된 말뭉치에서 1,200개 샘플을 무작위로 골라 전문가가 수동으로 검증·확인하였다. 데이터셋을 더 강화하기 위해 LLM에 원래 위험 서술의 의미적 재작성을 수행하도록 지시하였다. 이 과정은 의미는 같지만 언어적으로 다양한 새 인스턴스를 생성하여 학습 데이터를 풍부하게 하였다. 과정의 각 단계별 위험 샘플 통계는 표 5에 요약되어 있다.

4.2.2 실험 구성과 평가 지표

Given that the tasks in this study are based on Chinese engineering texts…

본 연구의 과제가 중국어 공학 텍스트를 기반으로 하므로, 주로 중국어 말뭉치로 학습된 오픈소스 LLM을 실험에 선택하였다. DeepSeek-V3-671B, Qwen3-32B, GLM4-32B, Qwen3-14B, GLM4-9B, Qwen3-8B가 포함된다. 모든 실험은 NVIDIA H800 80 GB GPU 8개를 갖춘 서버에서 Python 3.10과 CUDA 12.6으로 수행하였다. 모델 미세조정은 LLaMA-Factory 프레임워크로 구현하였으며 모델 양자화는 적용하지 않았다. DeepSeek-V3-671B는 계산 자원과 데이터셋 규모의 한계로 미세조정하지 않았으며, 기준(baseline) 참고용으로만 사용하였다는 점에 유의해야 한다.

During fine-tuning, the maximum learning rate was set to 5×10…

미세조정 중 최대 학습률은 5×10^-4, 학습 에폭 수는 7로 설정하였다. 데이터셋은 학습, 검증, 시험 부분집합으로 7:1:2 비율로 나누었다. 과적합 위험을 줄이기 위해 조기 종료 전략을 채택하였다[62]. 구체적으로 검증 손실이 여러 에폭에 걸쳐 계속 증가하면 미세조정을 미리 종료하였다. (※ 역자 주: 원문에서 이 문장이 다음 문단 첫머리에 한 번 더 반복되고, 이어지는 문장의 앞부분이 빠져 있음) …'False'로 표시된 경우는 출력이 없는 경우, 즉 대상 개체가 식별되지 않은 것으로 간주하였다. 평가 지표에는 매크로 평균 정밀도 Pmacro, 매크로 평균 재현율 Rmacro, 매크로 평균 F1 점수 F1macro가 포함되며, 계산식은 식 (12)–(14)와 같다.

Pmacro = (1/n) Σ Pi = (1/n) Σ TPi / (TPi + FPi) (12)
Rmacro = (1/n) Σ Ri = (1/n) Σ TPi / (TPi + FNi) (13)
F1macro = (1/n) Σ F1i = (1/n) Σ 2·Pi·Ri / (Pi + Ri) (14)
여기서 TPi는 실제 라벨이 클래스 i이고 (→ 10쪽으로 이어짐) 모델이 올바르게 예측한 샘플 수이고…

그림 5. 데이터셋 구축

표 5. 단계별 위험 샘플 수 (유형: 샘플 수 / 전문가 수정 샘플 / 데이터 증강)

홍수 방어: 210 / 241 / 1,205
침투: 313 / 339 / 1,695
구조: 372 / 353 / 1,765
내진: 187 / 188 / 940
금속 구조: 218 / 179 / 895
합계: 1,300 / 1,300 / 6,500

메모

correctly predicted by the model, FP_i is the number of samples whose true labels belong to other classes but are incorrectly predicted as class i, and FN_i is the number of samples whose true labels are class i but are incorrectly predicted as other classes.

4.2.3. Experimental evaluation

(1) Fine-tuning performance evaluation

The fine-tuning results are shown in Fig. 6. To ensure comparability across different models and between the pre- and post-fine-tuning results, all models were evaluated using the same prompt template during inference, in which the complete set of candidate labels was provided. The temperature parameter was uniformly set to 0 to reduce the influence of random sampling on model outputs. From the baseline results, the overall recognition performance generally improves as the model parameter scale increases. DeepSeek-V3-671B achieves the best baseline performance in both class c_5 and class c_6. This indicates that ultra-large general-purpose LLMs have stronger basic capabilities in semantic understanding of dam hazard descriptions and fine-grained category discrimination without domain-specific fine-tuning. This result also supports the use of large-parameter models in the data pre-annotation stage of this study, as they can generate relatively high-quality candidate labels and thereby reduce the workload required for subsequent manual correction.

After fine-tuning, the fine-tuned models showed substantial improvements in both class c_5 and class c_6 recognition tasks, with $F1_{macro}$ increasing by approximately 26–34 percentage points compared with the baseline results. This indicates that domain-specific fine-tuning effectively improves the model's capability for hazard classification. Among the tested models, GLM4-32B achieved the best overall performance, with all three evaluation metrics approaching 90 % for class c_5 and also close to 90 % for class c_6. Qwen3-32B also achieved strong results after fine-tuning, although its metrics were slightly lower than those of GLM4-32B. In comparison, the 8B–14B models showed lower overall performance than the 32B models, but they require fewer computational resources and lower deployment costs, while still achieving relatively stable recognition results after fine-tuning. Therefore, in resource-constrained or cost-sensitive scenarios, 8B–14B models remain a practical option that balances performance and efficiency. For the subsequent experiments in this study, GLM4-32B was selected as the base model to ensure higher accuracy and stability in dam hazard entity recognition.

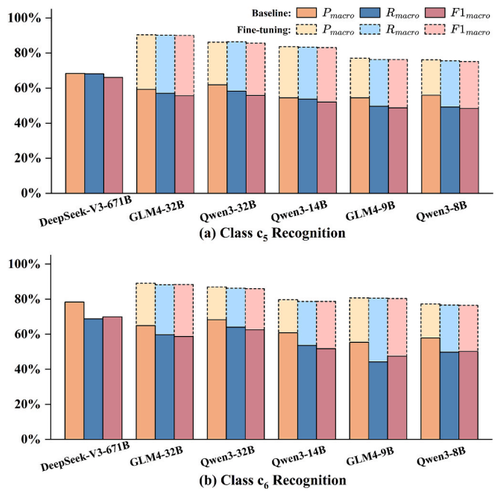


Fig. 6. Model performance before and after fine-tuning.

Further inspection of the prediction results shows that the remaining errors in class c_5 recognition are mainly associated with structural hazards. For structural hazards, the models tend to confuse fine-grained categories such as insufficient structural strength and structural instability. This is mainly because these categories are described in highly similar ways in engineering reports. Expressions such as "not satisfying specification requirements", "insufficient safety", and "inadequate bearing capacity" are frequently used, but the text does not always clearly indicate whether the problem refers to material- or member-level bearing capacity, or to the overall stability, sliding stability, or overturning stability of the structure. As a result, the models can generally identify such descriptions as structural safety problems, but still face difficulties in aligning them with the correct fine-grained hazard form. In contrast, the recognition results for class c_6 are relatively balanced across different categories, with no obvious performance bottleneck. This indicates that the models can identify dam components.

(2) Performance evaluation under different temperature parameters

Furthermore, we conducted voting experiments under temperature perturbations using the fine-tuned GLM4-32B and Qwen3-32B models. For the entity classification task, adjusting the temperature can influence output diversity. However, excessively high values may lead to overly divergent outputs and the generation of irrelevant content. In our experiments, six temperature values between 0 and 1 were tested, specifically $\mathcal{T} = \{0, 0.2, 0.4, 0.6, 0.8, 1.0\}$. The resulting performance variations of the models across these temperature settings are presented in Fig. 7.

The experimental results show that model performance under a single temperature setting fluctuates with changes in temperature, and the trends vary across models and recognition tasks. GLM4-32B maintains high overall performance in both the c5 and c6 tasks, but noticeable fluctuations occur at certain temperature settings, such as 0.4 and 0.6. In contrast, Qwen3-32B shows a slight overall decline in task performance as the temperature increases, suggesting that higher temperatures may affect output stability to some extent. Overall, the P, R, and F1 values obtained through multi-temperature voting are higher than those obtained under single-temperature settings across all experimental groups. This indicates that the voting strategy can effectively integrate model outputs under different temperature conditions and reduce the influence of single-inference errors on the final classification results, thereby improving the stability and overall performance of entity recognition.

In addition, the experiment further examined a cross-model hybrid voting strategy. Specifically, the predictions of Qwen3-32B and GLM4-32B under their relatively optimal temperature settings were selected, and the final labels were generated through majority voting. The results show that the overall performance of hybrid voting did not exceed that of the better-performing GLM4-32B model alone. A possible reason is that the overall prediction quality of Qwen3-32B was relatively lower, and its incorrect predictions may have weakened the decision advantage of GLM4-32B during voting. In addition, the two models may have shared similar confusion patterns for some fine-grained categories, preventing cross-model voting from forming effective complementarity.

(3) Ablation study.

The ablation study was conducted based on the GLM4-32B model to evaluate the contribution of the main components of OHCF. As shown in Table 6, fine-tuning provides the dominant performance gain, demonstrating its importance for adapting the model to the dam hazard classification task. The voting and consistency checking modules bring further but relatively modest improvements. Overall, the complete OHCF achieves the best performance for both c_5 and c_6 classification, with all evaluation metrics exceeding 90 %.

해석 (p.10)

(9쪽에서 이어짐) correctly predicted by the model, FPi is the number…

…FPi는 실제 라벨이 다른 클래스인데 클래스 i로 잘못 예측된 샘플 수이며, FNi는 실제 라벨이 클래스 i인데 다른 클래스로 잘못 예측된 샘플 수이다.

4.2.3 실험 평가 / (1) 미세조정 성능 평가

The fine-tuning results are shown in Fig. 6. To ensure comparability…

미세조정 결과는 그림 6에 나타나 있다. 서로 다른 모델 사이, 그리고 미세조정 전후 결과 사이의 비교 가능성을 보장하기 위해, 모든 모델은 추론 시 후보 라벨 전체 집합을 제공하는 동일한 프롬프트 템플릿으로 평가하였다. 무작위 샘플링이 모델 출력에 미치는 영향을 줄이기 위해 온도 파라미터는 일괄 0으로 설정하였다. 기준 결과에서 전체 인식 성능은 대체로 모델 파라미터 규모가 커질수록 향상된다. DeepSeek-V3-671B는 클래스 c5와 c6 모두에서 가장 좋은 기준 성능을 낸다. 이는 초대형 범용 LLM이 도메인 특화 미세조정 없이도 댐 위험 서술의 의미 이해와 세밀한 범주 구별에서 더 강한 기본 능력을 가짐을 보여준다. 이 결과는 또한 본 연구의 데이터 사전 주석 단계에서 대규모 파라미터 모델을 사용한 것을 뒷받침한다. 대형 모델은 비교적 고품질의 후보 라벨을 생성하여 이후 수동 수정에 필요한 작업량을 줄일 수 있기 때문이다.

After fine-tuning, the fine-tuned models showed substantial improvements…

미세조정 후, 미세조정된 모델은 클래스 c5와 c6 인식 과제 모두에서 크게 향상되었으며, F1macro가 기준 결과보다 약 26–34 %p 증가하였다. 이는 도메인 특화 미세조정이 위험 분류 능력을 효과적으로 향상시킴을 보여준다. 시험한 모델 중 GLM4-32B가 가장 좋은 전체 성능을 보였으며, 세 평가 지표 모두 클래스 c5에서 90 %에 근접했고 클래스 c6에서도 90 %에 가까웠다. Qwen3-32B도 미세조정 후 강한 결과를 냈지만, 지표가 GLM4-32B보다 약간 낮았다. 이에 비해 8B–14B 모델은 32B 모델보다 전체 성능이 낮았지만, 더 적은 계산 자원과 낮은 배포 비용을 요구하면서도 미세조정 후 비교적 안정적인 인식 결과를 냈다. 따라서 자원이 제한되거나 비용에 민감한 상황에서 8B–14B 모델은 성능과 효율의 균형을 맞추는 실용적인 선택지로 남는다. 이후 실험에서는 댐 위험 개체 인식의 정확도와 안정성을 높이기 위해 GLM4-32B를 기본 모델로 선택하였다.

Further inspection of the prediction results shows that the remaining errors…

예측 결과를 더 살펴보면 클래스 c5 인식에 남은 오류는 주로 구조 위험과 관련된다. 구조 위험의 경우 모델은 구조 강도 부족과 구조 불안정 같은 세밀한 범주를 혼동하는 경향이 있다. 이는 주로 이 범주들이 공학 보고서에서 매우 비슷하게 서술되기 때문이다. '규정 요구사항을 충족하지 않음', '안전성 부족', '지지력 부족' 같은 표현이 자주 쓰이지만, 텍스트가 그 문제가 재료·부재 수준의 지지력을 말하는지, 구조의 전체 안정성, 활동 안정성, 전도 안정성을 말하는지를 항상 분명히 밝히지는 않는다. 그 결과 모델은 이런 서술을 대체로 구조 안전 문제로 식별할 수는 있지만, 올바른 세밀 위험 형태에 대응시키는 데는 여전히 어려움을 겪는다. 반면 클래스 c6의 인식 결과는 범주 간에 비교적 고르며 뚜렷한 성능 병목이 없다. 이는 모델이 댐 구성요소를 식별할 수 있음을 보여준다.

(2) 서로 다른 온도 파라미터에서의 성능 평가

Furthermore, we conducted voting experiments under temperature perturbations…

나아가 미세조정된 GLM4-32B와 Qwen3-32B 모델을 사용하여 온도 교란 하에서 투표 실험을 수행하였다. 개체 분류 과제에서 온도를 조정하면 출력 다양성에 영향을 줄 수 있다. 그러나 값이 지나치게 높으면 출력이 지나치게 발산하고 관련 없는 내용이 생성될 수 있다. 실험에서는 0과 1 사이의 여섯 가지 온도 값, 구체적으로 T = {0, 0.2, 0.4, 0.6, 0.8, 1.0}을 시험하였다. 이 온도 설정들에 따른 모델의 성능 변화는 그림 7에 제시되어 있다.

The experimental results show that model performance under a single temperature setting…

실험 결과, 단일 온도 설정에서의 모델 성능은 온도 변화에 따라 변동하며, 그 경향은 모델과 인식 과제에 따라 다르다. GLM4-32B는 c5와 c6 과제 모두에서 높은 전체 성능을 유지하지만, 0.4와 0.6 같은 일부 온도 설정에서 눈에 띄는 변동이 나타난다. 반면 Qwen3-32B는 온도가 올라갈수록 과제 성능이 전반적으로 약간 떨어져, 높은 온도가 출력 안정성에 어느 정도 영향을 줄 수 있음을 시사한다. 전체적으로 다중 온도 투표로 얻은 P, R, F1 값은 모든 실험 그룹에서 단일 온도 설정에서 얻은 값보다 높다. 이는 투표 전략이 서로 다른 온도 조건의 모델 출력을 효과적으로 통합하고 단일 추론 오류가 최종 분류 결과에 미치는 영향을 줄여, 개체 인식의 안정성과 전체 성능을 향상시킬 수 있음을 보여준다.

In addition, the experiment further examined a cross-model hybrid voting strategy…

또한 실험에서는 모델 간 혼합 투표 전략도 추가로 검토하였다. 구체적으로 Qwen3-32B와 GLM4-32B의 상대적으로 최적인 온도 설정에서의 예측을 골라 다수결 투표로 최종 라벨을 생성하였다. 그 결과 혼합 투표의 전체 성능은 성능이 더 좋은 GLM4-32B 단독 모델의 성능을 넘지 못했다. 가능한 이유는 Qwen3-32B의 전체 예측 품질이 상대적으로 낮아, 그 잘못된 예측이 투표에서 GLM4-32B의 결정 우위를 약화시켰을 수 있기 때문이다. 또한 두 모델이 일부 세밀한 범주에 대해 비슷한 혼동 패턴을 공유하여, 모델 간 투표가 효과적인 상호 보완을 이루지 못했을 수 있다.

(3) 제거 실험 (Ablation study)

The ablation study was conducted based on the GLM4-32B model…

OHCF 주요 구성요소의 기여를 평가하기 위해 GLM4-32B 모델을 기반으로 제거 실험을 수행하였다. 표 6에서 보듯 미세조정이 지배적인 성능 향상을 제공하며, 이는 모델을 댐 위험 분류 과제에 적응시키는 데 미세조정이 중요함을 보여준다. 투표와 일관성 검사 모듈은 추가적이지만 비교적 작은 향상을 가져온다. 전체적으로 완전한 OHCF가 c5와 c6 분류 모두에서 가장 좋은 성능을 내며, 모든 평가 지표가 90 %를 넘는다.

그림 6. 미세조정 전후의 모델 성능

메모

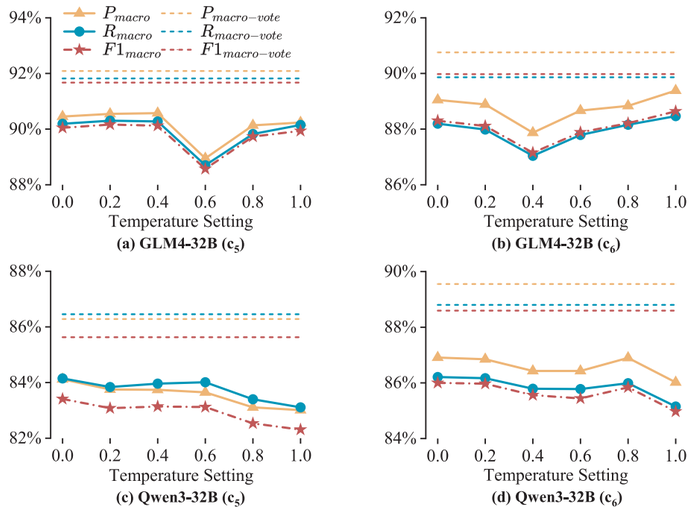


Fig. 7. Model performance under temperature perturbation and voting strategy.

Table 6
Ablation results of OHCF based on GLM4-32B.

	Class c_5 Classification			Class c_6 Classification		
	P_{macro}	R_{macro}	$F1_{macro}$	P_{macro}	R_{macro}	$F1_{macro}$
Baseline	59.29 %	57.06 %	55.65 %	64.88 %	59.69 %	58.66 %
w/o Voting & Consistency checking	90.45 %	90.19 %	90.04 %	89.05 %	88.20 %	88.30 %
w/o Consistency Checking	92.09 %	91.82 %	91.67 %	90.76 %	89.86 %	89.98 %
OHCF	93.26 %	93.01 %	92.87 %	91.55 %	90.62 %	90.76 %

4.3. Construction and retrieval application of DDKG

4.3.1. DDKG construction and visualization

Based on the experimental results, the fine-tuned GLM4-32B model was adopted as the backbone of OHCF and applied to all hazard description texts. The data layer entities associated with each engineering instance were organized into independent JSON files and batch-imported into the Neo4j graph database using Python scripts. In total, the constructed DDKG contained 201,362 nodes and 953,447 relationships. The number of nodes associated with each top-level class is listed in Table 7. Parameter nodes account for a relatively large proportion because each dam instance is described by multiple engineering and hydrological indicators, including dam height, reservoir capacity, and characteristic water levels.

Fig. 8 illustrates the main knowledge structure of the DDKG. Each dam instance is semantically mapped to its corresponding entity node. Under the semantic constraints defined in the dam domain ontology (DDO), each dam engineering entity is connected to its associated attribute, evaluation, hazard-form, and hazard-component entities. These entities can be further traced upward along the ontology hierarchy to establish multi-level semantic associations with their parent nodes (e.g., Dam → c_5(5,2,2) ← c_5(5,2) ← c_5(5)). In addition, engineering entities can be topologically connected across different projects through shared entity nodes. For example, two dam instances in Fig. 8 are associated through common nodes such as “River Basin: Pearl River Basin”, “Scale: Small”, and “Dam type: Homogeneous Earth Dam”. This interconnected structure provides a robust foundation for advanced tasks such as clustering analysis of dam hazard knowledge and knowledge reasoning.

Table 7
Number of nodes associated with each top-level class.

c_i	Entity class	Quantity
c_1	Dam	22,076
c_2	Properties	58
c_3	Location	1,922
c_4	Parameter	76,152
c_5	HazardForm	73
c_6	HazardComponent	44
c_7	SafetyEvaluation	15
Total		100,340

4.3.2. Example of multi-constraint retrieval

The core function of KGs lies in efficient knowledge retrieval. By constraining key entity nodes, the DDKG can retrieve the distribution of engineering hazards under specific boundary conditions. Fig. 9 illustrates the retrieval of structural safety hazards under multiple constraints. This retrieval involves three fixed constraints: Yangtze River Basin (River_Basin), embankment dam (Dam_Type), and medium (Scale). These constraints restrict the search scope to all dam projects corresponding to this combination. Within the defined sample pool, hazard nodes associated with these projects are traced via the (:Dam)-[:exhibitsHazards]->(:HazardForm) relationship. At the same time, constraints on hazard forms are constructed based on the hierarchical structure under the top-level class c_5:HazardForm in the DDO: (:HazardForm {node_name:'Structure'})-[:hasSubclass*0..]->(: HazardForm). This strictly limits the retrieval to the “Structure Hazards” node and all

해석 (p.11)

4.3 DDKG의 구축과 검색 응용 / 4.3.1 DDKG 구축과 시각화

Based on the experimental results, the fine-tuned GLM4-32B model was adopted…

실험 결과를 바탕으로, 미세조정된 GLM4-32B 모델을 OHCF의 기반 모델로 채택하여 모든 위험 서술 텍스트에 적용하였다. 각 공학 인스턴스와 연관된 데이터 계층 개체는 독립된 JSON 파일로 정리되어 Python 스크립트로 Neo4j 그래프 데이터베이스에 일괄 입력되었다. 구축된 DDKG는 총 201,362개의 노드와 953,447개의 관계를 포함하였다. 각 최상위 클래스와 연관된 노드 수는 표 7에 나열되어 있다. 각 댐 인스턴스가 댐 높이, 저수 용량, 특성 수위 등 여러 공학·수문 지표로 기술되기 때문에 Parameter 노드가 비교적 큰 비중을 차지한다.

Fig. 8 illustrates the main knowledge structure of the DDKG…

그림 8은 DDKG의 주요 지식 구조를 보여준다. 각 댐 인스턴스는 대응하는 개체 노드에 의미적으로 대응된다. 댐 도메인 온톨로지(DDO)에 정의된 의미 제약 아래에서, 각 댐 공학 개체는 연관된 속성, 평가, 위험 형태, 위험부위 개체와 연결된다. 이 개체들은 온톨로지 계층을 따라 위로 더 추적하여 상위 노드와 다단계 의미 연관을 형성할 수 있다(예: Dam → c5(5,2,2) ← c5(5,2) ← c5(5)). 또한 공학 개체는 공유 개체 노드를 통해 서로 다른 사업 간에 위상적으로 연결될 수 있다. 예를 들어 그림 8의 두 댐 인스턴스는 '유역: 주강 유역', '규모: 소형', '댐 형식: 균질 흙댐' 같은 공통 노드를 통해 연관된다. 이렇게 서로 연결된 구조는 댐 위험 지식의 군집 분석과 지식 추론 같은 고급 과제의 견고한 기반을 제공한다.

4.3.2 다중 제약 검색의 예

The core function of KGs lies in efficient knowledge retrieval…

KG의 핵심 기능은 효율적인 지식 검색에 있다. 핵심 개체 노드에 제약을 걸어, DDKG는 특정 경계 조건에서의 공학 위험 분포를 검색할 수 있다. 그림 9는 다중 제약 하에서 구조 안전 위험을 검색하는 예를 보여준다. 이 검색에는 양쯔강 유역(River_Basin), 필댐(Dam_Type), 중형(Scale)의 세 가지 고정 제약이 포함된다. 이 제약들은 검색 범위를 이 조합에 해당하는 모든 댐 사업으로 제한한다. 정의된 표본 집합 안에서 이 사업들과 연관된 위험 노드를 (:Dam)-[:exhibitsHazards]->(:HazardForm) 관계를 통해 추적한다. 동시에 DDO의 최상위 클래스 c5:HazardForm 아래 계층 구조를 바탕으로 위험 형태에 대한 제약을 구성한다: (:HazardForm {node_name:'Structure'})-[:hasSubclass*0..]->(:HazardForm). 이는 검색을 '구조 위험' 노드와 그 모든 (→ 12쪽으로 이어짐) 재귀적 하위 클래스로 엄격하게 제한한다.

그림 7. 온도 교란과 투표 전략 하의 모델 성능

표 6. GLM4-32B 기반 OHCF 제거 실험 결과 (c5: P/R/F1, c6: P/R/F1)

기준(Baseline): c5 59.29 / 57.06 / 55.65 %, c6 64.88 / 59.69 / 58.66 %
투표·일관성 검사 제외: c5 90.45 / 90.19 / 90.04 %, c6 89.05 / 88.20 / 88.30 %
일관성 검사 제외: c5 92.09 / 91.82 / 91.67 %, c6 90.76 / 89.86 / 89.98 %
OHCF 전체: c5 93.26 / 93.01 / 92.87 %, c6 91.55 / 90.62 / 90.76 %

표 7. 최상위 클래스별 노드 수

c1 Dam 22,076 / c2 Properties 58 / c3 Location 1,922 / c4 Parameter 76,152 / c5 HazardForm 73 / c6 HazardComponent 44 / c7 SafetyEvaluation 15 / 합계 100,340
※ 역자 주: 본문에는 전체 노드가 201,362개로 적혀 있어 표의 합계와 다름(원문 그대로)

메모

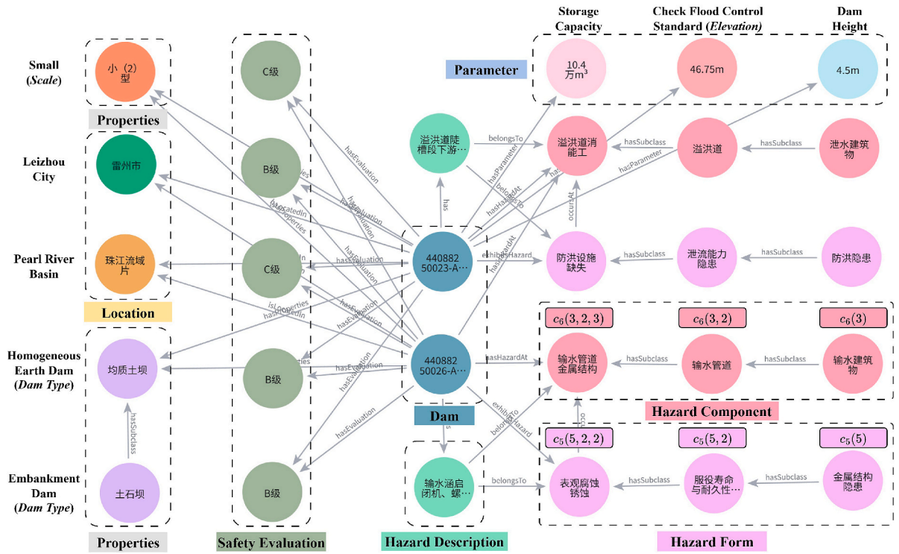


Fig. 8. Visualization of the main DDKG structure.

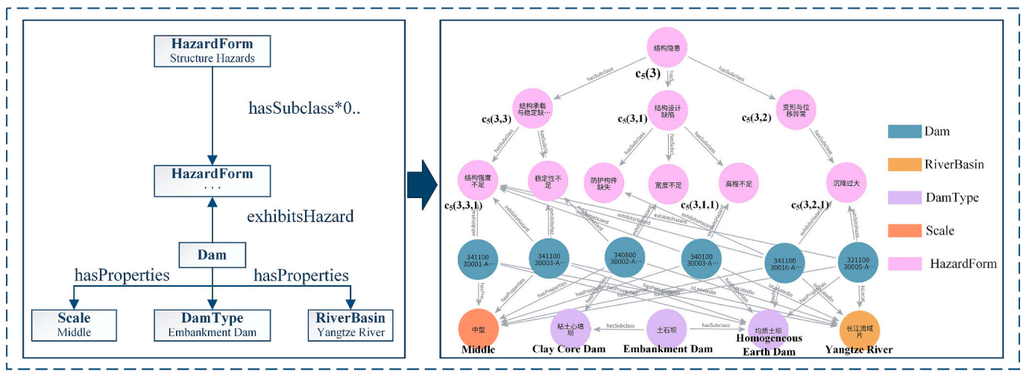


Fig. 9. Example of Structural Hidden Danger Knowledge Retrieval.

its recursive subclasses.

The DDKG, as a structured knowledge base, organizes originally scattered information on river basins, dam types, and defective and dangerous dam hazards into an ordered network through entity and relationship links. In this way, complex retrieval and reasoning tasks—such as multi-conditional filtering or cross-node risk tracing—can be performed based on graph paths, rather than simple text matching.

4.4. DDKG-based analysis of dam defects in the Yangtze River Basin

This section takes dam projects in the Yangtze River Basin as the research object and conducts a case analysis of dam safety defects. The purpose is to further verify the application potential and value of the DDKG in engineering defect analysis and decision-support tasks.

In practical engineering, a Grade-C result in a specific safety evaluation category indicates that the project has relatively serious safety defects in that category. To identify the major safety weaknesses of dam projects in the Yangtze River Basin, the occurrence frequencies and co-occurrence frequencies of different Grade-C safety evaluation indicators were statistically analyzed, as shown in Fig. 10. In the figure, $c_7(1)$, $c_7(2)$, $c_7(3)$, $c_7(4)$, and $c_7(5)$ represent flood-control safety, seepage safety, structural safety, seismic safety, and metal-structure safety evaluations, respectively. The diagonal values indicate the occurrence frequency of each Grade-C safety evaluation indicator.

From the perspective of individual safety evaluation results, Grade-C problems in dam projects of the Yangtze River Basin are mainly concentrated in seepage safety, structural safety, and flood-control safety. Among them, seepage safety has the highest Grade-C occurrence frequency, indicating that seepage-related defects are the most

해석 (p.12)

(11쪽에서 이어짐) its recursive subclasses. The DDKG, as a structured knowledge base…

구조화된 지식 베이스로서 DDKG는 유역, 댐 형식, 결함·위험 댐의 위험에 관해 원래 흩어져 있던 정보를 개체와 관계 연결을 통해 질서 있는 네트워크로 조직한다. 이를 통해 다중 조건 필터링이나 노드 간 리스크 추적 같은 복잡한 검색·추론 과제를 단순 텍스트 매칭이 아니라 그래프 경로를 바탕으로 수행할 수 있다.

4.4 DDKG 기반 양쯔강 유역 댐 결함 분석

This section takes dam projects in the Yangtze River Basin as the research object…

이 절은 양쯔강 유역의 댐 사업을 연구 대상으로 삼아 댐 안전 결함의 사례 분석을 수행한다. 목적은 공학 결함 분석과 의사결정 지원 과제에서 DDKG의 응용 잠재력과 가치를 더 검증하는 것이다.

In practical engineering, a Grade-C result in a specific safety evaluation category…

실제 공학에서 특정 안전평가 범주의 C등급 결과는 그 사업이 해당 범주에서 비교적 심각한 안전 결함을 가지고 있음을 뜻한다. 양쯔강 유역 댐 사업의 주요 안전 취약점을 식별하기 위해, 서로 다른 C등급 안전평가 지표의 발생 빈도와 동시 발생 빈도를 통계적으로 분석하였으며, 그림 10과 같다. 그림에서 c7(1), c7(2), c7(3), c7(4), c7(5)는 각각 홍수 방어 안전, 침투 안전, 구조 안전, 내진 안전, 금속 구조 안전 평가를 나타낸다. 대각선 값은 각 C등급 안전평가 지표의 발생 빈도를 나타낸다.

From the perspective of individual safety evaluation results…

개별 안전평가 결과의 관점에서, 양쯔강 유역 댐 사업의 C등급 문제는 주로 침투 안전, 구조 안전, 홍수 방어 안전에 집중되어 있다. 그중 침투 안전의 C등급 발생 빈도가 가장 높아, 침투 관련 결함이 (→ 13쪽으로 이어짐) 이 유역 댐 사업 안전평가에서 가장 두드러진 취약점임을 보여준다.

그림 8. DDKG 주요 구조의 시각화 / 그림 9. 구조 위험 지식 검색의 예

메모

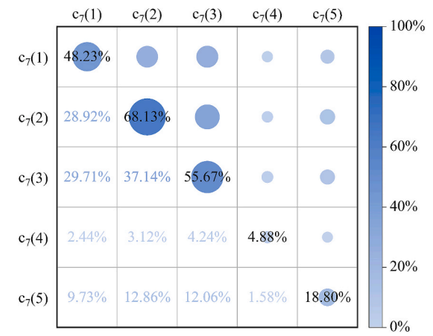


Fig. 10. Occurrence and co-occurrence frequencies of Grade-C safety evaluation indicators in the Yangtze River Basin.

prominent weakness in the safety evaluation of dam projects in this basin. The Grade-C occurrence frequencies of structural safety and flood-control safety are also relatively high, reaching 55.67 % and 48.23 %, respectively. This suggests that dams in the Yangtze River Basin commonly face problems such as structural aging, insufficient seepage-control capacity, and inadequate flood-control capacity during long-term operation. In contrast, metal-structure safety defects and seismic defects are not the dominant problems for dam projects in the Yangtze River Basin.

4.4.1. Analysis of seepage–structure compound defects

The co-occurrence analysis of Grade-C safety evaluation indicators shows a relatively strong association between seepage defects and structural defects in the Yangtze River Basin. To further identify the specific defect combinations underlying this association, the top five co-occurrence patterns of severe seepage and structural defects were extracted, as shown in Table 8.

It can be seen that seepage leakage "$c_5(2,2,1)$" in conveyance culverts "$c_6(3,2,1)$" has the highest co-occurrence probability with insufficient structural strength "$c_5(3,3,1)$". This combination represents the most typical seepage–structure compound defect in the Yangtze River Basin. In early earth-rockfill dams, conveyance culverts were mostly embedded within the dam body and were commonly built as masonry structures. Their material properties differ markedly from those of the surrounding dam-fill materials, making it difficult to maintain coordinated seepage deformation and stress deformation. As a result, concentrated seepage paths are likely to develop along the contact zones between the culvert and the dam body. Long-term seepage erosion may not only weaken the seepage stability of these contact zones, but also accelerate the deterioration of the masonry culvert structure. This may reduce structural strength and further induce or aggravate culvert leakage.

In addition, seepage leakage c5(2,2,1) in dam foundations c6(1,1,3) is also likely to be coupled with structural instability defects. Long-term foundation seepage may cause soil loss or local erosion at the contact zones between the dam foundation and the dam body, thereby weakening the supporting conditions of the dam. This process may induce excessive settlement c5(3,2,1) of dam slopes c6(1,1,6), and may even develop into overall sliding instability c5(3,3,2). Meanwhile, uneven settlement of the dam body or foundation may also adversely affect auxiliary structures such as the spillway c6(2,1,1), leading to structural cracking or deformation at contact zones, which may further induce seepage problems.

Therefore, seepage anomalies may weaken the stability conditions of the dam body and foundation, while long-term seepage action may further accelerate structural deterioration and local damage. Conversely, structural defects can also aggravate seepage problems by inducing cracking, deformation, or contact-zone failure, and may further affect the overall flood-control capacity and operational safety of the project. These results indicate that seepage and structural defects in the Yangtze River Basin are not independent problems, but are often coupled and mutually reinforcing. Therefore, safety diagnosis and reinforcement measures should focus on the combined effects of seepage control, structural stability, and component integrity, rather than treating seepage and structural defects as isolated issues.

Table 8
Top five co-occurrence combinations of seepage and structural defects.

No.	Seepage Hazards		Structure Hazards		Co-occurrence Frequency
	Class c_5	Class c_6	Class c_5	Class c_6	
1	$c_5(2,2,1)$	$c_6(3,2,1)$	$c_5(3,3,1)$	$c_6(3,2,1)$	13.99 %
2	$c_5(2,2,1)$	$c_6(1,1,3)$	$c_5(3,3,2)$	$c_6(1,1,6)$	13.83 %
3	$c_5(2,2,1)$	$c_6(1,1,3)$	$c_6(1,1,6)$	$c_6(2,1,1)$	13.55 %
4	$c_5(2,2,1)$	$c_6(1,1,3)$	$c_5(3,2,1)$	$c_6(1,1,6)$	12.96 %
5	$c_5(2,2,1)$	$c_6(1,1,3)$	$c_5(3,3,1)$	$c_6(3,2,1)$	10.57 %

4.4.2. Flood control hazard analysis of embankment dams

Flood control and disaster mitigation are among the primary functions of reservoir dams. For embankment dams, insufficient flood-control capacity may directly increase the risk of overtopping and threaten the overall safety of the dam.

Fig. 11 depicts the frequency distribution of various flood control hazard forms for embankment dams of different project scales in the Yangtze River Basin. Panels (a), (b), and (c) correspond to small, medium, and large projects, respectively. The occurrence frequency of each flood control hazard was calculated using Equation (15):

$$P\left(c_5(1,j_2,j_3)|\lambda_k,\Omega\right)=\frac{N_{dam}\left(c_5(1,j_2,j_3)\cap\lambda_k\cap\Omega\right)}{N_{dam}(\lambda_k\cap\Omega)}\times 100\% \tag{15}$$

where λ_k is the project scale, with k = 1, 2, and 3 corresponding to small, medium, and large projects, respectively; Ω is the constraint set ({Yangtze River Basin (River_Basin), embankment dam (Dam_Type)}; $N_{dam}(\lambda_k\cap\Omega)$ is the number of dams with "project scale = λ_k & Ω"; and $N_{dam}\left(c_5(1,j_2,j_3)\cap\lambda_k\cap\Omega\right)$ is the number of dams with "flood control hazard exists $c_5(1,j_2,j_3)$ & project scale = λ_k & Ω."

Overall, "$c_5(1,2)$ Insufficient freeboard of water-retaining structures" and "$c_5(1,3)$ Discharge capacity hazards" emerge as the most critical flood control hazards. Within these categories, "$c_5(1,2,1)$ Insufficient dam crest elevation" and "$c_5(1,3,2)$ Insufficient discharge capacity of the spillway" are the most frequently occurring specific hazard forms.

Small-scale projects are more prone than medium- and large-scale projects to issues such as "$c_5(1,1,2)$ Insufficient design flood standard" and "$c_5(1,2,1)$ Insufficient dam crest elevation." This reflects the limitations of small reservoirs, which—constrained by lower fortification standards and limited technical investment during earlier construction periods— not only struggle to meet current design codes in terms of technical parameters but also lack sufficient structural height margins to safely accommodate extreme conditions.

The occurrence frequency of "$c_5(1,3,2)$ Insufficient discharge capacity" increases with project scale. Compared with small-scale projects, medium- and large-scale projects generally face greater flood pressures and more complex flood routing processes. These characteristics place higher demands on the discharge capacity of hydraulic structures, the efficiency of operational response, and the coordination of the overall flood release system. As a result, mismatches between discharge capacity and actual flood control demands are more likely to occur in larger projects.

In small projects, although insufficient discharge capacity is relatively less prominent, "$c_5(1,3,1)$ Missing flood control facilities" is more severe. This is mainly because some small reservoirs have remained empty for many years owing to prolonged periods without inflow. Under

해석 (p.13)

(12쪽에서 이어짐) prominent weakness… The Grade-C occurrence frequencies of structural safety…

구조 안전과 홍수 방어 안전의 C등급 발생 빈도도 비교적 높아 각각 55.67 %와 48.23 %에 이른다. 이는 양쯔강 유역의 댐들이 장기 운영 중에 구조 노후화, 침투 방지 능력 부족, 홍수 방어 능력 부족 같은 문제를 공통적으로 겪고 있음을 시사한다. 반면 금속 구조 안전 결함과 내진 결함은 양쯔강 유역 댐 사업의 주된 문제가 아니다.

4.4.1 침투-구조 복합 결함 분석

The co-occurrence analysis of Grade-C safety evaluation indicators shows…

C등급 안전평가 지표의 동시 발생 분석은 양쯔강 유역에서 침투 결함과 구조 결함 사이에 비교적 강한 연관이 있음을 보여준다. 이 연관의 바탕이 되는 구체적인 결함 조합을 더 식별하기 위해, 심각한 침투 결함과 구조 결함의 상위 다섯 개 동시 발생 패턴을 추출하였으며, 표 8과 같다.

It can be seen that seepage leakage "c5(2,2,1)" in conveyance culverts…

도수 암거 'c6(3,2,1)'의 침투 누수 'c5(2,2,1)'이 구조 강도 부족 'c5(3,3,1)'과 동시 발생 확률이 가장 높음을 알 수 있다. 이 조합은 양쯔강 유역에서 가장 전형적인 침투-구조 복합 결함이다. 초기 흙-사력댐에서 도수 암거는 대부분 댐 본체 안에 매설되었고 흔히 조적 구조로 건설되었다. 그 재료 특성이 주변 댐 성토 재료와 크게 달라 침투 변형과 응력 변형의 조화를 유지하기 어렵다. 그 결과 암거와 댐 본체 사이의 접촉부를 따라 집중 침투 경로가 생기기 쉽다. 장기간의 침투 침식은 이 접촉부의 침투 안정성을 약화시킬 뿐 아니라 조적 암거 구조의 열화를 가속할 수 있다. 이는 구조 강도를 낮추고 암거 누수를 더 유발하거나 악화시킬 수 있다.

In addition, seepage leakage c5(2,2,1) in dam foundations c6(1,1,3)…

또한 댐 기초 c6(1,1,3)의 침투 누수 c5(2,2,1)도 구조 불안정 결함과 결합되기 쉽다. 장기간의 기초 침투는 댐 기초와 댐 본체 사이 접촉부에서 토사 유실이나 국부 침식을 일으켜 댐의 지지 조건을 약화시킬 수 있다. 이 과정은 댐 사면 c6(1,1,6)의 과다 침하 c5(3,2,1)를 유발할 수 있고, 심지어 전체 활동 불안정 c5(3,3,2)로 발전할 수도 있다. 한편 댐 본체나 기초의 부등 침하는 여수로 c6(2,1,1) 같은 부속 구조물에도 악영향을 주어 접촉부의 구조 균열이나 변형을 일으키고, 이는 다시 침투 문제를 유발할 수 있다.

Therefore, seepage anomalies may weaken the stability conditions…

따라서 침투 이상은 댐 본체와 기초의 안정 조건을 약화시킬 수 있고, 장기간의 침투 작용은 구조 열화와 국부 손상을 더 가속할 수 있다. 반대로 구조 결함도 균열, 변형, 접촉부 파괴를 유발하여 침투 문제를 악화시킬 수 있으며, 사업의 전체 홍수 방어 능력과 운영 안전에 더 영향을 줄 수 있다. 이 결과는 양쯔강 유역의 침투 결함과 구조 결함이 독립된 문제가 아니라 흔히 결합되어 서로를 강화한다는 것을 보여준다. 따라서 안전 진단과 보강 대책은 침투와 구조 결함을 고립된 문제로 다루기보다, 침투 제어, 구조 안정성, 구성요소 무결성의 결합 효과에 초점을 맞춰야 한다.

4.4.2 필댐의 홍수 방어 위험 분석

Flood control and disaster mitigation are among the primary functions…

홍수 방어와 재해 저감은 저수지 댐의 주요 기능 중 하나이다. 필댐의 경우 홍수 방어 능력 부족은 월류 위험을 직접 높이고 댐 전체의 안전을 위협할 수 있다.

Fig. 11 depicts the frequency distribution of various flood control hazard forms…

그림 11은 양쯔강 유역에서 사업 규모가 다른 필댐들의 다양한 홍수 방어 위험 형태의 빈도 분포를 보여준다. (a), (b), (c) 패널은 각각 소형, 중형, 대형 사업에 해당한다. 각 홍수 방어 위험의 발생 빈도는 식 (15)로 계산하였다.
P(c5(1,j2,j3) | λk, Ω) = Ndam(c5(1,j2,j3) ∩ λk ∩ Ω) / Ndam(λk ∩ Ω) × 100% (15)
여기서 λk는 사업 규모이며 k = 1, 2, 3은 각각 소형, 중형, 대형 사업에 해당한다. Ω는 제약 집합({양쯔강 유역(River_Basin), 필댐(Dam_Type)})이다. Ndam(λk∩Ω)는 '사업 규모 = λk 이고 Ω'인 댐의 수이고, Ndam(c5(1,j2,j3)∩λk∩Ω)는 '홍수 방어 위험 c5(1,j2,j3)이 있고, 사업 규모 = λk 이고 Ω'인 댐의 수이다.

Overall, "c5(1,2) Insufficient freeboard of water-retaining structures"…

전체적으로 'c5(1,2) 차수 구조물 여유고 부족'과 'c5(1,3) 방류 능력 위험'이 가장 중대한 홍수 방어 위험으로 나타난다. 이 범주들 안에서 'c5(1,2,1) 댐 마루 표고 부족'과 'c5(1,3,2) 여수로 방류 능력 부족'이 가장 자주 발생하는 구체적인 위험 형태이다.

Small-scale projects are more prone than medium- and large-scale projects…

소형 사업은 중·대형 사업보다 'c5(1,1,2) 설계 홍수 기준 부족'과 'c5(1,2,1) 댐 마루 표고 부족' 같은 문제가 생기기 쉽다. 이는 초기 건설 시기의 낮은 방호 기준과 제한된 기술 투자에 묶인 소형 저수지가, 기술 파라미터 측면에서 현행 설계 기준을 맞추기 어려울 뿐 아니라 극한 조건을 안전하게 수용할 충분한 구조 높이 여유도 부족하다는 한계를 반영한다.

The occurrence frequency of "c5(1,3,2) Insufficient discharge capacity" increases…

'c5(1,3,2) 방류 능력 부족'의 발생 빈도는 사업 규모가 클수록 증가한다. 소형 사업에 비해 중·대형 사업은 일반적으로 더 큰 홍수 압력과 더 복잡한 홍수 추적(routing) 과정에 직면한다. 이러한 특성은 수리 구조물의 방류 능력, 운영 대응의 효율, 전체 홍수 방류 체계의 조정에 더 높은 요구를 가한다. 그 결과 방류 능력과 실제 홍수 방어 수요 사이의 불일치가 큰 사업에서 생기기 쉽다.

In small projects, although insufficient discharge capacity is relatively less prominent…

소형 사업에서는 방류 능력 부족이 상대적으로 덜 두드러지지만, 'c5(1,3,1) 홍수 방어 시설 누락'이 더 심각하다. 이는 주로 일부 소형 저수지가 오랜 기간 유입이 없어 여러 해 동안 빈 상태로 남아 있었기 때문이다. 이런 (→ 14쪽으로 이어짐) 조건에서…

그림 10. 양쯔강 유역 C등급 안전평가 지표의 발생·동시 발생 빈도

표 8. 침투·구조 결함의 상위 5개 동시 발생 조합 (침투 위험 c5, c6 / 구조 위험 c5, c6 / 동시 발생 빈도)

1. c5(2,2,1), c6(3,2,1) / c5(3,3,1), c6(3,2,1) / 13.99 %
2. c5(2,2,1), c6(1,1,3) / c5(3,3,2), c6(1,1,6) / 13.83 %
3. c5(2,2,1), c6(1,1,3) / c6(1,1,6), c6(2,1,1) / 13.55 %
4. c5(2,2,1), c6(1,1,3) / c5(3,2,1), c6(1,1,6) / 12.96 %
5. c5(2,2,1), c6(1,1,3) / c5(3,3,1), c6(3,2,1) / 10.57 %

메모

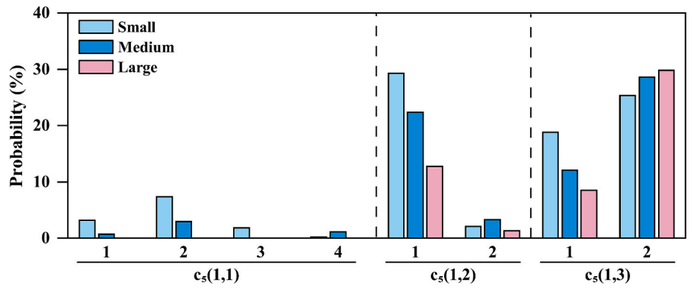


Fig. 11. Frequency distribution of flood control hazard forms.

such conditions, their original water release or conveyance facilities may gradually fall into disuse and become inoperative, leading to a substantial weakening of flood control function. Although these reservoirs may currently have little practical need for discharge, the associated risk should not be overlooked. Once a flood event occurs, the reservoir may rapidly shift from an empty state to an impounding state. In the absence of functional flood release facilities, inflow cannot be discharged in time, which greatly increases the risk of overtopping and, in severe cases, dam failure.

In summary, the DDKG provides a structured basis for multi-dimensional dam hazard analysis. The Yangtze River Basin case study shows that hazard information can be retrieved and compared by basin, dam type, project scale, hazard type, and affected component. This demonstrates the potential of the DDKG to support regional dam safety analysis and management decision-making.

5. Conclusion and future work

To address the underutilization of unstructured text data in the dam safety domain and the challenges of knowledge adaptation when applying general-purpose LLMs to specialized fields, this study proposes a KG construction method that integrates a domain knowledge ontology with LLMs. The main contributions of this research are as follows:

(1) A dam defects ontology (DDO) was developed to provide a structured representation framework for dam hazard knowledge. In particular, the classes of hazard forms and affected components were refined to support fine-grained modeling of dam defects.

(2) An Ontology-guided Hazard Classification Framework (OHCF) was proposed for standardizing unstructured hazard descriptions. By integrating fine-tuning, temperature-perturbed voting, ontology-constraint consistency checking, and expert validation, OHCF improves the reliability of hazard classification and provides structured inputs for KG construction.

(3) Based on the proposed method, a dam defects knowledge graph (DDKG) was constructed using safety appraisal reports from 22,076 dams. The case study shows that the DDKG can support multi-constraint retrieval and regional hazard analysis, demonstrating its potential value for dam safety management.

Despite these contributions, the proposed method has limitations that will be addressed in future work:

(1) The application of the DDKG in this study remains preliminary, focusing mainly on a single large-scale regional analysis. Future research will further expand its application to more refined spatial-scale and project-level hazard analyses, to reveal regional differences in hazard distribution and provide more targeted support for dam safety management.

(2) At present, the DDKG is a static knowledge base, as its hazard information is derived from historical evaluation reports. Future work will incorporate temporal data and explore automated update methods to transform the DDKG into a dynamic, evolving system.

(3) Although this study evaluates hazard knowledge extraction and includes expert validation, the constructed knowledge graph itself still requires systematic assessment. Future research will examine its structural properties, completeness, consistency, and practical effectiveness in supporting dam defect analysis and engineering decision-making.

Declaration of generative AI and AI-assisted technologies in the manuscript preparation process

During the preparation of this work the author(s) used Gemini 2.5 in order to improve the language and readability. After using this tool/service, the author(s) reviewed and edited the content as needed and take(s) full responsibility for the content of the published article.

CRediT authorship contribution statement

Jianfeng Huang: Writing – review & editing, Writing – original draft, Visualization, Validation, Methodology, Investigation, Formal analysis, Conceptualization. **Wenang Hou:** Writing – review & editing, Supervision, Project administration, Funding acquisition, Data curation. **Shichen Zhang:** Writing – review & editing, Supervision, Project administration, Funding acquisition, Conceptualization. **Zhenhan Du:** Visualization, Investigation, Data curation. **Jiangshan Yin:** Validation, Formal analysis.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgments

This work was supported by the National Key Research and Development Program of China (Grant No. 2024YFC3210700), and the Central Public-interest Scientific Institution Basal Research Fund (Grant Nos. Y724007, Y724010).

Data availability

The data that has been used is confidential.

References

[1] I. Zamarrón-Mieza, V. Yepes, J.M. Moreno-Jiménez, A systematic review of application of multi-criteria decision analysis for aging-dam management, J. Clean. Prod. 147 (2017) 217–230, https://doi.org/10.1016/j.jclepro.2017.01.092.
[2] J. Liu, F. Wang, X. Wang, Z. Hu, C. Liang, Temperature monitoring and cracking risk analysis of corridor top arch of baihetan arch dam during construction period,

해석 (p.14)

메모

그림 11. 홍수 방어 위험 형태의 빈도 분포 (소형·중형·대형)

(13쪽에서 이어짐) such conditions, their original water release or conveyance facilities…

…원래의 방류·도수 시설이 점차 방치되어 작동하지 않게 되고, 홍수 방어 기능이 크게 약화된다. 이 저수지들은 현재 방류의 실질적 필요가 거의 없을 수 있지만, 관련 리스크를 간과해서는 안 된다. 홍수가 발생하면 저수지는 빈 상태에서 저류 상태로 빠르게 바뀔 수 있다. 제 기능을 하는 홍수 방류 시설이 없으면 유입량을 제때 방류할 수 없어 월류 위험이 크게 높아지며, 심한 경우 댐 붕괴로 이어질 수 있다.

In summary, the DDKG provides a structured basis for multi-dimensional dam hazard analysis…

요약하면, DDKG는 다차원적 댐 위험 분석의 구조화된 기반을 제공한다. 양쯔강 유역 사례 연구는 위험 정보를 유역, 댐 형식, 사업 규모, 위험 유형, 영향 부위별로 검색하고 비교할 수 있음을 보여준다. 이는 DDKG가 지역 댐 안전 분석과 관리 의사결정을 지원할 잠재력이 있음을 보여준다.

5. 결론과 향후 연구

To address the underutilization of unstructured text data in the dam safety domain…

댐 안전 분야에서 비정형 텍스트 데이터가 충분히 활용되지 않는 문제와, 범용 LLM을 전문 분야에 적용할 때의 지식 적응 문제를 해결하기 위해, 본 연구는 도메인 지식 온톨로지와 LLM을 통합한 KG 구축 방법을 제안한다. 본 연구의 주요 기여는 다음과 같다.

(1) 댐 위험 지식의 구조화된 표현 틀을 제공하는 댐 결함 온톨로지(DDO)를 개발하였다. 특히 위험 형태와 영향 부위의 클래스를 정교화하여 댐 결함의 세밀한 모델링을 지원하였다.

(2) 비정형 위험 서술을 표준화하기 위한 온톨로지 기반 위험 분류 프레임워크(OHCF)를 제안하였다. 미세조정, 온도 교란 투표, 온톨로지 제약 일관성 검사, 전문가 검증을 통합하여 OHCF는 위험 분류의 신뢰성을 높이고 KG 구축을 위한 구조화된 입력을 제공한다.

(3) 제안 방법을 바탕으로 22,076개 댐의 안전 감정 보고서를 사용하여 댐 결함 지식그래프(DDKG)를 구축하였다. 사례 연구는 DDKG가 다중 제약 검색과 지역 위험 분석을 지원할 수 있음을 보여주어, 댐 안전관리에 대한 잠재적 가치를 입증한다.

Despite these contributions, the proposed method has limitations…

이러한 기여에도 불구하고, 제안 방법에는 향후 연구에서 다룰 한계가 있다.

(1) 본 연구에서 DDKG의 응용은 아직 초기 단계로, 주로 단일한 대규모 지역 분석에 초점을 맞추었다. 향후 연구는 더 세밀한 공간 규모와 사업 수준의 위험 분석으로 응용을 확장하여, 위험 분포의 지역적 차이를 밝히고 댐 안전관리에 더 표적화된 지원을 제공할 것이다.

(2) 현재 DDKG는 위험 정보가 과거 평가 보고서에서 나온 정적 지식 베이스이다. 향후 연구는 시간 데이터를 통합하고 자동 갱신 방법을 탐색하여 DDKG를 동적으로 진화하는 시스템으로 바꿀 것이다.

(3) 본 연구는 위험 지식 추출을 평가하고 전문가 검증을 포함하지만, 구축된 지식그래프 자체는 여전히 체계적인 평가가 필요하다. 향후 연구는 그 구조적 특성, 완전성, 일관성, 그리고 댐 결함 분석과 공학 의사결정 지원에서의 실질적 효과를 검토할 것이다.

원고 준비 과정의 생성형 AI 사용 고지 / 저자 기여 등

저자들은 언어와 가독성을 개선하기 위해 Gemini 2.5를 사용하였으며, 사용 후 내용을 검토·편집하고 출판된 논문 내용에 전적인 책임을 진다. (이하 저자 기여, 이해 상충, 감사의 글, 참고문헌은 해석 생략)

Eng. Fail. Anal. 167 (2025) 108903, https://doi.org/10.1016/j.engfailanal.2024.108903.
[3] P. Bu, Y. Li, W. Tang, X. Chen, B. Li, Semi-quantitative risk analysis of high concrete face rockfill dams under seismic action, Structures 45 (2022) 685–694, https://doi.org/10.1016/j.istruc.2022.09.013.
[4] Y. Liu, D. Zheng, E. Cao, X. Wu, Z. Chen, Cracking risk analysis of face slabs in concrete face rockfill dams during the operation period, Structures 40 (2022) 621–632, https://doi.org/10.1016/j.istruc.2022.04.054.
[5] J. Wang, Z. Zhang, Y. Huang, H. Hu, Proactive dispatch of rail maintenance equipment under weather-induced disruptions: an optimization framework integrating machine learning-driven risk assessment, Adv. Eng. Inform. 69 (2026) 103990, https://doi.org/10.1016/j.aei.2025.103990.
[6] X. Huo, Y. Yin, L. Jiao, Y. Zhang, A data-driven and knowledge graph-based analysis of the risk hazard coupling mechanism in subway construction accidents, Reliab. Eng. Syst. Saf. 250 (2024) 110254, https://doi.org/10.1016/j.ress.2024.110254.
[7] S. Fu, Q. Tang, M. Zhang, B. Han, Z. Wu, W. Mao, A data-driven framework for risk and resilience analysis in maritime transportation systems: a case study of domino effect accidents in arctic waters, Reliab. Eng. Syst. Saf. 260 (2025) 111049, https://doi.org/10.1016/j.ress.2025.111049.
[8] M. Marzouk, M. Enaba, Text analytics to analyze and monitor construction project contract and correspondence, Autom. Constr. 98 (2019) 265–274, https://doi.org/10.1016/j.autcon.2018.11.018.
[9] S. Ji, S. Pan, E. Cambria, P. Marttinen, P.S. Yu, A survey on knowledge graphs: Representation, acquisition and applications, IEEE Trans. Neural Netw. Learn. Syst. 33 (2022) 494–514, https://doi.org/10.1109/TNNLS.2021.3070843.
[10] D.W. Otter, J.R. Medina, J.K. Kalita, A survey of the usages of deep learning for natural language processing, IEEE Trans. Neural Netw. Learn. Syst. 32 (2021) 604–624, https://doi.org/10.1109/TNNLS.2020.2979670.
[11] M. Shim, H. Choi, H. Koo, K. Um, K.-H. Lee, S. Lee, OmEGa(Ω): Ontology-based information extraction framework for constructing task-centric knowledge graph from manufacturing documents with large language model, Adv. Eng. Inform. 64 (2025) 103001, https://doi.org/10.1016/j.aei.2024.103001.
[12] Y. Duan, Y. Tian, S. Ghosh, V. Venugopal, J. Chen, E.A. Olivetti, LLM-empowered literature mining for material substitution studies in sustainable concrete, Resour. Conserv. Recycl. 221 (2025) 108379, https://doi.org/10.1016/j.resconrec.2025.108379.
[13] W.X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, Y. Min, B. Zhang, J. Zhang, Z. Dong, Y. Du, C. Yang, Y. Chen, Z. Chen, J. Jiang, R. Ren, Y. Li, X. Tang, Z. Liu, P. Liu, J.-Y. Nie, J.-R. Wen, A survey of large language models, (2025). https://doi.org/10.48550/arXiv.2303.18223.
[14] Q. Dong, L. Li, D. Dai, C. Zheng, J. Ma, R. Li, H. Xia, J. Xu, Z. Wu, T. Liu, B. Chang, X. Sun, L. Li, Z. Sui, A survey on in-context learning, (2024). https://doi.org/10.48550/arXiv.2301.00234.
[15] J. Zhou, T. Lu, S. Mishra, S. Brahma, S. Basu, Y. Luan, D. Zhou, L. Hou, Instruction-following evaluation for large language models, (2023). https://doi.org/10.48550/arXiv.2311.07911.
[16] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le, D. Zhou, Chain-of-thought prompting elicits reasoning in large language models, (2023). https://doi.org/10.48550/arXiv.2201.11903.
[17] LLM-based framework for bearing fault diagnosis, Mech. Syst. Signal Process. 224 (2025) 112127, https://doi.org/10.1016/j.ymssp.2024.112127.
[18] T.R. Gruber, A translation approach to portable ontology specifications, Knowl. Acquis. 5 (1993) 199–220, https://doi.org/10.1006/knac.1993.1008.
[19] X. Huang, C. Yang, Y. Zhang, S. Lou, L. Kong, H. Zhou, Ontology guided multi-level knowledge graph construction and its applications in blast furnace ironmaking process, Adv. Eng. Inform. 62 (2024) 102927, https://doi.org/10.1016/j.aei.2024.102927.
[20] D. Zhang, G. Ma, T. Qu, X. Wang, W. Zhou, X. Wang, A knowledge graph-enhanced large language model for question answering of hydraulic structure safety management, Adv. Eng. Inform. 66 (2025) 103468, https://doi.org/10.1016/j.aei.2025.103468.
[21] B.-L. Gan, D.-M. Zhang, Z.-K. Huang, F.-Y. Zheng, R. Zhu, W. Zhang, Ontology-driven knowledge graph for decision-making in resilience enhancement of underground structures: Framework and application, Tunn. Undergr. Space Technol. 163 (2025) 106739, https://doi.org/10.1016/j.tust.2025.106739.
[22] X. Liu, H. Lu, H. Li, Intelligent generation method of emergency plan for hydraulic engineering based on knowledge graph – take the south-to-north water diversion project as an example, LHB 108 (2022) 2153629, https://doi.org/10.1080/27678490.2022.2153629.
[23] Y. Zhou, T. Bao, X. Shu, Y. Li, Y. Li, BIM and ontology-based knowledge management for dam safety monitoring, Autom. Constr. 145 (2023) 104649, https://doi.org/10.1016/j.autcon.2022.104649.
[24] C. Baudrit, F. Taillandier, C. Curt, Q.A. Hoang, Z.-M. Sbartaï, D. Breysse, Graph based knowledge models for capitalizing, predicting and learning: a proof of concept applied to the dam systems, Adv. Eng. Inform. 52 (2022) 101551, https://doi.org/10.1016/j.aei.2022.101551.
[25] A. Hogan, E. Blomqvist, M. Cochez, C. d'Amato, G. de Melo, C. Gutierrez, J.E. L. Gayo, S. Kirrane, S. Neumaier, A. Polleres, R. Navigli, A.-C.-N. Ngomo, S. M. Rashid, A. Rula, L. Schmelzeisen, J. Sequeda, S. Staab, A. Zimmermann, Knowledge graphs, ACM Comput. Surv. 54 (2022) 1–37, https://doi.org/10.1145/3447772.
[26] L. Pei, Y. Li, X. Lu, J. Zhou, Y. Li, Ontology - and data-driven defect diagnosis with knowledge graphs and causal reasoning: Application to the risk management of gravity dams, Reliab. Eng. Syst. Saf. 270 (2026) 112224, https://doi.org/10.1016/j.ress.2026.112224.
[27] X. Bai, S. He, Y. Li, Y. Xie, X. Zhang, W. Du, J.-R. Li, Construction of a knowledge graph for framework material enabled by large language models and its application, npj Comput. Mater. 11 (2025) 51, https://doi.org/10.1038/s41524-025-01540-6.
[28] Y. Huang, Z. Zhang, H. Hu, Risk propagation mechanisms in railway systems under extreme weather: a knowledge graph-based unsupervised causation chain approach, Reliab. Eng. Syst. Saf. 260 (2025) 110976, https://doi.org/10.1016/j.ress.2025.110976.
[29] Y. Yang, P. Xiang, D. Wang, Knowledge graph and mitigation measures recommendation for safety hazards in large-scale hydropower projects using diverse heterogeneous inspection data, Autom. Constr. 178 (2025) 106419, https://doi.org/10.1016/j.autcon.2025.106419.
[30] O. Etzioni, M. Cafarella, D. Downey, A.-M. Popescu, T. Shaked, S. Soderland, D. S. Weld, A. Yates, Unsupervised named-entity extraction from the web: an experimental study, Artif. Intell. 165 (2005) 91–134, https://doi.org/10.1016/j.artint.2005.03.001.
[31] D. Hanisch, K. Fundel, H.-T. Mevissen, R. Zimmer, J. Fluck, ProMiner: Rule-based protein and gene entity recognition, BMC Bioinf. 6 (2005) S14, https://doi.org/10.1186/1471-2105-6-S1-S14.
[32] S. Zhang, N. Elhadad, Unsupervised biomedical named entity recognition: Experiments with clinical and biological texts, J. Biomed. Inform. 46 (2013) 1088–1098, https://doi.org/10.1016/j.jbi.2013.08.004.
[33] M. Gridach, Character-level neural network for biomedical named entity recognition, J. Biomed. Inform. 70 (2017) 85–91, https://doi.org/10.1016/j.jbi.2017.05.002.
[34] I. Jauregi Unanue, E. Zare Borzeshi, M. Piccardi, Recurrent neural networks with specialized word embeddings for health-domain named-entity recognition, J. Biomed. Inform. 76 (2017) 102–109, https://doi.org/10.1016/j.jbi.2017.11.007.
[35] T. Chen, R. Xu, Y. He, X. Wang, Improving sentiment analysis via sentence type classification using BiLSTM-CRF and CNN, Expert Syst. Appl. 72 (2017) 221–230, https://doi.org/10.1016/j.eswa.2016.10.065.
[36] Q. Li, L. Li, W. Wang, Q. Li, J. Zhong, A comprehensive exploration of semantic relation extraction via pre-trained CNNs, Knowl.-Based Syst. 194 (2020) 105488. https://doi.org/10.1016/j.knosys.2020.105488.
[37] J. Wang, W. Xu, X. Fu, G. Xu, Y. Wu, ASTRAL: Adversarial trained LSTM-CNN for named entity recognition, Knowl.-Based Syst. 197 (2020) 105842. https://doi.org/10.1016/j.knosys.2020.105842.
[38] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A.N. Gomez, L. Kaiser, I. Polosukhin, Attention is all you need, (2023). https://doi.org/10.48550/arXiv.1706.03762.
[39] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, BERT: Pre-training of deep bidirectional transformers for language understanding, (2019). https://doi.org/10.48550/arXiv.1810.04805.
[40] Y. Ding, F. Zhu, H. Li, A.K. Parlikad, M. Xie, A failure knowledge graph learning framework for offshore wind turbines with incomplete knowledge, Renew. Sustain. Energy Rev. 215 (2025) 115561, https://doi.org/10.1016/j.rser.2025.115561.
[41] Z. Zhang, X. Yang, L. Sun, Y. Sun, J. Kang, Research on constructing and reasoning the collision knowledge graph of autonomous navigation ship based on enhanced BERT model, Expert Syst. Appl. 278 (2025) 127429, https://doi.org/10.1016/j.eswa.2025.127429.
[42] Y. Hu, H. Wang, J. Chen, C. Zhang, M. Ren, M. Dong, H. Zhang, Z. Hu, X. Dong, Construction and application of conditional event-based knowledge graphs for electric power standards, Expert Syst. Appl. 297 (2026) 129291, https://doi.org/10.1016/j.eswa.2025.129291.
[43] X. Liu, J.A. Erkoyuncu, J.Y.H. Fuh, W.F. Lu, B. Li, Knowledge extraction for additive manufacturing process via named entity recognition with LLMs, Robot. Comput.-Integr. Manuf. 93 (2025) 102900, https://doi.org/10.1016/j.rcim.2024.102900.
[44] Inf. Process. Manag. 62 (2025) 104129, https://doi.org/10.1016/j.ipm.2025.104129.
[45] X. Liao, C. Chen, Z. Wang, Y. Liu, T. Wang, L. Cheng, Large language model assisted fine-grained knowledge graph construction for robotic fault diagnosis, Adv. Eng. Inform. 65 (2025) 103134, https://doi.org/10.1016/j.aei.2025.103134.
[46] Y. Huang, R. Yan, Z. Zhang, Automated knowledge extraction from marine accident reports using large language models: Graph construction and evaluation, Ocean Coast. Manag. 272 (2026) 108015, https://doi.org/10.1016/j.ocecoaman.2025.108015.
[47] M. Monajatipoor, J. Yang, J. Stremmel, M. Emami, F. Mohaghegh, M. Rouhsedaghat, K.-W. Chang, LLMs in biomedicine: A study on clinical named entity recognition, (2024). https://doi.org/10.48550/arXiv.2404.07376.
[48] J. Choi, B. Lee, Accelerating materials language processing with large language models, Commun. Mater. 5 (2024) 13, https://doi.org/10.1038/s43246-024-00449-9.
[49] D. Cotroneo, R. Natella, V. Orbinato, Elevating cyber threat intelligence against disinformation campaigns with LLM-based concept extraction and the FakeCTI dataset, J. Syst. Softw. 232 (2026) 112660, https://doi.org/10.1016/j.jss.2025.112660.
[50] M. Val-Calvo, M. Egaña Aranguren, J. Mulero-Hernández, G. Almagro-Hernández, P. Deshmukh, J.A. Bernabé-Díaz, P. Espinoza-Arias, J.L. Sánchez-Fernández, J. Mueller, J.T. Fernández-Breis, OntoGenix: Leveraging large language models for enhanced ontology engineering from datasets, Inf. Process. Manag. 62 (2025) 104042, https://doi.org/10.1016/j.ipm.2024.104042.
[51] G. Ciatto, A. Agiollo, M. Magnini, A. Omicini, Large language models as oracles for instantiating ontologies with domain-specific knowledge, Knowl.-Based Syst. 310 (2025) 112940, https://doi.org/10.1016/j.knosys.2024.112940.

해석 (p.15)

참고문헌

(참고문헌 목록: 해석 생략)

메모

[52] L. Huang, W. Yu, W. Ma, W. Zhong, Z. Feng, H. Wang, Q. Chen, W. Peng, X. Feng, B. Qin, T. Liu, A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions, ACM Trans. Inf. Syst. 43 (2025) 1–55, https://doi.org/10.1145/3703155.
[53] J. Zhou, Z. Ma, Named entity recognition for construction documents based on fine-tuning of large language models with low-quality datasets, Autom. Constr. 174 (2025) 106151, https://doi.org/10.1016/j.autcon.2025.106151.
[54] Adv. Eng. Inform. 74 (2026) 104646, https://doi.org/10.1016/j.aei.2026.104646.
[55] F. Ali, S. El-Sappagh, S.M.R. Islam, A. Ali, M. Attique, M. Imran, K.-S. Kwak, An intelligent healthcare monitoring framework using wearable sensors and social networking data, Future Gener. Comput. Syst. 114 (2021) 23–43, https://doi.org/10.1016/j.future.2020.07.047.
[56] C. Cui, T. Sun, S. Liang, T. Gao, Z. Zhang, J. Liu, X. Wang, C. Zhou, H. Liu, M. Lin, Y. Zhang, Y. Zhang, H. Zheng, J. Zhang, J. Zhang, Y. Liu, D. Yu, Y. Ma, PaddleOCR-VL: Boosting multilingual document parsing via a 0.9B ultra-compact vision-language model, (2025). https://doi.org/10.48550/arXiv.2510.14528.
[57] E.J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen, LoRA: Low-rank adaptation of large language models, (2021). https://doi.org/10.48550/arXiv.2106.09685.
[58] F. Ravat, J. Song, O. Teste, C. Trojahn, Efficient querying of multidimensional RDF data with aggregates: Comparing NoSQL, RDF and relational data stores, Int. J. Inf. Manag. 54 (2020) 102089, https://doi.org/10.1016/j.ijinfomgt.2020.102089.
[59] Y. Ma, S. Zheng, Z. Yang, P. Zheng, J. Leng, J. Hong, Aircraft assembly process planning based on knowledge graph constructed by integrating LLMs and SLMs, J. Manuf. Syst. 84 (2026) 1–19, https://doi.org/10.1016/j.jmsy.2025.11.016.
[60] W. Dou, D. Shen, X. Zhou, Y. Kou, T. Nie, H. Cui, G. Yu, Weakly-supervised entity matching via LLM-guided data augmentation and knowledge transfer, Knowl.-Based Syst. 335 (2026) 115238, https://doi.org/10.1016/j.knosys.2025.115238.
[61] N. Ding, Y. Chen, B. Xu, Y. Qin, Z. Zheng, S. Hu, Z. Liu, M. Sun, B. Zhou, Enhancing chat language models by scaling high-quality instructional conversations, (2023). https://doi.org/10.48550/arXiv.2305.14233.
[62] L. Prechelt, Early stopping — but when? in: G. Montavon, G.B. Orr, K.-.-R. Müller (Eds.), Neural Netw. Tricks Trade Springer, Berlin Heidelberg, Berlin, Heidelberg, 2012, pp. 53–67, https://doi.org/10.1007/978-3-642-35289-8_5.

해석 (p.16)

참고문헌

(참고문헌 목록: 해석 생략)

메모