DDKG 논문 해석

Huang, J., Hou, W., Zhang, S., Du, Z., & Yin, J. (2026). Dam defects ontology and knowledge graph construction from multi-source hazard data using large language models. *Advanced Engineering Informatics*, 76, 104987.
문단마다 회색 글씨는 원문 문단의 첫머리이고, 그 아래가 해석이다. 쪽 번호는 원문 PDF의 쪽이다.

원문 1쪽

제목·저자

대규모 언어모델을 이용한 다중 출처 위험(hazard) 데이터로부터의 댐 결함 온톨로지 및 지식그래프 구축

Jianfeng Huang, Wenang Hou(교신저자), Shichen Zhang, Zhenhan Du, Jiangshan Yin
난징수리과학연구원 댐안전관리부, 수리부 저수지·댐안전 중점실험실, 허하이대학교 토목·교통공학원, 쓰촨대학교 수자원·수력발전학원
키워드: 댐 공학 위험, 대규모 언어모델, 지식 추출, 미세조정, 지식그래프

초록 (Abstract)

During dam operation, large volumes of information on dam defects…
댐 운영 중에는 댐 결함에 관한 많은 양의 정보가 다양한 종이 기반 보고서에 기록된다. 이 정보는 효과적인 댐 안전관리에 필수적이지만, 흩어져 분포하고 비정형 텍스트 형태로 되어 있어 구조화되고 재사용 가능한 지식으로 바꾸기 어렵다. 따라서 이러한 자료에서 지식을 발굴하여 효과적으로 활용할 수 있는 지식그래프를 구축하는 것이 시급하다. 본 연구는 대규모 언어모델(LLM)을 활용하여 그러한 그래프를 구축하고 응용한 결과를 제시한다. 댐 개체의 속성, 공간적 분포, 기술 파라미터, 안전 위험을 체계적으로 모델링하기 위해 댐 결함 온톨로지(DDO)를 설계하였으며, 특히 공학적 위험 형태와 그 구성요소에 대한 세밀한 계층적 지식 모델링에 중점을 두었다. 댐 안전이라는 전문 분야에서 LLM의 '환각' 문제를 완화하기 위해, 도메인 적응형 온톨로지 기반 위험 분류 프레임워크(OHCF)를 개발하였다. OHCF는 미세조정, 온도 교란 투표, 온톨로지 제약 일관성 검사, 전문가 검증의 네 가지 핵심 모듈을 통합하여 댐 위험 개체 인식의 정확도를 높인다. 또한 OHCF는 준지도(semi-supervised) 메커니즘을 통해 DDO를 동적으로 확장한다. 실험 결과 OHCF의 모든 평가 지표가 90 %를 넘었다. 제안 방법을 바탕으로 본 연구는 중국의 결함·위험 댐 22,076개의 댐 안전평가 보고서를 분석하여 댐 결함 지식그래프(DDKG)를 구축하였다. 나아가 제안된 DDKG는 댐 위험 리스크 분석과 댐 안전관리를 위한 전문가 의사결정 지원에 폭넓은 응용 가능성을 보여준다.

1. 서론 (Introduction)

Reservoir and dam projects are globally important infrastructure…
저수지와 댐은 홍수 방어와 재해 저감, 용수 공급, 농업 관개, 수력 발전 등 여러 기능을 제공하는 세계적으로 중요한 기반시설이다. 이러한 시설의 안전은 사회 안정과 직결된다. 운영 연수가 늘어나면서 댐은 흔히 구조적 노후화와 기능 저하를 겪는다[1]. 여기에 현재 자연재해가 빈번히 발생하고 인간 활동이 강화되면서 댐의 안전 상황은 계속 심각해지고 있다. 전통적인 리스크 분석 방법은 대부분 개별 댐을 대상으로 하며 전문가 판단이나 수치 계산에 크게 의존한다[2–4]. 지역 규모에서 여러 댐에 걸친 리스크 요인 분석은 여전히 제한적이다. 데이터 기반 방법의 등장은 (→ 오른쪽 열로 이어짐) 리스크 평가에 새로운 관점을 도입하였다[5–7]. 고급 지식공학 기법을 사용하면 흩어진 방대한 위험 정보를 구조적으로 재조직하여 깊은 상관관계를 식별할 수 있다. 이는 리스크 추적과 과학적 의사결정을 위한 견고한 지식 기반을 제공한다.
※ 역자 주: 원문의 'project'(중국어 '工程'의 번역)는 사업 계획이 아니라 댐 시설 하나하나를 가리킨다. 그래서 '댐'으로 옮겼다(예: dam projects → 댐, project scale → 댐 규모).

At present, much of the critical key information related to dam defects…
현재 댐 결함과 관련된 핵심 정보의 상당 부분은 비정형 텍스트로 기록되어 있다[8]. 이러한 텍스트 데이터는 형식이 이질적이고 구조화가 잘 되어 있지 않아, 그 안에 담긴 지식을 상관 분석과 추론에 효과적으로 적용하기 어

렵다. 이로 인해 '데이터는 풍부하지만 지식은 빈약한' 딜레마가 생기며, 이는 댐 결함과 위험의 메커니즘에 대한 심층적이고 체계적인 지식 발견을 제약한다.

Knowledge graphs (KGs) [9] offer an efficient tool…

지식그래프(KG)[9]는 이러한 정보를 조직과 (→ 2쪽으로 이어짐) 분석을 위한 구조화된 지식으로 변환하는 효율적인 도구를 제공한다.

원문 2쪽

(1쪽에서 이어짐) analysis. They can reveal complex semantic relationships…

KG는 개체 간의 복잡한 의미 관계를 드러낼 수 있으며 위 문제에 대한 실현 가능한 해법을 제공한다. 대량의 공학 텍스트로부터 KG를 구축하는 일은 효과적인 지식 추출에 달려 있다. 이와 관련하여 딥러닝 기반 자연어처리는 상당한 진전을 이루었다[10]. 특히 최근 대규모 언어모델(LLM)의 발전은 방대한 텍스트 말뭉치로부터 대규모로 지식을 추출할 새로운 기회를 만들었다[11,12]. LLM은 문맥 이해와 추론에서 강력한 능력을 보이며, 자연어 지시를 따라 작업을 수행할 수 있다[13–16].

However, when applied to the specialized domain of dam engineering…

그러나 댐 공학이라는 전문 분야에 적용할 때 LLM은 도메인 적응성, 지식의 복잡성, 적용의 경제성과 관련된 복합적인 어려움에 직면한다[17]. 범용 모델은 댐 공학 전문 지식에 대한 깊은 이해가 부족하여 도메인 고유 용어를 정확히 대응시키고 복잡한 계층 관계를 해석하는 데 어려움을 겪으며, 그 결과 사실 오류가 자주 발생한다. 또한 대규모 모델을 데이터셋 처리에 적용하면 계산 비용이 높아, 실제 공학 응용에서 효율성과 확장성이 제한된다.

To address these challenges, this study develops a dam defects ontology (DDO)…

이러한 과제를 해결하기 위해 본 연구는 댐 위험 지식에 대한 구조화된 표현 틀을 제공하는 댐 결함 온톨로지(DDO)를 개발한다. 나아가 LLM을 활용하여 비정형 위험 서술의 분류를 표준화하는 온톨로지 기반 위험 분류 프레임워크(OHCF)를 제안한다. 이 과정을 바탕으로 댐 결함 지식그래프(DDKG)를 구축하여 여러 댐에 걸친 위험 정보를 구조적으로 통합하고, 이를 통해 댐 안전관리를 지원한다.

The remainder of this paper is organized as follows…

이 논문의 나머지 구성은 다음과 같다. 2장은 관련 연구를 검토한다. 3장은 제안 방법론을 자세히 설명한다. 4장은 모델 성능을 평가하고 KG를 이용한 사례 연구를 제시한다. 5장은 연구를 결론짓고 향후 연구 방향을 제시한다.

2. 관련 연구 / 2.1 수리공학 분야의 지식 표현

With the deepening application of digital twin technology…

수리 분야에서 디지털 트윈 기술의 적용이 심화되면서, 공학 전 생애주기에 걸친 방대한 정보를 효율적으로 조직하고 활용하는 일이 산업의 지능화를 위한 핵심 과제가 되었다. 그 결과 많은 연구가 관련 데이터와 요구사항을 구조화된 방식으로 표현하기 위한 전문 온톨로지 개발에 집중해 왔다.

As an explicit and formal specification of a shared conceptualization [18]…

공유된 개념화에 대한 명시적이고 형식적인 명세로서[18], 온톨로지는 시맨틱 웹 기반 구조의 근본적인 기둥이며 지식그래프 구축에서 결정적인 역할을 한다[19]. 공학 분야에서 온톨로지는 전문 지식을 모델링하고 도메인 데이터에 견고한 조직 틀을 제공하기 위해 도입된다. 온톨로지 구축의 본질적인 복잡성 때문에, 기존 도메인 온톨로지를 평가하고 재사용하는 일은 새로운 프로젝트를 시작하는 연구자에게 중요한 사전 단계가 되었다.

To date, various ontologies tailored for hydraulic engineering safety…

지금까지 수리공학 안전을 위한 다양한 온톨로지가 개발되었다. Zhang 등[20]은 공학 위험의 원인과 대응책을 중심으로 수리공학 안전관리 지식 온톨로지를 구축하여 리스크 관리의 의사결정을 강화하는 구조화된 지식 모델을 제공하였다. Gan 등[21]은 지하 구조물의 회복력 강화를 위한 다층의 온톨로지 기반 KG 프레임워크를 개

발하였으며, 회복력 정량화와 재해 연쇄 분석을 통합하여 주관적 경험과 지능형 의사결정 사이의 간극을 메웠다. Liu 등[22]은 남수북조 중선 사업의 리스크 예방 매뉴얼과 설계안 같은 비정형 데이터를 활용하여 비상계획 온톨로지를 개발하였고, 이는 비상 전략의 지능적 생성과 재사용을 핵심적으로 지원한다. Zhou 등[23]은 '구조-공정-환경-재료'의 네 차원에 초점을 맞추어 BIM(건물정보모델링)과 도메인 온톨로지를 연결함으로써 이질적인 모니터링 데이터의 단편화를 해결하는 통합 지식관리 프레임워크를 제안하였고, 댐 안전 시스템에서 효율적인 지식 추출과 의미 통합을 가능하게 하였다. 또한 Baudrit 등[24]은 개념 그래프 형식론을 이용하여 이질적이고 학제적인 지식 흐름을 통합하는 댐 시스템의 총체적 그래프 기반 지식 모델을 개발하여, 경험의 활용, 구조 상태 예측, 법공학적 토목공학 지원을 위한 편리한 틀을 제공하였다.

While the aforementioned studies all aim to enhance the operation…

앞서 언급한 연구들은 모두 수리공학의 운영과 유지관리를 향상시키는 것을 목표로 하지만, 표현의 세밀도와 주제 초점에서 상당히 다르다. 일반적으로 기존 연구는 결함의 구체적인 양상과 관련 영향 요인 사이의 복잡한 관계를 특성화하는 데 여전히 부족하다. 이러한 한계는 현재 모델이 댐 안전 분야에서 세밀한 분석과 고급 추론을 지원하는 능력을 저해한다.

2.2 지식그래프의 구축

In 2012, Google introduced the concept of the KGs [25]…

2012년 Google이 KG 개념을 도입한 이후[25], KG는 다양한 분야에서 폭넓게 연구·적용되어 왔다[26–29]. KG는 '개체-관계-개체' 삼항으로 현실 세계의 지식을 묘사하는 구조화된 의미 네트워크이다. 온톨로지가 지식의 스키마 계층을 정의하는 개념적 틀이라면, KG는 이 틀 안에서 현실 세계 데이터로 인스턴스화된 지식 베이스를 나타낸다.

A key step in constructing the KG data layer is the extraction of domain entities…

KG 데이터 계층을 구축하는 핵심 단계는 비정형 텍스트에서 도메인 개체를 추출하는 것이며, 이는 흔히 자연어 처리(NLP)의 개체명 인식(NER) 과제로 정식화된다. NER은 텍스트에서 개체 언급을 식별하고 미리 정의된 개체 유형 라벨을 부여하는 것을 목표로 한다. 초기 NER 방법은 대개 복잡한 수작업 규칙에 의존했다[30–32]. 딥러닝이 부상하면서 NER 시스템은 텍스트 특징 표현을 자동으로 학습하여 성능을 크게 향상시켰다. 처음에는 순환신경망[33,34]과 합성곱신경망[35–37]이 문맥 정보를 부호화하는 데 쓰였다. 이후 자기주의(self-attention) 메커니즘에 기반한 Transformer[38] 구조가 BERT[39]와 같은 사전학습 언어모델(PLM)의 개발로 이어졌다. 라벨이 붙은 데이터셋으로 지도 미세조정을 하여, PLM 기반 방법은 다양한 NER 과제에서 강한 성능을 보였다[40–42]. 그러나 이러한 방법은 대개 상당한 양의 고품질 주석 데이터와 잘 정의된 라벨 체계에 의존한다[43]. 이 라벨 체계가 제한된 전문가 지식에 묶여 있으면, 결과 모델은 표현이 약하거나, 정의가 모호하거나, 미리 정의된 스키마에 없는 도메인 개념으로 일반화하는 데 어려움을 겪을 수 있다.

Recently, the application of LLMs in NER has gained widespread attention [44]…

최근 NER에서 LLM의 적용이 폭넓은 주목을 받고 있다[44]. 방대하고 다양한 비라벨 데이터로 깊은 사전학습을 거친 LLM은 강력한 일반화 능력과 폭넓은 언어 지식을 갖추고 있다. NER 같은 하위 과제에서 LLM은 자연어 지시만으로도 우수한 성능을 낼 수 있다. 많은 연구가 KG 구축을 보조하는 데 LLM을 활용하였다[45–49]. 주류 방법론은 대개 정교하게 설계된 구조화 프롬프트에 의존하며, 소수 예시(few-shot)를 대상 텍스트와 결합하여 모델이 개체, 속성, 관계를 추출하는 표준화된 출력을 생성하도록 유도한다. 또한 LLM이 온톨로지 모델의 구축과 확장을 효과적으로 보조할 수 있다는 연구도 있다[50,51]. 그럼에도 수리공학 같은 전문 분야에 LLM을 직접 적용하는 것은 여전히 어렵다. 이는 주로 학습 데이터와 도메인 고유 맥락 사이의 분포 차이 때문이며, 그 결과 전문 용어와 도메인 지식의 숙달이 불충분해진다[52]. 특정 분야에서 모델의 유용성을 높이기 위해 최근 연구는 (→ 3쪽으로 이어짐) 매개변수 효율적 미세조정(PEFT)…

원문 3쪽

(2쪽에서 이어짐) Fine-Tuning [53] and Chain-of-Thought [54]…

…[53]과 사고의 연쇄(Chain-of-Thought)[54] 같은 전략을 도입하여, 모델 출력의 구조적 규칙성과 복잡한 의미를 포착하는 능력을 효과적으로 향상시켰다. 요컨대, LLM은 NER에 새로운 가능성을 제공하지만, 고유의 환각 문제로 개체 라벨이 잘못되거나 임의로 부여될 수 있으며, 이는 추출 결과의 신뢰성을 떨어뜨리고 지식의 구조적 조직과 통합을 방해한다.

2.3 지식 공백 (Knowledge gap)

The above studies show growing interest in building hydraulic engineering knowledge systems…

위 연구들은 지능형 안전관리를 지원하기 위한 수리공학 지식 시스템 구축과, 도메인 지식 처리에 대규모 언어모델을 사용하는 것에 대한 관심이 커지고 있음을 보여준다. 그러나 몇 가지 연구 공백이 남아 있다. 첫째, 수리공학 분야의 기존 연구가 온톨로지 구축의 견고한 기반을 마련했지만, 댐 결함, 특히 위험 형태와 영향받는 구성요소를 모델링하는 세밀한 표현에는 여전히 부족하다. 둘째, BERT 같은 PLM에 기반한 기존 지식 추출 방법은 댐 공학 텍스트에 대해 충분히 유연하지 않다. 이러한 텍스트의 위험 서술은 흔히 단편적이고, 중첩되며, 다양한 방식으로 표현되어 지식 추출의 어려움을 키운다. 이 방법들은 라벨 수가 적은 분류 과제에서는 좋은 성능을 보였지만, 라벨 집합이 크고 클래스 관계가 복잡한 과제에 적용할 때는 대개 훨씬 더 많은 주석 데이터가 필요하다. 또한 이 모델들은 전문가 지식에서 나온 미리 정의된 범주에 묶여 있어, 이전에 정의되지 않은 개념을 식별하기 어렵다. 셋째, 대규모 언어모델은 NER 과제에서 강한 잠재력을 보였지만, 댐 안전 시나리오에 직접 적용하는 것은 도메인 지식 부족으로 여전히 제한되며, 이는 흔히 심각한 환각 문제로 이어진다. 이러한 공백을 해결하기 위해, 본 연구는 세밀한 댐 결함 온톨로지를 개발하고, 댐 결함 지식그래프 구축을 위한 온톨로지 기반 위험 지식 인식과 온톨로지 확장을 지원하는 OHCF를 제안한다.

3. 방법론 (Methodology)

This section describes the implementation of ontology construction…

이 장은 온톨로지 구축, 데이터 계층 개발, KG 저장의 구현을 설명한다. 그림 1은 DDKG의 전체 구축 틀을 보여주며, 이는 DDO 구축, 지식 추출, 지식 융합의 세 가지 주요 구성요소로 이루어진다.

3.1 DDO 구축

An ontology is a standardized representation of concepts, entities, attributes…

온톨로지는 특정 도메인 안의 개념, 개체, 속성, 그리고 그들 사이의 의미 관계를 표준화하여 표현한 것이다. KG 구축에서 온톨로지 계층은 핵심 구조적 뼈대 역할을 한다. 그 설계의 명확성과 완전성이 KG의 지식 포괄 범위와 표현 정확도를 직접 결정한다[55]. 댐 공학에서 결함에 대한 구조화·표준화된 온톨로지를 개발하는 것은 위험 용어를 통일하고, 복잡한 원인 메커니즘의 상관 분석을 가능하게 하며, 지능형 진단과 의사결정 같은 하위 응용을 지원하는 데 필수적이다.

In this study, a seven-step methodology is adopted to construct the DDO…

본 연구는 DDO를 구축하기 위해 7단계 방법론을 채택한다. 그 과정은 다음 단계로 이루어진다. (1) 댐 위험 도메인 온톨로지와 그 온톨로지가 쓰일 관련 작업(tasks) 정의, (2) 댐 위험과 관련된 기존 온톨로지 모델의 재사용 검토, (3) 관련 용어 나열, (4) 온톨로지 클래스와 계층 구조 정의, (5) 클래스 속성과 관계 정의, (6) 제약 명시, (7) 인스턴스 생성.
※ 역자 주: 원문 'related tasks'는 용역의 '과업'이 아니라 온톨로지를 어디에 쓸지(활용 목적·작업)를 뜻한다. Noy & McGuinness의 1단계 '도메인과 범위 결정'에 해당한다.

The DDO is constructed using the Web Ontology Language (OWL)…

DDO는 웹 온톨로지 언어(OWL)로 구축되며 Protégé 도구로 저장·관리된다. OWL은 어휘를 정의하고 자원을 기술하기 위해 W3C(월드와이드웹 컨소시엄)가 권고하는 온톨로지 언어이다. 클래스, 속성, 값을 명시함으로써 OWL은 사용자가 (→ 4쪽으로 이어짐) 도메인 고유의 클래스와 속성을 기술하는 표준화된 방법을 제공한다.

그림 1. DDKG의 구축 틀

원문 4쪽

(3쪽에서 이어짐) describe domain-specific classes and attributes. The structure of the DDO…

…도메인 고유의 클래스와 속성을 기술하는 표준화된 방법을 제공한다. DDO의 구조는 식 (1)의 삼항 형식으로 나타낼 수 있다.

DDO = 〈C, P, H〉 (1)

여기서 C = {ci | i∈N*}는 최상위 클래스의 집합이고 ci는 i번째 최상위 클래스이다. P = {pij | i,j∈N*, i≠j}는 객체 속성(object property)의 집합이며, pij는 방향이 있는 관계 ci→cj를 나타낸다. H = {Si | ci∈C*}는 각 최상위 클래스 아래 모든 하위 클래스의 집합이며, Si = {ci(j1,j2,…,jk) | i,k,jk∈N*}는 최상위 클래스 ci 아래의 하위 클래스 집합을 나타내고, ci(j1,j2,…,jk)는 경로 색인 순서열을 뜻한다(예: c3(2,1)은 최상위 클래스 c3의 두 번째 하위 클래스의 첫 번째 자식을 나타낸다).

Dam defects arise from the coupled effects of intrinsic engineering factors…

댐 결함은 공학 내부 요인과 환경 조건의 결합 효과로 발생한다. 따라서 DDO에는 처음에 7개의 최상위 클래스를 정의하였으며, 이는 표 1에 요약되어 있다.

To further enhance the semantic expressiveness and structural rigor of the DDO…

DDO의 의미 표현력과 구조적 엄밀성을 더 높이기 위해 의미 관계와 계층 관계를 모두 구성한다. 의미 관계는 주로 서로 다른 최상위 개체 클래스를 연결하는 객체 속성을 정의하여 구성한다. 표 2는 온톨로지 구조에 정의된 객체 속성을 보여준다. 모든 최상위 클래스는 관련 정보를 구체적인 공학 인스턴스에 고정(anchor)하기 위해 Dam 개체에 연결된다. 구체적으로 HazardForm은 'occursAt'을 통해 HazardComponent와 연결된다. 계층 관계는 'hasSubclass'를 사용하여 각 최상위 클래스 내부의 계층 구조를 형성하며, 지식 표현의 깊이와 세밀도를 높이는 것을 목표로 한다. 예를 들어 Parameter 클래스 아래에는 '댐 높이', '저수 용량' 같은 하위 클래스가 정의된다. 계층 관계를 통해 하위 클래스는 상위 클래스의 객체 속성을 상속할 수 있다. 이는 모델의 재사용성, 확장성, 추론 능력을 효과적으로 향상시킨다. 그림 2는 Protégé에서의 DDO 모델링을 보여준다.

Among the top-level classes, “c5 HazardForm” and “c6 HazardComponent”…

최상위 클래스 중 'c5 HazardForm(위험 형태)'과 'c6 HazardComponent(위험 부위)'는 공학 위험과 직접 관련되며 DDKG의 가장 핵심적인 요소이다. 이 개체들은 비정형 텍스트에서 추출해야 하므로 상당한 어려움이 따른다. 예를 들어 LLM은 '여수로(spillway)'와 '측벽(Side wall)' 같은 개체를 인식할 수는 있지만, 그 사이의 내재적인 '전체-부분' 논리를 올바르게 해석하지 못하는 경우가 많다. LLM은 종속 관계에 있는 개체를 같은 계층으로 잘못 분류하여, '측벽'이 '여수로'의 구성 하위 단위라는 사실을 간과할 수 있다. 이러한 해석 오류는 DDKG 지식 구조의 무결성을 직접 훼손할 수 있다.

To overcome these limitations in semantic understanding…

이러한 의미 이해의 한계를 극복하기 위해, 본 연구는 전문가 지식을 바탕으로 최상위 클래스 c5와 c6의 계층 구성을 정교화한다. 자세한 구성은 다음과 같다.

(a) Hierarchical structure of HazardForm. To ensure scientific rigor…

(a) HazardForm의 계층 구조. 계층 구조의 과학적 엄밀성과 타당성을 확보하려면 일반적으로 산업 기술 표준이나 국가·지역 행정 규정을 참조해야 한다. 예를 들어 중국에서는 「댐 안전평가 지침(SL 258–2017)」이 댐의 안전을 홍수 방어, 침투, 구조 안정성, 내진 성능, 금속 구조의 다섯 가지 전문 지표 범주로 평가하도록 규정한다. 이 지표들은 댐 안전평가의 표준화된 기준을 제공한다. 그 결과, 이 다섯 범주에 해당하는 위험 문제를 HazardForm의 1단계 하위 클래스로 정의한다. 각 1단계 하위 클래스 아래에는 공학 위험의 세부 양상을 담기 위해 2단계와 3단계 하위 클래스를 추가로 정의한다. 표 3은 HazardForm 클래스의 계층 구조를 보여준다.

(b) Hierarchical structure of Hazard Component…

(b) HazardComponent의 계층 구조. HazardComponent 클래스는 공학 위험이 발생한 구체적인 구조적 위치를 특정하는 데 쓰인다. 댐 공학 구조물은 기능에 따라 크게 차수(물막이) 구조물, 방류 구조물, 도수 구조물로 나눌 수 있다. 차수 구조물에는 댐 본체, 기초, 댐 접합부(abutment)가 포함된다. 방류 구조물에는 여수로, 홍수 방류

터널, 바닥 배수구(저층 방류구)가 포함된다. 도수 구조물은 취수 구조물, 도수 관로, 제어 구조물로 이루어진다. 표 4는 HazardComponent 클래스의 계층 구조를 자세히 나열하며, 세 가지 구조물 유형이 1단계 하위 클래스가 된다.

In practical applications, hierarchical modeling of complex engineering entities…

실제 응용에서, 댐 같은 복잡한 공학 개체의 계층 모델링을 전문가 경험만으로 하는 것은 지식의 경계에 의해 불가피하게 제약된다. 그 결과 온톨로지의 포괄 범위가 제한될 수 있다. 이를 해결하기 위해, 3.2.3절에서 설명하는 것처럼 지식 추출 과정에서 식별된 미정의 개체를 바탕으로 온톨로지를 개념적으로 보완하거나 계층적으로 확장한다.

3.2 데이터 계층 구축

The data layer is designed to extract knowledge from multi-source heterogeneous data…

데이터 계층은 DDO를 바탕으로, 저수지 댐 공학 시스템의 장기 운영 중에 생성된 다중 출처의 이질적 데이터로부터 지식을 추출하도록 설계된다. 이 절은 DDKG 데이터 계층의 구축을 제시하고 OHCF를 자세히 설명한다. 데이터 계층 구축의 전체 틀은 그림 3에 나타나 있다.

3.2.1 지식 출처와 전처리

The China Reservoir Operation and Management Platform stores…

중국 저수지 운영관리 플랫폼은 많은 양의 기본 공학 데이터를 정형 표 형태로 저장하며, 이는 DDO의 최상위 클래스 c1–c4의 데이터 요구를 대부분 충족한다.

In contrast, the data corresponding to top-level classes c5–c7…

반면 최상위 클래스 c5–c7에 해당하는 데이터는 비정형 텍스트에서 나온다. 이 텍스트들은 PDF, DOC, PNG 파일 등 형식이 매우 이질적이며, 원본 문서에는 중복되거나 관련 없는 정보가 많이 들어 있다. 지식 추출에 앞서 잡음을 제거하고 데이터를 정규화하기 위해 텍스트를 전처리한다.

For a given unstructured text D, its format is first converted…

주어진 비정형 텍스트 D에 대해, 먼저 그 형식을 구조화된 마크다운 표현 Dmd로 변환한다. 이때 최신 광학 문자 인식(OCR) 모델[56]을 적용하여 레이아웃 분석과 형식 변환을 수행한다. 다음으로 정규식을 사용하여 관련 지식 개체를 포함하는 텍스트 블록 Dmd,i의 경계를 구분하고 중복 내용을 제거한다. 마지막으로 추출된 텍스트 블록을 하나의 말뭉치 T로 통합한다.

$$T = \{D_{md,1}, D_{md,2}, \cdots, D_{md,n}\} \quad (2)$$

표 1. DDO의 최상위 개체 클래스

c1 Dam(댐), c2 Properties(특성), c3 Location(위치), c4 Parameter(매개변수), c5 HazardForm(위험 형태), c6 HazardComponent(위험 부위), c7 SafetyEvaluation(안전평가)

표 2. DDO의 객체 속성 정의 (속성: 정의역 → 치역)

p12 hasProperties: c1 → c2

p13 isLocatedIn: c1 → c3

p14 hasParameter: c1 → c4

p15 exhibitsHazard: c1 → c5

p16 hasHazardAt: c1 → c6

p17 hasEvaluation: c1 → c7

p56 occursAt: c5 → c6

그림 2. Protégé에서의 DDO

원문 6쪽

3.2.2 규칙 기반 지식 추출

Entities associated with the top-level class c7 represent safety evaluation results…

최상위 클래스 c7과 연관된 개체는 댐 안전 보고서의 안전평가 결과를 나타내며, 홍수 방어, 침투, 구조, 내진, 금속 구조 안전평가를 포함한다. 각 평가는 A, B, C 등급으로 분류되며, 각각 결함 없음, 경미한 결함, 심각한 결함에 해당한다. 이 결과들은 일반적으로 고도로 표준화된 형태로 서술되므로 정규식으로 바로 추출할 수 있다. 예를 들어 '홍수 방어 안전 등급은 C등급이다'라는 표현에서, 딥러닝 기반 인식 없이도 홍수 방어 안전평가 결과를 'C'로 정확히 추출할 수 있다.

3.2.3 LLM 기반 지식 추출

In contrast, the extraction of engineering hazard entities is more challenging…

반면 공학 위험 개체의 추출은 더 어려우며, 핵심 난점은 복잡하고 다양한 형태로 표현된 위험 정보를 DDO의 미리 정의된 범주 체계에 어떻게 정확히 배정하느냐에 있다.

General-purpose language models achieve relatively low accuracy…

범용 언어모델은 이처럼 고도로 전문적인 과제에서 비교적 낮은 정확도를 보이며, 이는 4.2.3절의 실험 결과로도 뒷받침된다. 범용 LLM은 세밀한 분류에서는 성능이 제한적이지만, 명시적인 지시 제약 아래에서는 공학 보고서로부터 위험 관련 서술 조각을 효율적으로 추출할 수 있다. 즉 텍스트의 어느 부분이 위험 (→ 7쪽으로 이어짐) 서술에 해당하는지를 효과적으로 판단할 수 있다.

표 3. 'c5 HazardForm(위험 형태)'의 하위 클래스 (1단계 / 2단계 / 3단계)

c5(1) 홍수 방어 위험
· (1,1) 홍수 방어 기준 위험: 설계 기준 초과 홍수, 설계 홍수 기준 부족, 설계 홍수 산정이 요구 미충족, 최근 이상홍수 운영 기준 미충족
· (1,2) 차수 구조물 여유고 부족: 차수 표고 부족, 차수 구조물 폐합 불완전
· (1,3) 방류 능력 위험: 홍수 방어 시설 누락, 방류 능력 부족
c5(2) 침투 위험
· (2,1) 침투 방지 체계 결함: 차수체 불완전·기능 상실, 그라우팅 부적절, 필터·배수 시설 이상, 접촉부 침투 방지 결함
· (2,2) 누수·이상 침투 현상: 과다 침투량, 접촉 침투, 우회 침투, 확산 침투, 탁한 침투수
· (2,3) 침투 안정 문제: 침투 안정성 부족, 파이핑, 토사 유출
· (2,4) 침투 계측 지표 이상: 침투량 이상 변화, 침윤선 이상, 양압력 이상
c5(3) 구조 위험
· (3,1) 구조 설계 결함: 폭 부족, 표고 부족, 보호 부재 누락
· (3,2) 이상 변형·변위: 과다 침하, 이상 변위, 변형이 요구 미충족
· (3,3) 구조 하중 지지·안정 결함: 구조 강도 부족, 안정성 부족
c5(4) 내진 위험
· (4,1) 내진 설계·방호 결함: 내진 설계 강도 부족, 내진 범주 오류, 설계 지진 파라미터 오류
· (4,2) 내진 하중 지지·안정 결함: 내진 강도 부족, 내진 안정성 부족, 내진 조치 부적절, 구조 액상화 가능성
c5(5) 금속 구조 위험
· (5,1) 배치·형식 선정 결함: 배치 불합리, 형식 선정 불합리, 권양기 양정 부족, 권양기 경간 부족
· (5,2) 내용연수·내구성 결함: 감가·폐기 내용연수 초과, 표면 부식·녹, 수밀 기능 상실
· (5,3) 금속 구조 성능 결함: 금속 구조 강도 부족, 안정성 부족

· (5,4) 운전 기능 이상: 권양력 부족, 개폐 동작 걸림·고장, 안전 보호 장치 이상, 잠금·압력 평형 장치 이상
· (5,5) 보조·지원 계통 이상: 전원 공급 이상, 제어 계통 이상

표 4. 'c6 HazardComponent(위험 부위)'의 하위 클래스

c6(1) 차수 구조물
· (1,1) 주 댐 구조물: 댐 마루, 댐 접합부, 기초, 댐 선단(toe), 댐 본체, 댐 사면·표면, 파랑벽(wave wall), 홍수 방어 계통
· (1,2) 차수체: 댐 차수체, 기초 차수체
· (1,3) 배수 계통: 댐 본체 배수, 기초 배수, 접합부 배수
c6(2) 방류 구조물
· (2,1) 여수로: 유입·조절부, 급경사 수로, 측벽, 감세 구조물, 여수로 금속 구조물
· (2,2) 홍수 방류 터널: (원문에서 여수로와 같은 항목 반복)
· (2,4) 기타 방류 구조물: 바닥 배수구, 비상 여수로, 배수관, 기타 방류 금속 구조물
c6(3) 도수 구조물
· (3,1) 취수 구조물: 취수탑, 경사 취수관, 취수 시설 금속 구조물
· (3,3) 도수 관로: 도수 암거, 도수 터널, 도수 관로 금속 구조물
※ 역자 주: (원문 표의 번호 표기 일부가 어긋나 있음: (2,2)·(2,4)·(3,3) 등)

원문 7쪽

(6쪽에서 이어짐) descriptions. Accordingly, given an input report text T…

따라서 입력 보고서 텍스트 T가 주어지면, 먼저 추출 프롬프트 P1을 사용하여 위험 관련 서술 조각을 식별한다. 그러나 이 단계에서 얻은 결과는 대개 여전히 원문에서 직접 추출한 서술 조각이며, 중첩된 표현을 포함하는 경우가 많다. 즉 한 문장이 여러 위험 형태와 위험 부위의 조합을 동시에 포함할 수 있다. 이는 이후의 위험 분류에 장애가 된다. 이 문제를 해결하기 위해 본 연구는 그림 4와 같이 복잡한 위험 표현을 의미가 더 명확하고 구조가 더 단일한 위험 서술 단위로 분해하는 서술 분할 프롬프트 P2를 추가로 설계한다. 위의 두 단계 과정은 식 (3)으로 정식화할 수 있다.

$$T \xrightarrow{(P1)} H = \{h1, h2, \cdots, hm\} \xrightarrow{(P2)} E = \{e1, e2, \cdots, en\} \quad (3)$$

여기서 hi는 원문에서 추출한 위험 관련 서술 조각이고, ei는 서술 분할 후 얻은 위험 서술 단위이다. 인스턴스 수준의 관찰에 따르면, 범용 LLM은 과제 특화 학습 없이 프롬프트만으로 두 과제를 비교적 안정적으로 수행할 수 있다.

On this basis, OHCF is designed to classify each hazard description unit…

이를 바탕으로 OHCF는 각 위험 서술 단위를 DDO에 정의된 클래스 c5와 c6의 3단계 라벨로 분류하도록 설계된다. OHCF는 네 단계로 구성된다.

a) LLM fine-tuning. To improve the model's ability…

a) LLM 미세조정. 제한된 계산 자원에서 세밀한 분류를 수행하는 모델의 능력을 높이기 위해, 저랭크 적응(LoRA)을 (→ 8쪽으로 이어짐) 채택하여 경량 LLM을 미세조정한다.

그림 3. 데이터 계층 구축의 틀 / 그림 4. 프롬프트를 이용한 중첩 위험 서술 분할 예시

원문 8쪽

(7쪽에서 이어짐) adopted to fine-tune a lightweight LLM…

…경량 LLM을 미세조정하여, 위험 서술 단위와 온톨로지에 정의된 라벨 사이의 의미적 대응을 학습하게 한다.

LoRA is an efficient parameter-adaptation method for fine-tuning large models [57]…

LoRA는 대형 모델을 미세조정하기 위한 효율적인 파라미터 적응 방법이다[57]. 하위 과제의 성능을 높이기 위해 소수의 파라미터만 갱신하면 된다. LoRA의 핵심 원리는 모델의 원래 가중치 행렬 W0∈R^(m×n)을 고정하고 증분 행렬 ΔW의 파라미터만 갱신하는 것이다. 증분 갱신은 식 (4)로 표현할 수 있으며, 여기서 ΔW는 두 개의 더 작은 행렬 A와 B로 분해된다. 미세조정된 모델의 출력 h는 같은 입력 벡터 x에 원래 가중치 행렬 W0과 증분 행렬 ΔW를 각각 곱한 값을 더하여 얻으며, 식 (5)와 같다.

W0 + ΔW = W0 + BA, A∈R^(r×n), B∈R^(m×r) (4)

h = W0x + ΔWx = W0x + BAx (5)

미세조정 후 모델의 기능은 임의의 후보 개체에 대해 해당하는 표준화된 개체 라벨을 생성하는 함수 fθ*로 형식적으로 기술할 수 있다.

fθ*: ei → (sf, sc), sf = c5(j1,j2,j3), sc = c6(k1,k2,k3) (6)

b) Temperature-perturbed voting strategy for hazard classification…

b) 위험 분류를 위한 온도 교란 투표 전략. 생성 모델에서 한 번의 추론 결과가 반드시 전역 최적 해는 아니다. 오분류 확률을 더 줄이기 위해 투표 메커니즘을 도입한다. 구체적으로, 주어진 위험 서술 개체 ei에 대해 서로 다른 n개의 모델 온도 T = {τ1, τ2, …, τn}을 사용하여 n번의 추론을 독립적으로 수행한다. 그런 다음 각 후보 라벨이 이 실행들에서 나타난 빈도를 득표수로 센다. 다수결 원칙에 따라 가장 많은 표를 받은 후보 라벨을 최종적이며 가장 신뢰할 수 있는 분류 결과 L*i로 선택하며, 식 (7)–(9)로 정의된다.

L*i = (s*f, s*c) (7)

s*f = argmax_{sf∈S5} Σ_{k=1}^{n} I(sf,k = sf) (8)

s*c = argmax_{sc∈S6} Σ_{k=1}^{n} I(sc,k = sc) (9)

여기서 sf,k와 sc,k는 ei의 k번째 독립 추론에서 얻은 c5 클래스와 c6 클래스이고, s*f와 s*c는 k개의 추론 결과 중 점수가 가장 높은 결과, 즉 최적 해이다. 모델이 분류 라벨을 내지 못하거나 투표 결과가 동점인 샘플에는 시스템이 일괄적으로 'False' 식별자를 부여하고 추가 처리를 위해 d단계로 넘긴다.

c) Ontology-constraint consistency checking…

c) 온톨로지 제약 일관성 검사. 온도 교란 투표 전략이 위험 분류의 안정성을 높이기는 하지만, 모델은 여전히 명백히 일관되지 않은 라벨 쌍을 생성할 수 있다. 예를 들어 '기존 파랑벽 마루 표고가 부족하다'라는 위험 서술이 투표 후 라벨 쌍 (s*f: c5(1,2,1) 차수 표고 부족, s*c: c6(1,2,1) 댐 차수체)으로 분류된다면, 그 결과 쌍은 공학 지식과 명백히 맞지 않는다.

To further improve the reliability of classification results…

분류 결과의 신뢰성을 더 높이기 위해, 본 연구는 온톨로지 제약 일관성 검사 모듈을 도입한다. 데카르트 곱의 희소한 부분집합으로 정의되는 제약 충돌 집합 A를 도입하여, DDO 계층과 공학 지식에 따라 명백히 양립할 수 없는 c5와 c6 라벨 쌍을 기록하며, 이는 식 (10)과 같다.

A ⊆ Sf × Sc (10)

이 제약 충돌 집합을 바탕으로 분류 일관성 검사 함수 V를 정의한다. V는 b단계의 최종 분류 결과 L*i = (s*f, s*c)를 입력으로 받아, 그 분류 결과가 미리 정의된 온톨로지 제약을 위반하는지 판단하고 불리언 값을 출력한다.

V(L*i) = V(s*f, s*c) = False (s*f, s*c)∈A인 경우 / True (s*f, s*c)가 A에 속하지 않는 경우 (11)

V(L*i) = True인 개체 샘플은 수용되고, V(L*i) = False인 샘플은 추가 처리를 위해 d단계로 넘겨진다.

d) Expert review and ontology expansion…

d) 전문가 검토와 온톨로지 확장. 'False'로 표시된 샘플은 시스템이 자동으로 모아 전문가 검토 대기열에 제출하며, 도메인 전문가의 수동 평가를 기다린다.

During the review process, experts first determine whether the concept…

검토 과정에서 전문가는 먼저 해당 샘플에 대응하는 개념이 DDO에 이미 있는지 판단한다. 개념이 이미 있으면, 전문가는 위험 서술 단위를 올바른 기존 온톨로지 노드에 연결하여 분류 라벨을 수정한다. 전문가가 새로운 개념이라고 확인하면, DDO에 해당 노드를 추가하고 위험 서술 개체를 새로 만든 노드에 연결한다. 이 준자동 작업

흐름에서 시스템은 모호한 샘플을 자동으로 걸러내고, 전문가는 최종 라벨 수정과 온톨로지 진화를 수행한다. 이런 방식으로 DDO는 동적 갱신과 반복적 확장을 이룬다.

3.3 KG 저장

In this paper, the Neo4j graph database is selected as the underlying storage platform…

본 논문은 DDKG의 기반 저장 플랫폼으로 Neo4j 그래프 데이터베이스를 선택한다. Cypher 질의 언어를 활용하여 Neo4j는 효율적인 지식 질의, 추가, 삭제, 수정을 가능하게 한다. 또한 깊은 연관 질의와 다중 홉(multi-hop) 추론 실행에서 우수한 성능을 보여[58], 이후의 지식 검색과 상호작용을 견고하게 지원한다.

The knowledge extracted in Section 3.2 is integrated into JSON format…

3.2절에서 추출한 지식은 JSON 형식으로 통합된다. DDO 안의 의미 관계와 계층 관계를 바탕으로, JSON의 키-값 쌍을 파싱하여 해당하는 Cypher 문을 생성하는 Python 스크립트를 개발하였다. 이 과정은 DDKG 노드의 일괄 생성과 개체 간 관계 구성을 용이하게 하여, 댐 위험 지식을 Neo4j 데이터베이스에 주입하는 일을 완료한다.

4. 사례 연구 (Case study)

This section begins by outlining the data sources for the case study…

이 장은 먼저 사례 연구의 데이터 출처를 개괄한다. 이어서 OHCF의 핵심 구성요소의 효과를 체계적으로 검증하기 위해 제거 실험(ablation)을 수행한다. 마지막으로 DDKG를 구축하고 댐 결함 분석에서의 응용을 시연한다.

4.1 데이터 출처

In China, dam projects are categorized into Class I, II, and III…

중국에서 댐은 안전 상태에 따라 1류, 2류, 3류로 분류된다. 상당한 안전 위험이 있는 것이 특징인 3류 댐은 안전 감정 보고서를 제공하며, 이는 위험 정보의 귀중한 데이터 출처가 된다. DDKG의 지식은 두 가지 주요 데이터셋에서 나온다. (1) 중국 저수지 운영관리 플랫폼에서 수집한 기본 공학 속성, 수문 기록, 지리공간 데이터, (2) 2000년부터 2025년까지 기록된 중국 전역 22,076개 위험 댐의 안전 감정 보고서.

The safety assessment reports of dams in China have a unified standardized structure…

중국의 댐 안전평가 보고서는 통일된 표준 구조를 가진다. 최상위 클래스 c5–c7과 관련된 개체는 보고서의 다음 네 부분에 들어 있다. 현장 점검(공학 외관 점검, 지질 조사, (→ 9쪽으로 이어짐)…

원문 9쪽

(8쪽에서 이어짐) etc.), dam safety analysis and evaluation…

…등), 댐 안전 분석·평가(댐의 홍수 방어, 침투, 구조 등 측면의 세부 항목 분석), 주요 문제 요약, 안전평가 결론. 3.2.1절의 전처리 방법을 사용하여, 각 댐 안전평가 보고서에서 이 네 개의 주요 부분을 정규식으로 식별·추출하고, 이후 개체 인식을 위한 말뭉치로 사용한다.

4.2 모델 학습과 평가 / 4.2.1 데이터셋 구축

Currently, there are no publicly available model training datasets…

현재 수리공학 안전 위험에 대해 공개된 모델 학습 데이터셋은 없다. 따라서 본 연구는 준자동 주석 작업 흐름을 사용하여 도메인 특화 데이터셋을 구축하며, 이는 예비 기계 라벨링[59], 전문가 검증, 데이터 증강[60]의 세 단계로 이루어진다. 먼저 DeepSeek-V3-671B를 사용하여 추출된 위험 서술 샘플에 예비 라벨을 생성하였다. 이 라벨들은 이후 도메인 전문가가 검증·수정하였고, 전문가가 수정한 샘플을 바탕으로 데이터 증강을 수행하였다.

Fig. 5 illustrates the comprehensive workflow for the fine-tuning dataset construction…

그림 5는 미세조정 데이터셋 구축의 전체 작업 흐름을 보여준다. 데이터셋 구조는 '지시(Instruction)-입력(Input)-출력(Output)' 삼항 패러다임을 따르는 Alpaca 형식[61]을 채택한다. 이 틀에서 '입력'은 전처리된 원본 보고서 텍스트이고, '출력'은 수정된 구조화 개체 집합이다. '지시'는 역할 설정, 과제 설명, 출력 요구사항의 세 요소로

구성된다. 역할 설정은 모델에 특정 정체성과 기능을 부여하여 과제 배경의 이해를 유도하도록 설계된다. 과제 설명은 모델이 수행해야 할 구체적인 작업과 목표를 정의한다. 출력 요구사항은 결과의 원하는 형식과 내용을 규정하며, 본 연구에서는 출력 형식을 JSON으로 지정한다.

A total of 120,471 hazard description samples were extracted…

총 120,471개의 위험 서술 샘플을 추출하여 초기 기계 라벨링을 하였다. 이 주석 샘플들은 DDO에 정의된 계층 관계를 통해 다섯 가지 위험 범주에 대응되었다. 이후 주석된 말뭉치에서 1,200개 샘플을 무작위로 골라 전문가가 수동으로 검증·확인하였다. 데이터셋을 더 강화하기 위해 LLM에 원래 위험 서술의 의미적 재작성을 수행하도록 지시하였다. 이 과정은 의미는 같지만 언어적으로 다양한 새 인스턴스를 생성하여 학습 데이터를 풍부하게 하였다. 과정의 각 단계별 위험 샘플 통계는 표 5에 요약되어 있다.

4.2.2 실험 구성과 평가 지표

Given that the tasks in this study are based on Chinese engineering texts…

본 연구의 과제가 중국어 공학 텍스트를 기반으로 하므로, 주로 중국어 말뭉치로 학습된 오픈소스 LLM을 실험에 선택하였다. DeepSeek-V3-671B, Qwen3-32B, GLM4-32B, Qwen3-14B, GLM4-9B, Qwen3-8B가 포함된다. 모든 실험은 NVIDIA H800 80 GB GPU 8개를 갖춘 서버에서 Python 3.10과 CUDA 12.6으로 수행하였다. 모델 미세조정은 LLaMA-Factory 프레임워크로 구현하였으며 모델 양자화는 적용하지 않았다. DeepSeek-V3-671B는 계산 자원과 데이터셋 규모의 한계로 미세조정하지 않았으며, 기준(baseline) 참고용으로만 사용하였다는 점에 유의해야 한다.

During fine-tuning, the maximum learning rate was set to 5×10…

미세조정 중 최대 학습률은 5×10^-4, 학습 에폭 수는 7로 설정하였다. 데이터셋은 학습, 검증, 시험 부분집합으로 7:1:2 비율로 나누었다. 과적합 위험을 줄이기 위해 조기 종료 전략을 채택하였다[62]. 구체적으로 검증 손실이 여러 에폭에 걸쳐 계속 증가하면 미세조정을 미리 종료하였다. (※ 역자 주: 원문에서 이 문장이 다음 문단 첫 머리에 한 번 더 반복되고, 이어지는 문장의 앞부분이 빠져 있음) …'False'로 표시된 경우는 출력이 없는 경우, 즉 대상 개체가 식별되지 않은 것으로 간주하였다. 평가 지표에는 매크로 평균 정밀도 Pmacro, 매크로 평균 재현율 Rmacro, 매크로 평균 F1 점수 F1macro가 포함되며, 계산식은 식 (12)–(14)와 같다.

Pmacro = (1/n) Σ Pi = (1/n) Σ TPi / (TPi + FPi) (12)

Rmacro = (1/n) Σ Ri = (1/n) Σ TPi / (TPi + FNi) (13)

F1macro = (1/n) Σ F1i = (1/n) Σ 2·Pi·Ri / (Pi + Ri) (14)

여기서 TPi는 실제 라벨이 클래스 i이고 (→ 10쪽으로 이어짐) 모델이 올바르게 예측한 샘플 수이고…

그림 5. 데이터셋 구축

표 5. 단계별 위험 샘플 수 (유형: 샘플 수 / 전문가 수정 샘플 / 데이터 증강)

홍수 방어: 210 / 241 / 1,205

침투: 313 / 339 / 1,695

구조: 372 / 353 / 1,765

내진: 187 / 188 / 940

금속 구조: 218 / 179 / 895

합계: 1,300 / 1,300 / 6,500

원문 10쪽

(9쪽에서 이어짐) correctly predicted by the model, FPi is the number…

…FPi는 실제 라벨이 다른 클래스인데 클래스 i로 잘못 예측된 샘플 수이며, FNi는 실제 라벨이 클래스 i인데 다른 클래스로 잘못 예측된 샘플 수이다.

4.2.3 실험 평가 / (1) 미세조정 성능 평가

The fine-tuning results are shown in Fig. 6. To ensure comparability…

미세조정 결과는 그림 6에 나타나 있다. 서로 다른 모델 사이, 그리고 미세조정 전후 결과 사이의 비교 가능성을 보장하기 위해, 모든 모델은 추론 시 후보 라벨 전체 집합을 제공하는 동일한 프롬프트 템플릿으로 평가하였다. 무작위 샘플링이 모델 출력에 미치는 영향을 줄이기 위해 온도 파라미터는 일괄 0으로 설정하였다. 기준 결과에서 전체 인식 성능은 대체로 모델 파라미터 규모가 커질수록 향상된다. DeepSeek-V3-671B는 클래스 c5와 c6 모두에서 가장 좋은 기준 성능을 낸다. 이는 초대형 범용 LLM이 도메인 특화 미세조정 없이도 댐 위험 서술의 의미 이해와 세밀한 범주 구별에서 더 강한 기본 능력을 가짐을 보여준다. 이 결과는 또한 본 연구의 데이터 사전 주석 단계에서 대규모 파라미터 모델을 사용한 것을 뒷받침한다. 대형 모델은 비교적 고품질의 후보 라벨을 생성하여 이후 수동 수정에 필요한 작업량을 줄일 수 있기 때문이다.

After fine-tuning, the fine-tuned models showed substantial improvements…

미세조정 후, 미세조정된 모델은 클래스 c5와 c6 인식 과제 모두에서 크게 향상되었으며, F1macro가 기준 결과보다 약 26–34 %p 증가하였다. 이는 도메인 특화 미세조정이 위험 분류 능력을 효과적으로 향상시킴을 보여준다. 시험한 모델 중 GLM4-32B가 가장 좋은 전체 성능을 보였으며, 세 평가 지표 모두 클래스 c5에서 90 %에 근접했고 클래스 c6에서도 90 %에 가까웠다. Qwen3-32B도 미세조정 후 강한 결과를 냈지만, 지표가 GLM4-32B보다 약간 낮았다. 이에 비해 8B–14B 모델은 32B 모델보다 전체 성능이 낮았지만, 더 적은 계산 자원과 낮은 배포 비용을 요구하면서도 미세조정 후 비교적 안정적인 인식 결과를 냈다. 따라서 자원이 제한되거나 비용에 민감한 상황에서 8B–14B 모델은 성능과 효율의 균형을 맞추는 실용적인 선택지로 남는다. 이후 실험에서는 댐 위험 개체 인식의 정확도와 안정성을 높이기 위해 GLM4-32B를 기본 모델로 선택하였다.

Further inspection of the prediction results shows that the remaining errors…

예측 결과를 더 살펴보면 클래스 c5 인식에 남은 오류는 주로 구조 위험과 관련된다. 구조 위험의 경우 모델은 구조 강도 부족과 구조 불안정 같은 세밀한 범주를 혼동하는 경향이 있다. 이는 주로 이 범주들이 공학 보고서에서 매우 비슷하게 서술되기 때문이다. '규정 요구사항을 충족하지 않음', '안전성 부족', '지지력 부족' 같은 표현이 자주 쓰이지만, 텍스트가 그 문제가 재료·부재 수준의 지지력을 말하는지, 구조의 전체 안정성, 활동 안정성, 전도 안정성을 말하는지를 항상 분명히 밝히지는 않는다. 그 결과 모델은 이런 서술을 대체로 구조 안전 문제로 식별할 수는 있지만, 올바른 세밀 위험 형태에 대응시키는 데는 여전히 어려움을 겪는다. 반면 클래스 c6의 인식 결과는 범주 간에 비교적 고르며 뚜렷한 성능 병목이 없다. 이는 모델이 댐 구성요소를 식별할 수 있음을 보여준다.

(2) 서로 다른 온도 파라미터에서의 성능 평가

Furthermore, we conducted voting experiments under temperature perturbations…

나아가 미세조정된 GLM4-32B와 Qwen3-32B 모델을 사용하여 온도 교란 하에서 투표 실험을 수행하였다. 개체 분류 과제에서 온도를 조정하면 출력 다양성에 영향을 줄 수 있다. 그러나 값이 지나치게 높으면 출력이 지나치게 발산하고 관련 없는 내용이 생성될 수 있다. 실험에서는 0과 1 사이의 여섯 가지 온도 값, 구체적으로 T = {0, 0.2, 0.4, 0.6, 0.8, 1.0}을 시험하였다. 이 온도 설정들에 따른 모델의 성능 변화는 그림 7에 제시되어 있다.

The experimental results show that model performance under a single temperature setting…

실험 결과, 단일 온도 설정에서의 모델 성능은 온도 변화에 따라 변동하며, 그 경향은 모델과 인식 과제에 따라 다르다. GLM4-32B는 c5와 c6 과제 모두에서 높은 전체 성능을 유지하지만, 0.4와 0.6 같은 일부 온도 설정에서 눈에 띄는 변동이 나타난다. 반면 Qwen3-32B는 온도가 올라갈수록 과제 성능이 전반적으로 약간 떨어져, 높은 온도가 출력 안정성에 어느 정도 영향을 줄 수 있음을 시사한다. 전체적으로 다중 온도 투표로 얻은 P, R, F1 값은 모든 실험 그룹에서 단일 온도 설정에서 얻은 값보다 높다. 이는 투표 전략이 서로 다른 온도 조건의 모델 출력을 효과적으로 통합하고 단일 추론 오류가 최종 분류 결과에 미치는 영향을 줄여, 개체 인식의 안정성과 전체 성능을 향상시킬 수 있음을 보여준다.

In addition, the experiment further examined a cross-model hybrid voting strategy…

또한 실험에서는 모델 간 혼합 투표 전략도 추가로 검토하였다. 구체적으로 Qwen3-32B와 GLM4-32B의 상대적으로 최적인 온도 설정에서의 예측을 골라 다수결 투표로 최종 라벨을 생성하였다. 그 결과 혼합 투표의 전체 성

능은 성능이 더 좋은 GLM4-32B 단독 모델의 성능을 넘지 못했다. 가능한 이유는 Qwen3-32B의 전체 예측 품질이 상대적으로 낮아, 그 잘못된 예측이 투표에서 GLM4-32B의 결정 우위를 약화시켰을 수 있기 때문이다. 또한 두 모델이 일부 세밀한 범주에 대해 비슷한 혼동 패턴을 공유하여, 모델 간 투표가 효과적인 상호 보완을 이루지 못했을 수 있다.

(3) 제거 실험 (Ablation study)

The ablation study was conducted based on the GLM4-32B model…

OHCF 주요 구성요소의 기여를 평가하기 위해 GLM4-32B 모델을 기반으로 제거 실험을 수행하였다. 표 6에서 보듯 미세조정이 지배적인 성능 향상을 제공하며, 이는 모델을 댐 위험 분류 과제에 적응시키는 데 미세조정이 중요함을 보여준다. 투표와 일관성 검사 모듈은 추가적이지만 비교적 작은 향상을 가져온다. 전체적으로 완전한 OHCF가 c5와 c6 분류 모두에서 가장 좋은 성능을 내며, 모든 평가 지표가 90 %를 넘는다.

그림 6. 미세조정 전후의 모델 성능

원문 11쪽

4.3 DDKG의 구축과 검색 응용 / 4.3.1 DDKG 구축과 시각화

Based on the experimental results, the fine-tuned GLM4-32B model was adopted…

실험 결과를 바탕으로, 미세조정된 GLM4-32B 모델을 OHCF의 기반 모델로 채택하여 모든 위험 서술 텍스트에 적용하였다. 각 공학 인스턴스와 연관된 데이터 계층 개체는 독립된 JSON 파일로 정리되어 Python 스크립트로 Neo4j 그래프 데이터베이스에 일괄 입력되었다. 구축된 DDKG는 총 201,362개의 노드와 953,447개의 관계를 포함하였다. 각 최상위 클래스와 연관된 노드 수는 표 7에 나열되어 있다. 각 댐 인스턴스가 댐 높이, 저수 용량, 특성 수위 등 여러 공학·수문 지표로 기술되기 때문에 Parameter 노드가 비교적 큰 비중을 차지한다.

Fig. 8 illustrates the main knowledge structure of the DDKG…

그림 8은 DDKG의 주요 지식 구조를 보여준다. 각 댐 인스턴스는 대응하는 개체 노드에 의미적으로 대응된다. 댐 도메인 온톨로지(DDO)에 정의된 의미 제약 아래에서, 각 댐 공학 개체는 연관된 속성, 평가, 위험 형태, 위험 부위 개체와 연결된다. 이 개체들은 온톨로지 계층을 따라 위로 더 추적하여 상위 노드와 다단계 의미 연관을 형성할 수 있다(예: Dam → c5(5,2,2) ← c5(5,2) ← c5(5)). 또한 공학 개체는 공유 개체 노드를 통해 서로 다른 댐 간에 위상적으로 연결될 수 있다. 예를 들어 그림 8의 두 댐 인스턴스는 '유역: 주강 유역', '규모: 소형', '댐 형식: 균질 흙댐' 같은 공통 노드를 통해 연관된다. 이렇게 서로 연결된 구조는 댐 위험 지식의 군집 분석과 지식 추론 같은 고급 과제의 견고한 기반을 제공한다.

4.3.2 다중 제약 검색의 예

The core function of KGs lies in efficient knowledge retrieval…

KG의 핵심 기능은 효율적인 지식 검색에 있다. 핵심 개체 노드에 제약을 걸어, DDKG는 특정 경계 조건에서의 공학 위험 분포를 검색할 수 있다. 그림 9는 다중 제약 하에서 구조 안전 위험을 검색하는 예를 보여준다. 이 검색에는 양쯔강 유역(River_Basin), 필댐(Dam_Type), 중형(Scale)의 세 가지 고정 제약이 포함된다. 이 제약들은 검색 범위를 이 조합에 해당하는 모든 댐으로 제한한다. 정의된 표본 집합 안에서 이 댐들과 연관된 위험 노드를 (:Dam)-[:exhibitsHazards]->(:HazardForm) 관계를 통해 추적한다. 동시에 DDO의 최상위 클래스 c5:HazardForm 아래 계층 구조를 바탕으로 위험 형태에 대한 제약을 구성한다: (:HazardForm {node_name:'Structure'})-[:hasSubclass*0..]->(:HazardForm). 이는 검색을 '구조 위험' 노드와 그 모든 (→ 12쪽으로 이어짐) 재귀적 하위 클래스로 엄격하게 제한한다.

그림 7. 온도 교란과 투표 전략 하의 모델 성능

표 6. GLM4-32B 기반 OHCF 제거 실험 결과 (c5: P/R/F1, c6: P/R/F1)

기준(Baseline): c5 59.29 / 57.06 / 55.65 %, c6 64.88 / 59.69 / 58.66 %
투표·일관성 검사 제외: c5 90.45 / 90.19 / 90.04 %, c6 89.05 / 88.20 / 88.30 %
일관성 검사 제외: c5 92.09 / 91.82 / 91.67 %, c6 90.76 / 89.86 / 89.98 %
OHCF 전체: c5 93.26 / 93.01 / 92.87 %, c6 91.55 / 90.62 / 90.76 %

표 7. 최상위 클래스별 노드 수

c1 Dam 22,076 / c2 Properties 58 / c3 Location 1,922 / c4 Parameter 76,152 / c5 HazardForm 73 / c6 HazardComponent 44 / c7 SafetyEvaluation 15 / 합계 100,340
※ 역자 주: 본문에는 전체 노드가 201,362개로 적혀 있어 표의 합계와 다름(원문 그대로)

원문 12쪽

(11쪽에서 이어짐) its recursive subclasses. The DDKG, as a structured knowledge base…
구조화된 지식 베이스로서 DDKG는 유역, 댐 형식, 결함·위험 댐의 위험에 관해 원래 흩어져 있던 정보를 개체와 관계 연결을 통해 질서 있는 네트워크로 조직한다. 이를 통해 다중 조건 필터링이나 노드 간 리스크 추적 같은 복잡한 검색·추론 과제를 단순 텍스트 매칭이 아니라 그래프 경로를 바탕으로 수행할 수 있다.

4.4 DDKG 기반 양쯔강 유역 댐 결함 분석

This section takes dam projects in the Yangtze River Basin as the research object…
이 절은 양쯔강 유역의 댐을 연구 대상으로 삼아 댐 안전 결함의 사례 분석을 수행한다. 목적은 공학 결함 분석과 의사결정 지원 과제에서 DDKG의 응용 잠재력과 가치를 더 검증하는 것이다.

In practical engineering, a Grade-C result in a specific safety evaluation category…
실제 공학에서 특정 안전평가 범주의 C등급 결과는 그 댐이 해당 범주에서 비교적 심각한 안전 결함을 가지고 있음을 뜻한다. 양쯔강 유역 댐의 주요 안전 취약점을 식별하기 위해, 서로 다른 C등급 안전평가 지표의 발생 빈도와 동시 발생 빈도를 통계적으로 분석하였으며, 그림 10과 같다. 그림에서 c7(1), c7(2), c7(3), c7(4), c7(5)는 각각 홍수 방어 안전, 침투 안전, 구조 안전, 내진 안전, 금속 구조 안전 평가를 나타낸다. 대각선 값은 각 C등급 안전평가 지표의 발생 빈도를 나타낸다.

From the perspective of individual safety evaluation results…
개별 안전평가 결과의 관점에서, 양쯔강 유역 댐의 C등급 문제는 주로 침투 안전, 구조 안전, 홍수 방어 안전에 집중되어 있다. 그중 침투 안전의 C등급 발생 빈도가 가장 높아, 침투 관련 결함이 (→ 13쪽으로 이어짐) 이 유역 댐 안전평가에서 가장 두드러진 취약점임을 보여준다.

그림 8. DDKG 주요 구조의 시각화 / 그림 9. 구조 위험 지식 검색의 예

원문 13쪽

(12쪽에서 이어짐) prominent weakness… The Grade-C occurrence frequencies of structural safety…
구조 안전과 홍수 방어 안전의 C등급 발생 빈도도 비교적 높아 각각 55.67 %와 48.23 %에 이른다. 이는 양쯔강 유역의 댐들이 장기 운영 중에 구조 노후화, 침투 방지 능력 부족, 홍수 방어 능력 부족 같은 문제를 공통적으로 겪고 있음을 시사한다. 반면 금속 구조 안전 결함과 내진 결함은 양쯔강 유역 댐의 주된 문제가 아니다.

4.4.1 침투-구조 복합 결함 분석

The co-occurrence analysis of Grade-C safety evaluation indicators shows…
C등급 안전평가 지표의 동시 발생 분석은 양쯔강 유역에서 침투 결함과 구조 결함 사이에 비교적 강한 연관이 있음을 보여준다. 이 연관의 바탕이 되는 구체적인 결함 조합을 더 식별하기 위해, 심각한 침투 결함과 구조 결함의 상위 다섯 개 동시 발생 패턴을 추출하였으며, 표 8과 같다.

It can be seen that seepage leakage “c5(2,2,1)” in conveyance culverts…

도수 암거 'c6(3,2,1)'의 침투 누수 'c5(2,2,1)'이 구조 강도 부족 'c5(3,3,1)'과 동시 발생 확률이 가장 높음을 알 수 있다. 이 조합은 양쯔강 유역에서 가장 전형적인 침투-구조 복합 결함이다. 초기 흙·사력댐에서 도수 암거는 대부분 댐 본체 안에 매설되었고 흔히 조적 구조로 건설되었다. 그 재료 특성이 주변 댐 성토 재료와 크게 달라 침투 변형과 응력 변형의 조화를 유지하기 어렵다. 그 결과 암거와 댐 본체 사이의 접촉부를 따라 집중 침투 경로가 생기기 쉽다. 장기간의 침투 침식은 이 접촉부의 침투 안정성을 약화시킬 뿐 아니라 조적 암거 구조의 열화를 가속할 수 있다. 이는 구조 강도를 낮추고 암거 누수를 더 유발하거나 악화시킬 수 있다.

In addition, seepage leakage c5(2,2,1) in dam foundations c6(1,1,3)…

또한 댐 기초 c6(1,1,3)의 침투 누수 c5(2,2,1)도 구조 불안정 결함과 결합되기 쉽다. 장기간의 기초 침투는 댐 기초와 댐 본체 사이 접촉부에서 토사 유실이나 국부 침식을 일으켜 댐의 지지 조건을 약화시킬 수 있다. 이 과정은 댐 사면 c6(1,1,6)의 과다 침하 c5(3,2,1)를 유발할 수 있고, 심지어 전체 활동 불안정 c5(3,3,2)로 발전할 수도 있다. 한편 댐 본체나 기초의 부등 침하는 여수로 c6(2,1,1) 같은 부속 구조물에도 악영향을 주어 접촉부의 구조 균열이나 변형을 일으키고, 이는 다시 침투 문제를 유발할 수 있다.

Therefore, seepage anomalies may weaken the stability conditions…

따라서 침투 이상은 댐 본체와 기초의 안정 조건을 약화시킬 수 있고, 장기간의 침투 작용은 구조 열화와 국부 손상을 더 가속할 수 있다. 반대로 구조 결함도 균열, 변형, 접촉부 파괴를 유발하여 침투 문제를 악화시킬 수 있으며, 댐의 전체 홍수 방어 능력과 운영 안전에 더 영향을 줄 수 있다. 이 결과는 양쯔강 유역의 침투 결함과 구조 결함이 독립된 문제가 아니라 흔히 결합되어 서로를 강화한다는 것을 보여준다. 따라서 안전 진단과 보강 대책은 침투와 구조 결함을 고립된 문제로 다루기보다, 침투 제어, 구조 안정성, 구성요소 무결성의 결합 효과에 초점을 맞춰야 한다.

4.4.2 필댐의 홍수 방어 위험 분석

Flood control and disaster mitigation are among the primary functions…

홍수 방어와 재해 저감은 저수지 댐의 주요 기능 중 하나이다. 필댐의 경우 홍수 방어 능력 부족은 월류 위험을 직접 높이고 댐 전체의 안전을 위협할 수 있다.

Fig. 11 depicts the frequency distribution of various flood control hazard forms…

그림 11은 양쯔강 유역에서 댐 규모가 다른 필댐들의 다양한 홍수 방어 위험 형태의 빈도 분포를 보여준다. (a), (b), (c) 패널은 각각 소형, 중형, 대형 댐에 해당한다. 각 홍수 방어 위험의 발생 빈도는 식 (15)로 계산하였다.

$$P(c5(1,j2,j3) \mid \lambda k, \Omega) = Ndam(c5(1,j2,j3) \cap \lambda k \cap \Omega) / Ndam(\lambda k \cap \Omega) \times 100\% \quad (15)$$

여기서 λk는 댐 규모이며 k = 1, 2, 3은 각각 소형, 중형, 대형 댐에 해당한다. Ω는 제약 집합({양쯔강 유역(River_Basin), 필댐(Dam_Type)})이다. Ndam(λk∩Ω)는 '댐 규모 = λk 이고 Ω'인 댐의 수이고, Ndam(c5(1,j2,j3)∩λk∩Ω)는 '홍수 방어 위험 c5(1,j2,j3)이 있고, 댐 규모 = λk 이고 Ω'인 댐의 수이다.

Overall, “c5(1,2) Insufficient freeboard of water-retaining structures”…

전체적으로 'c5(1,2) 차수 구조물 여유고 부족'과 'c5(1,3) 방류 능력 위험'이 가장 중대한 홍수 방어 위험으로 나타난다. 이 범주들 안에서 'c5(1,2,1) 댐 마루 표고 부족'과 'c5(1,3,2) 여수로 방류 능력 부족'이 가장 자주 발생하는 구체적인 위험 형태이다.

Small-scale projects are more prone than medium- and large-scale projects…

소형 댐은 중·대형 댐보다 'c5(1,1,2) 설계 홍수 기준 부족'과 'c5(1,2,1) 댐 마루 표고 부족' 같은 문제가 생기기 쉽다. 이는 초기 건설 시기의 낮은 방호 기준과 제한된 기술 투자에 묶인 소형 저수지가, 기술 파라미터 측면에서 현행 설계 기준을 맞추기 어려울 뿐 아니라 극한 조건을 안전하게 수용할 충분한 구조 높이 여유도 부족하다는 한계를 반영한다.

The occurrence frequency of “c5(1,3,2) Insufficient discharge capacity” increases…

'c5(1,3,2) 방류 능력 부족'의 발생 빈도는 댐 규모가 클수록 증가한다. 소형 댐에 비해 중·대형 댐은 일반적으로 더 큰 홍수 압력과 더 복잡한 홍수 추적(routing) 과정에 직면한다. 이러한 특성은 수리 구조물의 방류 능력, 운영

대응의 효율, 전체 홍수 방류 체계의 조정에 더 높은 요구를 가한다. 그 결과 방류 능력과 실제 홍수 방어 수요 사이의 불일치가 규모가 큰 댐에서 생기기 쉽다.

In small projects, although insufficient discharge capacity is relatively less prominent…

소형 댐에서는 방류 능력 부족이 상대적으로 덜 두드러지지만, 'c5(1,3,1) 홍수 방어 시설 누락'이 더 심각하다. 이는 주로 일부 소형 저수지가 오랜 기간 유입이 없어 여러 해 동안 빈 상태로 남아 있었기 때문이다. 이런 (→ 14쪽으로 이어짐) 조건에서…

그림 10. 양쯔강 유역 C등급 안전평가 지표의 발생·동시 발생 빈도

표 8. 침투·구조 결함의 상위 5개 동시 발생 조합 (침투 위험 c5, c6 / 구조 위험 c5, c6 / 동시 발생 빈도)

1. c5(2,2,1), c6(3,2,1) / c5(3,3,1), c6(3,2,1) / 13.99 %
2. c5(2,2,1), c6(1,1,3) / c5(3,3,2), c6(1,1,6) / 13.83 %
3. c5(2,2,1), c6(1,1,3) / c6(1,1,6), c6(2,1,1) / 13.55 %
4. c5(2,2,1), c6(1,1,3) / c5(3,2,1), c6(1,1,6) / 12.96 %
5. c5(2,2,1), c6(1,1,3) / c5(3,3,1), c6(3,2,1) / 10.57 %

원문 14쪽

그림 11. 홍수 방어 위험 형태의 빈도 분포 (소형·중형·대형)

(13쪽에서 이어짐) such conditions, their original water release or conveyance facilities…

…원래의 방류·도수 시설이 점차 방치되어 작동하지 않게 되고, 홍수 방어 기능이 크게 약화된다. 이 저수지들은 현재 방류의 실질적 필요가 거의 없을 수 있지만, 관련 리스크를 간과해서는 안 된다. 홍수가 발생하면 저수지는 빈 상태에서 저류 상태로 빠르게 바뀔 수 있다. 제 기능을 하는 홍수 방류 시설이 없으면 유입량을 제때 방류할 수 없어 월류 위험이 크게 높아지며, 심한 경우 댐 붕괴로 이어질 수 있다.

In summary, the DDKG provides a structured basis for multi-dimensional dam hazard analysis…

요약하면, DDKG는 다차원적 댐 위험 분석의 구조화된 기반을 제공한다. 양쯔강 유역 사례 연구는 위험 정보를 유역, 댐 형식, 댐 규모, 위험 유형, 영향 부위별로 검색하고 비교할 수 있음을 보여준다. 이는 DDKG가 지역 댐 안전 분석과 관리 의사결정을 지원할 잠재력이 있음을 보여준다.

5. 결론과 향후 연구

To address the underutilization of unstructured text data in the dam safety domain…

댐 안전 분야에서 비정형 텍스트 데이터가 충분히 활용되지 않는 문제와, 범용 LLM을 전문 분야에 적용할 때의 지식 적응 문제를 해결하기 위해, 본 연구는 도메인 지식 온톨로지와 LLM을 통합한 KG 구축 방법을 제안한다. 본 연구의 주요 기여는 다음과 같다.

(1) 댐 위험 지식의 구조화된 표현 틀을 제공하는 댐 결함 온톨로지(DDO)를 개발하였다. 특히 위험 형태와 영향 부위의 클래스를 정교화하여 댐 결함의 세밀한 모델링을 지원하였다.

(2) 비정형 위험 서술을 표준화하기 위한 온톨로지 기반 위험 분류 프레임워크(OHCF)를 제안하였다. 미세조정, 온도 교란 투표, 온톨로지 제약 일관성 검사, 전문가 검증을 통합하여 OHCF는 위험 분류의 신뢰성을 높이고 KG 구축을 위한 구조화된 입력을 제공한다.

(3) 제안 방법을 바탕으로 22,076개 댐의 안전 감정 보고서를 사용하여 댐 결함 지식그래프(DDKG)를 구축하였다. 사례 연구는 DDKG가 다중 제약 검색과 지역 위험 분석을 지원할 수 있음을 보여주어, 댐 안전관리에 대한 잠재적 가치를 입증한다.

Despite these contributions, the proposed method has limitations…

이러한 기여에도 불구하고, 제안 방법에는 향후 연구에서 다룰 한계가 있다.

(1) 본 연구에서 DDKG의 응용은 아직 초기 단계로, 주로 단일한 대규모 지역 분석에 초점을 맞추었다. 향후 연구

는 더 세밀한 공간 규모와 개별 댐 수준의 위험 분석으로 응용을 확장하여, 위험 분포의 지역적 차이를 밝히고 댐 안전관리에 더 표적화된 지원을 제공할 것이다.
(2) 현재 DDKG는 위험 정보가 과거 평가 보고서에서 나온 정적 지식 베이스이다. 향후 연구는 시간 데이터를 통합하고 자동 갱신 방법을 탐색하여 DDKG를 동적으로 진화하는 시스템으로 바꿀 것이다.
(3) 본 연구는 위험 지식 추출을 평가하고 전문가 검증을 포함하지만, 구축된 지식그래프 자체는 여전히 체계적인 평가가 필요하다. 향후 연구는 그 구조적 특성, 완전성, 일관성, 그리고 댐 결함 분석과 공학 의사결정 지원에서의 실질적 효과를 검토할 것이다.

원고 준비 과정의 생성형 AI 사용 고지 / 저자 기여 등

저자들은 언어와 가독성을 개선하기 위해 Gemini 2.5를 사용하였으며, 사용 후 내용을 검토·편집하고 출판된 논문 내용에 전적인 책임을 진다. (이하 저자 기여, 이해 상충, 감사의 글, 참고문헌은 해석 생략)

원문 15쪽

참고문헌

(참고문헌 목록: 해석 생략)

원문 16쪽

참고문헌

(참고문헌 목록: 해석 생략)