2024 IEEE International Conference on Big Data (BigData) | 979-8-3503-6248-0/24/$31.00 ©2024 IEEE | DOI: 10.1109/BigData62323.2024.10825705

GraphAide: Advanced Graph-Assisted Query and Reasoning System

Sumit Purohit, George Chin, Patrick S Mackey, Joseph A Cottam
Pacific Northwest National Laboratory
Richland, Washington 99352
{sumit.purohit, george.chin, patrick.mackey, joseph.cottam}@pnnl.gov

***Abstract*—Curating knowledge from multiple siloed sources that contain both structured and unstructured data is a major challenge in many real-world applications. Pattern matching and querying represent fundamental tasks in modern data analytics that leverage this curated knowledge. The development of such applications necessitates overcoming several research challenges, including data extraction, named entity recognition, data modeling, and designing query interfaces. Moreover, the explainability of these functionalities is critical for their broader adoption.**

The emergence of Large Language Models (LLMs) has accelerated the development lifecycle of new capabilities. Nonetheless, there is an ongoing need for domain-specific tools tailored to user activities. The creation of such digital assistants has gained considerable traction in recent years, with LLMs offering a promising avenue to develop such assistants utilizing domain-specific knowledge and assumptions.

In this context, we introduce an advanced query and reasoning system, *GraphAide*, which constructs a knowledge graph (KG) from diverse sources and allows to query and reason over the resulting KG. *GraphAide* harnesses both the KG and LLMs to rapidly develop domain-specific digital assistants. It integrates design patterns from retrieval augmented generation (RAG) and the semantic web to create an agentic LLM application. *GraphAide* underscores the potential for streamlined and efficient development of specialized digital assistants, thereby enhancing their applicability across various domains.

I. Introduction

Large Language Models (LLMs) [1] represent the cutting edge of generative artificial intelligence (GenAI) and machine learning research and development. They have been adopted at an extraordinary rate across a range of disciplines, including scientific research, engineering, economics, and social sciences. By enabling domain experts to utilize pre-trained, ready-to-use models, LLMs have democratized the application development process, catalyzing innovations in both scientific and technological domains. The development of LLM-based applications remains a dynamic area of research, offering superior performance in tasks such as summarization, correlation, and inference across various input sources [2].

Knowledge Graphs (KGs) are formal representations of key concepts as entities and the relationships between them [3], [4]. KGs serve as powerful tools that can be employed in diverse user environments as foundational reference knowledge sources. However, constructing these KGs presents substantial challenges due to the scale of input data, the heterogeneity of use-case-specific concepts, and the costs associated with KG construction. LLMs have demonstrated higher accuracy in extracting relevant entities and forming relationships, significantly contributing to KG construction [5].

A major challenge in developing accurate and consistent capabilities based on LLMs is *hallucination* [6], which occurs when LLMs generate non-existent facts in response to user queries. The memorization of training data by LLMs and the subsequent reliance on corpus-based heuristics are significant factors contributing to hallucinations [7]. Addressing this issue is crucial for the reliability and trustworthiness of LLM-derived applications.

Retrieval-augmented generation (RAG) [8] is a well-established design pattern aimed at mitigating hallucination in Large Language Models (LLMs) by providing additional context during the generation of responses to user queries. This additional *context* is domain-specific and acts as *grounding* for the model's generative capabilities. A foundational RAG-based system employs a vector database to store *embeddings* of a domain-specific knowledge corpus and utilizes semantic similarity algorithms to retrieve the context relevant to the user query. The semantic similarity algorithms measure how closely the meanings of two concepts align. This context is then combined with the user query and forwarded to the LLM, serving as a guardrail for its generation process. The RAG-based approach has demonstrated efficacy in reducing hallucination by constraining the LLM's generative output to the localized region of the provided context.

However, a vector search-based method is constrained by the semantic similarity between the query and the corpus. It fails to leverage the structural context, such as the relationships between documents within the corpus, their metadata, or the associated reasoning. Knowledge Graphs (KGs) offer a robust solution to these limitations by efficiently storing domain-specific information and establishing relationships between information sources dispersed across documents in the corpus. KGs can also significantly enhance various components of an LLM-based application, including retrieval, summarization, and inference.

By integrating KGs into the design pattern, the system can utilize both the semantic and structural context, thereby improving the accuracy and consistency of the generated responses. This comprehensive approach enables a more nuanced understanding and utilization of the knowledge corpus, offering a sophisticated strategy to further reduce hallucination

979-8-3503-6248-0/24/$31.00 ©2024 IEEE
Authorized licensed use limited to: Kookmin University. Downloaded on August 31,2026 at 11:15:48 UTC from IEEE Xplore. Restrictions apply.

해석 (p.1)

제목·저자

GraphAide: 그래프를 활용한 고급 질의·추론 시스템
Sumit Purohit, George Chin, Patrick S Mackey, Joseph A Cottam
퍼시픽 노스웨스트 국립연구소(PNNL), 미국 워싱턴주 리치랜드
2024 IEEE 빅데이터 국제학술대회(BigData)

초록 (Abstract)

Curating knowledge from multiple siloed sources

정형 자료와 비정형 자료가 섞여 있고 서로 떨어져 있는 여러 출처에서 지식을 모아 정리하는 일은 많은 실제 응용에서 큰 과제다. 패턴 매칭과 질의는 이렇게 정리한 지식을 활용하는 현대 데이터 분석의 기본 작업이다. 이런 응용을 개발하려면 자료 추출, 개체명 인식, 자료 모델링, 질의 인터페이스 설계 등 여러 연구 과제를 풀어야 한다. 또한 이런 기능이 널리 쓰이려면 설명 가능성이 매우 중요하다.

The emergence of Large Language Models

대규모 언어모델(LLM)의 등장으로 새 기능을 개발하는 주기가 빨라졌다. 그래도 사용자의 활동에 맞춘 분야 특화 도구는 계속 필요하다. 이런 디지털 조수를 만드는 일은 최근 몇 년 사이 큰 관심을 받았고, LLM은 분야의 지식과 가정을 활용해 그런 조수를 개발할 유망한 길을 열어 준다.

In this context, we introduce an advanced query

이런 맥락에서 우리는 고급 질의·추론 시스템인 GraphAide를 소개한다. GraphAide는 다양한 출처에서 지식그래프(KG)를 구축하고, 그 KG에 질의하고 추론할 수 있게 한다. GraphAide는 KG와 LLM을 함께 활용해 분야 특화 디지털 조수를 빠르게 개발한다. 검색 증강 생성(RAG)과 시맨틱 웹의 설계 방식을 통합해 에이전트형 LLM 응용을 만든다. GraphAide는 전문화된 디지털 조수를 간결하고 효율적으로 개발할 수 있음을 보여 주며, 여러 분야에 걸친 적용 가능성을 높인다.

I. 서론

Large Language Models (LLMs) [1] represent

대규모 언어모델(LLM)[1]은 생성형 인공지능(GenAI)과 기계학습 연구개발의 최전선에 있다. 과학 연구, 공학, 경제학, 사회과학 등 여러 분야에서 매우 빠른 속도로 채택되고 있다. 분야 전문가가 사전 학습된 모델을 바로 쓸 수 있게 되면서, LLM은 응용 개발 과정을 대중화했고 과학과 기술 양쪽에서 혁신을 촉진했다. LLM 기반 응용의 개발은 여전히 활발한 연구 분야이며, 여러 입력 자료에 대한 요약, 연관, 추론 같은 작업에서 뛰어난 성능을 보인다[2].

Knowledge Graphs (KGs) are formal representations

지식그래프(KG)는 핵심 개념을 개체로, 그 사이를 관계로 나타낸 형식적 표현이다[3], [4]. KG는 다양한 사용자 환경에서 기초 참조 지식으로 쓸 수 있는 강력한 도구다. 그러나 KG를 구축하는 데는 입력 자료의 규모, 사용 사례마다 다른 개념의 이질성, 구축에 드는 비용 때문에 큰 어려움이 있다. LLM은 관련 개체를 추출하고 관계를 만드는 데서 더 높은 정확도를 보여 KG 구축에 크게 기여했다[5].

A major challenge in developing accurate

LLM을 바탕으로 정확하고 일관된 기능을 개발할 때의 주요 과제는 환각[6]이다. 환각은 LLM이 사용자 질의에 대해 존재하지 않는 사실을 만들어 낼 때 일어난다. LLM이 학습 자료를 암기하고 이후 말뭉치 기반의 어림짐작에 의존하는 것이 환각의 주요 원인이다[7]. 이 문제를 해결하는 것은 LLM에서 나온 응용의 신뢰성과 신뢰도에 매우 중요하다.

Retrieval-augmented generation (RAG) [8] is

검색 증강 생성(RAG)[8]은 사용자 질의에 대한 응답을 생성할 때 추가 문맥을 제공해 LLM의 환각을 줄이는, 잘 확립된 설계 방식이다. 이 추가 문맥은 분야에 특화된 것이며 모델의 생성 능력에 근거가 된다. 기본적인 RAG 기반 시스템은 분야 지식 말뭉치의 임베딩을 벡터 데이터베이스에 저장하고, 의미 유사도 알고리즘으로 사용자 질의와 관련된 문맥을 찾는다. 의미 유사도 알고리즘은 두 개념의 뜻이 얼마나 가까운지를 잰다. 이 문맥을 사용자 질의와 합쳐 LLM에 보내면, 생성 과정의 안전장치 구실을 한다. RAG 기반 접근은 LLM의 생성 결과를 제공된 문맥의 범위 안으로 제한해 환각을 줄이는 데 효과가 있음을 보였다.

However, a vector search-based method

그러나 벡터 검색 기반 방법은 질의와 말뭉치 사이의 의미 유사도에 제약된다. 말뭉치 안 문서들 사이의 관계, 메타데이터, 관련된 추론 같은 구조적 문맥을 활용하지 못한다. 지식그래프(KG)는 분야 정보를 효율적으로 저장하고 말뭉치의 여러 문서에 흩어진 정보 출처 사이에 관계를 세워 이 한계에 대한 견고한 해법을 준다. KG는 검색, 요약, 추론 등 LLM 기반 응용의 여러 구성요소도 크게 향상시킬 수 있다.

By integrating KGs into the design pattern

KG를 설계 방식에 통합하면 시스템은 의미 문맥과 구조 문맥을 모두 활용할 수 있어, 생성된 응답의 정확성과 일관성이 높아진다. 이 포괄적인 접근은 지식 말뭉치를 더 세밀하게 이해하고 활용하게 해 주며, 환각을 더 줄이고 응용의 전체 성능을 높이는 정교한 전략이 된다.

메모

and enhance the application's overall performance.

We introduce GraphAide, an advanced capability based on Large Language Models (LLMs) that offers insights into domain-specific data and allows users to ask natural language questions. GraphAide presents a methodology and reference architecture to develop advanced GenAI applications using different components such as LLMs, vector database, and graph database. GraphAide employs a modular, extensible, and user-friendly retrieval-augmented generation (RAG) approach, incorporating both vector and graph databases. The novelty of GraphAide lies in its comprehensive design for integrating GenAI and semantic web technologies. GraphAide curates multi-source data and constructs ontology-guided knowledge graphs to address the challenges faced by baseline LLM-only applications. The platform also provides efficient data persistence, enabling interactions via a natural language question-answering interface.

GraphAide combines a robust graph matching approach with the semantic similarity provided by vector databases to enhance the accuracy and explainability of LLM-generated responses. Developed as an extensible agentic RAG application, GraphAide reuses data ingestion, entity disambiguation, storage, query, and reasoning components throughout the application lifecycle. Key capabilities of GraphAide include:

- **Ontology-guided Knowledge Graph construction:** Handles multi-value, multi-source, temporal attributes from common data formats such as .txt, .html, .pdf, etc.
- **Generation and maintenance of embeddings:** Configures vector databases for storage and retrieval, maintaining multiple vector databases and dynamically selecting sources based on user queries.
- **Template-based ontology configuration:** Enables dynamic input ontology configuration and generation of multiple KG versions for a given source dataset.
- **Enhanced context generation:** Combines vector-based retrieval with graph-based subgraph matching to improve the relevancy of LLM-generated responses.
- **External function execution capability:** Enriches context by retrieving multi-modal data sources, such as temporal data from time-series databases.

GraphAide represents a significant advancement in the development of domain-specific digital assistants, integrating state-of-the-art GenAI and semantic technologies for improved performance and extensibility. Section II provides an overview of related work, while Section III details the GraphAide architecture along with its key components. Section IV showcases a real-world use case, presenting experimental results and evaluation metrics.

II. Related Work

The integration of generative artificial intelligence (GenAI) and semantic technologies is an active and burgeoning area of research. Existing Knowledge Graph (KG)-based LLM capabilities often focus on specific applications. A baseline RAG approach [9] transforms unstructured data into multiple chunks, creates embeddings for these chunks, and stores them in a vector database. These embeddings are then used to perform semantic similarity matching for an input user query, retrieving the most similar chunks. This retrieval process constructs the *context* to augment user queries sent to the LLM. The RAG approach has shown promising results in addressing challenges such as hallucination, outdated knowledge, and the explainability of generated responses. However, the baseline RAG is limited by its reliance on semantic similarity.

GraphRAG [10] advances this field by presenting a query-focused summarization task (QFS) that builds efficient text indices over a KG. GraphRAG leverages community detection to partition the graph index and uses it to generate "global answers" to user queries. Other approaches, such as the work by Trajanoska et al. [11], focus on creating KGs from sustainability-related text and evaluating their quality with specialized models for joint entity and relation extraction. Similarly, Ban et al. [12] introduce a set of prompts to extract causal graphs for causal structural learning. A common challenge with these approaches is their limited extensibility, as they do not leverage state-of-the-art open-source application development frameworks. There exists a significant opportunity to utilize KGs more effectively in various phases of LLM-based application development and usage.

III. Architecture

GraphAide is a retrieval-augmented generation (RAG)-based system that employs multiple LLM instances and knowledge graphs (KGs) to perform diverse tasks. An *Agent*-based LLM application leverages its reasoning capabilities to determine the appropriate sequence of actions in response to user queries. Unlike hardcoded instructions (i.e., *chains*), an *agentic application* can comprehend the LLM's response and construct subsequent queries dynamically. GraphAide is a hybrid application leveraging both chains and agents to handle a variety of user queries. GraphAide's hybrid approach enables the system to effectively manage a wide array of user queries, ensuring accurate and contextually relevant responses.

Figure 1 details GraphAide architecture and highlights use of ontology, vector database, and multiple LLM agents to perform different tasks. GraphAide delineates specific *phases* corresponding to the set of features required to complete a user task. As illustrated in Figure 1, the *generation* phase combines information from multiple sources to construct a Knowledge Graph (KG), which serves as a knowledge repository alongside the vector database. In the *query* phase, GraphAide provides a user interface that allows querying the knowledge sources and generating responses in a user-specified format, accompanied by explanations and reasoning.

GraphAide decomposes the query and reasoning research problem into following sub-problems and addresses them using a graph-based RAG approach:

- Data ETL and Normalization
- Named-Entity Recognition
- Domain-aware semantic annotation
- Graph Modeling and Storage
- Query interpretation and context generation

Authorized licensed use limited to: Kookmin University. Downloaded on August 31,2026 at 11:15:48 UTC from IEEE Xplore. Restrictions apply.

해석 (p.2)

메모

We introduce GraphAide, an advanced capability

우리는 GraphAide를 소개한다. GraphAide는 LLM에 기반한 고급 기능으로, 분야 자료에 대한 통찰을 제공하고 사용자가 자연어로 질문할 수 있게 한다. GraphAide는 LLM, 벡터 데이터베이스, 그래프 데이터베이스 같은 구성요소로 고급 생성형 AI 응용을 개발하는 방법론과 참조 구조를 제시한다. GraphAide는 벡터 데이터베이스와 그래프 데이터베이스를 모두 쓰는, 모듈식이고 확장 가능하며 쓰기 쉬운 RAG 접근을 채택한다. GraphAide의 새로운 점은 생성형 AI와 시맨틱 웹 기술을 통합하는 포괄적인 설계에 있다. GraphAide는 여러 출처의 자료를 정리하고 온톨로지에 따라 지식그래프를 구축해, LLM만 쓰는 기본 응용이 겪는 문제를 해결한다. 이 플랫폼은 효율적인 자료 저장도 제공하며, 자연어 질의응답 인터페이스로 상호작용할 수 있게 한다.

GraphAide combines a robust graph matching

GraphAide는 견고한 그래프 매칭 접근과 벡터 데이터베이스가 제공하는 의미 유사도를 결합해, LLM이 생성한 응답의 정확성과 설명 가능성을 높인다. 확장 가능한 에이전트형 RAG 응용으로 개발된 GraphAide는 자료 적재, 개체 구분, 저장, 질의, 추론 구성요소를 응용의 전 주기에 걸쳐 재사용한다. GraphAide의 주요 기능은 다음과 같다.
? 온톨로지에 따른 지식그래프 구축: .txt, .html, .pdf 등 흔한 자료 형식에서 여러 값, 여러 출처, 시간 속성을 다룬다.
? 임베딩의 생성과 유지: 저장과 검색을 위한 벡터 데이터베이스를 설정하고, 여러 벡터 데이터베이스를 유지하며 사용자 질의에 따라 출처를 동적으로 고른다.
? 틀 기반 온톨로지 설정: 입력 온톨로지를 동적으로 설정하고, 주어진 원천 자료에 대해 여러 판의 KG를 생성할 수 있게 한다.
? 강화된 문맥 생성: 벡터 기반 검색과 그래프 기반 부분 그래프 매칭을 결합해 LLM이 생성한 응답의 관련성을 높인다.
? 외부 함수 실행 기능: 시계열 데이터베이스의 시간 자료 같은 여러 형태의 자료 출처를 가져와 문맥을 풍부하게 한다.

GraphAide represents a significant advancement

GraphAide는 최신 생성형 AI와 시맨틱 기술을 통합해 성능과 확장성을 높인, 분야 특화 디지털 조수 개발의 중요한 진전이다. II절은 관련 연구를 개관하고, III절은 GraphAide의 구조와 주요 구성요소를 자세히 설명한다. IV절은 실제 사용 사례를 보이고 실험 결과와 평가 지표를 제시한다.

II. 관련 연구

The integration of generative artificial intelligence

생성형 인공지능(GenAI)과 시맨틱 기술의 통합은 활발하고 빠르게 커지는 연구 분야다. 기존의 KG 기반 LLM 기능은 특정 응용에 초점을 두는 경우가 많다. 기본 RAG 접근[9]은 비정형 자료를 여러 조각으로 바꾸고, 조각의 임베딩을 만들어 벡터 데이터베이스에 저장한다. 이 임베딩으로 입력된 사용자 질의에 대해 의미 유사도 매칭을 수행해 가장 비슷한 조각을 찾는다. 이 검색 과정이 LLM에 보내는 사용자 질의를 보강할 문맥을 만든다. RAG 접근은 환각, 오래된 지식, 생성된 응답의 설명 가능성 같은 문제에서 유망한 결과를 보였다. 그러나 기본 RAG는 의미 유사도에 의존한다는 한계가 있다.

GraphRAG [10] advances this

GraphRAG[10]는 KG 위에 효율적인 글 색인을 만드는 질의 중심 요약(QFS) 과제를 제시해 이 분야를 발전시켰다. GraphRAG는 커뮤니티 탐지로 그래프 색인을 나누고, 이를 사용자 질의에 대한 "전역적 답"을 만드는 데 쓴다. Trajanoska 등[11]의 연구 같은 다른 접근은 지속가능성 관련 글에서 KG를 만들고, 개체와 관계를 함께 추출하는 전용 모델로 그 품질을 평가하는 데 초점을 둔다. 비슷하게 Ban 등[12]은 인과 구조 학습을 위해 인과 그래프를 추출하는 프롬프트 모음을 소개한다. 이런 접근의 공통 과제는 확장성이 제한된다는 점이다. 최신 오픈소스 응용 개발 프레임워크를 활용하지 않기 때문이다. LLM 기반 응용의 개발과 사용의 여러 단계에서 KG를 더 효과적으로 활용할 기회가 크다.

III. 구조

GraphAide is a retrieval-augmented generation

GraphAide는 여러 LLM 인스턴스와 지식그래프(KG)를 써서 다양한 작업을 수행하는 RAG 기반 시스템이다. 에이전트 기반 LLM 응용은 추론 능력을 활용해 사용자 질의에 대한 적절한 행동 순서를 정한다. 미리 정해 둔 지시(즉 체인)와 달리, 에이전트형 응용은 LLM의 응답을 이해하고 다음 질의를 동적으로 구성할 수 있다. GraphAide는 체인과 에이전트를 모두 활용해 다양한 사용자 질의를 처리하는 혼합형 응용이다. 이 혼합 접근 덕분에 시스템은 폭넓은 사용자 질의를 효과적으로 다루고, 정확하고 문맥에 맞는 응답을 보장한다.

Figure 1 details GraphAide architecture

그림 1은 GraphAide의 구조를 자세히 보여 주며, 서로 다른 작업을 수행하기 위해 온톨로지, 벡터 데이터베이스, 여러 LLM 에이전트를 쓰는 것을 강조한다. GraphAide는 사용자 작업을 완료하는 데 필요한 기능 묶음에 대응하는 단계들을 구분한다. 그림 1에 나타낸 것처럼, 생성 단계는 여러 출처의 정보를 결합해 지식그래프(KG)를 구축하고, 이 KG는 벡터 데이터베이스와 함께 지식 저장소 구실을 한다. 질의 단계에서 GraphAide는 지식 출처에 질의하고, 설명과 추론을 붙여 사용자가 지정한 형식으로 응답을 생성하는 사용자 인터페이스를 제공한다.

GraphAide decomposes the query and reasoning

GraphAide는 질의·추론 연구 문제를 다음의 하위 문제로 나누고, 그래프 기반 RAG 접근으로 푼다.
? 자료 추출·변환·적재(ETL)와 정규화
? 개체명 인식
? 분야를 고려한 의미 주석
? 그래프 모델링과 저장
? 질의 해석과 문맥 생성
? 질의 확장과 후보 생성
? 요약과 설명 가능한 응답 생성

- Query expansion and candidate generation
- Summarization and explainable response generation

A. Data Ingestion

Domain-specific datasets are available in multiple structured and unstructured formats, depending on the use cases. GraphAide creates an abstraction layer that allows end users to work with commonly used data formats such as plain text, CSV, PDF, etc. A collection of source data (i.e., files) is ingested into GraphAide, followed by a process of text splitting and chunking to support efficient search over vector data and to manage data larger than the maximum context window size (in number of tokens) of an LLM. GraphAide employs a byte pair encoding (BPE)-based tokenizer [13] that segments input text into sub-word units, enabling the system to handle a wide variety of languages. The BPE-based encoding is also supported by OpenAI embedding models [14] and has been shown to perform well across different query scenarios due to its lossless, reversible, and efficient encoding. Additionally, GraphAide uses the $RecursiveCharacterTextSplitter$, which recursively examines characters in the input data to dynamically identify the optimal splitting strategy. GraphAide employs static $chunk_size$ and $chunk_overlap$ values, as suggested in related work [15], and also allows users to configure the text splitter for specific application domains.

B. Data Storage

Persistence of knowledge curated from multiple sources is critical for the reproducibility and incremental updates of the underlying digital assistant. In contrast to basic RAG, GraphAide persists contextual knowledge in both vector and graph databases. After splitting and chunking, as discussed in Section III-A, the source data is converted into a collection of $documents$, where each $document$ serves as an atomic knowledge source used to answer user queries. In a RAG-based LLM application, *embedding*-based semantic similarity is a key feature. Embeddings are numerical representations of information, where semantically similar content is placed closer together in the embedding space. GraphAide uses a vector database to store embeddings of domain-specific reference datasets or general-purpose knowledge bases, such as WikiData [16]. GraphAide provides a simple API to ingest datasets into the vector database and persist them locally for future use. The novelty of GraphAide lies in its use of a graph database to store additional structural information. GraphAide's API offers domain-specific graph modeling and graph persistence functionality. The graph database is used in subsequent phases to enhance the performance of retrieval operations.

C. Knowledge Graph Generation

Generation of an ontology-guided Knowledge Graph (KG) from heterogeneous sources is one of the key contributions of GraphAide. GraphAide defines a KG generation phase that supports operations such as named entity extraction, relationship extraction, entity disambiguation, KG encoding, and KG maintenance. It employs a prompt-based, few-shot approach to instruct an LLM to generate a knowledge graph. GraphAide supports the dynamic selection of an ontology or a list of node and edge types as input to the generation phase, which restricts the LLM's response schema, ensuring it generates an attributed subgraph for a given input text. For the KG generation phase, an example query could be a paragraph from an unstructured source, such as a news article. GraphAide uses Pydantic [17], an annotation-based schema validator, to maintain the consistency of the generated subgraph throughout the entire KG generation phase.

GraphAide Component	Metrics
Named Entity Mention Extraction	Answer Accuracy
Semantic Annotation	Context Relevancy, Context Accuracy, Answer Relevancy, Answer Accuracy, Semantic Similarity
Entity Disambiguation	Context Precision, Context Recall, ROC Curve
Query Expansion	Answer Relevancy
Graph Query Generation	Answer Accuracy, Answer Relevancy

TABLE I: Metrics for Different Components in GraphAide

D. Subgraph Query Generation

GraphAide's *query phase* begins with a natural language user query, as shown in Figure 1. User queries are often incomplete and imprecise, which can lead to reduced retrieval accuracy and relevance when using vector databases. To address query-document mismatch in sparse retrieval, LLM-based query expansion has been shown to alleviate these challenges [18]. GraphAide applies a similar approach to embedding-based dense retrieval, using a template-based method to generate additional versions of the input query while preserving the key entities and relationships mentioned in the original query. Subsequently, GraphAide leverages LLMs to convert the expanded set of queries into attributed subgraph matching templates, as illustrated in Figure 1. By combining expressive subgraph matching with vector-based semantic similarity, GraphAide enhances retrieval accuracy. The GraphAide API supports commonly used graph databases, such as Neo4J [19], and can auto-generate Cypher queries for the expanded query set. Moreover, the GraphAide API provides different prompt templates to generate queries for domain-specific graph data models based on custom schema.

E. Metrics and Evaluation

Evaluation of a comprehensive GenAI application with multiple components (aka *agents*) requires a collection of relevant quantitative metrics, as a single metric is often insufficient to explain the performance of all components. There is also a need to identify relevant metrics for each agent based on its functionality, role, and the type of data it processes. Both phases of GraphAide involve multiple sub-problems, each with different metric requirements as shown in table I. GraphAide leverages RAGAS [20] to prepare evaluation dataset and compute a collection of relevant quantitative metrics. Future work will focus on developing an API to auto-generate evaluation datasets and metrics. Additionally,

Authorized licensed use limited to: Kookmin University. Downloaded on August 31,2026 at 11:15:48 UTC from IEEE Xplore. Restrictions apply.

해석 (p.3)

메모

A. 자료 적재

Domain-specific datasets are available

분야 자료는 사용 사례에 따라 여러 정형·비정형 형식으로 존재한다. GraphAide는 최종 사용자가 일반 텍스트, CSV, PDF 등 흔히 쓰는 자료 형식으로 작업할 수 있게 하는 추상화 계층을 만든다. 원천 자료(즉 파일) 모음을 GraphAide에 적재한 다음, 글을 나누고 조각내는 과정을 거친다. 이는 벡터 자료에 대한 효율적인 검색을 지원하고, LLM의 최대 문맥 창 크기(토큰 수)보다 큰 자료를 다루기 위해서다. GraphAide는 바이트 쌍 부호화(BPE) 기반 토크나이저[13]를 쓴다. 이 토크나이저는 입력 글을 단어보다 작은 단위로 나눠 시스템이 다양한 언어를 다룰 수 있게 한다. BPE 기반 부호화는 OpenAI 임베딩 모델[14]도 지원하며, 손실이 없고 되돌릴 수 있으며 효율적이어서 여러 질의 상황에서 잘 동작하는 것으로 나타났다. 또한 GraphAide는 RecursiveCharacterTextSplitter를 쓴다. 이것은 입력 자료의 글자를 재귀적으로 살펴 가장 알맞은 나누기 전략을 동적으로 찾는다. GraphAide는 관련 연구[15]가 제안한 대로 고정된 조각 크기와 조각 겹침 값을 쓰며, 사용자가 특정 응용 분야에 맞게 글 나누기를 설정할 수도 있게 한다.

B. 자료 저장

Persistence of knowledge curated from multiple

여러 출처에서 정리한 지식을 저장해 두는 것은 바탕이 되는 디지털 조수의 재현성과 점진적 갱신에 매우 중요하다. 기본 RAG와 달리 GraphAide는 문맥 지식을 벡터 데이터베이스와 그래프 데이터베이스 양쪽에 저장한다. III-A절에서 논한 대로 나누고 조각낸 뒤, 원천 자료는 문서 모음으로 바뀌고, 각 문서는 사용자 질의에 답하는 데 쓰는 지식의 최소 단위가 된다. RAG 기반 LLM 응용에서 임베딩 기반 의미 유사도는 핵심 기능이다. 임베딩은 정보를 수치로 나타낸 것이며, 뜻이 비슷한 내용은 임베딩 공간에서 서로 가까이 놓인다. GraphAide는 벡터 데이터베이스에 분야 참조 자료나 WikiData[16] 같은 범용 지식베이스의 임베딩을 저장한다. GraphAide는 자료를 벡터 데이터베이스에 적재하고 나중에 쓰도록 로컬에 저장하는 간단한 API를 제공한다. GraphAide의 새로운 점은 그래프 데이터베이스를 써서 추가적인 구조 정보를 저장한다는 데 있다. GraphAide의 API는 분야에 맞는 그래프 모델링과 그래프 저장 기능을 제공한다. 그래프 데이터베이스는 이후 단계에서 검색 작업의 성능을 높이는 데 쓰인다.

C. 지식그래프 생성

Generation of an ontology-guided Knowledge Graph

이질적인 출처에서 온톨로지에 따른 지식그래프(KG)를 생성하는 것은 GraphAide의 핵심 기여 가운데 하나다. GraphAide는 개체명 추출, 관계 추출, 개체 구분, KG 부호화, KG 유지 같은 작업을 지원하는 KG 생성 단계를 정의한다. 프롬프트에 예시 몇 개를 넣는 방식(few-shot)으로 LLM에 지식그래프를 생성하도록 지시한다. GraphAide는 생성 단계의 입력으로 온톨로지 또는 노드·엣지 유형 목록을 동적으로 고를 수 있게 한다. 이것이 LLM의 응답 형식을 제한해, 주어진 입력 글에 대해 속성이 붙은 부분 그래프를 생성하게 한다. KG 생성 단계에서 질의의 예는 뉴스 기사 같은 비정형 출처의 한 문단이 될 수 있다. GraphAide는 주석 기반 형식 검사기인 Pydantic[17]을 써서 KG 생성 단계 전체에서 생성된 부분 그래프의 일관성을 유지한다.

D. 부분 그래프 질의 생성

GraphAide's query phase begins with a natural

GraphAide의 질의 단계는 그림 1에 보인 대로 자연어 사용자 질의에서 시작한다. 사용자 질의는 불완전하고 부정확한 경우가 많아, 벡터 데이터베이스를 쓸 때 검색 정확도와 관련성이 떨어질 수 있다. 희소 검색에서 질의와 문서가 어긋나는 문제에 대해, LLM 기반 질의 확장이 이를 완화하는 것으로 나타났다[18]. GraphAide는 비슷한 접근을 임베딩 기반 밀집 검색에 적용한다. 틀 기반 방법으로, 원래 질의에 언급된 핵심 개체와 관계는 유지하면서 입력 질의의 다른 판들을 추가로 생성한다. 이어서 GraphAide는 그림 1에 나타낸 것처럼 LLM을 활용해 확장된 질의 묶음을 속성이 붙은 부분 그래프 매칭 틀로 바꾼다. 표현력이 좋은 부분 그래프 매칭과 벡터 기반 의미 유사도를 결합해 GraphAide는 검색 정확도를 높인다. GraphAide API는 Neo4J[19] 같은 흔히 쓰는 그래프 데이터베이스를 지원하며, 확장된 질의 묶음에 대해 Cypher 질의를 자동 생성할 수 있다. 또한 GraphAide API는 사용자 정의 스키마에 기반한 분야별 그래프 자료 모델에 대한 질의를 생성하는 여러 프롬프트 틀을 제공한다.

E. 지표와 평가

Evaluation of a comprehensive GenAI application

여러 구성요소(즉 에이전트)를 가진 종합적인 생성형 AI 응용을 평가하려면 관련된 정량 지표의 모음이 필요하다. 지표 하나로는 모든 구성요소의 성능을 설명하기에 부족한 경우가 많기 때문이다. 또한 각 에이전트의 기능, 역할, 처리하는 자료의 종류에 따라 알맞은 지표를 찾아야 한다. GraphAide의 두 단계는 모두 여러 하위 문제를 포함하며, 표 I에 보인 대로 각각 요구되는 지표가 다르다. GraphAide는 RAGAS[20]를 활용해 평가 자료를 준비하고 관련된 정량 지표 모음을 계산한다. 향후 연구는 평가 자료와 지표를 자동 생성하는 API 개발에 초점을 둘 것이다. 또한

표 I: GraphAide 구성요소별 지표

개체 언급 추출: 답 정확도
의미 주석: 문맥 관련성, 문맥 정확도, 답 관련성, 답 정확도, 의미 유사도
개체 구분: 문맥 정밀도, 문맥 재현율, ROC 곡선
질의 확장: 답 관련성
그래프 질의 생성: 답 정확도, 답 관련성

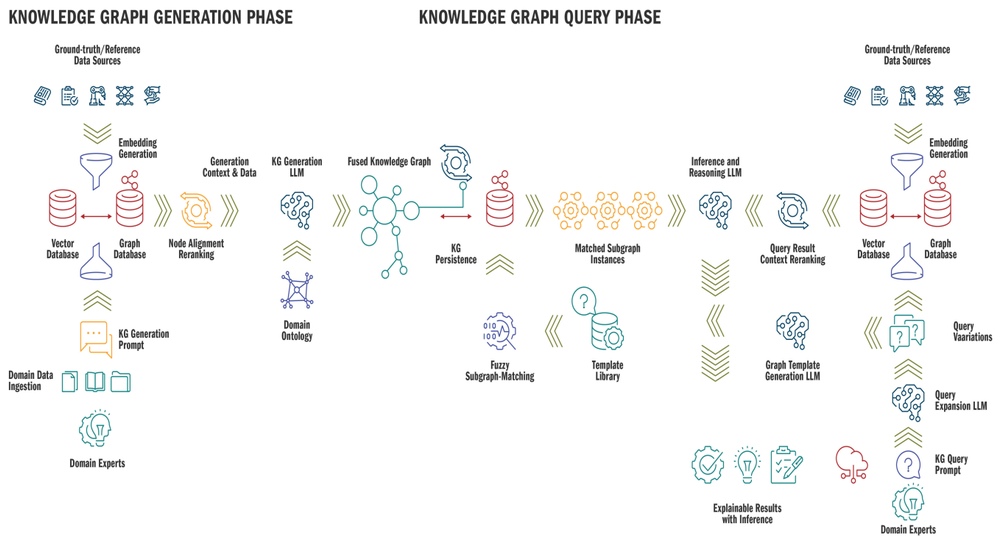


Fig. 1: GraphAide Architecture, representing different phases and agentic workflow

qualitative metrics are required to evaluate generated responses in application domains with a *human-in-the-loop* approach. GraphAide provides methods to configure different retrieval and LLM models, producing comparable results for subject matter expert (SME) evaluation. Examples of different metrics are presented in section IV.

F. Explainable Result Generation

GraphAide simplifies the execution of the templates generated in section III-D for a given graph database and facilitates subgraph matching. It offers an API to combine subgraph matching results with vector-based semantic similarity, creating a local context for the LLM during the query phase. Unlike the KG-generation phase, the query phase uses templates to summarize and explain results from multiple retrieval sources, rather than focusing on entity disambiguation. GraphAide executes multiple parallel requests to the LLM for the expanded query set and makes a secondary call to aggregate all the responses, generating a single coherent response for the user query. Auto-generation of complex templates with multiple constraints and clauses is a part of our future work. We plan to use a few-shot prompt approach to enhance the template generation process.

IV. Experiment

For our experiment, we instantiated GraphAide using OpenAI LLM, Chroma vector database, Neo4j graph database, and LangChain application development framework. We used GPT-4o model that has larger context window and improved reasoning and deduction capabilities. GPT-4o has also shown improved multi-lingual support and that makes it relevant for our use case discussed below. We leveraged the work of two existing DARPA efforts. Active Interpretation of Disparate Alternatives (AIDA) [21] developed multi-hypothesis semantic engines to generates and understand different interpretations of events, situations, and trends from a variety of unstructured sources. Generating Alternative Interpretations for Analysis (GAIA) [22] developed automated solutions to extract entities, emerging events, situations, and trends of interest for Ukraine-Russia political conflict scenario. An ontology [23] is also constructed containing approximately 190 entity types, 140 event types, and 50 relation types. A DARPA version of WikiData (DWD) is also developed as a reference knowledge base for the entity disambiguation process focused on geopolitical scenarios.

To demonstrate GraphAide's capabilities, we used AIDA source data in text format and a Web Ontology Language (OWL) ontology in Terse RDF Triple Language (TURTLE)

Authorized licensed use limited to: Kookmin University. Downloaded on August 31,2026 at 11:15:48 UTC from IEEE Xplore. Restrictions apply.

해석 (p.4)

메모

qualitative metrics are required to evaluate

(앞 쪽에서 이어짐) 사람이 참여하는 방식으로 응용 분야에서 생성된 응답을 평가하려면 정성 지표가 필요하다. GraphAide는 서로 다른 검색 모델과 LLM 모델을 설정하는 방법을 제공해, 분야 전문가(SME) 평가를 위한 비교 가능한 결과를 만든다. 여러 지표의 예는 IV절에 제시한다.

F. 설명 가능한 결과 생성

GraphAide simplifies the execution of the templates

GraphAide는 III-D절에서 생성한 틀을 주어진 그래프 데이터베이스에서 실행하는 일을 단순하게 하고 부분 그래프 매칭을 돕는다. 부분 그래프 매칭 결과와 벡터 기반 의미 유사도를 결합해, 질의 단계에서 LLM을 위한 국소 문맥을 만드는 API를 제공한다. KG 생성 단계와 달리 질의 단계는 개체 구분에 초점을 두지 않고, 틀을 써서 여러 검색 출처의 결과를 요약하고 설명한다. GraphAide는 확장된 질의 묶음에 대해 LLM에 여러 요청을 병렬로 실행하고, 한 번 더 호출해 모든 응답을 모아 사용자 질의에 대한 하나의 일관된 응답을 생성한다. 여러 제약과 절을 가진 복잡한 틀을 자동 생성하는 것은 향후 연구의 일부다. 우리는 예시 몇 개를 넣는 프롬프트 접근으로 틀 생성 과정을 개선할 계획이다.

IV. 실험

For our experiment, we instantiated GraphAide

실험을 위해 우리는 OpenAI LLM, Chroma 벡터 데이터베이스, Neo4j 그래프 데이터베이스, LangChain 응용 개발 프레임워크로 GraphAide를 구현했다. 문맥 창이 더 크고 추론·연역 능력이 향상된 GPT-4o 모델을 썼다. GPT-4o는 다국어 지원도 개선되어 아래에서 논할 우리 사용 사례에 적합하다. 우리는 기존 DARPA 사업 두 가지의 성과를 활용했다. AIDA(Active Interpretation of Disparate Alternatives)[21]는 다양한 비정형 출처에서 사건, 상황, 추세에 대한 서로 다른 해석을 생성하고 이해하는 다중 가설 의미 엔진을 개발했다. GAIA(Generating Alternative Interpretations for Analysis)[22]는 우크라이나·러시아 정치 분쟁 시나리오에 대해 개체, 새로 나타나는 사건, 상황, 관심 추세를 추출하는 자동화 해법을 개발했다. 약 190개의 개체 유형, 140개의 사건 유형, 50개의 관계 유형을 담은 온톨로지[23]도 구축되어 있다. 지정학 시나리오에 초점을 둔 개체 구분 과정의 참조 지식베이스로 DARPA판 WikiData(DWD)도 개발되어 있다.

To demonstrate GraphAide's capabilities, we used

GraphAide의 기능을 보이기 위해, 우리는 글 형식의 AIDA 원천 자료와 TURTLE(Terse RDF Triple Language) 형식의 OWL(Web Ontology Language) 온톨로지를 써서 KG를 생성했다.

그림 1

GraphAide의 구조. 여러 단계와 에이전트 작업 흐름을 나타낸다.

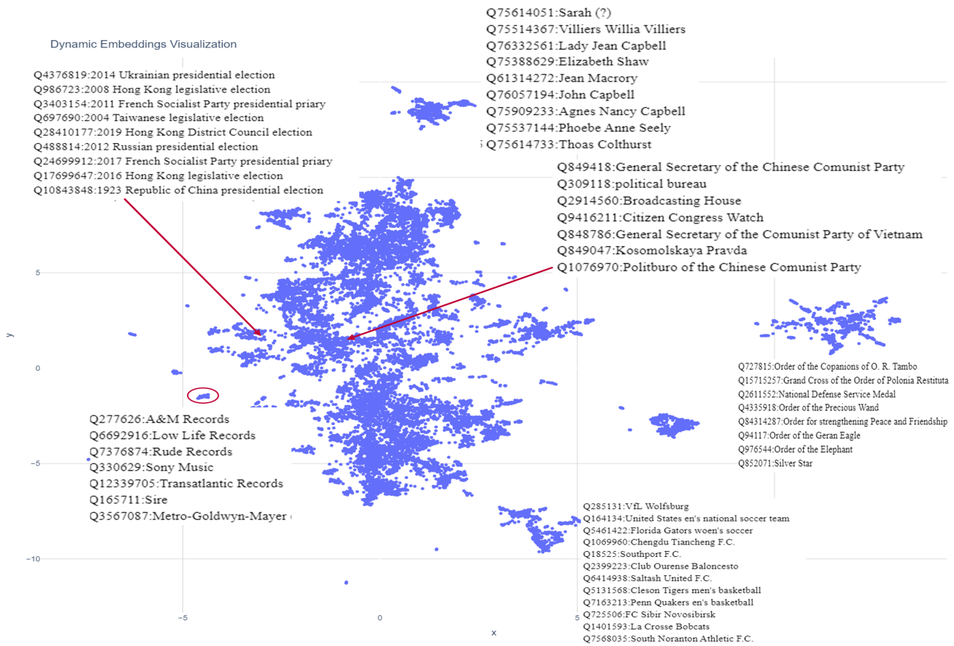


Fig. 2: DARPA WikiData (DWD) Embeddings Used in Retrieval

format to generate a KG. We evaluated the quality of the generated KG by comparing it with a GAIA-generated KG. We also used DWD as a reference knowledge base, stored in Chroma vector database for retrieval during KG generation phase. We curated natural language description of DWD identifiers (i.e., QIDs) and constructed *documents* to store in the vector database. We use QIDs as the document identifier and use LLMs to disambiguate mentions to top-ranked QID. GraphAide also generate UMAP embeddings of vector database to visualize the clusters of topics discussed in the KG, as shown in Figure 2. The embeddings display distinct clusters of concepts such as music, sports, politics, etc. Additionally, they show high similarity between named entities, which is used in the entity disambiguation process. Future work will also incorporate the temporal properties of these named entities to perform disambiguation during the KG generation phase.

GraphAide's *generation* phase processed 1,846 news articles and generated a KG, as shown in Figure 3. An ontology-guided and DWD-based disambiguation agent extracts entity mentions from the text and performs RAG-based node re-ranking to identify the closest matched QID. GraphAide iteratively performed text chunking, generated partial KGs from the given chunks, and loaded them into the Neo4j graph database.

In contrast to the basic RAG, GraphAide's KG-based hybrid-RAG approach provides higher specificity and cross-document inference to construct a richer context for LLM queries. Additionally, GraphAide's modular design allows dynamic selection from multiple retrieval sources for benchmarking purposes. We performed a qualitative evaluation of the generated responses in each phase. For the generation phase, LLM query templates were designed to extract natural language mentions from the input text, perform entity disambiguation using DWD, and perform type assignment (nodes and edges) based on the input ontology. As shown in Figure 3, the KG schema is constrained by the domain-specific ontology. The resulting KG has demonstrated better NER and relation extraction quality than the baseline KG [22], [24]. An extracted node type follows a hierarchical schema to represent the most specific concept about the node. For example, $GPE_UrbanArea_City$ represents a class $City$, which is a subclass of an urban area, itself a subclass of a geopolitical entity. Similarly, $ConflictAttack_FirearmAttack$ represents an attack event related to some conflict that involves firearms. As shown in Figure 5, the baseline KG shows a node type imbalance, where the most frequently extracted type is "PER" and the rest of the node types constitute a small fraction of semantic annotations. Similarly, non-binary relationship

Authorized licensed use limited to: Kookmin University. Downloaded on August 31,2026 at 11:15:48 UTC from IEEE Xplore. Restrictions apply.

해석 (p.5)

메모

format to generate a KG. We evaluated

(앞 쪽에서 이어짐) 우리는 생성한 KG의 품질을 GAIA가 생성한 KG와 비교해 평가했다. 또한 DWD를 참조 지식베이스로 쓰고, KG 생성 단계에서 검색할 수 있도록 Chroma 벡터 데이터베이스에 저장했다. DWD 식별자(QID)의 자연어 설명을 정리하고, 벡터 데이터베이스에 저장할 문서를 구성했다. QID를 문서 식별자로 쓰고, LLM으로 언급을 가장 순위가 높은 QID에 대응시켜 개체를 구분했다. GraphAide는 그림 2에 보인 대로 벡터 데이터베이스의 UMAP 임베딩도 생성해 KG에서 다루는 주제의 군집을 시각화한다. 임베딩은 음악, 스포츠, 정치 같은 개념의 뚜렷한 군집을 보여 준다. 또한 개체명 사이의 높은 유사도를 보여 주며, 이것이 개체 구분 과정에 쓰인다. 향후 연구에서는 KG 생성 단계에서 이 개체명들의 시간 속성도 반영해 개체를 구분할 것이다.

generation phase processed 1,846 news articles

GraphAide의 생성 단계는 뉴스 기사 1,846건을 처리해 그림 3에 보인 KG를 생성했다. 온톨로지에 따르고 DWD에 기반한 개체 구분 에이전트가 글에서 개체 언급을 추출하고, RAG 기반으로 노드 순위를 다시 매겨 가장 가깝게 맞는 QID를 찾는다. GraphAide는 글 조각내기, 주어진 조각에서 부분 KG 생성, Neo4j 그래프 데이터베이스에 적재를 반복해서 수행했다.

In contrast to the basic RAG

기본 RAG와 달리, GraphAide의 KG 기반 혼합 RAG 접근은 더 높은 구체성과 문서를 넘나드는 추론을 제공해 LLM 질의에 더 풍부한 문맥을 구성한다. 또한 GraphAide의 모듈식 설계는 성능 비교를 위해 여러 검색 출처 가운데서 동적으로 고를 수 있게 한다. 우리는 각 단계에서 생성된 응답을 정성적으로 평가했다. 생성 단계에서는 LLM 질의 틀을 설계해 입력 글에서 자연어 언급을 추출하고, DWD로 개체를 구분하고, 입력 온톨로지에 따라 유형(노드와 엣지)을 부여했다. 그림 3에 보인 대로 KG 스키마는 분야 온톨로지로 제약된다. 결과로 나온 KG는 기준 KG[22], [24]보다 개체명 인식과 관계 추출의 품질이 더 좋았다. 추출된 노드 유형은 계층적 스키마를 따라 그 노드에 대한 가장 구체적인 개념을 나타낸다. 예를 들어 GPE_UrbanArea_City는 클래스 City를 나타내며, 이는 도시 지역의 하위 클래스이고, 도시 지역은 지정학적 개체의 하위 클래스다. 비슷하게 ConflictAttack_FirearmAttack은 어떤 분쟁과 관련된, 화기가 쓰인 공격 사건을 나타낸다. 그림 5에 보인 대로 기준 KG는 노드 유형의 불균형을 보인다. 가장 자주 추출된 유형은 "PER"이고 나머지 노드 유형은 의미 주석의 작은 부분만 차지한다. 비슷하게, 이항이 아닌 관계

그림 2

검색에 쓰인 DARPA WikiData(DWD) 임베딩

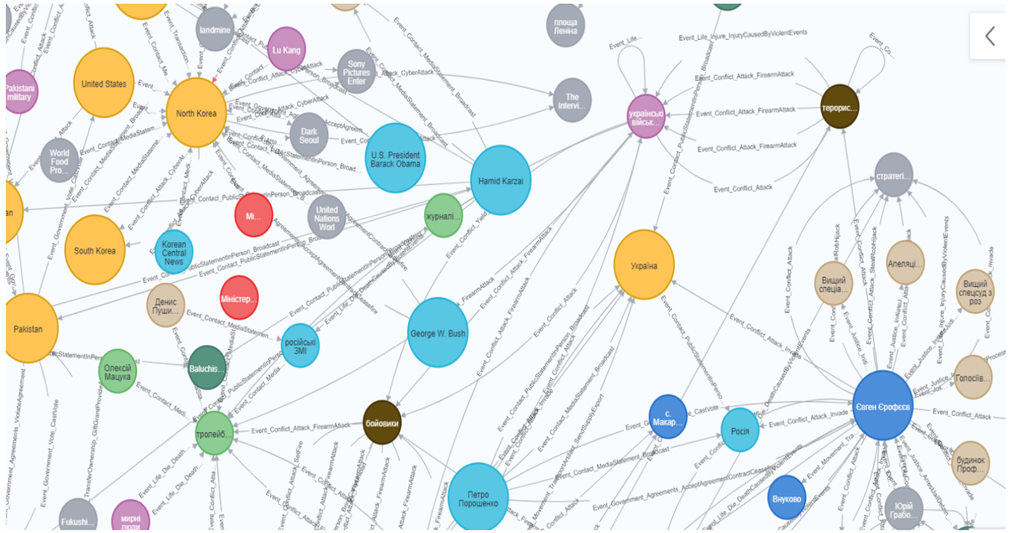


Fig. 3: GraphAide generated KG from News Sources

types such as “Evaluate” and “GeneralAffiliation” dominate the relationship extraction. In contrast, GraphAide extracts a more diverse and dense node type distribution, as shown in Figure 4. Similarly, for the edge types, GraphAide performs better in extracting event-based types, given the input data describes many temporal events.

We evaluated the semantic annotation process of assigning node types using answer relevancy, answer correctness, and semantic similarity metrics, leveraging the RAGAS library. As shown in figure 6, we observed some anomalous node type assignments that cannot be explained using answer relevancy or correctness alone. In such cases, semantic similarity can be used to explain the assignment made by the LLM, as discussed next.

For a user input “The Illinois Traction Building serves dual functions as both a railway terminal and commercial structure in Champaign, USA. The architectural design allows for its dual functionality. As such, the building is a marked example of multi-use infrastructure in the region.”, answer correctness is measured as 0.230700, but further evaluation reveals that the LLM’s prediction about this node, *FAC.Building, ORG.Government.Railway*, is semantically similar to the ground truth, *FAC.Building.OfficeBuilding, FAC.Installation.TrainStation*, which leads to a high semantic similarity of 0.922801.

In the query phase, we used GraphAide to analyze the input data from multiple sources and provide responses to user queries that rely upon the curated knowledge, providing contextual information to the LLM. To demonstrate GraphAide’s modularity, we set up a pipeline to use different levels of augmentation in responding to user queries. In addition to using OpenAI’s GPT-4o as the baseline LLM, we also utilized WikiData, a domain-specific dataset, and an enriched KG from the domain-specific dataset to answer user queries. For the qualitative evaluation of the generated responses, we compared outputs from different augmentation levels. As shown in Figure 7, the specificity of the generated response increases as we enrich the *context* shared with LLMs. Figure 7 shows that a direct query to the LLM endpoint may fail to provide a relevant response either because the LLM is not trained on data about the specific fact or because the fact is more recent than the LLM’s cutoff date. Using a reference KB may improve the response as it grounds the user query into a set of disambiguated entities. Additionally, the use of domain-specific ground-truth documents enables sharing the provenance of the generated response. As shown in Figure 7, the AIDA document corpus contains ground-truth related to the query and allows the LLM to provide a highly relevant response. Taking this a step further, the KG-based retrieval improves *context relevancy* by including entities and concepts spread across documents in the corpus. Entities such as “Donetsk People’s Republic” and “Russian Volunteer” are not necessarily mentioned in the same document in the vector database but are rather connected through a subgraph. The context generated from the subgraph is crucial for the LLM to generate additional evidence and explanations in the response. In addition to the qualitative evaluation based on user feedback, we have also identified individual components of GraphAide suitable for quantitative evaluation to measure the impact of the domain ontology and reference knowledge base. Future work will leverage

Authorized licensed use limited to: Kookmin University. Downloaded on August 31,2026 at 11:15:48 UTC from IEEE Xplore. Restrictions apply.

해석 (p.6)

types such as “Evaluate” and “GeneralAffiliation”

(앞 쪽에서 이어짐) 유형인 "Evaluate"와 "GeneralAffiliation"이 관계 추출의 대부분을 차지한다. 반면 GraphAide는 그림 4에 보인 대로 더 다양하고 조밀한 노드 유형 분포를 추출한다. 엣지 유형에서도, 입력 자료가 시간에 따른 사건을 많이 서술하고 있는 만큼, GraphAide는 사건 기반 유형을 더 잘 추출한다.

We evaluated the semantic annotation process

우리는 RAGAS 라이브러리를 활용해 답 관련성, 답 정확도, 의미 유사도 지표로 노드 유형을 부여하는 의미 주석 과정을 평가했다. 그림 6에 보인 대로, 답 관련성이나 정확도만으로는 설명할 수 없는 이상한 노드 유형 부여가 몇 건 관찰되었다. 그런 경우에는 다음에 논하는 것처럼 의미 유사도로 LLM의 부여를 설명할 수 있다.

For a user input “The Illinois Traction Building

사용자 입력 "일리노이 트랙션 빌딩은 미국 샘페인에서 철도 터미널과 상업 건물의 두 가지 기능을 한다. 건축 설계가 이 이중 기능을 가능하게 한다. 그래서 이 건물은 이 지역의 다용도 기반시설의 두드러진 예다."에 대해 답 정확도는 0.230700으로 측정된다. 그러나 더 살펴보면 이 노드에 대한 LLM의 예측인 FAC.Building, ORG.Government.Railway가 정답인 FAC.Building.OfficeBuilding, FAC.Installation.TrainStation과 의미상 비슷해, 의미 유사도는 0.922801로 높게 나온다.

In the query phase, we used GraphAide to analyze

질의 단계에서 우리는 GraphAide로 여러 출처의 입력 자료를 분석하고, 정리된 지식에 의존하는 사용자 질의에 응답하면서 LLM에 문맥 정보를 제공했다. GraphAide의 모듈성을 보이기 위해, 사용자 질의에 응답할 때 서로 다른 수준의 보강을 쓰는 파이프라인을 구성했다. OpenAI의 GPT-4o를 기준 LLM으로 쓰는 것에 더해, WikiData, 분야 자료, 그리고 그 분야 자료에서 만든 보강된 KG도 사용자 질의에 답하는 데 활용했다. 생성된 응답의 정성 평가를 위해 서로 다른 보강 수준의 출력을 비교했다. 그림 7에 보인 대로, LLM과 공유하는 문맥을 풍부하게 할수록 생성된 응답의 구체성이 높아진다. 그림 7은 LLM에 직접 질의하면 관련된 응답을 내지 못할 수 있음을 보여 준다. LLM이 그 사실에 대한 자료로 학습되지 않았거나, 그 사실이 LLM의 학습 기준일보다 최근이기 때문이다. 참조 지식베이스를 쓰면 사용자 질의를 구분된 개체들에 근거하게 하므로 응답이 나아질 수 있다. 또한 분야의 정답 문서를 쓰면 생성된 응답의 출처를 함께 제시할 수 있다. 그림 7에 보인 대로 AIDA 문서 말뭉치는 질의와 관련된 정답을 담고 있어 LLM이 관련성이 높은 응답을 내게 한다. 한 걸음 더 나아가, KG 기반 검색은 말뭉치의 여러 문서에 흩어진 개체와 개념을 포함시켜 문맥 관련성을 높인다. "도네츠크 인민공화국"과 "러시아 의용군" 같은 개체는 벡터 데이터베이스의 같은 문서에 반드시 함께 언급되는 것이 아니라 부분 그래프로 연결되어 있다. 부분 그래프에서 생성한 문맥은 LLM이 응답에 추가 증거와 설명을 생성하는 데 매우 중요하다. 사용자 의견에 기반한 정성 평가에 더해, 우리는 분야 온톨로지와 참조 지식베이스의 영향을 측정하기 위해 정량 평가에 알맞은 GraphAide의 개별 구성요소도 찾아냈다. 향후 연구는

그림 3

GraphAide가 뉴스 출처에서 생성한 KG

메모

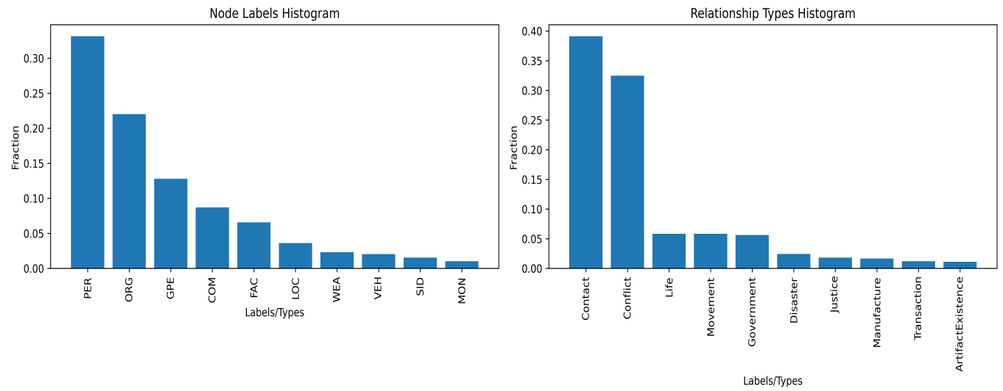


Fig. 4: Type Distributions (Top-10) of GraphAide generated KG

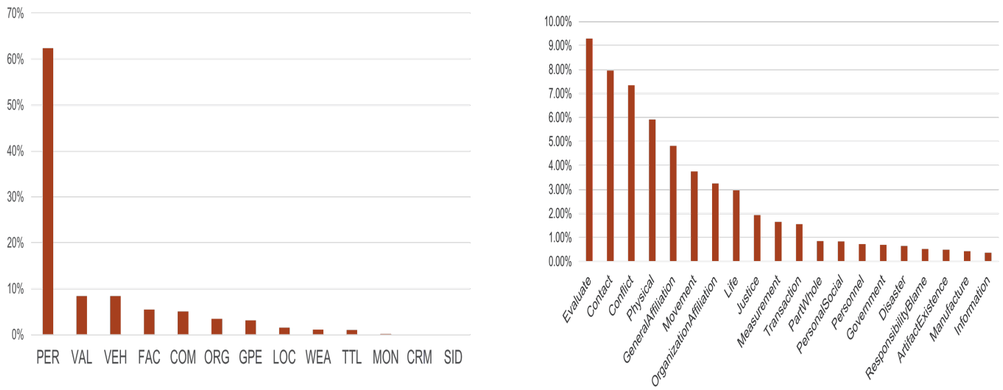


Fig. 5: Type Distributions of Baseline KG. Node (left), Relationship (right)

quantitative metrics such as precision, recall, and retrieval relevancy to measure improvements in entity disambiguation, semantic type assignment, and KG generation tasks for a KG-based hybrid RAG.

V. Conclusion

Large Language Models (LLMs) offer exciting opportunities to develop digital assistents for domain-specific tasks. Advanced Retrieval Augmentation Generation (RAG) addresses explainability, scalability, and usability concerns in using LLMs and increases user confidence in the technology adoption. We present GraphAide, that leverages knowledge graph and subgraph matching capabilities to improve the accuracy of RAG-based applications. We present the reference architecture and its key components. We also demonstrate an instance of GraphAide to generate a Knowledge Graph (KG) from news articles describing historical ukraine-russian political conflict scenario. Future work will focus on formal evaluation to report quantitative improvements in metrics such as accuracy and relevancy.

Acknowledgement

The research described in this paper is partially supported by the Resilience Through Data Driven, Intelligently Designed Control (RD2C) Initiative at Pacific Northwest National Laboratory (PNNL) and the United States federal government. Pacific Northwest National Laboratory is a multiprogram national laboratory operated for the US Department of Energy (DOE) by Battelle Memorial Institute under Contract No. DE-AC05-76RL01830. PNNL Information Release PNNL-SA-205147.

Authorized licensed use limited to: Kookmin University. Downloaded on August 31,2026 at 11:15:48 UTC from IEEE Xplore. Restrictions apply.

해석 (p.7)

메모

quantitative metrics such as precision, recall

(앞 쪽에서 이어짐) 정밀도, 재현율, 검색 관련성 같은 정량 지표를 활용해, KG 기반 혼합 RAG의 개체 구분, 의미 유형 부여, KG 생성 작업에서의 개선을 측정할 것이다.

V. 결론

Large Language Models (LLMs) offer exciting

대규모 언어모델(LLM)은 분야 특화 작업을 위한 디지털 조수를 개발할 좋은 기회를 준다. 고급 검색 증강 생성(RAG)은 LLM을 쓸 때의 설명 가능성, 확장성, 사용성 우려를 해결하고, 기술 도입에 대한 사용자의 신뢰를 높인다. 우리는 지식그래프와 부분 그래프 매칭 기능을 활용해 RAG 기반 응용의 정확도를 높이는 GraphAide를 제시한다. 참조 구조와 그 주요 구성요소를 제시한다. 또한 GraphAide의 한 구현으로, 과거 우크라이나-러시아 정치 분쟁 시나리오를 서술한 뉴스 기사에서 지식그래프(KG)를 생성하는 것을 보인다. 향후 연구는 정확도와 관련성 같은 지표의 정량적 개선을 보고하는 정식 평가에 초점을 둘 것이다.

감사의 글

The research described in this paper is partially

이 논문에 기술한 연구는 퍼시픽 노스웨스트 국립연구소(PNNL)의 RD2C(Resilience Through Data Driven, Intelligently Designed Control) 사업과 미국 연방정부의 일부 지원을 받았다. PNNL은 미국 에너지부(DOE)를 위해 바텔 기념 연구소가 계약 번호 DE-AC05-76RL01830에 따라 운영하는 다목적 국립연구소다. PNNL 정보 공개 번호 PNNL-SA-205147.

그림 4, 그림 5

그림 4: GraphAide가 생성한 KG의 유형 분포(상위 10개)
그림 5: 기준 KG의 유형 분포. 노드(왼쪽), 관계(오른쪽)

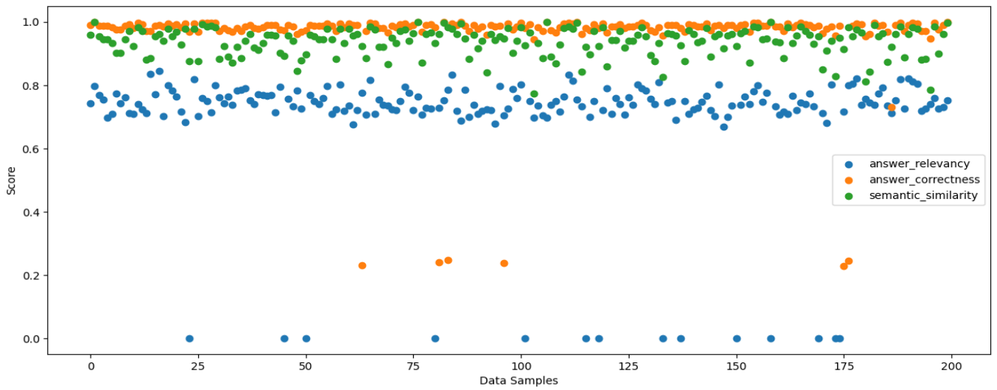


Fig. 6: Evaluation of Semantic Annotation Process

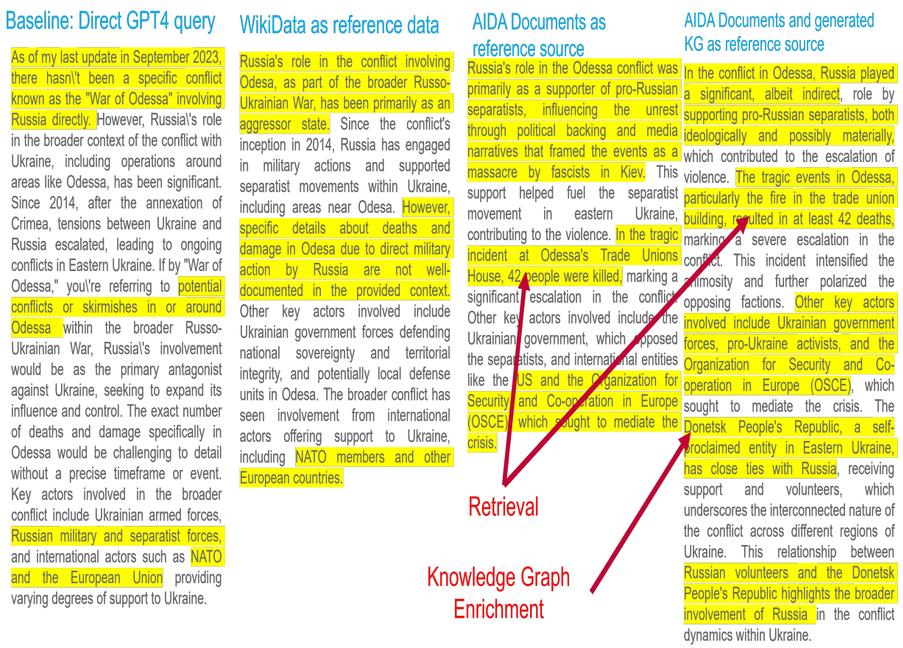


Fig. 7: GraphAide results for a user query 'Describe the role of Russia in the of war of Odessa in 100 words and list how many deaths and damage happened there. Also list other key actors involved.'

REFERENCES

[1] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell *et al.*, "Language models are few-shot learners," *Advances in neural information processing systems*, vol. 33, pp. 1877–1901, 2020.

[2] T. Zhang, F. Ladhak, E. Durmus, P. Liang, K. McKeown, and T. B. Hashimoto, "Benchmarking large language models for news summarization," *Transactions of the Association for Computational Linguistics*,

Authorized licensed use limited to: Kookmin University. Downloaded on August 31,2026 at 11:15:48 UTC from IEEE Xplore. Restrictions apply.

해석 (p.8)

그림 6, 그림 7

그림 6: 의미 주석 과정의 평가
그림 7: 사용자 질의 "오데사 전투에서 러시아의 역할을 100단어로 서술하고, 거기서 발생한 사망자 수와 피해를 나열하라. 관련된 다른 주요 행위자도 나열하라."에 대한 GraphAide의 결과

참고문헌

(8~9쪽은 참고문헌 목록이라 해석하지 않음)

메모

vol. 12, pp. 39–57, 2024.
[3] T. Berners-Lee, J. Hendler, and O. Lassila, “The semantic web: A new form of web content that is meaningful to computers will unleash a revolution of new possibilities,” in *Linking the World’s Information: Essays on Tim Berners-Lee’s Invention of the World Wide Web*, 2023, pp. 91–103.
[4] C. Bizer, T. Heath, and T. Berners-Lee, “Linked data-the story so far,” in *Linking the World’s Information: Essays on Tim Berners-Lee’s Invention of the World Wide Web*, 2023, pp. 115–143.
[5] A. Bosselut, H. Rashkin, M. Sap, C. Malaviya, A. Celikyilmaz, and Y. Choi, “Comet: Commonsense transformers for automatic knowledge graph construction,” *arXiv preprint arXiv:1906.05317*, 2019.
[6] J.-Y. Yao, K.-P. Ning, Z.-H. Liu, M.-N. Ning, and L. Yuan, “Llm lies: Hallucinations are not bugs, but features as adversarial examples,” *arXiv preprint arXiv:2310.01469*, 2023.
[7] N. McKenna, T. Li, L. Cheng, M. J. Hosseini, M. Johnson, and M. Steedman, “Sources of hallucination by large language models on inference tasks,” *arXiv preprint arXiv:2305.14552*, 2023.
[8] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel *et al.*, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
[9] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, and H. Wang, “Retrieval-augmented generation for large language models: A survey,” *arXiv preprint arXiv:2312.10997*, 2023.
[10] D. Edge, H. Trinh, N. Cheng, J. Bradley, A. Chao, A. Mody, S. Truitt, and J. Larson, “From local to global: A graph rag approach to query-focused summarization,” *arXiv preprint arXiv:2404.16130*, 2024.
[11] M. Trajanoska, R. Stojanov, and D. Trajanov, “Enhancing knowledge graph construction using large language models,” *arXiv preprint arXiv:2305.04676*, 2023.
[12] T. Ban, L. Chen, X. Wang, and H. Chen, “From query tools to causal architects: Harnessing large language models for advanced causal discovery from data,” *arXiv preprint arXiv:2306.16902*, 2023.
[13] P. Gage, “A new algorithm for data compression,” *The C Users Journal*, vol. 12, no. 2, pp. 23–38, 1994.
[14] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever *et al.*, “Language models are unsupervised multitask learners,” *OpenAI blog*, vol. 1, no. 8, p. 9, 2019.
[15] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, “Dense passage retrieval for open-domain question answering,” *arXiv preprint arXiv:2004.04906*, 2020.
[16] D. Vrandečić and M. Krötzsch, “Wikidata: a free collaborative knowledgebase,” *Communications of the ACM*, vol. 57, no. 10, pp. 78–85, 2014.
[17] S. Colvin, “Pydantic,” 2023, version 2.x. [Online]. Available: https://github.com/pydantic/pydantic
[18] M. A. K. Ayoub, Z. Su, and Q. Li, “A case study of enhancing sparse retrieval using llms,” in *Companion Proceedings of the ACM on Web Conference 2024*, 2024, pp. 1609–1615.
[19] Neo4j, Inc., *Neo4j Graph Database*, Neo4j, Inc., San Mateo, CA, 2024, available at: https://neo4j.com. [Online]. Available: https://neo4j.com
[20] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, “Ragas: Automated evaluation of retrieval augmented generation,” *arXiv preprint arXiv:2309.15217*, 2023.
[21] “Active interpretation of disparate alternatives (aida),” https://www.darpa.mil/program/active-interpretation-of-disparate-alternatives, accessed: 2024-10-09.
[22] T. Zhang, A. Subburathinam, G. Shi, L. Huang, D. Lu, X. Pan, M. Li, B. Zhang, Q. Wang, S. Whitehead *et al.*, “Gaia-a multi-media multilingual knowledge extraction and hypothesis generation system.” in *TAC*, 2018.
[23] Next Century Corporation, “Aida interchange format,” https://github.com/NextCenturyCorporation/AIDA-Interchange-Format, 2023, accessed: 2024-10-09.
[24] S. Purohit, N. Van, and G. Chin, “Semantic property graph for scalable knowledge graph analytics,” in *2021 IEEE International Conference on Big Data (Big Data)*, 2021, pp. 2672–2677.

Authorized licensed use limited to: Kookmin University. Downloaded on August 31,2026 at 11:15:48 UTC from IEEE Xplore. Restrictions apply.

해석 (p.9)

메모