GraphAide: Advanced Graph-Assisted Query and Reasoning System — 문단별 해석

Purohit, S., Chin, G., Mackey, P. S., & Cottam, J. A. (2024). 2024 IEEE International Conference on Big Data (BigData), 3485–3493.
문단마다 회색 글씨는 원문 문단의 첫머리이고, 그 아래가 해석이다. 쪽 번호는 원문 PDF의 쪽이다.

원문 1쪽

제목·저자

GraphAide: 그래프를 활용한 고급 질의·추론 시스템
Sumit Purohit, George Chin, Patrick S Mackey, Joseph A Cottam
퍼시픽 노스웨스트 국립연구소(PNNL), 미국 워싱턴주 리치랜드
2024 IEEE 빅데이터 국제학술대회(BigData)

초록 (Abstract)

Curating knowledge from multiple siloed sources
정형 자료와 비정형 자료가 섞여 있고 서로 떨어져 있는 여러 출처에서 지식을 모아 정리하는 일은 많은 실제 응용에서 큰 과제다. 패턴 매칭과 질의는 이렇게 정리한 지식을 활용하는 현대 데이터 분석의 기본 작업이다. 이런 응용을 개발하려면 자료 추출, 개체명 인식, 자료 모델링, 질의 인터페이스 설계 등 여러 연구 과제를 풀어야 한다. 또한 이런 기능이 널리 쓰이려면 설명 가능성이 매우 중요하다.

The emergence of Large Language Models
대규모 언어모델(LLM)의 등장으로 새 기능을 개발하는 주기가 빨라졌다. 그래도 사용자의 활동에 맞춘 분야 특화 도구는 계속 필요하다. 이런 디지털 조수를 만드는 일은 최근 몇 년 사이 큰 관심을 받았고, LLM은 분야의 지식과 가정을 활용해 그런 조수를 개발할 유망한 길을 열어 준다.

In this context, we introduce an advanced query
이런 맥락에서 우리는 고급 질의·추론 시스템인 GraphAide를 소개한다. GraphAide는 다양한 출처에서 지식그래프(KG)를 구축하고, 그 KG에 질의하고 추론할 수 있게 한다. GraphAide는 KG와 LLM을 함께 활용해 분야 특화 디지털 조수를 빠르게 개발한다. 검색 증강 생성(RAG)과 시맨틱 웹의 설계 방식을 통합해 에이전트형 LLM 응용을 만든다. GraphAide는 전문화된 디지털 조수를 간결하고 효율적으로 개발할 수 있음을 보여 주며, 여러 분야에 걸친 적용 가능성을 높인다.

I. 서론

Large Language Models (LLMs) [1] represent
대규모 언어모델(LLM)[1]은 생성형 인공지능(GenAI)과 기계학습 연구개발의 최전선에 있다. 과학 연구, 공학, 경제학, 사회과학 등 여러 분야에서 매우 빠른 속도로 채택되고 있다. 분야 전문가가 사전 학습된 모델을 바로 쓸 수 있게 되면서, LLM은 응용 개발 과정을 대중화했고 과학과 기술 양쪽에서 혁신을 촉진했다. LLM 기반 응용의 개발은 여전히 활발한 연구 분야이며, 여러 입력 자료에 대한 요약, 연관, 추론 같은 작업에서 뛰어난 성능을 보인다[2].

Knowledge Graphs (KGs) are formal representations
지식그래프(KG)는 핵심 개념을 개체로, 그 사이를 관계로 나타낸 형식적 표현이다[3], [4]. KG는 다양한 사용자 환경에서 기초 참조 지식으로 쓸 수 있는 강력한 도구다. 그러나 KG를 구축하는 데는 입력 자료의 규모, 사용 사례마다 다른 개념의 이질성, 구축에 드는 비용 때문에 큰 어려움이 있다. LLM은 관련 개체를 추출하고 관계를 만드는 데서 더 높은 정확도를 보여 KG 구축에 크게 기여했다[5].

A major challenge in developing accurate

LLM을 바탕으로 정확하고 일관된 기능을 개발할 때의 주요 과제는 환각[6]이다. 환각은 LLM이 사용자 질의에 대해 존재하지 않는 사실을 만들어 낼 때 일어난다. LLM이 학습 자료를 암기하고 이후 말뭉치 기반의 어림짐작에 의존하는 것이 환각의 주요 원인이다[7]. 이 문제를 해결하는 것은 LLM에서 나온 응용의 신뢰성과 신뢰도에 매우 중요하다.

Retrieval-augmented generation (RAG) [8] is

검색 증강 생성(RAG)[8]은 사용자 질의에 대한 응답을 생성할 때 추가 문맥을 제공해 LLM의 환각을 줄이는, 잘 확립된 설계 방식이다. 이 추가 문맥은 분야에 특화된 것이며 모델의 생성 능력에 근거가 된다. 기본적인 RAG 기반 시스템은 분야 지식 말뭉치의 임베딩을 벡터 데이터베이스에 저장하고, 의미 유사도 알고리즘으로 사용자 질의와 관련된 문맥을 찾는다. 의미 유사도 알고리즘은 두 개념의 뜻이 얼마나 가까운지를 잰다. 이 문맥을 사용자 질의와 합쳐 LLM에 보내면, 생성 과정의 안전장치 구실을 한다. RAG 기반 접근은 LLM의 생성 결과를 제공된 문맥의 범위 안으로 제한해 환각을 줄이는 데 효과가 있음을 보였다.

However, a vector search-based method

그러나 벡터 검색 기반 방법은 질의와 말뭉치 사이의 의미 유사도에 제약된다. 말뭉치 안 문서들 사이의 관계, 메타데이터, 관련된 추론 같은 구조적 문맥을 활용하지 못한다. 지식그래프(KG)는 분야 정보를 효율적으로 저장하고 말뭉치의 여러 문서에 흩어진 정보 출처 사이에 관계를 세워 이 한계에 대한 견고한 해법을 준다. KG는 검색, 요약, 추론 등 LLM 기반 응용의 여러 구성요소도 크게 향상시킬 수 있다.

By integrating KGs into the design pattern

KG를 설계 방식에 통합하면 시스템은 의미 문맥과 구조 문맥을 모두 활용할 수 있어, 생성된 응답의 정확성과 일관성이 높아진다. 이 포괄적인 접근은 지식 말뭉치를 더 세밀하게 이해하고 활용하게 해 주며, 환각을 더 줄이고 응용의 전체 성능을 높이는 정교한 전략이 된다.

원문 2쪽

We introduce GraphAide, an advanced capability

우리는 GraphAide를 소개한다. GraphAide는 LLM에 기반한 고급 기능으로, 분야 자료에 대한 통찰을 제공하고 사용자가 자연어로 질문할 수 있게 한다. GraphAide는 LLM, 벡터 데이터베이스, 그래프 데이터베이스 같은 구성요소로 고급 생성형 AI 응용을 개발하는 방법론과 참조 구조를 제시한다. GraphAide는 벡터 데이터베이스와 그래프 데이터베이스를 모두 쓰는, 모듈식이고 확장 가능하며 쓰기 쉬운 RAG 접근을 채택한다. GraphAide의 새로운 점은 생성형 AI와 시맨틱 웹 기술을 통합하는 포괄적인 설계에 있다. GraphAide는 여러 출처의 자료를 정리하고 온톨로지에 따라 지식그래프를 구축해, LLM만 쓰는 기본 응용이 겪는 문제를 해결한다. 이 플랫폼은 효율적인 자료 저장도 제공하며, 자연어 질의응답 인터페이스로 상호작용할 수 있게 한다.

GraphAide combines a robust graph matching

GraphAide는 견고한 그래프 매칭 접근과 벡터 데이터베이스가 제공하는 의미 유사도를 결합해, LLM이 생성한 응답의 정확성과 설명 가능성을 높인다. 확장 가능한 에이전트형 RAG 응용으로 개발된 GraphAide는 자료 적재, 개체 구분, 저장, 질의, 추론 구성요소를 응용의 전 주기에 걸쳐 재사용한다. GraphAide의 주요 기능은 다음과 같다.

• 온톨로지에 따른 지식그래프 구축: .txt, .html, .pdf 등 흔한 자료 형식에서 여러 값, 여러 출처, 시간 속성을 다룬다.

• 임베딩의 생성과 유지: 저장과 검색을 위한 벡터 데이터베이스를 설정하고, 여러 벡터 데이터베이스를 유지하며 사용자 질의에 따라 출처를 동적으로 고른다.

• 틀 기반 온톨로지 설정: 입력 온톨로지를 동적으로 설정하고, 주어진 원천 자료에 대해 여러 판의 KG를 생성할 수 있게 한다.

• 강화된 문맥 생성: 벡터 기반 검색과 그래프 기반 부분 그래프 매칭을 결합해 LLM이 생성한 응답의 관련성을 높인다.

• 외부 함수 실행 기능: 시계열 데이터베이스의 시간 자료 같은 여러 형태의 자료 출처를 가져와 문맥을 풍부하게 한다.

GraphAide represents a significant advancement

GraphAide는 최신 생성형 AI와 시맨틱 기술을 통합해 성능과 확장성을 높인, 분야 특화 디지털 조수 개발의 중요한 진전이다. II절은 관련 연구를 개관하고, III절은 GraphAide의 구조와 주요 구성요소를 자세히 설명한다. IV절은 실제 사용 사례를 보이고 실험 결과와 평가 지표를 제시한다.

II. 관련 연구

The integration of generative artificial intelligence

생성형 인공지능(GenAI)과 시맨틱 기술의 통합은 활발하고 빠르게 커지는 연구 분야다. 기존의 KG 기반 LLM 기능은 특정 응용에 초점을 두는 경우가 많다. 기본 RAG 접근[9]은 비정형 자료를 여러 조각으로 바꾸고, 조각의 임베딩을 만들어 벡터 데이터베이스에 저장한다. 이 임베딩으로 입력된 사용자 질의에 대해 의미 유사도 매칭을 수행해 가장 비슷한 조각을 찾는다. 이 검색 과정이 LLM에 보내는 사용자 질의를 보강할 문맥을 만든다. RAG 접근은 환각, 오래된 지식, 생성된 응답의 설명 가능성 같은 문제에서 유망한 결과를 보였다. 그러나 기본 RAG는 의미 유사도에 의존한다는 한계가 있다.

GraphRAG [10] advances this

GraphRAG[10]는 KG 위에 효율적인 글 색인을 만드는 질의 중심 요약(QFS) 과제를 제시해 이 분야를 발전시켰다. GraphRAG는 커뮤니티 탐지로 그래프 색인을 나누고, 이를 사용자 질의에 대한 "전역적 답"을 만드는 데 쓴다. Trajanoska 등[11]의 연구 같은 다른 접근은 지속가능성 관련 글에서 KG를 만들고, 개체와 관계를 함께 추출하는 전용 모델로 그 품질을 평가하는 데 초점을 둔다. 비슷하게 Ban 등[12]은 인과 구조 학습을 위해 인과 그래프를 추출하는 프롬프트 모음을 소개한다. 이런 접근의 공통 과제는 확장성이 제한된다는 점이다. 최신 오픈소스 응용 개발 프레임워크를 활용하지 않기 때문이다. LLM 기반 응용의 개발과 사용의 여러 단계에서 KG를 더 효과적으로 활용할 기회가 크다.

III. 구조

GraphAide is a retrieval-augmented generation

GraphAide는 여러 LLM 인스턴스와 지식그래프(KG)를 써서 다양한 작업을 수행하는 RAG 기반 시스템이다. 에이전트 기반 LLM 응용은 추론 능력을 활용해 사용자 질의에 대한 적절한 행동 순서를 정한다. 미리 정해 둔 지시(즉 체인)와 달리, 에이전트형 응용은 LLM의 응답을 이해하고 다음 질의를 동적으로 구성할 수 있다. GraphAide는 체인과 에이전트를 모두 활용해 다양한 사용자 질의를 처리하는 혼합형 응용이다. 이 혼합 접근 덕분에 시스템은 폭넓은 사용자 질의를 효과적으로 다루고, 정확하고 문맥에 맞는 응답을 보장한다.

Figure 1 details GraphAide architecture

그림 1은 GraphAide의 구조를 자세히 보여 주며, 서로 다른 작업을 수행하기 위해 온톨로지, 벡터 데이터베이스, 여러 LLM 에이전트를 쓰는 것을 강조한다. GraphAide는 사용자 작업을 완료하는 데 필요한 기능 묶음에 대응하는 단계들을 구분한다. 그림 1에 나타낸 것처럼, 생성 단계는 여러 출처의 정보를 결합해 지식그래프(KG)를 구축하고, 이 KG는 벡터 데이터베이스와 함께 지식 저장소 구실을 한다. 질의 단계에서 GraphAide는 지식 출처에 질의하고, 설명과 추론을 붙여 사용자가 지정한 형식으로 응답을 생성하는 사용자 인터페이스를 제공한다.

GraphAide decomposes the query and reasoning

GraphAide는 질의·추론 연구 문제를 다음의 하위 문제로 나누고, 그래프 기반 RAG 접근으로 푼다.

• 자료 추출·변환·적재(ETL)와 정규화
• 개체명 인식
• 분야를 고려한 의미 주석
• 그래프 모델링과 저장
• 질의 해석과 문맥 생성

• 질의 확장과 후보 생성
• 요약과 설명 가능한 응답 생성

원문 3쪽

A. 자료 적재

Domain-specific datasets are available

분야 자료는 사용 사례에 따라 여러 정형·비정형 형식으로 존재한다. GraphAide는 최종 사용자가 일반 텍스트, CSV, PDF 등 흔히 쓰는 자료 형식으로 작업할 수 있게 하는 추상화 계층을 만든다. 원천 자료(즉 파일) 모음을 GraphAide에 적재한 다음, 글을 나누고 조각내는 과정을 거친다. 이는 벡터 자료에 대한 효율적인 검색을 지원하고, LLM의 최대 문맥 창 크기(토큰 수)보다 큰 자료를 다루기 위해서다. GraphAide는 바이트 쌍 부호화(BPE) 기반 토크나이저[13]를 쓴다. 이 토크나이저는 입력 글을 단어보다 작은 단위로 나눠 시스템이 다양한 언어를 다룰 수 있게 한다. BPE 기반 부호화는 OpenAI 임베딩 모델[14]도 지원하며, 손실이 없고 되돌릴 수 있으며 효율적이어서 여러 질의 상황에서 잘 동작하는 것으로 나타났다. 또한 GraphAide는 RecursiveCharacterTextSplitter를 쓴다. 이것은 입력 자료의 글자를 재귀적으로 살펴 가장 알맞은 나누기 전략을 동적으로 찾는다. GraphAide는 관련 연구[15]가 제안한 대로 고정된 조각 크기와 조각 겹침 값을 쓰며, 사용자가 특정 응용 분야에 맞게 글 나누기를 설정할 수도 있게 한다.

B. 자료 저장

Persistence of knowledge curated from multiple

여러 출처에서 정리한 지식을 저장해 두는 것은 바탕이 되는 디지털 조수의 재현성과 점진적 갱신에 매우 중요하다. 기본 RAG와 달리 GraphAide는 문맥 지식을 벡터 데이터베이스와 그래프 데이터베이스 양쪽에 저장한다. III-A절에서 논한 대로 나누고 조각낸 뒤, 원천 자료는 문서 모음으로 바뀌고, 각 문서는 사용자 질의에 답하는 데 쓰는 지식의 최소 단위가 된다. RAG 기반 LLM 응용에서 임베딩 기반 의미 유사도는 핵심 기능이다. 임베딩은 정보를 수치로 나타낸 것이며, 뜻이 비슷한 내용은 임베딩 공간에서 서로 가까이 놓인다. GraphAide는 벡터 데이터베이스에 분야 참조 자료나 WikiData[16] 같은 범용 지식베이스의 임베딩을 저장한다. GraphAide는 자료를 벡터 데이터베이스에 적재하고 나중에 쓰도록 로컬에 저장하는 간단한 API를 제공한다. GraphAide의 새로운 점은 그래프 데이터베이스를 써서 추가적인 구조 정보를 저장한다는 데 있다. GraphAide의 API는 분야에 맞는 그래프 모델링과 그래프 저장 기능을 제공한다. 그래프 데이터베이스는 이후 단계에서 검색 작업의 성능을 높이는 데 쓰인다.

C. 지식그래프 생성

Generation of an ontology-guided Knowledge Graph

이질적인 출처에서 온톨로지에 따른 지식그래프(KG)를 생성하는 것은 GraphAide의 핵심 기여 가운데 하나다. GraphAide는 개체명 추출, 관계 추출, 개체 구분, KG 부호화, KG 유지 같은 작업을 지원하는 KG 생성 단계를 정의한다. 프롬프트에 예시 몇 개를 넣는 방식(few-shot)으로 LLM에 지식그래프를 생성하도록 지시한다. GraphAide는 생성 단계의 입력으로 온톨로지 또는 노드·엣지 유형 목록을 동적으로 고를 수 있게 한다. 이것이 LLM의 응답 형식을 제한해, 주어진 입력 글에 대해 속성이 붙은 부분 그래프를 생성하게 한다. KG 생성 단계에서 질의의 예는 뉴스 기사 같은 비정형 출처의 한 문단이 될 수 있다. GraphAide는 주석 기반 형식 검사기인 Pydantic[17]을 써서 KG 생성 단계 전체에서 생성된 부분 그래프의 일관성을 유지한다.

D. 부분 그래프 질의 생성

GraphAide’s query phase begins with a natural

GraphAide의 질의 단계는 그림 1에 보인 대로 자연어 사용자 질의에서 시작한다. 사용자 질의는 불완전하고 부정확한 경우가 많아, 벡터 데이터베이스를 쓸 때 검색 정확도와 관련성이 떨어질 수 있다. 희소 검색에서 질의와 문서가 어긋나는 문제에 대해, LLM 기반 질의 확장이 이를 완화하는 것으로 나타났다[18]. GraphAide는 비슷한

접근을 임베딩 기반 밀집 검색에 적용한다. 틀 기반 방법으로, 원래 질의에 언급된 핵심 개체와 관계는 유지하면서 입력 질의의 다른 판들을 추가로 생성한다. 이어서 GraphAide는 그림 1에 나타낸 것처럼 LLM을 활용해 확장된 질의 묶음을 속성이 붙은 부분 그래프 매칭 틀로 바꾼다. 표현력이 좋은 부분 그래프 매칭과 벡터 기반 의미 유사도를 결합해 GraphAide는 검색 정확도를 높인다. GraphAide API는 Neo4J[19] 같은 흔히 쓰는 그래프 데이터베이스를 지원하며, 확장된 질의 묶음에 대해 Cypher 질의를 자동 생성할 수 있다. 또한 GraphAide API는 사용자 정의 스키마에 기반한 분야별 그래프 자료 모델에 대한 질의를 생성하는 여러 프롬프트 틀을 제공한다.

E. 지표와 평가

Evaluation of a comprehensive GenAI application

여러 구성요소(즉 에이전트)를 가진 종합적인 생성형 AI 응용을 평가하려면 관련된 정량 지표의 모음이 필요하다. 지표 하나로는 모든 구성요소의 성능을 설명하기에 부족한 경우가 많기 때문이다. 또한 각 에이전트의 기능, 역할, 처리하는 자료의 종류에 따라 알맞은 지표를 찾아야 한다. GraphAide의 두 단계는 모두 여러 하위 문제를 포함하며, 표 I에 보인 대로 각각 요구되는 지표가 다르다. GraphAide는 RAGAS[20]를 활용해 평가 자료를 준비하고 관련된 정량 지표 모음을 계산한다. 향후 연구는 평가 자료와 지표를 자동 생성하는 API 개발에 초점을 둘 것이다. 또한

표 I: GraphAide 구성요소별 지표

개체 언급 추출: 답 정확도
의미 주석: 문맥 관련성, 문맥 정확도, 답 관련성, 답 정확도, 의미 유사도
개체 구분: 문맥 정밀도, 문맥 재현율, ROC 곡선
질의 확장: 답 관련성
그래프 질의 생성: 답 정확도, 답 관련성

원문 4쪽

qualitative metrics are required to evaluate

(앞 쪽에서 이어짐) 사람이 참여하는 방식으로 응용 분야에서 생성된 응답을 평가하려면 정성 지표가 필요하다. GraphAide는 서로 다른 검색 모델과 LLM 모델을 설정하는 방법을 제공해, 분야 전문가(SME) 평가를 위한 비교 가능한 결과를 만든다. 여러 지표의 예는 IV절에 제시한다.

F. 설명 가능한 결과 생성

GraphAide simplifies the execution of the templates

GraphAide는 III-D절에서 생성한 틀을 주어진 그래프 데이터베이스에서 실행하는 일을 단순하게 하고 부분 그래프 매칭을 돕는다. 부분 그래프 매칭 결과와 벡터 기반 의미 유사도를 결합해, 질의 단계에서 LLM을 위한 국소 문맥을 만드는 API를 제공한다. KG 생성 단계와 달리 질의 단계는 개체 구분에 초점을 두지 않고, 틀을 써서 여러 검색 출처의 결과를 요약하고 설명한다. GraphAide는 확장된 질의 묶음에 대해 LLM에 여러 요청을 병렬로 실행하고, 한 번 더 호출해 모든 응답을 모아 사용자 질의에 대한 하나의 일관된 응답을 생성한다. 여러 제약과 절을 가진 복잡한 틀을 자동 생성하는 것은 향후 연구의 일부다. 우리는 예시 몇 개를 넣는 프롬프트 접근으로 틀 생성 과정을 개선할 계획이다.

IV. 실험

For our experiment, we instantiated GraphAide

실험을 위해 우리는 OpenAI LLM, Chroma 벡터 데이터베이스, Neo4j 그래프 데이터베이스, LangChain 응용 개발 프레임워크로 GraphAide를 구현했다. 문맥 창이 더 크고 추론·연역 능력이 향상된 GPT-4o 모델을 썼다. GPT-4o는 다국어 지원도 개선되어 아래에서 논할 우리 사용 사례에 적합하다. 우리는 기존 DARPA 사업 두 가지의 성과를 활용했다. AIDA(Active Interpretation of Disparate Alternatives)[21]는 다양한 비정형 출처에서 사건, 상황, 추세에 대한 서로 다른 해석을 생성하고 이해하는 다중 가설 의미 엔진을 개발했다. GAIA(Generating Alternative

Interpretations for Analysis)[22]는 우크라이나·러시아 정치 분쟁 시나리오에 대해 개체, 새로 나타나는 사건, 상황, 관심 추세를 추출하는 자동화 해법을 개발했다. 약 190개의 개체 유형, 140개의 사건 유형, 50개의 관계 유형을 담은 온톨로지[23]도 구축되어 있다. 지정학 시나리오에 초점을 둔 개체 구분 과정의 참조 지식베이스로 DARPA판 WikiData(DWD)도 개발되어 있다.

To demonstrate GraphAide's capabilities, we used

GraphAide의 기능을 보이기 위해, 우리는 글 형식의 AIDA 원천 자료와 TURTLE(Terse RDF Triple Language) 형식의 OWL(Web Ontology Language) 온톨로지를 써서 KG를 생성했다.

그림 1

GraphAide의 구조. 여러 단계와 에이전트 작업 흐름을 나타낸다.

원문 5쪽

format to generate a KG. We evaluated

(앞 쪽에서 이어짐) 우리는 생성한 KG의 품질을 GAIA가 생성한 KG와 비교해 평가했다. 또한 DWD를 참조 지식베이스로 쓰고, KG 생성 단계에서 검색할 수 있도록 Chroma 벡터 데이터베이스에 저장했다. DWD 식별자(QID)의 자연어 설명을 정리하고, 벡터 데이터베이스에 저장할 문서를 구성했다. QID를 문서 식별자로 쓰고, LLM으로 언급을 가장 순위가 높은 QID에 대응시켜 개체를 구분했다. GraphAide는 그림 2에 보인 대로 벡터 데이터베이스의 UMAP 임베딩도 생성해 KG에서 다루는 주제의 군집을 시각화한다. 임베딩은 음악, 스포츠, 정치 같은 개념의 뚜렷한 군집을 보여 준다. 또한 개체명 사이의 높은 유사도를 보여 주며, 이것이 개체 구분 과정에 쓰인다. 향후 연구에서는 KG 생성 단계에서 이 개체명들의 시간 속성도 반영해 개체를 구분할 것이다.

generation phase processed 1,846 news articles

GraphAide의 생성 단계는 뉴스 기사 1,846건을 처리해 그림 3에 보인 KG를 생성했다. 온톨로지에 따르고 DWD에 기반한 개체 구분 에이전트가 글에서 개체 언급을 추출하고, RAG 기반으로 노드 순위를 다시 매겨 가장 가깝게 맞는 QID를 찾는다. GraphAide는 글 조각내기, 주어진 조각에서 부분 KG 생성, Neo4j 그래프 데이터베이스에 적재를 반복해서 수행했다.

In contrast to the basic RAG

기본 RAG와 달리, GraphAide의 KG 기반 혼합 RAG 접근은 더 높은 구체성과 문서를 넘나드는 추론을 제공해 LLM 질의에 더 풍부한 문맥을 구성한다. 또한 GraphAide의 모듈식 설계는 성능 비교를 위해 여러 검색 출처 가운데서 동적으로 고를 수 있게 한다. 우리는 각 단계에서 생성된 응답을 정성적으로 평가했다. 생성 단계에서는 LLM 질의 틀을 설계해 입력 글에서 자연어 언급을 추출하고, DWD로 개체를 구분하고, 입력 온톨로지에 따라 유형(노드와 엣지)을 부여했다. 그림 3에 보인 대로 KG 스키마는 분야 온톨로지로 제약된다. 결과로 나온 KG는 기준 KG[22], [24]보다 개체명 인식과 관계 추출의 품질이 더 좋았다. 추출된 노드 유형은 계층적 스키마를 따라 그 노드에 대한 가장 구체적인 개념을 나타낸다. 예를 들어 GPE_UrbanArea_City는 클래스 City를 나타내며, 이는 도시 지역의 하위 클래스이고, 도시 지역은 지정학적 개체의 하위 클래스다. 비슷하게 ConflictAttack_FirearmAttack은 어떤 분쟁과 관련된, 화기가 쓰인 공격 사건을 나타낸다. 그림 5에 보인 대로 기준 KG는 노드 유형의 불균형을 보인다. 가장 자주 추출된 유형은 "PER"이고 나머지 노드 유형은 의미 주석의 작은 부분만 차지한다. 비슷하게, 이항이 아닌 관계

그림 2

검색에 쓰인 DARPA WikiData(DWD) 임베딩

원문 6쪽

types such as “Evaluate” and “GeneralAffiliation”

(앞 쪽에서 이어짐) 유형인 "Evaluate"와 "GeneralAffiliation"이 관계 추출의 대부분을 차지한다. 반면 GraphAide는 그림 4에 보인 대로 더 다양하고 조밀한 노드 유형 분포를 추출한다. 엣지 유형에서도, 입력 자료가 시간에 따른 사건을 많이 서술하고 있는 만큼, GraphAide는 사건 기반 유형을 더 잘 추출한다.

We evaluated the semantic annotation process

우리는 RAGAS 라이브러리를 활용해 답 관련성, 답 정확도, 의미 유사도 지표로 노드 유형을 부여하는 의미 주석 과정을 평가했다. 그림 6에 보인 대로, 답 관련성이나 정확도만으로는 설명할 수 없는 이상한 노드 유형 부여가 몇 건 관찰되었다. 그런 경우에는 다음에 논하는 것처럼 의미 유사도로 LLM의 부여를 설명할 수 있다.

For a user input “The Illinois Traction Building

사용자 입력 "일리노이 트랙션 빌딩은 미국 샘페인에서 철도 터미널과 상업 건물의 두 가지 기능을 한다. 건축 설계가 이 이중 기능을 가능하게 한다. 그래서 이 건물은 이 지역의 다용도 기반시설의 두드러진 예다."에 대해 답 정확도는 0.230700으로 측정된다. 그러나 더 살펴보면 이 노드에 대한 LLM의 예측인 FAC.Building, ORG.Government.Railway가 정답인 FAC.Building.OfficeBuilding, FAC.Installation.TrainStation과 의미상 비슷해, 의미 유사도는 0.922801로 높게 나온다.

In the query phase, we used GraphAide to analyze

질의 단계에서 우리는 GraphAide로 여러 출처의 입력 자료를 분석하고, 정리된 지식에 의존하는 사용자 질의에 응답하면서 LLM에 문맥 정보를 제공했다. GraphAide의 모듈성을 보이기 위해, 사용자 질의에 응답할 때 서로 다른 수준의 보강을 쓰는 파이프라인을 구성했다. OpenAI의 GPT-4o를 기준 LLM으로 쓰는 것에 더해, WikiData, 분야 자료, 그리고 그 분야 자료에서 만든 보강된 KG도 사용자 질의에 답하는 데 활용했다. 생성된 응답의 정성 평가를 위해 서로 다른 보강 수준의 출력을 비교했다. 그림 7에 보인 대로, LLM과 공유하는 문맥을 풍부하게 할수록 생성된 응답의 구체성이 높아진다. 그림 7은 LLM에 직접 질의하면 관련된 응답을 내지 못할 수 있음을 보여준다. LLM이 그 사실에 대한 자료로 학습되지 않았거나, 그 사실이 LLM의 학습 기준일보다 최근이기 때문이다. 참조 지식베이스를 쓰면 사용자 질의를 구분된 개체들에 근거하게 하므로 응답이 나아질 수 있다. 또한 분야의 정답 문서를 쓰면 생성된 응답의 출처를 함께 제시할 수 있다. 그림 7에 보인 대로 AIDA 문서 말뭉치는 질의와 관련된 정답을 담고 있어 LLM이 관련성이 높은 응답을 내게 한다. 한 걸음 더 나아가, KG 기반 검색은 말뭉치의 여러 문서에 흩어진 개체와 개념을 포함시켜 문맥 관련성을 높인다. "도네츠크 인민공화국"과 "러시아 의용군" 같은 개체는 벡터 데이터베이스의 같은 문서에 반드시 함께 언급되는 것이 아니라 부분 그래프로 연결되어 있다. 부분 그래프에서 생성한 문맥은 LLM이 응답에 추가 증거와 설명을 생성하는 데 매우 중요하다. 사용자 의견에 기반한 정성 평가에 더해, 우리는 분야 온톨로지와 참조 지식베이스의 영향을 측정하기 위해 정량 평가에 알맞은 GraphAide의 개별 구성요소도 찾아냈다. 향후 연구는

그림 3

GraphAide가 뉴스 출처에서 생성한 KG

원문 7쪽

quantitative metrics such as precision, recall

(앞 쪽에서 이어짐) 정밀도, 재현율, 검색 관련성 같은 정량 지표를 활용해, KG 기반 혼합 RAG의 개체 구분, 의미 유형 부여, KG 생성 작업에서의 개선을 측정할 것이다.

V. 결론

Large Language Models (LLMs) offer exciting

대규모 언어모델(LLM)은 분야 특화 작업을 위한 디지털 조수를 개발할 좋은 기회를 준다. 고급 검색 증강 생성(RAG)은 LLM을 쓸 때의 설명 가능성, 확장성, 사용성 우려를 해결하고, 기술 도입에 대한 사용자의 신뢰를 높인다. 우리는 지식그래프와 부분 그래프 매칭 기능을 활용해 RAG 기반 응용의 정확도를 높이는 GraphAide를 제시한다. 참조 구조와 그 주요 구성요소를 제시한다. 또한 GraphAide의 한 구현으로, 과거 우크라이나·러시아 정치

분쟁 시나리오를 서술한 뉴스 기사에서 지식그래프(KG)를 생성하는 것을 보인다. 향후 연구는 정확도와 관련성 같은 지표의 정량적 개선을 보고하는 정식 평가에 초점을 둘 것이다.

감사의 글

The research described in this paper is partially
이 논문에 기술한 연구는 퍼시픽 노스웨스트 국립연구소(PNNL)의 RD2C(Resilience Through Data Driven, Intelligently Designed Control) 사업과 미국 연방정부의 일부 지원을 받았다. PNNL은 미국 에너지부(DOE)를 위해 바텔 기념 연구소가 계약 번호 DE-AC05-76RL01830에 따라 운영하는 다목적 국립연구소다. PNNL 정보 공개 번호 PNNL-SA-205147.

그림 4, 그림 5

그림 4: GraphAide가 생성한 KG의 유형 분포(상위 10개)
그림 5: 기준 KG의 유형 분포. 노드(왼쪽), 관계(오른쪽)

원문 8쪽

그림 6, 그림 7

그림 6: 의미 주석 과정의 평가
그림 7: 사용자 질의 "오데사 전투에서 러시아의 역할을 100단어로 서술하고, 거기서 발생한 사망자 수와 피해를 나열하라. 관련된 다른 주요 행위자도 나열하라."에 대한 GraphAide의 결과

참고문헌

(8~9쪽은 참고문헌 목록이라 해석하지 않음)